

PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Prof.º Simone Erbs da Costa



Indaial – 2020

1ª Edição



Copyright © UNIASSELVI 2020

Elaboração:

Prof.^a Simone Erbs da Costa

Revisão, Diagramação e Produção:

Centro Universitário Leonardo da Vinci – UNIASSELVI

Ficha catalográfica elaborada na fonte pela Biblioteca Dante Alighieri
UNIASSELVI – Indaial.

C837p

Costa, Simone Erbs da

Preparação e análise exploratória de dados. / Simone Erbs da Costa. – Indaial: UNIASSELVI, 2020.

285 p.; il.

ISBN 978-65-5663-026-7

1. Preparação de dados. - Brasil. 2. Análise exploratória de dados. – Brasil. Centro Universitário Leonardo Da Vinci.

CDD 004

APRESENTAÇÃO

Caro acadêmico, estamos iniciando o estudo da disciplina Preparação e Análise Exploratória de Dados. Esta disciplina objetiva reconhecer e aplicar o processo de preparação de dados (*Data Preparation*) para a posterior análise, além da exploração de dados. Ainda, é preciso reconhecer as principais técnicas e ferramentas para a preparação de dados.

Este livro conta com diversos recursos didáticos externos. Portanto, recomendamos que você realize todos os exemplos e exercícios resolvidos para um aproveitamento excepcional da disciplina.

No contexto apresentado, o livro Preparação e Análise Exploratória de Dados está dividido em três unidades: Unidade 1 – Preparação de Dados; Unidade 2 – Limpeza, Transformação e Redução de Dados; Unidade 3 – Análise Exploratória de Dados.

Aproveitamos a oportunidade para destacar a importância de desenvolver as autoatividades, lembrando que essas atividades não são opcionais. Elas objetivam a fixação dos conceitos apresentados. Em caso de dúvida, na realização das atividades, sugerimos que você entre em contato com seu tutor externo ou com a tutoria da UNIASSELVI, não prosseguindo sem ter sanado todas as dúvidas.

Bom estudo! Sucesso na sua trajetória acadêmica e profissional!

Prof.^a Simone Erbs da Costa



Você já me conhece das outras disciplinas? Não? É calouro? Enfim, tanto para você que está chegando agora à UNIASSELVI quanto para você que já é veterano, há novidades em nosso material.

Na Educação a Distância, o livro impresso, entregue a todos os acadêmicos desde 2005, é o material base da disciplina. A partir de 2017, nossos livros estão de visual novo, com um formato mais prático, que cabe na bolsa e facilita a leitura.

O conteúdo continua na íntegra, mas a estrutura interna foi aperfeiçoada com nova diagramação no texto, aproveitando ao máximo o espaço da página, o que também contribui para diminuir a extração de árvores para produção de folhas de papel, por exemplo.

Assim, a UNIASSELVI, preocupando-se com o impacto de nossas ações sobre o ambiente, apresenta também este livro no formato digital. Assim, você, acadêmico, tem a possibilidade de estudá-lo com versatilidade nas telas do celular, tablet ou computador.

Eu mesmo, UNI, ganhei um novo layout, você me verá frequentemente e surgirei para apresentar dicas de vídeos e outras fontes de conhecimento que complementam o assunto em questão.

Todos esses ajustes foram pensados a partir de relatos que recebemos nas pesquisas institucionais sobre os materiais impressos, para que você, nossa maior prioridade, possa continuar seus estudos com um material de qualidade.

Aproveito o momento para convidá-lo para um bate-papo sobre o Exame Nacional de Desempenho de Estudantes – ENADE.

Bons estudos!



Olá acadêmico! Para melhorar a qualidade dos materiais ofertados a você e dinamizar ainda mais os seus estudos, a Uniasselvi disponibiliza materiais que possuem o código **QR Code**, que é um código que permite que você acesse um conteúdo interativo relacionado ao tema que você está estudando. Para utilizar essa ferramenta, acesse as lojas de aplicativos e baixe um leitor de **QR Code**. Depois, é só aproveitar mais essa facilidade para aprimorar seus estudos!



BATE SOBRE O PAPO ENADE!



Olá, acadêmico!

Você já ouviu falar sobre o **ENADE**?

Se ainda não ouviu falar nada sobre o ENADE, agora você receberá algumas informações sobre o tema.

Ouviu falar? Ótimo, este informativo reforçará o que você já sabe e poderá lhe trazer novidades.



Vamos lá!

Qual é o significado da expressão ENADE?

EXAME NACIONAL DE DESEMPENHO DOS ESTUDANTES

Em algum momento de sua vida acadêmica você precisará fazer a prova ENADE.



Que prova é essa?

É **obrigatória**, organizada pelo INEP – Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira.

Quem determina que esta prova é obrigatória... O **MEC – Ministério da Educação**.

O objetivo do MEC com esta prova é o de avaliar seu desempenho acadêmico assim como a qualidade do seu curso.



Fique atento! Quem não participa da prova fica impedido de se formar e não pode retirar o diploma de conclusão do curso até regularizar sua situação junto ao MEC.

Não se preocupe porque a partir de hoje nós estaremos auxiliando você nesta caminhada.

Você receberá outros informativos como este, complementando as orientações e esclarecendo suas dúvidas.



Você tem uma trilha de aprendizagem do ENADE, receberá e-mails, SMS, seu tutor e os profissionais do polo também estarão orientados.

Participará de webconferências entre outras tantas atividades para que esteja preparado para #mandar bem na prova ENADE.

Nós aqui no NEAD e também a equipe no polo estamos com você para vencermos este desafio.

Conte sempre com a gente, para juntos mandarmos bem no ENADE!





Olá, acadêmico! Iniciamos agora mais uma disciplina e com ela um novo conhecimento.



Com o objetivo de enriquecer seu conhecimento, construímos, além do livro que está em suas mãos, uma rica trilha de aprendizagem, por meio dela você terá contato com o vídeo da disciplina, o objeto de aprendizagem, materiais complementares, entre outros, todos pensados e construídos na intenção de auxiliar seu crescimento.

Acesse o QR Code, que levará ao AVA, e veja as novidades que preparamos para seu estudo.

Conte conosco, estaremos juntos nesta caminhada!

SUMÁRIO

UNIDADE 1 – PREPARAÇÃO DE DADOS	1
TÓPICO 1 – CONCEITOS FUNDAMENTAIS DA PREPARAÇÃO DE DADOS	3
1 INTRODUÇÃO.....	3
2 IMPORTÂNCIA DO ESTUDO DE DADOS E APLICAÇÕES.....	6
3 TIPOS DE DADOS, MEDIDAS ESCALARES E EXTRAÇÃO DE INFORMAÇÃO.....	13
3.1 TIPOS DE DADOS	16
3.2 ESCALAS DE MEDIÇÃO	17
3.3 EXTRAINDO INFORMAÇÃO DE DIFERENTES TIPOS DE DADOS.....	22
RESUMO DO TÓPICO 1.....	25
AUTOATIVIDADE	29
TÓPICO 2 – COLETA DE DADOS	33
1 DOMÍNIO DO PROBLEMA	33
2 DADOS DE DIFERENTES ORIGENS	40
2.1 DADOS ESTRUTURADOS X DADOS NÃO ESTRUTURADOS	40
2.2 BANCO DE DADOS	46
3 ENRIQUECIMENTO DE DADOS	49
3.1 ESTUDO DE CASO: ENRIQUECENDO UMA BASE DE DADOS.....	56
RESUMO DO TÓPICO 2.....	58
AUTOATIVIDADE	61
TÓPICO 3 – FERRAMENTAS DE PREPARAÇÃO DE DADOS, DATA LAKES E DATA PONDS	65
1 FERRAMENTAS PARA PREPARAÇÃO DE DADOS.....	65
2 LINGUAGEM R E LINGUAGEM PYTHON	69
LEITURA COMPLEMENTAR.....	73
RESUMO DO TÓPICO 3.....	83
AUTOATIVIDADE	87
UNIDADE 2 – LIMPEZA, TRANSFORMAÇÃO E REDUÇÃO DE DADOS	89
TÓPICO 1 – LIMPEZA E PREENCHIMENTO DE DADOS	91
1 INTRODUÇÃO.....	91
2 ORGANIZANDO OS DADOS.....	93
3 LIMPEZA E PREENCHIMENTO DE VALORES AUSENTES.....	101
3.1 LIMPEZA DE INFORMAÇÕES AUSENTES	104
3.2 LIMPEZA DE INCONSISTÊNCIA	106
3.3 LIMPEZA DE VALORES NÃO PERTENCENTES AO DOMÍNIO	107
3.4 LIMPEZA DE VALORES REDUNDANTES	107
4 DADOS FORA DO PADRÃO (OUTLIERS).....	109
RESUMO DO TÓPICO 1.....	115
AUTOATIVIDADE	119

TÓPICO 2 – TRANSFORMAÇÃO DE DADOS.....	123
1 INTRODUÇÃO	123
2 TRANSFORMAÇÕES BÁSICAS DE CARACTERÍSTICAS	124
2.1 DISCRETIZAÇÃO, NORMALIZAÇÃO E CALIBRAÇÃO	125
2.2 DISCRETIZAÇÃO	125
2.3 NORMALIZAÇÃO	128
2.4 CALIBRAÇÃO	130
3 CODIFICAÇÃO DE DADOS CATEGÓRICOS	131
3.1 EXEMPLIFICAÇÃO DA CODIFICAÇÃO DE DADOS CATEGÓRICOS EM PYTHON.....	133
3.2 EXEMPLIFICAÇÃO DA CODIFICAÇÃO DE DADOS CATEGÓRICOS PELO DATASET DO TITANIC DA KAGGLE	135
RESUMO DO TÓPICO 2.....	148
AUTOATIVIDADE	151
 TÓPICO 3 – REDUÇÃO DE DADOS E ANÁLISE POR COMPONENTES PRINCIPAIS	 155
1 INTRODUÇÃO	155
2 PRINCIPAIS ABORDAGENS DA REDUÇÃO DE DADOS	156
3 ANÁLISE POR COMPONENTES PRINCIPAIS PARA IDENTIFICAÇÃO DE GRUPOS.....	157
LEITURA COMPLEMENTAR.....	161
RESUMO DO TÓPICO 3.....	168
AUTOATIVIDADE	172
 UNIDADE 3 – ANÁLISE EXPLORATÓRIA DE DADOS	 175
TÓPICO 1 – EXPLORAÇÃO DE DADOS	177
1 INTRODUÇÃO	177
2 TÉCNICAS DE ANÁLISE EXPLORATÓRIA DE DADOS	178
2.1 SUMÁRIO DE CINCO-NÚMEROS (FIVE-NUMBER).....	179
2.2 EXIBIÇÃO DE CAULE E FOLHAS (STEM-AND-LEAF)	179
2.3 EXIBIÇÃO SCATTERPLOT MATRIX.....	180
2.4 EXIBIÇÃO POR <i>OUTLIERS</i>	181
2.5 RESIDUAL PLOTS.....	182
2.6 BAG PLOTS	183
2.7 SMOOTHER	184
2.8 ROBUST VARIANT	184
2.9 REEXPRESSION.....	185
2.10 MEDIAN POLISH.....	185
RESUMO DO TÓPICO 1.....	187
AUTOATIVIDADE	190
 TÓPICO 2 – VISUALIZAÇÃO DE DADOS.....	 195
1 INTRODUÇÃO	195
2 CONHECENDO UM POUCO MAIS SOBRE A VISUALIZAÇÃO DE DADOS E SUA IMPORTÂNCIA.....	196
3 PRINCIPAIS GRÁFICOS PARA REPRESENTAR VALORES NUMÉRICOS	199
4 PRINCIPAIS GRÁFICOS PARA REPRESENTAR VALORES CATEGÓRICOS	204
RESUMO DO TÓPICO 2.....	208
AUTOATIVIDADE	210

TÓPICO 3 – DESCRITORES ESTATÍSTICOS COM PANDAS, A REPRESENTAÇÃO GRÁFICA COM MATPLOB LIB E OS GRÁFICOS DE PARES COM SEABORN	215
1 INTRODUÇÃO	215
2 MEDIDAS DE TENDÊNCIA CENTRAL	216
2.1 MEDIDAS DE DISPERSÃO	219
3 REPRESENTAÇÃO GRÁFICA COM MATPLOB LIB	223
4 GRÁFICOS DE PARES COM SEABORN.....	246
4.1 ABSTRAÇÃO DE API ENTRE VISUALIZAÇÕES	248
4.2 ESTIMATIVA ESTATÍSTICA E BARRAS DE FERRO.....	249
4.3 PARCELAS CATEGÓRICAS ESPECIALIZADAS	251
4.4 FUNÇÕES DE NÍVEL E DE EIXO.....	253
4.5 VISUALIZAÇÃO DA ESTRUTURA DO CONJUNTO DE DADOS.....	255
4.6 PERSONALIZAÇÃO DA PLOTATEM.....	257
LEITURA COMPLEMENTAR.....	261
RESUMO DO TÓPICO 3.....	268
AUTOATIVIDADE	274
REFERÊNCIAS	279

PREPARAÇÃO DE DADOS

OBJETIVOS DE APRENDIZAGEM

A partir do estudo desta unidade, você deverá ser capaz de:

- saber a definição, a importância do estudo de dados e aplicações e conhecer as atividades que envolvem o processo;
- aprender os tipos de dados existentes e suas escalas de medição;
- aprender a extrair informações de diferentes tipos de dados de forma geral;
- conhecer estratégias que o preparador de dados pode seguir para o entendimento do domínio do problema;
- trabalhar com dados de diferentes origens e saber como fazer o enriquecimento de dados;
- conhecer as principais ferramentas para a preparação de dados;
- conhecer comandos referentes à preparação de dados na linguagem R e na linguagem Python.

PLANO DE ESTUDOS

Esta unidade está dividida em três tópicos. No decorrer da unidade, você encontrará autoatividades com o objetivo de reforçar o conteúdo apresentado.

TÓPICO 1 – CONCEITOS FUNDAMENTAIS DA PREPARAÇÃO DE DADOS

TÓPICO 2 – COLETA DE DADOS

TÓPICO 3 – FERRAMENTAS DE PREPARAÇÃO DE DADOS E *DATA LAKES* E *DATA PONDS*



Preparado para ampliar seus conhecimentos? Respire e vamos em frente! Procure um ambiente que facilite a concentração, assim absorverá melhor as informações.



CONCEITOS FUNDAMENTAIS DA PREPARAÇÃO DE DADOS

1 INTRODUÇÃO

Sempre que vamos lidar com um grande volume de dados, vamos nos deparar com o termo preparação de dados e com a análise exploratória de dados. A preparação de dados se refere a tratar, de forma correta, os dados antes de utilizá-los ou armazená-los. Já a análise exploratória de dados se refere a estudar as características dos dados, utilizando, geralmente, gráficos.


Estamos vivendo a era dos dados, comumente chamada de *Big Data*. Esses termos são utilizados para descrever situações envolvendo um enorme volume de dados que foi gerado de forma eletrônica. Cabe ressaltar que esses dados podem ser tanto processados como analisados para os mais diferentes fins.

O avanço tecnológico e a transformação digital possibilitaram que esse enorme volume de dados, ou seja, que essa quantidade de dados fosse gerada, coletada, armazenada, propiciando que esses dados fossem compartilhados. Azevedo (2020, p. 1) coloca que “a capacidade de armazenamento de dados e informações, hoje, dobra a cada dez meses e a própria Lei de Moore flerta com a obsolescência diante da proximidade da Computação Quântica”.

Azevedo (2020, p. 1) também observa que “esse crescimento exponencial é o que se chama de *Big Data*. Um mundo onde os dados são fornecidos e circulam em grande volume, velocidade, variedade e incerteza. Nunca tivemos tantos dados disponíveis para tantos e ao mesmo tempo”.


Em Reinsel, Gantz e Rydning (2020), o Institute Data Corporation (IDC) prevê que a esfera de dados global aumentará de 33 ZettaBytes (ZB) do ano de 2018 para 175 ZB no ano de 2025, e em IDC Infographic (2017), foi previsto 163 ZB para o ano de 2025. Esses dados propiciam experiências únicas aos usuários, além de oportunidades de negócios.

GRÁFICO 1 – VOLUME DE DADOS/INFORMAÇÕES EM TODO O MUNDO ENTRE 2010 E 2025 (EM ZETABYTES) COM PROJEÇÃO EM 2018



FONTE: Adaptado de Reinsel, Gantz e Rydning (2020)

FIGURA 1 – VOLUME DE DADOS /INFORMAÇÕES EM TODO O MUNDO ENTRE 2010 E 2025 (EM ZETABYTES) COM PROJEÇÃO EM 2017



Fonte: A Autora

Outras projeções incluem que quase 30% da esfera global de dados será em tempo real até 2025 (COUGHLIN, 2018). Reinsel, Gantz e Rydning (2020) também acreditam que, até o ano de 2025, todas as pessoas conectadas no mundo (cerca de 75% da população total na época) terão um envolvimento de dados digitais mais de 4.900 vezes por dia, uma vez a cada 18 segundos.

A Internet das Coisas (IoT) deve aumentar o volume de dados. Espera-se que os aplicativos de IoT produzam 90 ZB (90 bilhões de terabytes) de dados anualmente até 2025. O estudo ainda constatou que mais dados serão migrados para a nuvem, comparados com o que é realizado hoje em dia. A IDC espera que até 40% dos dados globais sejam armazenados em ambientes de nuvem pública até 2025.



Na Unidade 2, determinaremos quais dos dados do conjunto de dados corporativos serão preparados.



Contudo, qual é o tamanho de 175 ZettaByte (ZB)? Um ZB equivale a um trilhão de gigabytes. Esse volume de dados armazenado pode ser comparado com 23 pilhas de Digital Versatile Disc (DVDs) da Terra até a Lua ou circular pela Terra 222 vezes (REINSEL; GANTZ; RYDNING, 2020).

A organização SGB elencou alguns números para termos uma ideia melhor do volume de dados:

O volume de dados criado nos últimos anos é maior do que a quantidade produzida em toda a história.

Estima-se que, até 2020, existirão cerca de 50 bilhões de dispositivos conectados desenvolvidos para a coleta, análise e compartilhamento de dados.

A produção de dados dobra a cada dois anos e a previsão é de que em 2020 sejam gerados 350 zettabytes de dados ou 35 trilhões de gigabytes; A rede social Facebook gera mais de 500 terabytes de dados diariamente.

O volume de dados no Brasil pode chegar a 1,6 bilhões de gigabytes em 2020 (SGB, 2019, p. 1).

Entretanto, esse volume de dados não significa qualidade de dados. Uma expressão utilizada é "*Garbage in, Garbage out*", além de ser uma ameaça para o sucesso do projeto. Isso decorre pelo fato de a qualidade do insumo ser uma peça fundamental na qualidade do produto. Assim, pode-se dizer que a preparação de dados é essencial para todo e qualquer projeto que envolver a análise exploratória de dados.

Em computação, como reconhecimento de padrões, recuperação de informações, aprendizado de máquina, mineração de dados e inteligência na Web, é necessário preparar dados de qualidade, processando os dados brutos. Para Mashanovich (2017), pelo menos 70%, às vezes mais de 90% do tempo total do projeto é dedicado à preparação de dados: coleta de dados, combinar as diversas fontes de dados, agregações, transformações, limpeza de dados e “fatiar e cortar em cubos”. Essa atividade ainda envolve examinar a amplitude e profundidade dos dados para obter um entendimento claro, além de transformar a quantidade de dados em qualidade de dados (MASHANOVICH, 2017).

Afinal, qual é a importância da preparação adequada dos dados? Segundo Pyle (1999), depois de encontrar o problema certo para resolver, a preparação de dados é a chave para resolver o problema. É a diferença entre sucesso e fracasso.



A preparação dos dados é, portanto, um tópico de pesquisa crucial.

O objetivo, a partir daqui, é trazer o conhecimento necessário para enfrentar o desafio do volume de dados referente à preparação e à análise exploratória de dados.

2 IMPORTÂNCIA DO ESTUDO DE DADOS E APLICAÇÕES

Considere o seguinte problema: um gerente deseja conhecer o perfil dos clientes e dos possíveis clientes para criar campanhas de marketing direcionado. Os objetivos são aumentar a carteira de clientes da empresa e fidelizar os clientes existentes. Esse gerente não sabe como resolver o problema, porém, ele sabe quem pode ajudar: a Tecnologia da Informação (TI) da empresa.

Dentro da TI, temos diversos profissionais que estarão envolvidos na resolução do problema: o engenheiro de dados, o cientista de dados, o analista de negócio etc. As responsabilidades de cada um podem se intercalar no decorrer do projeto, porém, o esperado é que o engenheiro de dados cuide de como os dados serão armazenados e processados. O cientista de dados será o responsável por fazer a extração de conhecimento dos dados e o analista de negócio utilizará o conhecimento obtido para gerar relatórios de acordo com a necessidade das partes interessadas.

Considere que o profissional envolvido no problema faça a identificação dos dados relacionados com o problema. Esses dados podem ser internos e externos. Essa identificação inicial será o ponto de partida para fazer a coleta dos dados e a integração em um conjunto de dados que será utilizado no projeto.

Considere que, no exemplo, o profissional faça a identificação dos dados disponíveis com o problema.

Os tipos de dados identificados e suas fontes são apresentados a seguir, possibilitando identificar que os dados estruturados são oriundos de bancos de dados relacionais da organização. Os dados não estruturados e semiestruturados podem ser provenientes das mais diversas fontes, como de arquivos de texto, imagem, áudio, vídeo, planilhas, além de pesquisas realizadas de mercado. Outras fontes de dados importantes são as redes sociais e bases externas abertas. Os dados provenientes dessas fontes podem ser requisitos básicos para o problema e utilizados para o enriquecimento do conjunto de dados que será preparado.


FIGURA 2 – TIPOS DE DADOS IDENTIFICADOS E SUAS FONTES



FONTE: Adaptado de Caetano (2018a)

Vamos retomar ao problema exposto inicialmente, que se refere ao gerente conhecer o perfil dos clientes e dos futuros clientes. Será que já estamos prontos para realizar essa atividade? Não, ainda não estamos preparados, pois apenas foram identificados os tipos de dados e seus respectivos dados, e estes foram integrados em um conjunto de dados. Esse conjunto de dados precisa realizar o processo de preparação.

FIGURA 3 – PROCESSO INTERMEDIÁRIO - PREPARAÇÃO DE DADOS NA SOLUÇÃO DO PROBLEMA



FONTE: Adaptado de Caetano (2018b)

O grande problema é que os dados identificados e integrados ao conjunto de dados nem sempre estão prontos para serem utilizados. Dessa forma, é necessária uma etapa de preparação, na qual esse conjunto de dados será coletado, limpo, normalizado e combinado, possibilitando, assim, uma posterior análise.




É necessário que a preparação de dados seja adequada, caso contrário, o conhecimento não poderá ser extraído, pois os dados estarão em estado bruto. Cabe ressaltar que é de responsabilidade do preparador de dados executar diversas atividades no processo de preparação de dados, transformando os dados brutos em informações significativas (relevantes) para o problema.

Afinal, qual é a definição de preparação de dados? É o ato de manipular (ou processar) dados brutos (que podem vir de fontes de dados diferentes), de uma forma que possam ser analisados com rapidez e precisão, por exemplo, para fins comerciais.

A preparação de dados visa resolver os dados que foram “lançados” dos mais diferentes lugares, estando, geralmente, em uma pilha de vários formatos e contendo erros e duplicações. Os objetivos são coletar e limpar esses dados, se livrando das inconsistências. Por exemplo, “Donato da Silva”, “Donatho da Silva” e “Donato Silva” são a mesma pessoa. Assim, a preparação de dados unifica esses registros.

Lembre-se: esses dados são transformados de dados brutos para informação e o conhecimento será extraído da informação que foi construída ao longo da preparação de dados. “O conhecimento são informações contextualizadas e baseadas em fatos. Por exemplo: um conjunto de informações relacionadas evidencia um perfil de cliente” (CAETANO, 2018a, p. 1). A sabedoria necessária para que as empresas possam tomar decisões é adquirida por meio do conhecimento.

FIGURA 4 – DOS DADOS À SABEDORIA



Fonte: A Autora

A preparação de dados é uma etapa fundamental nos projetos de *Big Data*. A seguir, é possível perceber que atividades de limpeza e organização consomem tempo. Ainda, são imprescindíveis para a atividade de análise.

QUADRO 1 – TEMPO GASTO EM ATIVIDADES NA PREPARAÇÃO DE DADOS

ANO	FONTE	RESULTADO
2014	New York Times	Os cientistas de dados, de acordo com entrevistas e estimativas de especialistas, passam de 50% a 80% de seu tempo envolvidos nesse trabalho mais mundano de coletar e preparar dados digitais indisciplinados.
2015	Crowdflower	66,7% deles disseram que limpar e organizar dados são tarefas que mais consomem tempo e não foi relatada estimativa de tempo gasto.
	Bizreport	Entre 50% e 90% do tempo dos funcionários de <i>Business Intelligence</i> (BI) é gasto na preparação de dados.
2016	Crowdflower	Quais dados os cientistas passam mais tempo fazendo? Limpeza e organização de dados: 60%; coleta de conjuntos de dados: 19%.
2017	Crowdflower	Que atividade ocupa a maior parte do seu tempo? 51% Coletando, rotulando, limpando e organizando dados.
2018	Kaggle	Durante um projeto típico de ciência de dados, qual porcentagem do seu tempo é gasta nas seguintes tarefas? 11% de coleta de dados, 15% de limpeza de dados.
	IGTI	Tempo gasto em projetos de Mineração de Dados? 53% Preparação de Dados; 20% Modelagem de Dados; 10% Aplicação de Algoritmos; 8% Otimização de Algoritmos e 8% Outros.
2019	Figura 8	Quase três quartos dos entrevistados técnicos 73,5% gastam 25% ou mais do tempo gerenciando, limpando e/ou rotulando dados.

Fonte: A Autora

Esse percentual apresentado pode aumentar se, durante a fase de mineração de dados, os dados não estiverem adequadamente preparados. Pode-se dizer que um conjunto de dados mal preparado ou não preparado de forma adequada eleva o tempo necessário do projeto, não possibilitando bons resultados.

ProjectPro (2016) conclui que a maior parte do tempo de um cientista de dados é gasta na preparação de dados (coleta, limpeza e organização), antes que eles possam começar a fazer a análise de dados. A preparação de dados também é chamada de disputa de dados, troca de dados ou limpeza de dados. A quantidade de tempo necessária para a preparação depende diretamente da integridade dos dados, ou seja, quantos valores ausentes existem, quão limpos são e quais são as inconsistências.

Existem ZetaBytes de dados disponíveis, mas a maioria não está em um formato fácil de usar para análise preditiva. A fase de limpeza ou preparação de dados do processo de ciência de dados garante que ele seja formatado corretamente e cumpra um conjunto específico de regras. A qualidade dos dados é o fator determinante para o processo de ciência de dados e dados limpos são importantes para criar modelos bem-sucedidos de aprendizado de máquina, aprimorando o desempenho e a precisão do modelo (PROJECTPRO, 2016).



Análises preditivas usam dados, algoritmos estatísticos e técnicas de *Machine Learning* para identificar a probabilidade de resultados futuros a partir de dados históricos. O objetivo é ir além de saber o que aconteceu para obter uma melhor avaliação do que poderá acontecer no futuro (SAS INSIGHTS, 2019).

Os cientistas de dados avaliam a adequação e a qualidade, identificando se alguma melhoria pode ser feita no conjunto de dados os resultados necessários. Por exemplo, um cientista de dados pode descobrir que poucos pontos de dados influenciam o modelo de aprendizado de máquina em direção a um determinado resultado.

Dados de baixa qualidade ou dados ruins custam, a uma organização, média de US \$ 13,5 milhões por ano, o que é um custo alto demais para suportar. Dados ruins ou má qualidade dos dados podem alterar a precisão dos *insights* ou podem ocasionar *insights* incorretos, e é por isso que a preparação é de extrema importância, mesmo que consuma tempo e seja a tarefa menos agradável do processo de ciência de dados.


Portanto, a preparação de dados é necessária devido à presença de dados não formatados do mundo real. A maioria dos dados do mundo real é composta por (VARIAWA, 2019):

- Dados imprecisos (dados ausentes): Existem muitos motivos para os dados ausentes não serem coletados continuamente: erro na entrada de dados, problemas técnicos com biometria e muito mais.
- A presença de dados ruidosos (dados errôneos e *outliers*): as razões para a existência de dados ruidosos podem ser um problema tecnológico de gadget que coleta dados, um erro humano durante a entrada de dados e muito mais.
- Dados inconsistentes: a presença de inconsistências se deve aos motivos que ocasionam a existência de duplicação de dados, entrada de dados humanos, contendo erros de códigos ou nomes, como violação de restrições de dados e muito mais.

A preparação de dados é a base da análise: a melhor maneira, e alguns diriam apenas, de acelerar o processo de análise, é reduzir o tempo de preparação de dados. Assim, pode-se dizer que, no contexto, a preparação de dados significa manipulação de dados em um formato adequado para análise e processamento.

A necessidade do pré-processamento dos dados decorre pelo fato dos dados no mundo real serem incompletos (ausência de atributos de interesse, dados agregados, ausência de valores), ruidosos (erros aleatórios, valores aberrantes (*outliers*) e inconsistentes (discrepâncias nas codificações ou nos nomes).

FIGURA 5 – AS ETAPAS NECESSÁRIAS NO PROCESSO



Fonte: A Autora

É possível perceber que várias atividades precisam ser realizadas para transformar os dados brutos em informações relevantes para a tomada de decisão, ou seja, na sabedoria necessária para as organizações. Caetano (2018b, p. 9-10) afirma que “espera-se que, ao final da preparação de dados, o profissional responsável entenda claramente o problema e se é possível solucioná-lo, e que seja entregue um conjunto de dados confiável, relevante e enriquecido”.

QUADRO 2 – PRINCIPAIS ATIVIDADES DA PREPARAÇÃO DE DADOS

ATIVIDADE	DESCRIÇÃO
Coleta	Processo de adquirir dados (de diversas fontes e tipos) que estão relacionados com o problema.
Integração de dados	Envolve combinar dados de diversas fontes e tipos em um único conjunto de dados.
	Entre 50% e 90% do tempo dos funcionários de <i>Business Intelligence</i> (BI) é gasto na preparação de dados para serem analisados.
Enriquecimento	O processo de agregar valor aos dados existentes.
Entendimento do problema	Tarefa fundamental que permite identificar se é possível ou não resolver o problema proposto.
Limpeza de dados ausentes	Consiste em eliminar ruídos, inconsistências e resolver problemas estruturais.
Tratamento de dados ausentes	Tratar dados que não estão no conjunto, porém são necessários para a análise.
Análise de <i>outliers</i>	Identificar registros com comportamento fora do comum e analisá-los de acordo com o interesse.
Análise estatística	Ao longo da preparação de dados, são executadas diversas análises estatísticas e visuais o auxílio nas análises e atividades envolvidas.
Normalização	Transformar um conjunto de dados que está em diferentes grandezas e escalas em um conjunto de dados padronizados.
Redução da dimensionalidade	Eliminação de características (atributos) redundantes, escolha das melhores características e seleção dos principais componentes dos dados.

FONTE: Adaptado de Caetano (2018b)

QUADRO 3 – RESULTADOS DA PREPARAÇÃO DE DADOS

RESULTADO	DESCRIÇÃO
Entendimento do domínio do problema	O preparador de dados deve saber o que é o problema, como vai resolvê-lo, quais são as formas de testar a solução e se é possível resolver.
Conjunto de dados confiável, relevante e enriquecido	O preparador de dados deve entregar esse conjunto para o cientista de dados, que aplicará os algoritmos necessários para a extração do conhecimento. Ainda, para o analista de negócios, que utilizará para a tomada de decisão ou gerenciar esse conjunto para análises futuras.

FONTE: Adaptado de Caetano (2018b)

3 TIPOS DE DADOS, MEDIDAS ESCALARES E EXTRAÇÃO DE INFORMAÇÃO

Percebe-se que as pessoas estão cada vez mais dependentes da tecnologia para executar suas atividades diárias, tanto profissionais, domésticas e de lazer. Para isso, as pessoas utilizam computadores, dispositivos móveis, armazenam os dados na nuvem, utilizam cartão de crédito, acessam redes sociais etc. Além disso, os usuários não admitem longas esperas após fazerem requisições. Se uma página de compra não carregar em poucos milésimos de segundos, por exemplo, ele já está clicando na página do concorrente. Os dados gerados por essas

transações podem se tornar um valioso ativo da empresa, extraindo valor desses dados, aumentando lucros e reduzindo custos. Um conceito que representa esse cenário é o termo *Big Data*.

O *Big Data* pode ser definido por volume, variedade e velocidade, constituindo-se em 3V's, devido ao grande volume de dados, alta variedade de dados estruturada e não estruturada e velocidade em tempo real (LANEY, 2001). Russom (2011) observa que essa definição é mais abrangente e quebra o mito de que o *Big Data* se refere apenas ao tamanho dos dados do armazenamento. Além disso, cada um dos 3Vs tem suas próprias ramificações para análises.

FIGURA 6 – OS 3V'S DO *BIG DATA*



FONTE: Adaptado de Laney (2001)


Cabe ressaltar que os avanços tecnológicos e a popularização dos dispositivos móveis, mídias sociais e Internet das Coisas (IoT) contribuem para o crescente volume de dados armazenados nos sistemas corporativos de Tecnologia da Informação (TI) (Volume).

Outro ponto é que as empresas estão criando dados em um ritmo muito rápido. As organizações de hoje precisam lidar com fluxos de dados em tempo real de fontes como Twitter, Facebook, sensores de IoT, tags de Radio Frequency IDentification (RFID) e aplicativos móveis. Dados armazenados nos sistemas de TI empresariais (Velocidade).

No passado, as organizações conseguiam armazenar muitos dados em sistemas estruturados de gerenciamento de banco de dados relacional. Hoje, no entanto, muitos dados corporativos não são estruturados e incluem documentos de texto, fotos, vídeos, arquivos de áudio, mensagens de e-mail e outros tipos de informações que não se encaixam em um banco de dados tradicional (Variedade) (LANEY, 2001).

A lista de Vs aumentou com o tempo, expandido para 5V's, enfatizando as oportunidades e os desafios que as empresas e organizações enfrentam ao incorporar *Big Data* em suas operações de negócios existentes.

FIGURA 7 – OS 5V'S DO *BIG DATA*



Fonte: Elaborado por HAMMER; KOSTROCH; QUIROS (2017) baseado em Lang (2001)

Veracidade refere-se ao ruído e ao viés nos dados. Volatilidade refere-se à mudança de ambientes tecnológicos ou de negócios nos quais o *Big Data* é produzido, ocasionando análises e resultados inválidos, além de fragilidade no *Big Data* (HAMMER; KOSTROCH; QUIROS, 2017).

Ter dados de diferentes tipos de dados (Variedade) é uma das características do *Big Data*. Esses dados podem ser tanto do tipo estruturado como do tipo não estruturado. Lembre-se: dado é tudo o que é observado ou conceituado. Em uma visão um tanto restrita, os dados são algo que pode ser medido. Os dados representam fatos ou algo que realmente ocorreu, que foi observado e medido. Podem resultar de observação passiva ou coleta ativa. Cada ponto de dados deve estar enraizado em um fenômeno físico, demográfico ou comportamental. Os dados são observados em cada unidade e armazenados em um dispositivo eletrônico (PENNSTATE, 2020).



- **Dados:** uma coleção de objetos e seus atributos.
- **Atributo:** recurso, variável ou campo, que é uma propriedade ou característica de um objeto.
- **Coleção de atributos:** descreve um objeto (indivíduo, entidade, caso ou registro).

Os atributos contêm informações sobre cada unidade de observação. Dependendo de quantos tipos diferentes de informações são coletados de cada unidade, os dados podem ser univariados, bivariados ou multivariados. Podem ter formas e estruturas variadas, mas em um critério são todos iguais: os dados contêm informações e características que separam uma unidade ou observação das outras (PENNSTATE, 2020).

Os valores que um atributo pode assumir são separados em tipo de dados e escala de medição. Os tipos de dados dizem respeito à quantização e a escala de medição é uma maneira de subcategorizar tipos diferentes de dados. Os tipos de dados, de forma geral, podem ser classificados em dois tipos: qualitativos e quantitativos. Os dados do tipo quantitativo ainda podem ser categorizados em contínuos e discretos. As quatro principais escalas de medição são: nominal, ordinal, intervalo e proporção (PYLE, 1999).

FIGURA 8 – TIPOS DE DADOS E ESCALAS DE MEDIÇÃO



Fonte: A Autora

3.1 TIPOS DE DADOS

Nossa primeira caracterização é se os dados são numéricos ou não. É bem simples de entender. Se você possui dados numéricos, possui dados quantitativos. Se você não possui números, possui dados qualitativos (não numéricos ou também chamados de dados categóricos). Como "quantitativo" e "qualitativo" são quase idênticos na ortografia, é fácil misturá-los.

Os dados quantitativos podem ser classificados quando é possível realizar operações aritméticas. Por exemplo: é possível somar dois pesos, duas temperaturas, então, peso e temperatura são quantitativos (PYLE, 1999). Dentro dos dados quantitativos (ou numéricos), existe um subnível de tipos de dados: dados discretos ou dados contínuos.

Segundo Pyle (1999), por discreto, entende-se os dados quantitativos que não têm valores em casas decimais, como inteiros e naturais (1, 0, -5). Os dados discretos são um número inteiro (inteiro) e não podem ser subdivididos em partes cada vez menores. Exemplos clássicos são o número de pessoas na sala de aula, o número de irmãos em uma família etc. Você não pode ter 30,5 pessoas na classe e não pode ter 1,5 irmãos. Um outro exemplo que podemos dar é o número de vitórias que um time de futebol obtém no brasileirão, o número de peixes dentro de um aquário ou a quantidade de alunos cursando a disciplina Preparação e Análise Exploratória de Dados etc.

Uma variável ou atributo é discreto se puder receber um conjunto de valores finito ou infinitamente contável. Uma variável discreta é frequentemente representada como uma variável com valor inteiro. Uma variável binária é um caso especial, em que o atributo pode assumir apenas dois valores, geralmente, representados por 0 e 1.

Os atributos contínuos são aqueles que assumem valores com casas decimais e que admitem que entre dois números há uma infinidade de números “quebrados”, por exemplo, o valor de Pi (3,1415), que fica entre 3,0 e 4,0 (PYLE, 1999). Os dados contínuos continuam indefinidamente. Esses dados podem ser divididos em unidades cada vez menores. Meu peso pode ser medido infinitamente usando equipamento de precisão e não há necessidade de parar a três metros.

Uma variável ou atributo é contínuo se puder receber algum valor em um determinado intervalo. Exemplos de variáveis contínuas são pesos e alturas de pássaros, temperatura de um dia etc. Ainda, os dados contínuos podem ser categorizados em dois tipos de escalas de medição: intervalo e proporção.

Para Pyle (1999), os dados que não se encaixam na situação de dados quantitativos são dados qualitativos. Pense nos dados qualitativos como informações não estruturadas (comentários de grupos focais, observações etc.) resumidas subjetivamente. Um bom exemplo para uma análise qualitativa de dados é uma nuvem de palavras. Pyle (1999) ainda coloca que os dados contínuos podem ser categorizados em dois tipos de escalas de medição: ordinal e nominal.

3.2 ESCALAS DE MEDIÇÃO

As escalas de medição são fornecidas em diferentes tipos de medidas. Pode-se dizer que escala é a razão constante entre qualquer grandeza química ou física, possibilitando uma medição. Contudo, como podemos ver isso de forma clara? É simples: pense em como medir a temperatura do seu café, limitando a medição a apenas quente ou frio. Você verá que essa medida contém menos informações: muito quente, agradável e quente, quente, não quente, quente e frio (PYLE, 1999). Ainda, existem quatro escalas de medição de dados: nominal, ordinal, intervalo e razão. São maneiras de subcategorizar tipos diferentes de dados.

• **Nominal**

As escalas nominais são usadas para rotular variáveis, sem nenhum valor quantitativo. As escalas nominais podem ser chamadas de etiquetas. Observe, a seguir, que todas essas escalas são mutuamente exclusivas (sem sobreposição) e nenhuma delas tem significado numérico. Uma boa maneira de lembrar tudo isso é que “nominal” soa muito como “nome” e escalas nominais são como “nomes” ou rótulos.

FIGURA 8 - EXEMPLOS DE ESCALA NOMINAL

Qual é o seu sexo?

☐ Masculino

☒ Feminino

☐ Outros

Qual é a sua faixa etária?

☐ 0 - 30

☒ 31 - 60

☐ 61 - 100

Fonte: A Autora

Os valores nominalmente dimensionados carregam a menor quantidade de informações dos tipos de medidas a serem considerados. Valores nominais apenas citam as coisas. Existe uma notável diferença de tipo ou identidade, mas pouco ou nada mais pode ser dito se a escala de medição é realmente nominal. Uma medida nominal é pouco mais que uma etiqueta usada para fins de identificação. Não há ordem inerente nas medições nominais. Nem mesmo os valores medidos nominalmente podem ser significativamente agrupados. Eles, no entanto, carregam informações definidas (PYLE, 1999).



Um subtipo de escala nominal com apenas duas categorias (por exemplo, masculino/feminino) é chamado de dicotômico. Outros subtipos de dados nominais são nominais com ordem (como frio, quente, muito quente) e nominais sem ordem (como homem/mulher).

• Ordinal

Nas escalas ordinais, a ordem dos valores é importante e significativa, mas as diferenças não são realmente conhecidas. Dê uma olhada no exemplo a seguir. Em cada caso, sabemos que a # 4 é melhor do que um # 3 ou # 2, mas nós não sabemos e não podemos quantificar muito. Por exemplo: a diferença entre “OK” e “Infeliz” é a mesma que entre “Muito feliz” e “Feliz”? Não podemos dizer.

FIGURA 9 – EXEMPLOS DE ESCALA ORDINAL

Como você está se sentindo hoje?

- ☐ Muito infeliz
- ☐ Infeliz
- ☐ ok
- ☐ Feliz
- ☐ Muito feliz

O quanto você está satisfeito com a Uniassevi

- ☐ Muito insatisfeito
- ☐ Insatisfeito
- ☐ Neutro
- ☐ Satisfeito
- ☐ Muito satisfeito

Fonte: A Autora



As escalas ordinais são medidas de conceitos não numéricos, como satisfação, felicidade, desconforto etc. A melhor maneira de determinar a tendência central em um conjunto de dados ordinais é usar a mediana. Um purista dirá que a média não pode ser definida a partir de um conjunto ordinal.

“Ordinal” é fácil de lembrar, porque soa como “ordem”, e essa é a chave para lembrar de “escalas ordinais”: é a ordem que importa, mas é tudo que você realmente obtém. Para Pyle (1999), as medidas ordinais carregam muito mais informações do que as nominais ou categóricas. A classificação das categorias deve ser feita sujeita a uma condição muito particular, chamada de transitividade, uma noção razoável, embora de importância crítica. Transitividade significa que se A é classificado acima de B e B acima de C, então A deve ser classificado acima de C. Ou seja: Se $A > B$ e $B > C$, então, $A > C$.

O uso de uma escala ordinal adiciona uma quantidade enorme de informações sobre as contidas em uma medição categórica. O requisito de transitividade impõe algumas restrições. Observe que a escala ordinal não exige que qualquer coisa deve ser especificada sobre a quantidade da diferença entre cada categoria. Por exemplo: em uma "degustação às cegas" para vinhos, você experimenta vários tipos e estilos diferentes de vinho e marca as combinações de preferência aos pares.

- **Intervalo**

Escala de intervalo são escalas numéricas nas quais conhecemos a ordem e as diferenças exatas entre os valores. O exemplo clássico é a temperatura Celsius, porque a diferença entre cada valor é a mesma. Por exemplo: a diferença entre 70 e 50 graus é de 20 graus mensuráveis, assim como a diferença entre 90 e 70 graus.

Escala de intervalo são boas porque o domínio da análise estatística é aberto. Por exemplo: a tendência central pode ser medida por modo, mediana ou média, e o desvio padrão também pode ser calculado. Como os outros, você pode se lembrar dos pontos principais de uma "escala de intervalo" com facilidade. O próprio "intervalo" significa "espaço intermediário". O que é importante lembrar: as escalas de intervalo não apenas nos dizem sobre a ordem, mas também sobre o valor.

Aqui está o problema com as escalas de intervalo: elas não têm um "zero verdadeiro". Por exemplo, não existe "sem temperatura", pelo menos não em graus Celsius. No caso de escalas de intervalo, zero não significa ausência de valor mas, na verdade, é outro número usado na escala, como 0 graus Celsius. Números negativos também têm significado. Sem um zero verdadeiro, é impossível calcular proporções. Com dados de intervalo, podemos adicionar e subtrair, mas não podemos multiplicar ou dividir (PYLE, 1999).

Confuso? Ok! Considere o seguinte exemplo: $20 \text{ graus C} + 20 \text{ graus C} = 40 \text{ graus C}$. Não há problema, certo?! 40 graus C não é duas vezes mais quente que 20 graus C , no entanto, não existe algo como "sem temperatura" quando se trata da escala Celsius. Quando há conversão para Fahrenheit, é possível observar que $20\text{C} = 68\text{F}$ e $40\text{C} = 104\text{F}$.



As escalas de intervalo são ótimas, mas não podemos calcular taxas.

- **Proporção (Razão)**

As escalas de proporção são o melhor nirvana quando há escalas de medição de dados. Há informação de ordem, o valor exato entre as unidades, possuindo um zero absoluto, este que permite uma ampla variedade de estatísticas descritivas e inferenciais. Correndo o risco de se repetir, tudo acima dos dados do intervalo se aplica às escalas de proporção, mas as escalas de proporção têm uma definição clara de zero. Bons exemplos de variáveis de proporção incluem altura, peso e duração.

As escalas de proporção fornecem uma riqueza de possibilidades quando se trata de análise estatística. Essas variáveis podem ser significativamente adicionadas, subtraídas, multiplicadas, divididas (proporções). A tendência central pode ser medida por modo, mediana ou média, medidas de dispersão, como desvio padrão e coeficiente de variação, ou a partir de escalas de proporção.



As variáveis nominais são usadas para "nomear" ou rotular uma série de valores. As escalas ordinais fornecem boas informações sobre a ordem das escolhas, como em uma pesquisa de satisfação do cliente. Escalas de intervalo nos dão a ordem dos valores + a capacidade de quantificar a diferença. Por fim, as escalas de proporção nos fornecem a ordem final, os valores de intervalo, além da capacidade de calcular as proporções, pois um "zero verdadeiro" pode ser definido.

Na hierarquia de dados, nominal está na classificação mais baixa, pois carrega o menor número de informações. O tipo mais alto de dados é a proporção, pois contém o máximo de informações possíveis.

Ao analisar os dados, é preciso observar que os procedimentos aplicáveis a um tipo de dado mais baixo podem ser aplicados a um tipo mais alto, mas o inverso não é verdadeiro. O procedimento de análise para dados nominais pode ser aplicado aos dados do tipo intervalo, mas não é recomendado, pois esse procedimento ignora completamente a quantidade de informações que os dados do tipo intervalo carregam. Contudo, os procedimentos desenvolvidos para dados do tipo intervalo ou proporção não podem ser aplicados a dados nominais nem ordinais. Um analista prudente deve reconhecer cada tipo de dado e, depois, decidir os métodos aplicáveis (PENNSTATE, 2020).

3.3 EXTRAINDO INFORMAÇÃO DE DIFERENTES TIPOS DE DADOS

Caetano (2019b) coloca que os dados coletados podem ser divididos em valores textuais e arquivos de mídia, além de numéricos e categóricos. As informações podem ser extraídas dos valores numéricos (quantitativos) e categóricos (qualitativos), fazendo uso de análises estatísticas e visuais. Contudo, em valores textuais e em arquivos de mídia, o processo não é explícito. O preparador de dados precisa estar atento ao valor que ele possuem, para que seus dados não sejam descartados.

- **Processamento de textos**

Extraír informações de textos envolve, principalmente, a área de processamento de linguagem natural. Alguns exemplos de processamento de linguagem natural são a análise de sentimento, identificação de tópicos e categorização de conteúdo. A análise de sentimentos diz respeito a uma técnica que processa o texto e determina qual o sentimento que aquele texto expressa. Geralmente, um texto pode ser classificado como negativo, neutro ou positivo.

Existem várias abordagens de análise de sentimentos. As mais conhecidas são baseadas em algoritmos de *Machine Learning* (aprendizado supervisionado e não supervisionado), em dicionários de palavras (cada palavra possui uma pontuação) e abordagens híbridas (combinação das duas abordagens anteriores). Várias outras áreas estão envolvidas na análise de sentimentos, como a análise de opiniões, detecção de humor e identificação de bem-estar e felicidade. Existem muitas aplicações práticas da análise de sentimentos. Por exemplo, responder perguntas como: a revisão do produto é positiva ou negativa? Qual é a percepção dos clientes nas redes sociais? Quais são os aspectos do produto/serviço que precisam ser melhorados?

A identificação de tópicos consiste no processamento de textos (corpus) por algoritmos que fazem a detecção automática dos tópicos abordados no texto. Isso possibilita que o analista faça a análise dos assuntos tratados no texto. Algumas das aplicações mais comuns da identificação de tópicos são: a identificação de contexto, monitoramento de clientes e equipes e a identificação de comportamentos virais e tendências (redes sociais).

A categorização de conteúdo compreende diversas atividades de análise semântica do texto. Por exemplo: a identificação do idioma do texto e a sumarização. A sumarização é um processo que reduz um texto através da detecção automática de estruturas gramaticais que carregam o máximo possível de informação. Pode-se entender a sumarização como o clássico problema da mochila na computação. A categorização de conteúdo pode ser aplicada para reduzir ruídos, reduzir os dados trabalhados e otimizar a análise de acordo com o idioma.

- **Processamento de arquivos de mídia**

O processamento de imagens permite, entre outras coisas, fazer a extração do texto da imagem, identificar emoções das pessoas que aparecem na imagem e, também, fazer a caracterização das imagens. A caracterização pode ser utilizada para identificar o gênero, etnia e faixa etária das pessoas que aparecem na imagem.

O processamento de áudio e vídeo possibilita, entre outras coisas, a transcrição do texto, identificação de emoções através da variação na voz ou expressões e a identificação dos interlocutores, isto é, quem participa do diálogo em uma cena ou em um áudio.

- **Estudo de caso: extraindo informações de dados**

Considere o seguinte problema: a empresa X, recentemente, elaborou um novo plano diretor. A partir de agora, o gerenciamento e utilização dos dados da empresa são consideradas atividades estratégicas para o negócio. Os objetivos do projeto são aumentar o índice de fidelização de clientes e abrir novos mercados. Diante dessa situação, o preparador de dados deve elaborar um planejamento de como esses dados podem ser explorados para a extração de informações.

Após um levantamento dos dados, o preparador de dados identifica as seguintes fontes de dados: vendas registradas pela empresa, os dados cadastrais dos clientes, as revisões do produto/serviço, registros de chats, e-mails e ligações telefônicas, e dados dos seguidores das contas oficiais da empresa em redes sociais. Todos esses dados podem ser coletados e explorados para a extração de informações.

As propostas de extração de informação dos dados são as seguintes: identificar qualidade do atendimento, pontos críticos da opinião dos clientes e perfis de seguidores para campanhas direcionadas.

Para fazer a análise dos áudios das ligações telefônicas, o preparador de dados pode fazer a transcrição para texto e a identificação dos participantes na conversa. Uma ferramenta que pode ser utilizada é a Google Speech API, que faz parte da Google Cloud Platform (cloud.google.com).

Com o uso do Google Speech API e com uma linguagem de programação (Python, por exemplo), o preparador de dados pode fazer o mapeamento do tempo gasto em ligações para medir a qualidade no atendimento. Com os textos de e-mails, chats e revisões, o preparador de dados pode aplicar uma análise de sentimentos utilizando a ferramenta SentiStrength (sentistrength.wlv.ac.uk). Essa ferramenta possui uma abordagem baseada em dicionários de palavras. Cada palavra possui uma pontuação de -5 a 5. Quanto mais próximo de 5, maior é a indicação de alegria e satisfação.

Outra abordagem que pode ser utilizada na análise de sentimentos é o uso da plataforma Mechanical Turk da Amazon (mturk.com). Nessa plataforma, é possível contratar pessoas para responderem questionários. Dessa forma, é possível que o preparador de dados contrate pessoas para rotularem os textos definindo se eles têm um sentimento positivo, neutro ou negativo. Com essas respostas, é possível construir um classificador de textos (análise de sentimentos, abordagem *Machine Learning*).

Os textos também podem ser processados para fazer análise de opiniões. Essa análise consiste em definir os sentimentos em relação a alguém ou a alguma pessoa. Certas ferramentas, como a Stanford Parser (nlp.stanford.edu), permitem identificar quais palavras estão associadas com cada sujeito da frase. Com o auxílio de uma ferramenta de análise de sentimentos, é possível fazer a análise de cada conjunto de palavras associadas com os sujeitos do texto.

Outra importante análise de texto é a identificação de idiomas. Vamos supor que, no exemplo do caso de estudo em questão, a empresa X tem clientes em diversos países. O proposto exige que sejam feitas análises específicas para cada idioma. A biblioteca do Python `langdetect` (pypi.org/project/langdetect) e a ferramenta Google Translation API podem ser utilizadas para executar essa análise.

A identificação do assunto tratado no atendimento aos clientes e o monitoramento das redes sociais podem ser feitos com a análise do conteúdo dos textos. Uma técnica utilizada para detecção dos tópicos é a Latent Dirichlet Allocation (LDA).

A biblioteca do Python `scikit-learn` (scikit-learn.org) implementa diversas técnicas de processamento de texto e *Machine Learning*. Finalmente, a identificação de perfis dos clientes pode ser realizada com a identificação do gênero, idade e emoções que as pessoas apresentam nas imagens das redes sociais. A ferramenta Face++ (faceplusplus.com) possibilita fazer muitas caracterizações em imagens.

RESUMO DO TÓPICO 1

Neste tópico, você aprendeu que:


- O volume de dados criado nos últimos anos é maior do que a quantidade produzida em toda a história.
- Volume de dados não significa qualidade de dados.
- Os dados estruturados são oriundos de bancos de dados relacionais da organização.
- Os dados não estruturados e semiestruturados podem ser provenientes das mais diversas fontes, como de arquivos de texto, imagem, áudio, vídeo, planilhas, além de pesquisas realizadas de mercado.
- As redes sociais e bases externas abertas são outras fontes importantes e enriquecem o conjunto de dados quando são utilizadas.
- A preparação de dados precisa ser adequada, caso contrário, o conhecimento não poderá ser extraído, devido que os dados estarão em estado bruto.
- A preparação de dados visa resolver os dados que foram “lançados” dos mais diferentes lugares, estando geralmente em uma pilha de vários formatos e contendo erros e duplicações. Ela visa coletar e limpar esses dados, se livrando das inconsistências.
- Dados são informações em seu estado bruto, não tendo passado por nenhum processo e/ou organização.
- Informação é o dado já processado, confiável, relevante e enriquecido.
- Conhecimentos são informações contextualizadas baseadas em fatos.
- Sabedoria é o conhecimento necessário para a tomada de decisão.
- Um conjunto de dados mal preparado ou não preparado de forma adequada eleva o tempo necessário do projeto.
- O processo de preparação de dados pode ser visto em cinco etapas: *Data Cleaning* (Limpeza), *Data Integration* (Integração), *Data Transformation* (Transformação), *Data Reduction* (Redução) e *Data Discretization* (Discretização).

- A etapa de *Data Cleaning* diz respeito à limpeza dos dados, que trata da parte de corrigir os dados inconsistentes, preencher valores ausentes e suavizar dados ruidosos, abordando os problemas da qualidade de dados.

A etapa de *Data Integration* envolve resolução de conflitos de dados, além da manipulação de redundâncias.

- A etapa de *Data Transformation* é para remover qualquer “ruído” dos dados, envolvendo a normalização, agregação e generalização.
- A etapa de *Data Reduction* diz respeito a reduzir o conjunto de dados por meio de estratégias, como a redução de dimensionalidade de requisitos, agregação de cubos de dados e redução de numerosidade.
- A etapa de *Data Discretization* ajuda a reduzir o tamanho dos dados para análise, muitas vezes, dividindo atributos contínuos em intervalos.
- As principais atividades da preparação de dados são coleta, integração de dados, enriquecimento, entendimento do problema, limpeza de dados ausentes, tratamento de dados ausentes, análise de *outliers*, análise estatística, normalização e redução da dimensionalidade.
- Coleta é o processo de aquisição de dados das mais diferentes fontes e tipos.
- Integração de dados é criar um único conjunto de dados, combinando dados das mais diferentes fontes e tipos.
- Enriquecimento é o processo de agregar valor aos dados que já existem.
- Entendimento do problema é a atividade que possibilita identificar a possibilidade (ou não) da solução do problema.
- Limpeza de dados ausentes se refere à eliminação de ruídos, inconsistências, além de tratar da resolução de problemas estruturais.
- Tratamento de dados ausentes é lidar com todos os dados que são necessários na análise.
- Análise de *outliers* é descobrir os registros com condutas fora do padrão e analisar conforme interesse.
- Análise estatística se refere às várias análises (estatísticas e visuais), auxiliando no processo de análise e nas tarefas.

- Normalização é criar um conjunto de dados padronizado proveniente de conjuntos de dados que possuem distintas grandezas e escalas.
- Redução da dimensionalidade é eliminar características (atributos) que são redundantes, fazendo uso das melhores características e seleção dos principais componentes dos dados.
- O conjunto de dados pode conter discrepâncias nos nomes ou códigos.
- O conjunto de dados pode conter valores discrepantes ou erros.
- O conjunto de dados não possui seus atributos de interesse para análise.
- O conjunto de dados não é qualitativo, apenas quantitativo.
- Os valores que um atributo pode assumir são separados em tipo de dados e escala de medição.
- Os tipos de dados dizem respeito à quantização e à escala de medição, maneiras de subcategorizar tipos diferentes de dados.
- Os tipos de dados, de forma geral, podem ser classificados em qualitativos e quantitativos e os dados do tipo quantitativo ainda podem ser categorizados em contínuos e discretos.
- As quatro principais escalas de medição são: nominal, ordinal, intervalo e proporção (razão).
- As variáveis nominais são usadas para "nomear" ou rotular uma série de valores.
- As escalas ordinais fornecem boas informações sobre a ordem das escolhas, como em uma pesquisa de satisfação do cliente.
- As escalas ordinais são tipicamente medidas de conceitos não numéricos, como satisfação, felicidade, desconforto etc.
- As escalas de intervalo nos dão a ordem dos valores + a capacidade de quantificar a diferença.
- As escalas de intervalo são ótimas, mas não podemos calcular taxas.
- As escalas de proporção fornecem a ordem final, os valores de intervalo, além da capacidade de calcular as proporções, pois um "zero verdadeiro" pode ser definido.



Fonte: A Autora



1 É necessário que a preparação de dados seja adequada, caso contrário, o conhecimento não poderá ser extraído, pois os dados estarão em estado bruto. Cabe ressaltar que é de responsabilidade do preparador de dados executar diversas atividades no processo de preparação de dados, transformando os dados brutos em informações significativas (relevantes) para o problema. No contexto apresentado, analise as sentenças a seguir e indique a afirmativa com a ordem CORRETA das definições:

- I- Dados confiáveis, relevantes e enriquecidos.
- II- Informações contextualizadas e baseadas em fatos.
- III- Fatos objetivos insignificantes quando isolados.
- IV- Conhecimento necessário para a tomada de decisões.

- a) () Sabedoria – Conhecimento – Informação – Dados.
- b) () Dados – Conhecimento – Informação – Sabedoria.
- c) () Informação – Sabedoria – Conhecimento – Dados.
- d) () Informação – Conhecimento – Dados – Sabedoria.

2 O processo de preparação de dados consiste em várias atividades que devem ser executadas para a transformação de dados brutos em informações. Espera-se que, ao final da preparação dos dados, o profissional responsável entenda claramente o problema e, se possível, solucioná-lo, e que seja entregue um conjunto de dados confiáveis, relevantes e enriquecidos, ou seja, na sabedoria necessária para a tomada de decisão. O processo de preparação de dados ocasiona duas grandes entregas. Com relação a essas duas grandes entregas resultantes da preparação de dados, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () O preparador de dados deve saber o que é o problema, como vai resolvê-lo, quais são as formas de testar a solução e se é possível resolver.
- () O preparador de dados deve entregar o conjunto para o cientista de dados, que aplicará os algoritmos necessários para a extração do conhecimento. Ainda, para o analista de negócios, que utilizará para a tomada de decisão ou para gerenciar o conjunto para análises futuras.
- () O processamento de imagens entregue pelo preparador de dados permite que sejam identificadas emoções das pessoas que aparecem na imagem. Ainda, é possível fazer a caracterização.
- () A preparação de dados deve ser aplicada em casos específicos. Aplicar algoritmos de *Machine Learning*, mesmo em dados ruins, gera bons resultados.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

3 A preparação de dados visa resolver os dados que foram “lançados” dos mais diferentes lugares, estando, geralmente, em uma pilha de vários formatos e contendo erros e duplicações. É possível coletar e limpar esses dados, livrando-se das inconsistências. Por exemplo: “Donato da Silva”, “Donatho da Silva” e “Donato Silva” são a mesma pessoa. Assim, a preparação de dados unifica esses registros. Para isso, é necessário que várias atividades sejam realizadas, como: coleta, integração de dados, enriquecimento, entendimento do problema, limpeza de dados ausentes, tratamento de dados ausentes, análise de *outliers*, análise estatística, normalização e redução da dimensionalidade. Com relação às atividades da preparação de dados, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () A limpeza de dados ausentes se refere à eliminação de ruídos, inconsistências, além de como tratar da resolução de problemas estruturais.
- () O tratamento de dados ausentes é lidar com todos os dados que são necessários nas análises, mesmo que não estiverem no conjunto de dados.
- () A análise de *outliers* se refere às várias análises (estatísticas e visuais) que auxiliem no processo de análise e nas tarefas.
- () A análise estatística é descobrir os registros com condutas fora do padrão e os analisar conforme interesse.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

4 Os valores que um atributo pode assumir são separados em tipo de dados e escala de medição. A quantização e a escala de medição são maneiras de subcategorizar tipos diferentes de dados. Os tipos de dados, de forma geral, podem ser classificados em dois tipos: qualitativos e quantitativos. Com relação aos tipos de dados quantitativo e qualitativo, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () O dado pode ser considerado qualitativo quando é possível realizar aritméticas.
- () O dado pode ser considerado quantitativo se se referir a informações não estruturadas (comentários de grupos focais, observações etc.) resumidas subjetivamente.
- () O tipo de dado quantitativo também é visto como tipo de dado numérico.
- () O tipo de dado qualitativo também é visto como tipo de dado categórico.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

5 A escala de medição é uma maneira de subcategorizar tipos diferentes de dados. Pode-se dizer que escala é a razão constante entre qualquer grandeza química ou física, possibilitando uma medição. As quatro principais escalas de medição são: nominal, ordinal, intervalo e proporção (razão). Com relação a essas escalas de medição, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () As escalas nominais são usadas para "nomear" ou rotular uma série de valores.
- () As escalas ordinais fornecem boas informações sobre a ordem das escolhas, como em uma pesquisa de satisfação do cliente.
- () As escalas de intervalo fornecem a ordem final, os valores de intervalo, além da capacidade de calcular as proporções, pois um "zero verdadeiro" pode ser definido.
- () As escalas de proporção dão a ordem dos valores + a capacidade de quantificar a diferença.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

COLETA DE DADOS

1 DOMÍNIO DO PROBLEMA

O mundo é um lugar de complexidade inacreditável. Por mais que olhemos atentamente para alguma faceta do mundo, há uma profundidade infinita de detalhes. No entanto, nossos cérebros e mentes constroem simplicidades significativas (para nós) a partir da impressionante complexidade que nos cerca. Ao usar essas simplicidades, fazemos representações do mundo que achamos úteis, como almoçar, dormir, trabalhar etc. Ainda, podemos coletar e registrar impressões sobre várias facetas, os dados. São esses dados que, em seguida, exploramos, pelo menos com a mineração de dados, para entender algo sobre a realidade do mundo – descobrir informações (PYLE, 1999).

O processo de coleta de dados é uma tarefa desafiadora e envolve muitos problemas que devem ser abordados antes que os dados sejam coletados e usados. Os principais problemas no processo de coleta e utilização de dados é:

- um trabalho tedioso, que gasta um tempo considerável, variando de semanas a meses;
- invasivo, envolvendo questões de privacidade do usuário, entre outros problemas;
- dados coletados podem não estar no formato utilizável imediatamente, exigindo esforços adicionais.

Nós somente teremos uma forte compreensão das características dos dados em questão se, primeiramente, conseguirmos entender e resolver os problemas de negócios. Para isso, precisamos compreender o domínio do problema. Um problema é uma situação que é julgada como algo que precisa ser resolvido. É nosso trabalho garantir que o problema certo seja resolvido, considerando que as informações podem não ser obtidas diretamente do cliente. Sempre devemos nos perguntar: o que realmente precisamos resolver?

Saber o que você deseja prever ajuda a decidir quais dados são mais valiosos. O domínio do problema precisa ser amplamente identificado para que sejam fornecidas informações precisas, oportunas e úteis sobre os problemas estratégicos.

Cabe ressaltar que o valor da informação é sempre proporcional à escala do problema. Às vezes, as declarações de problemas de negócio são claras e muito diretas, por exemplo: como são identificados os clientes mais valiosos? Como são

minimizadas as perdas do produto que não está disponível na prateleira? Como se minimiza meu inventário? Como se detecta um cliente com probabilidade de inadimplência em um pagamento de fatura?

Essas são declarações de problemas diretas e, realmente, não há confusão sobre o que estamos tentando alcançar com um projeto analítico. No entanto, às vezes, as declarações de negócios são de nível muito alto e, portanto, é necessário analisar o domínio do problema mais de perto para entender as necessidades e obter o contexto (GARG; UPADHYAYA; KWIAT, 2013).

Nessas situações, Etman (2018) sugere que o problema seja dividido em subproblemas para que os requisitos críticos sejam identificados. Além disso, você pode precisar pensar nas restrições que precisam ser incluídas na solução. Portanto, além de se pensar o que pode ser feito, deve ser identificado o que não pode ser feito.

Etman (2018) coloca o seguinte exemplo. Digamos que você trabalhe para uma empresa de cartão de crédito e que ela queira que somente os bons clientes realizem solicitações de atendimento de crédito.

Vamos analisar essa declaração do problema: sob a perspectiva dos negócios, certamente é uma definição válida, contudo, para o seu objetivo, que é criar uma solução para resolver a questão, essa informação é suficiente para que os dados possam ser analisados? Não. Essa descrição não é suficiente, pois as solicitações de crédito devem ser recebidas apenas de bons clientes, mas quem são os bons clientes? Se você tem algum conhecimento do setor de cartões de crédito, uma das respostas para um bom cliente pode ser uma pessoa que paga sua fatura em dia, ou um bom cliente pode ser pessoas que não pagam em dia. Porque, se você não pagar em dia, a empresa do cartão de crédito tem a oportunidade de cobrar altas taxas de juros sobre o saldo no seu cartão de crédito.

Quem é realmente bom cliente para uma administradora de cartão de crédito? Os clientes que pagam em dia? São os clientes inadimplentes, que não pagam em dia. Uma resposta pode ser que ambos são bons clientes. Como isso é possível? Realmente depende da sua perspectiva. Por exemplo, se você estiver interessado em minimizar o risco e trabalha na função de risco da administradora de cartão de crédito, sua definição de bom cliente pode ser os clientes que pagam em dia. Agora, se você considerar a receita, sua perspectiva de um bom cliente poderia ser uma pessoa que gasta muito no cartão de crédito e não paga tudo de volta. Como analista, quem decide quem são os bons clientes? Quando a administradora do cartão de crédito fornece um extrato e diz que é para aceitar somente as solicitações de cartão de crédito de bons clientes, como é possível saber de qual perspectiva há análise: risco ou receita? Depende realmente do interesse comercial, depende das metas de negócios para esse ano. De fato, um bom cliente, este ano, pode ser um mau cliente no próximo ano. É por isso que é importante obter o contexto ou a declaração do problema antes de iniciar uma análise.

Esse não é o único problema com a declaração de problema. Outro problema é pensar na decisão em si: você pode realmente insistir em receber boas solicitações ou em aprovar boas solicitações? A decisão está na fase de solicitação ou na fase de aprovação? Você pode realmente controlar o desempenho das solicitações ou ser referente a somente bons clientes terem a aprovação?

Outro problema é que queremos receber apenas solicitações de cartão de crédito de bons clientes. Ou seja, nunca poderemos receber uma solicitação de cartão de crédito de um cliente ruim. Provavelmente, isso seria muito difícil de se obter, para não dizer, impossível. Retornando novamente à questão da definição do domínio do problema, queremos obter bons clientes como administradora de cartão de crédito. Como podemos enquadrar esse problema de forma que a abordagem analítica possa resolver?



Uma das maneiras de identificar o domínio do problema é adicionar detalhes à declaração. Portanto, pense em resultados específicos, mensuráveis, atingíveis, realistas e oportunos que você pode anexar a essa afirmação.

No exemplo de Etman (2018), como é possível adicionar detalhes a essa declaração de problema? Pela perspectiva do risco, neste ano, a administradora de cartão de crédito se concentrou em reduzir o risco do portfólio. Assim, as declarações de problemas de negócios poderiam ser:

- Reduzir as perdas por inadimplência do cartão de crédito em, pelo menos, 30% nos primeiros doze meses após a implementação da nova estratégia.
- Desenvolver um algoritmo para rastrear as solicitações que não contemplam o critério de bom cliente, reduzindo os padrões em 20% nos próximos três meses.
- Identificar estratégias para reduzir os padrões em 20% nos próximos três meses, permitindo, aos clientes, opção de pagamento.

Agora, para a mesma declaração de negócios, temos três declarações de problemas diferentes que estão abordando três coisas diferentes. Novamente, qual devemos escolher como ponto de partida para a análise? Devemos identificar estratégias para nossos clientes ou devemos procurar identificar novos clientes? Novamente, isso é algo que pode ser impulsionado pelas necessidades de negócios. Portanto, é importante conversar constantemente com a empresa, para garantir que, ao iniciar um projeto de análise, você esteja enfrentando a afirmação correta.

Para Etman (2018), chegar a um problema claramente definido é uma ação orientada a descobertas. Comece com uma definição conceitual e, por meio da análise (causa, análise de impacto etc.), você forma e redefine o problema em termos de questões. Um problema se torna conhecido quando uma pessoa observa uma discrepância entre a maneira como as coisas são e como deveriam ser. Os problemas podem ser identificados por meio de:

- Estudos comparativos/de *benchmarking*.
- Relatório de desempenho - avaliação do desempenho atual em relação às metas e objetivos.
- Análise Strengths, Weaknesses, Opportunities e Threats (SWOT), que consiste em uma ferramenta para avaliar os pontos fortes, que são as Forças e Oportunidades, e os pontos fracos, que são Fraquezas e Ameaças (FOFA)
- Reclamações/Pesquisas.



Às vezes, o que pensamos ser um problema não é o problema real. Portanto, para chegar ao problema real, é necessário investigar. A análise de causa raiz é um método eficaz de análise: ajuda a identificar o que, como e por que algo aconteceu.

Vamos considerar que a taxa de rotatividade de funcionários em nossa organização está aumentando. Precisamos descobrir cinco causas, que se referem à prática de perguntar, cinco vezes, por que o problema existe, chegando à causa raiz do problema: por que os funcionários estão saindo para outros empregos? Por que os funcionários não estão satisfeitos? Por que os funcionários sentem que são mal pagos? Por que outros empregadores pagam salários mais altos? Por que a demanda por esses funcionários aumentou no mercado? Perguntas básicas a serem feitas na definição do problema (ETMAN, 2018):

- Quem está causando o problema?
- Quem é impactado por esse problema?
- O que acontecerá se esse problema não for resolvido? Quais são os impactos?
- Onde e quando esse problema ocorre?
- Por que esse problema está ocorrendo?
- Como o processo deve funcionar?
- Como as pessoas estão lidando com o problema atualmente?

Para converter um problema de negócios em uma solução, você precisa entender o problema, as metas e métricas de análise de dados e o mapeamento para um ou mais padrões de negócios. Mais importante: você precisa entender o que a empresa espera obter com a análise de dados e como os resultados da análise serão usados.

É necessário que o domínio do problema de dados seja resolvido de forma precisa. A formulação da hipótese ajuda. Para isso, divida os problemas e formule hipóteses; enquadre as perguntas que precisam ser respondidas ou os tópicos que precisam ser explorados para resolver um problema; desenvolva uma lista abrangente de todos os possíveis problemas relacionados ao problema; por fim, reduza a lista abrangente: eliminando duplicatas, combinando problemas sobrepostos e usando a construção de consenso, vá para uma lista de problemas importantes.



Para responder e validar as hipóteses, é necessário que a coleta de informações seja realista pois, dependendo do tipo de problema que se quer resolver, diferentes técnicas de coleta de dados podem ser usadas. A coleta de dados é um estágio crítico na solução de problemas: se ela for superficial, tendenciosa ou incompleta, será difícil realizar a análise dos dados (GARG; UPADHYAYA; KWIAT, 2013).

Warcholinski (2019) complementa que pode ser útil estruturar o problema adequadamente. Um método de estruturação de um espaço do problema é por meio da ferramenta conhecida como mapa cognitivo. O mapeamento cognitivo possibilita compreender como os diferentes aspectos da situação se relacionam. Um mapa cognitivo é uma imagem física de como são percebidos os objetos que compõem o espaço do problema, com a interconexões e interações das variáveis dos objetos.


Contudo, como sabemos se o problema foi identificado corretamente? Aqui estão algumas características básicas de um problema de dados bem definido: (i) é provável que a solução para o problema tenha impacto positivo suficiente para justificar o esforço; (ii) dados suficientes estão disponíveis em um formato utilizável; (iii) as partes interessadas estão interessadas em aplicar a ciência de dados para resolver o problema (WARCHOLINSKI, 2019). Portanto, o problema deve ser claro, conciso e mensurável. Para isso, segundo Caetano (2018b, p. 22):

[...] o preparador de dados precisa ter uma visão topdown (de cima para baixo), e não bottom-up (de baixo para cima) dos dados que ele precisa trabalhar. Ele precisa juntar as evidências sobre o problema, identificar os stakeholders que vão auxiliá-lo, definir a solução esperada, identificar as fontes de dados que ele deve trabalhar e, por fim, elaborar um plano de ação. Após ele ter uma visão global do problema, ele pode descer o nível de detalhamento até os registros que devem ser preparados.

Cai e Zhu (2015) observam que determinar os objetivos da coleta de dados é o primeiro passo de todo o processo de avaliação. Os usuários de *Big Data* escolhem racionalmente os dados a serem usados de acordo com seus objetivos estratégicos ou requisitos de negócios, como operações, tomada de decisão e planejamento. As fontes de dados, tipos, volume, requisitos de qualidade, critérios de avaliação, especificações e metas esperadas precisam ser determinados com antecedência (CAI; ZHU, 2015).

Caetano (2018b) sugere um processo com cinco fases para que o preparador de dados identifique o domínio do problema e determine adequadamente os seus objetivos. As fases se referem a definir o problema, identificar os *stakeholders*, definir solução esperada, identificar as fontes de dados e elaborar plano de ação. Cada uma das etapas deve ser interpretada no contexto do projeto de forma geral, além da preparação de dados.

FIGURA 10 – PROCESSO DE ENTENDIMENTO DO PROBLEMA



Fonte: A Autora

Um importante aspecto sobre o projeto em que o preparador de dados está envolvido é a definição dos objetivos. Existirão situações em que os objetivos serão delegados ao profissional responsável por preparar os dados, em outras situações, ele estará envolvido ou até mesmo fará parte da equipe que define os objetivos. Portanto, é de fundamental importância que o preparador de dados saiba como definir e reconhecer objetivos factíveis para, dessa forma, evitar a frustração das partes interessadas do projeto.

Uma estratégia é a definição de objetivos *Specific, Measurable, Achievable, Relevant e Time* (SMART), ou seja, que sejam Específicos, Mensuráveis, Alcançáveis, Relevantes e Temporais. A definição dos objetivos deve ser feita com uma linguagem clara. É preciso definir quem está envolvido, o que será alcançado e onde será executado o projeto, por que a equipe deve fazer e quais são as restrições do projeto.

Um objetivo deve ser mensurável. O preparador de dados e as partes interessadas devem definir como será feito o acompanhamento do progresso das atividades, além de milestones do projeto. Um objetivo deve ser alcançável. Torna-se necessário que o preparador de dados defina se os objetivos são factíveis ou se são insignificantes. Um objetivo deve ser relevante. As partes interessadas e o coordenador do projeto devem mostrar as contribuições (inclusive, da preparação de dados) e que os objetivos estão alinhados com a estratégia do negócio. Por fim, um objetivo deve ser temporal. Devem ser definidos os prazos para a execução do projeto e o projeto deve ser dividido em fases para se passar um senso de urgência.

Além dos pontos levantados, o profissional responsável pela preparação de dados deve levar em consideração as características da atividade que ele está envolvido. Se a atividade que ele executa faz parte de um projeto, então, o processo de preparação de dados será executado uma única vez, porém, se a atividade faz parte de um processo contínuo, então, a preparação de dados será executada várias vezes. Portanto, deve-se estar atento à forma como será feita a manutenção dos dados preparados.

Além disso, é fundamental que o preparador de dados tenha o processo *Extract, Transform e Load* (ETL) bem definido, referindo-se à extração, transformação e carga dos dados.

2 DADOS DE DIFERENTES ORIGENS

O *Big Data* apresenta novos recursos e enfrenta muitos desafios referentes à qualidade de dados. Como foi visto, uma das características do *Big Data* se refere à grande variedade de dados, de forma estruturada e não estruturada (CAI; ZHU, 2015). Taylor (2018) observa que os dados estruturados são muito mais fáceis de digerir pelos programas de *Big data*, enquanto os inúmeros formatos de dados não estruturados criam um desafio maior. No entanto, ambos os tipos de dados desempenham um papel fundamental na análise eficaz dos dados.

As fontes de dados comumente encontradas nas empresas são: Banco de Dados (BD), *Data Warehouse* (DW), *Data Mart* (DM) e outras. De acordo com Caetano (2018b, p. 25), “nesses locais podem estar dados relacionais e os não relacionais da empresa. A característica comum é que eles possuem uma mínima estrutura (dados relacionais são estruturados e não relacionais são semiestruturados)”.

2.1 DADOS ESTRUTURADOS X DADOS NÃO ESTRUTURADOS

Os dados estruturados são compostos por tipos de dados claramente definidos, cujo padrão os torna facilmente pesquisáveis. Já os dados não estruturados são compostos por dados que, geralmente, não são tão facilmente pesquisáveis, incluindo formatos como postagens de áudio, vídeo e mídia social.

Cabe destacar que não existe conflito entre dados não estruturados e dados estruturados. Os clientes selecionam um ou outro não com base em sua estrutura de dados, mas nos aplicativos: bancos de dados relacionais para estruturados e quase qualquer outro tipo de sistema para dados não estruturados.

FIGURA 11 – CLASSIFICAÇÃO DOS DADOS DE ACORDO COM A SUA ESTRUTURA



FONTE: Adaptado de Monteiro (2020)

É possível perceber “[...] que os dados estruturados são organizados em um padrão fixo, enquanto os não estruturados são seguem uma estrutura rígida. Os semiestruturados ficam entre os extremos: não são estruturados de forma rígida, mas também não são totalmente desestruturados” (MONTEIRO, 2020, p. 1).

• **Dados estruturados**

“Dados estruturados são aqueles organizados e representados com uma estrutura rígida, a qual foi previamente planejada para armazená-los” (MONTEIRO, 2020, p. 1). Podemos dar como exemplo um formulário cadastral contendo os campos: nome, sobrenome, telefone, e-mail e um campo perguntando se você é maior de idade, ou seja, se tem mais de 18 anos.

QUADRO 4 – DEFINIÇÃO DE CAMPO COM SUA ESTRUTURA RÍGIDA E BEM DEFINIDA

CAMPO	TIPO	COMPOSTO
Nome	Texto	Por uma sequência de letras com ou sem a presença de espaços em branco, não contendo símbolos ou números e terá um limite máximo.
Sobrenome	Texto	
Telefone	Numérico	Por número inteiro positivo.
E-mail	Texto	Por uma sequência de caracteres, contendo letras, números e símbolos, além da obrigatoriedade de uma arroba.
É maior de idade?	Valor binário	Por uma resposta: Não (armazena o valor 0) ou por uma resposta Sim (armazena o valor 1), ou seja, um bit, podendo ser 0 ou 1.

Fonte: A Autora

Taylor (2018, p. 1) destaca dois pontos:

Os dados de um mesmo cadastro estão relacionados (dizem respeito a uma mesma pessoa). Em outras palavras, os dados estruturados de um mesmo bloco (registro) possuem uma relação. Registros ou grupos de dados diferentes (como de pessoas diferentes) possuem diferentes valores, mas utilizam a mesma representação estrutural homogênea para o armazenamento dos dados.


Dessa forma, um Banco de Dados (BD) é um exemplo de dado estruturado, geralmente do tipo relacional, ou seja, um Sistema Gerenciador de Banco de Dados Relacional (SGBDR) ou, do inglês, *Relational DataBase Management System* (RDBMS) (MONTEIRO, 2020). Taylor (2018) acrescenta que esse tipo de formulário cadastral, mesmo que os dados fossem salvos em algum recurso diferente do banco de dados, como em um arquivo, continuaria sendo um dado estruturado, por ser composto por uma estrutura rígida e previamente projetada. Para Taylor (2018, p. 1):

[...] os dados são estruturados conforme a definição de um esquema, que define as tabelas com seus respectivos campos (ou atributos) e tipos (formato). O esquema pode ser pensado como uma informação do banco de dados, ou seja, uma descrição sobre a organização dos dados que serão armazenados no banco. É exatamente como no exemplo do formulário que, normalmente, está interligado com um banco de dados.

Monteiro (2020) coloca que os dados estruturados do tipo relacional podem ser gerados e pesquisados tanto por pessoas como por computador. As consultas podem ser realizadas ainda por *Structured Query Language* (SQL). Ademais, alguns bancos de dados relacionais armazenam ou apontam dados não estruturados, como os *Customer Relationship Management* (CRM).

A seguir, é possível observar os dados estruturados em um banco de dados relacional. Inicialmente, esses dados não são úteis, contudo, se analisarmos por meio de ferramentas analíticas, podem nos ajudar a desvendar padrões e tendências sobre um cliente ou uma base de clientes específica.

FIGURA 12 – EXEMPLO DE DADOS ESTRUTURADOS EM UM BANCO DE DADOS RELACIONAL



FONTE: Adaptado de Gomes (2019)

• **Dados não estruturados**

Os dados não estruturados são, geralmente, classificados como dados qualitativos e não podem ser processados e analisados usando ferramentas e métodos convencionais (PICKELL, 2018). De acordo com Taylor (2018), os dados não estruturados têm estrutura interna, mas não são estruturados por meio de modelos ou esquemas de dados predefinidos. Podem ser textuais ou não textuais e gerados por humanos ou por máquinas. Também podem ser armazenados em um banco de dados não relacional, o *Not only SQL* (NoSQL).

QUADRO 5 – DADOS NÃO ESTRUTURADOS GERADOS PELO HOMEM

TIPO	DESCRIÇÃO
Arquivos de texto	Processamento de texto, planilhas, apresentações, e-mail, logs.
E-mail	O e-mail possui estrutura interna graças aos seus metadados e, às vezes, referimo-nos a ele como semiestruturado. No entanto, seu campo de mensagens não é estruturado e as ferramentas analíticas tradicionais não podem analisá-lo.
Mídias sociais	Dados do Facebook, Twitter, LinkedIn.
Site	YouTube, Instagram, sites de compartilhamento de fotos.
Dados móveis	Mensagens de texto, locais.
Comunicações	Bate-papo, mensagens instantâneas, gravações telefônicas, software de colaboração.
Mídia	MP3, fotos digitais, arquivos de áudio e vídeo.
Aplicativos de negócio	Documentos do MS Office, aplicativos de produtividade.

FONTE: Adaptado de Taylor (2018)

QUADRO 6 – DADOS NÃO ESTRUTURADOS GERADOS PELO COMPUTADOR

TIPO	DESCRIÇÃO
Imagens de satélite	Dados meteorológicos, formas de terra, movimentos militares.
Dados científicos	Exploração de petróleo e gás, exploração espacial, imagens sísmicas, dados atmosféricos.
Vigilância digital	Fotos e vídeo de vigilância.
Dados do sensor	Tráfego, clima, sensores oceanográficos.

FONTE: Adaptado de Taylor (2018)

Pickell (2018) coloca que é difícil desconstruir dados não estruturados porque não há um modelo predefinido, não podendo ser organizado em bancos de dados relacionais. Em vez disso, os bancos de dados não relacionais ou NoSQL são mais adequados para gerenciar dados não estruturados. Outra maneira de gerenciar dados não estruturados é fazer fluírem para um Data Lake, permitindo que eles estejam em seu formato bruto e não estruturado (TAYLOR, 2018).

FIGURA 13 - VISUALIZAÇÃO DE DADOS NÃO ESTRUTURADOS



FONTE: Adaptado de Gomes (2019)

- **Dados semiestruturados**

Os dados semiestruturados apresentam uma representação heterogênea, ou seja, possuem estrutura, de forma flexível. Assim, eles agregam um pouco dos dois lados em termos de benefício, facilitando o controle por haver um pouco de estrutura, mas também tendo uma maior flexibilidade (MONTEIRO, 2020). Taylor (2018) complementa que os dados semiestruturados mantêm tags e marcações internas que identificam elementos de dados separados, permitindo o agrupamento e hierarquias de informações.


O e-mail é um exemplo muito comum de um tipo de dado semiestruturado. Embora ferramentas de análise mais avançadas sejam necessárias para rastreamento de *threads*, os metadados nativos do e-mail permitem classificação e pesquisa de palavras-chave sem nenhuma ferramenta adicional. Apesar do e-mail ser um grande caso de uso, a maioria dos centros de desenvolvimento semiestruturados se concentra em facilitar os problemas de transporte de dados. Compartilhar dados de sensores é um caso de uso crescente, assim como compartilhamento e transporte de dados baseados na Web: *Electronic Data Interchange* (EDI), muitas plataformas de mídia social, linguagens de marcação de documentos e bancos de dados NoSQL.

QUADRO 7 – DADOS SEMIESTRUTURADOS

TIPO	DESCRIÇÃO
<i>Markup language XML</i>	Esta é uma linguagem de documento semiestruturada. XML é um conjunto de regras de codificação de documentos que define um formato legível por humanos e máquinas. Embora dizer que XML seja legível por humanos não é um grande problema, quem tenta ler um documento XML tem coisas melhores a fazer com o seu tempo. Sua estrutura orientada a tags é altamente flexível e os codificadores podem universalizar a estrutura, o armazenamento e o transporte de dados na Web.
<i>Open standard JavaScript Object Notation (JSON)</i>	JSON é outro formato de intercâmbio de dados semiestruturado. Java está implícito no nome, mas outras linguagens de programação do tipo C o reconhecem. Sua estrutura consiste em pares nome/valor (ou objeto, tabela de hash etc.) e uma lista de valores ordenados (ou matriz, sequência, lista). Como a estrutura é intercambiável entre idiomas, o JSON se destaca na transmissão de dados entre aplicativos da web e servidores.
NoSQL	Os dados semiestruturados do NoSQL também são um elemento importante de muitos bancos de dados NoSQL. Os bancos de dados NoSQL diferem dos bancos de dados relacionais porque não separam a organização (esquema) dos dados. Isso torna o NoSQL a melhor opção para armazenar informações que não se encaixam facilmente no registro e tabela, como um texto com complementos variados. Há uma troca de dados mais fácil entre bancos de dados. Alguns bancos de dados NoSQL mais recentes também incorporam documentos semiestruturados, armazenando no formato JSON.

FONTE: Adaptado de Taylor (2018)

FIGURA 14 – VISUALIZAÇÃO DE DADOS SEMIESTRUTURADOS



```
{
  "image": "Cheryl-Carter.jpg",
  "firstname": "Cheryl",
  "lastname": "Carter",
  "company": "Skyble",
  "email": "ccarter@gmail.com",
  "phone": "2-(017)772-7449",
},
{ ...
```

FONTE: Adaptado de Gomes (2019)

Esses tipos de dados são comuns em infraestrutura de *Big Data* e aplicativos da Web em tempo real, como o LinkedIn. No LinkedIn, centenas de milhões de usuários corporativos compartilham livremente cargos, locais, habilidades e muito mais, e o LinkedIn captura os dados massivos em um formato semiestruturado. Quando os usuários que procuram emprego criam uma pesquisa, o LinkedIn faz a correspondência da consulta com seus enormes repositórios de dados semiestruturados, fazendo referência cruzada dos dados com as tendências de

contratação e compartilhando as recomendações resultantes com quem procura emprego. O mesmo processo opera com consultas de vendas e marketing em serviços premium do LinkedIn, como o Salesforce. A Amazon também baseia suas recomendações de leitores em bancos de dados semiestruturados (TAYLOR, 2018).

FIGURA 15 – RESUMO DA CLASSIFICAÇÃO DOS DADOS DE ACORDO COM A SUA ESTRUTURA




FONTE: Adaptado de Monteiro (2020)

Agora que já conhecemos as principais estruturas, precisamos conhecer as principais fontes de dados.

2.2 BANCO DE DADOS

Em um banco de dados relacional, os dados podem ser manipulados usando comandos SQL, tanto pela aplicação como pelo usuário, enquanto em um banco de dados não relacional os dados podem ser manipulados usando requisições próprias da linguagem de manipulação não relacional (pela aplicação ou pelo usuário) (CAETANO, 2018b).

FIGURA 16 – PRINCIPAIS DIFERENÇAS ENTRE BANCOS RELACIONAL E NÃO RELACIONAL



FONTE: Adaptado de Caetano (2018b)

Caetano (2018b, p. 25) coloca que, em um banco de dados relacional:

Os dados manipulados estão organizados em tabelas que pertencem a uma base de dados. As tabelas possuem uma estrutura predefinida em que é organizado um conjunto de registros e cada registro possui atributos. Podemos chamar os registros de linhas e os atributos de colunas. Cada instância de registro é uma tupla. Em um banco de dados relacional, cada tabela possui uma chave primária. Essa chave primária identifica os registros da tabela e permite fazer a ligação (joins) com outras tabelas (com o uso de chaves estrangeiras).

Ainda, Caetano (2018b, p. 25) menciona que:

Os dados manipulados estão organizados em documentos que pertencem a uma coleção. Os documentos não possuem uma estrutura predefinida e os dados podem ser armazenados de diversas formas. Bancos de dados não relacionais possuem chave primária, porém ela não funciona como chave estrangeira em outras coleções. Portanto, as ligações entre documentos devem ser feitas na aplicação ou de acordo com a estratégia mais comum: todos os dados correlatos ficam em um único documento (ao invés de serem separados em vários documentos).

• *Data Warehouse e Data Mart*

Para Inmon (2005), *Data Warehouse* (DW) é uma arquitetura que deve ser construída sob uma metodologia de desenvolvimento própria. O objetivo é armazenar dados atuais e históricos oriundos de uma ou mais fontes de dados, de forma integrada, orientada ao assunto, não volátil.

FIGURA 17 – PRINCIPAIS CARACTERÍSTICAS

Orientado por assunto

- os dados são organizados por assunto de interesse

Integrado

- representação única dos dados que são oriundos das várias fontes de dados

Não volátil


- conteúdo dos dados não é alterado ao longo do tempo

Variante no tempo (Histórico)

- existem dados atuais e históricos

FONTE: Adaptado de Inmon (2005)

FIGURA 18 – ARQUITETURA GENÉRICA DE DW



FONTE: Adaptado de Elias (2014)

QUADRO 8 – ELEMENTOS E DESCRIÇÕES

ELEMENTO	DESCRIÇÃO
Fonte de dados	Abrange todos os dados de origem que irão compor as informações do DW. Compreende os sistemas <i>OnLine Transaction Processing</i> (OLTP), arquivos em diversos formatos (XLS, TXT etc.), sistemas de <i>Customer Relationship Management</i> (CRM), <i>Enterprise Resource Planning</i> (ERP) etc.
<i>Extract, Transform and Load</i> (ETL)	É o principal processo de condução dos dados até o armazenamento definitivo no DW. É responsável por todas as tarefas de extração, tratamento e limpeza dos dados, além da inserção na base do DW.
<i>Staging Area</i>	É uma área de armazenamento intermediário situada dentro do processo de ETL. Auxilia a transição dos dados das origens para o destino final no DW.

<i>Data Warehouse</i>	Estrutura propriamente dita de armazenamento das informações decisivas, contendo apenas os dados com valor para a gestão corporativa.
<i>Data Mart</i>	Estrutura similar à do DW, porém, com uma proporção menor de informações. Trata-se de um subconjunto de informações do DW que pode ser identificado por assuntos ou departamentos específicos. O conjunto de <i>Data Marts</i> (DM) dentro da organização compõe o DW.
<i>On-line Analytical Processing (OLAP)</i>	Ferramentas com capacidade de análise em múltiplas perspectivas das informações armazenadas.
<i>Data Mining</i>	Ferramentas com capacidade de descoberta de conhecimento relevante dentro do DW. Encontram correlações e padrões dentro dos dados armazenados.

FONTE: Adaptado de Elias (2014)

Para Caetano (2018b, p. 27):

Um Data Mart é um Data Warehouse de um assunto específico que apoia análises de um setor ou área da empresa. Normalmente, a organização opta por implementar Data Marts pela especificidade do problema, por ser mais simples ou por questões de custo. Um Data Mart pode ser do tipo dependente ou independente. Em um Data Mart dependente, os dados inseridos no Data Warehouse são replicados no Data Mart e, em um Data Mart do tipo independente, os dados do Data Warehouse não são replicados no Data Mart. Um Data Mart é um sistema completo que pode conter dados de fontes operacionais ou externas, possuindo relação com os problemas da área ou setor que utiliza o Data Mart.



O armazenamento e gerenciamento de dados podem ocorrer de maneiras diferentes que as aqui colocadas, como é o caso dos *Data Lakes*.

3 ENRIQUECIMENTO DE DADOS

Enriquecer um conjunto de dados é uma atividade da preparação de dados que “[...] possibilita fazer a correlação dos eventos internos capturados pelos registros da organização com eventos externos do mundo real. Assim, é possível fazer a descoberta de novas análises, facilitando o processo de extração de informações dos dados” (CAETANO, 2018, p. 29). Katz (2019) coloca que o enriquecimento de dados descreve uma abordagem mais ampla que pode envolver a limpeza e o acréscimo de conjuntos de dados existentes, além de haver conexão com dados externos de mídias sociais, listas de contatos e outras

fontes de terceiros. Portanto, pode-se dizer que a atividade de enriquecimento de dados é qualquer coisa que refine e melhore a qualidade dos dados do cliente, preenchendo lacunas e corrigindo informações "ruins".

O enriquecimento ou aprimoramento de dados é o processo de aprimorar as informações existentes, complementando dados ausentes ou incompletos. Normalmente, o enriquecimento de dados é obtido usando fontes de dados externas, mas nem sempre é o caso. Em grandes empresas com diferentes sistemas e informações fragmentadas, não é incomum enriquecer as informações fornecidas por uma fonte com dados de outra. Isso é particularmente comum durante a migração de dados, em que as informações do cliente são fragmentadas entre vários sistemas e os dados de um sistema são usados para complementar dados do outro e formar um registro de dados mais completo no repositório.

Para Pyle (1999), o enriquecimento dos dados só ocorre quando as informações adicionadas ao conjunto de dados forem provenientes de fontes externas, caso contrário, há aprimoramento. Aprimoramento significa embelezar ou expandir o conjunto de dados existente sem adicionar fontes externas. A extração de recursos é uma maneira de aprimorar dados. Outro método é introduzir viés para um propósito particular. Adicionar viés introduz uma perspectiva em um conjunto de dados, isto é, as informações no conjunto de dados são percebidas mais prontamente de um ponto de vista específico ou para uma finalidade específica. Um conjunto de dados com uma perspectiva pode ou não reter seu valor para outros fins (PYLE, 1999).

Pode ser um grande desafio enriquecer dados. O processo se inicia com a qualidade dos dados existentes. Se as informações existentes estiverem incorretas ou incompletas, provavelmente, não será possível realizar a correspondência a uma fonte de referência para o complemento do que está faltando. Também pode ser muito caro, já que a maioria das fontes de referência exigirá uma taxa de assinatura ou cobrança por volume ou conjuntos de dados regionais específicos.


Toda forma de enriquecimento de dados é válida, dependendo apenas das metas de negócio da empresa. O importante é identificar o tipo de dados que você precisa buscar, coletar ou adquirir para obter uma solução positiva. Se tivéssemos que dizer apenas uma palavra, diríamos: cautela. Sempre que você adquire dados de terceiros ou tenta corresponder dois conjuntos de dados primários, deve haver um fator comum que vincula os dois conjuntos de dados (HINTON, 2018).

Ao corresponder dados a outra fonte, sempre existe o risco de a correspondência não ser precisa. A maioria das empresas que fornece serviços de correspondência de clientes com suas fontes incluirá uma pontuação automatizada que representa seu nível de confiança com a correspondência. Por exemplo, uma pontuação de 90 significa um nível de confiança de 90% de que a correspondência é boa. As empresas precisarão trabalhar com seus fornecedores de dados para determinar o que é aceitável para seus negócios. Há três intervalos:

- Intervalo superior: por exemplo, igual ou superior a 80% e acima, as correspondências são aceitas automaticamente.
- Intervalo intermediário: por exemplo, entre 60 e 80%, as correspondências precisam ser analisadas manualmente para determinar se são boas ou não.
- Intervalo inferior: por exemplo, igual ou inferior a 60%, as correspondências são recusadas automaticamente.

Ao considerar uma correspondência correta, as informações adicionais fornecidas pela fonte de referência podem ser usadas para enriquecer os dados existentes. O enriquecimento de endereço é muito comum, em que a combinação de alguns elementos de endereço é usada para encontrar o que está faltando. Os exemplos incluem o uso de código postal para descobrir cidade e estado, ou o uso da linha de endereço, cidade e estado para determinar o código postal.

O desafio surge quando há informações conflitantes. Por exemplo, digamos que cidade, estado e código postal sejam todos preenchidos. No entanto, ao tentar enriquecer as informações do município, o código postal sugere um município, enquanto a cidade e o estado sugerem outro. A escolha final se resume ao nível de confiança das informações originais. Se a intenção é automatizar o processo de correspondência, pode ser necessário avaliar quais informações geralmente são preenchidas com mais precisão, de acordo com o sistema fornecido e as práticas comerciais associadas. Caso não seja possível realizar essa determinação, provavelmente, será necessário um processo manual para situações conflitantes.



O enriquecimento de dados pode ser definido como a fusão de dados de terceiros (fonte externa), devidamente autorizada, ao conjunto de dados existentes primários.

Hinton (2018) coloca que existem vários tipos de enriquecimento de dados e fontes, sendo o enriquecimento de dados demográficos e o enriquecimento de dados geográficos os dois tipos mais comuns.

QUADRO 9 – DOIS TIPOS MAIS COMUNS DE ENRIQUECIMENTO DE DADOS

TIPO	DESCRIÇÃO
Enriquecimento de dados demográficos	O enriquecimento de dados demográficos envolve a aquisição de novos dados demográficos, como o estado civil e o nível de renda, e a inclusão em um conjunto de dados de clientes existente. Os tipos de dados demográficos são vastos, assim como as fontes. Você pode receber um conjunto de dados que inclui o número de filhos, o tipo de carro, o valor médio da residência etc. O que importa, com o enriquecimento demográfico, é qual é o seu objetivo final. Se você deseja fornecer ofertas de cartão de crédito, por exemplo, poderá adquirir um banco de dados que forneça a classificação de crédito de uma pessoa. Os dados enriquecidos, dessa maneira, podem ser aproveitados para melhorar a segmentação geral das ofertas de marketing.
Enriquecimento de dados geográficos	O enriquecimento de dados geográficos envolve a adição de dados postais ou latitude e longitude a um conjunto de dados existente que inclui endereços de clientes. Existem vários fornecedores que permitem comprar esses dados, que podem incluir códigos postais, limites geográficos entre cidades e vilas, informações de mapeamento, e assim por diante. Adicionar esse tipo de insight aos seus dados é útil em alguns contextos. Os varejistas podem usar dados geograficamente enriquecidos para determinar sua próxima localização na loja. Se o varejista quiser capturar o maior número de clientes dentro de um raio específico, por exemplo, 48 quilômetros, poderá aproveitar os dados enriquecidos para tomar essa decisão. Os profissionais de marketing também podem usar o enriquecimento geográfico para economizar em mala direta em massa.

FONTE: Adaptado de Hinton (2018)

O enriquecimento de um conjunto de dados com informações provenientes de fontes de dados de terceiros é uma tarefa comum de preparação de dados na ciência. Tecnologias semânticas e dados abertos vinculados podem fornecer suporte valioso, abrindo caminho para novas ferramentas amigáveis para cientistas de dados que podem facilitar atividades de preparação de dados que consomem esforço, são difíceis e chatas. A atividade pode ser realizada de várias maneiras, como pelo uso de dados internos (dados de planilhas, e-mails, mídias e de outros bancos não centralizados), uso de *Application Programming Interface* (API) (redes sociais e *web services*), uso de bases abertas (governamentais ou de plataformas especializadas) e, ainda, pelo uso de ferramentas (coleta de dados da web) (CAETANO, 2018b).

FIGURA 19 – ALGUMAS FONTES PARA ENRIQUECER DADOS



ONTE: Adaptado de Caetano (2018b)

É possível verificar o uso de APIs como forma de enriquecimento de dados, contudo, algumas redes sociais não possuem APIs para a coleta de dados. Por exemplo: WhatsApp, LinkedIn e Facebook não possibilitam ter os seus dados coletados, enquanto Youtube e o Twitter permitem a coleta de dados por meio de APIs. Geralmente, independentemente da rede social, existem características de restrição em comum. Para Caetano (2018, p. 30), “as principais são que elas requerem o uso de tokens e possuem restrições de tempo entre requisições e quantidade de dados”.

Outra forma de enriquecer os dados é fazer uso de bases de dados abertos. Ressaltamos que os dados também podem ser enriquecidos de fontes de dados pagas, como pela Agência Estado Broadcast, Bloomberg e Neoway.

QUADRO 10 – BASE DE DADOS ABERTA

FONTES DE DADOS PÚBLICAS	DESCRIÇÃO
data.gov	Bases de dados sobre dados demográficos dos Estados Unidos e de indústria, comércio e outros assuntos do contexto americano.
dados.gov.br	Bases de dados referentes a diversos segmentos e assuntos do Brasil. O Portal Brasileiro de Dados Abertos, em novembro de 2019, possuía 7209 conjuntos de dados de vários órgãos públicos, como o Banco Central, CVM, Ministérios, Estados, Municípios, Legislativo e Judiciário.
DBpedia	A Wikipedia é uma ótima fonte de informação. A DBpedia visa obter conteúdo estruturado a partir das informações criadas na Wikipedia. Possibilita pesquisar e explorar relacionamentos e propriedades do recurso da Wikipedia, incluindo links para outros conjuntos de dados relacionados também.
Datasets abertos do Yelp	O conjunto de dados do Yelp é, basicamente, um subconjunto dos nossos próprios negócios, revisões e dados do usuário para uso em atividades pessoais, educacionais e acadêmicas.
EU Open Data Portal	Dados abertos e essenciais relativos aos domínios políticos da UE. Esses domínios de políticas incluem economia, emprego, ciência, meio ambiente e educação.
FiveThirtyEight	Site para jornalismo baseado em dados, contendo uma breve explicação sobre cada conjunto de dados com relação à origem.

FreeCodeCamp	Comunidade de código aberto, podendo ser encontrados conjuntos de dados, análises e, até mesmo, demonstrações de projetos com base nos dados freeCodeCamp. Você também pode encontrar links para projetos externos envolvendo os dados freeCodeCamp.
Google public data explorer	Possibilita explorar centenas de fontes públicas de dados.
IBGE	Dados de diversas pesquisas e séries históricas para download.
Kaggle.com	Bases de dados coletadas por universidades e cientistas de dados.
LODUM	Dados abertos sobre artefatos científicos e codificados, como dados vinculados são disponibilizados sob o projeto, sendo uma iniciativa Open Data da Universidade de Münster.
Registry of Open Data on AWS	Catálogo de dados abertos disponíveis na Amazon Web Services (AWS).
Repositório de aprendizado de máquina da UCI	Repositório abrangente de bancos de dados, teorias de domínio e geradores de dados que são usados pela comunidade de aprendizado de máquina para a análise empírica de algoritmos de aprendizado de máquina.
UNdata	Base de dados das Nações Unidas, de forma pública.
UNICEF	Entidade que se preocupa com uma ampla variedade de questões críticas. Compilou dados relevantes sobre educação, trabalho infantil, deficiência infantil, mortalidade infantil, mortalidade materna, água e saneamento, subnutrição de recém-nascido, cuidados pré-natais, pneumonia, malária, deficiência de iodo, mutilação/corte genital feminino e adolescentes.
World Bank Open Data	Base gratuita e aberta de dados globais de desenvolvimento do Banco Mundial.
WHO (World Health Organization)	Site que acompanha as estatísticas específicas de saúde de seus 194 Estados Membros, mantendo seus dados organizados sistematicamente e podendo ser acessado de acordo com diferentes necessidades.

Fonte: A Autora

A coleta de dados também pode ser realizada por meio de ferramentas. Dependendo do objetivo da coleta, há a utilização da abordagem *Web Crawlers*, *Web Scrapers*, ou mesmo utilizadas conjuntamente. Data Science Academy (2018, p. 1) coloca que, “com Web Crawling, obtemos informações genéricas e, com Web Scraping, informações específicas”.

Web Crawler é um algoritmo utilizado para realizar uma varredura na web, para analisar sites e coletar informações. O algoritmo coleta informações do código do site, página por página. Ainda, segue cada um dos links, internos e externos. Alguns dos principais *Web Crawler* é o Googlebot (Google), Yahoo! Sluro (Yahoo) e Msnbot (Microsoft utiliza no buscador Bing). Além desses citados, é possível desenvolver um *crawler* específico, sendo necessário conhecimento em programação. Ainda, é possível utilizar opções pagas e públicas.

QUADRO 11 – WEB CRALWER

WEB CRALWER	DESCRIÇÃO
Apifer	Útil para o monitoramento da concorrência e guia decisões relevantes para o seu próprio site.
Arachnode.net	Sistema de código aberto escrito em linguagem C#.
Dyno Mapper	Objetiva criar automaticamente mapas do site.
Oncrawl	Realiza auditorias de SEO completas no seu site.
Screaming frog	Rastreador de sites, que permite rastrear <i>Uniform Resource Locator</i> (URLs) dos sites para analisar e auditar o <i>Search Engine Optimization</i> (SEO) técnico e local. Versão gratuita limitada e versão paga para recursos avançados.

Fonte: A Autora

Data Science Academy (2018, p.1) define *Web Crawler* como:

[...] o ato de baixar automaticamente os dados de uma página web, extrair os hiperlinks contidos e segui-los. Os dados baixados são, geralmente, armazenados em um índice ou banco de dados para facilitar sua busca. Web Crawling, também conhecido como Indexação, é usado para indexar as informações em uma página web usando bots, também chamados de crawlers.

Web Scraper é um sistema para realizar o processo de extração de dados de forma automática, simulando a navegação humana e copiando os dados que são requeridos. Estes são disponibilizados no fim da navegação em formato de planilha. Basicamente, extrai e reúne, da web, conjuntos de dados. Para Data Science Academy (2018, p.1), esse conjunto de dados é a base do “[...] Big Data Analytics, Machine Learning e Inteligência Artificial. Esses dados podem ser usados em projetos de Data Science para resolver problemas de negócio específicos e ajudar os tomadores de decisão, trazendo vantagem competitiva”. Data Science Academy (2018, p. 1) define *Web Scraper* como:

Os atos de baixar automaticamente os dados de uma página web e extrair informações muito específicas. As informações extraídas podem ser armazenadas praticamente em qualquer lugar (banco de dados, arquivo etc.). Web Scraping, também conhecido como Extração de Dados da Web, é uma maneira automatizada de extrair informações/conteúdo usando bots, conhecidos como scrapers. Aqui, as informações podem ser usadas para replicar em algum outro site ou podem ser usadas para análise de dados.



Considerações ao usar *Web Scraping* ou *Web Crawling*:

- Use uma *Application Programming Interface* (API) se uma for fornecida, em vez de coletar dados.
- Respeite os Termos de Serviço.
- Respeite as regras do robots.txt.
- Use uma taxa de rastreamento razoável, ou seja, não bombardeie o site com solicitações. Respeite a configuração de tempo de acesso de rastreamento no robots.txt; se não houver, use uma taxa de rastreamento conservadora (por exemplo, 1 solicitação por 10 a 15 segundos).
- Identifique seu scraper ou crawler com uma string legítima do agente do usuário. Crie uma página que explique o que você está fazendo e por que está fazendo. Ainda, faça um link para a página na string do agente (por exemplo, MY-BOT (+ <https://seusite.com/mybot.html>)).
- Se o termo de serviço ou o robots.txt impedir que você rastreie ou raspe, peça uma permissão por escrito ao proprietário do site antes de fazer qualquer outra coisa.
- Não publique novamente seus dados rastreados ou copiados ou qualquer conjunto de dados derivado sem verificar a licença dos dados ou sem obter uma permissão por escrito do detentor dos direitos autorais.
- Se você duvida da legalidade do que está fazendo, não faça. Procure o conselho de um advogado.
- Não baseie toda a sua empresa na extração de dados. O site que você raspa pode, eventualmente, bloquear você.
- Finalmente, você deve suspeitar de qualquer conselho que você encontrar na internet, então, por favor, consulte um advogado.
- Lembre-se: empresas e indivíduos estão perfeitamente livres para processar, por qualquer motivo que desejarem.

Se você raspar/rastrear o site deles sem permissão e fizer algo que eles não gostem, você definitivamente se colocará em uma posição vulnerável.

3.1 ESTUDO DE CASO: ENRIQUECENDO UMA BASE DE DADOS

Considere o seguinte problema: uma empresa está desenvolvendo um projeto de mineração de dados e, durante o entendimento do problema, percebe-se que os dados internos da empresa não são suficientes. O objetivo da organização é obter uma ampla compreensão sobre os perfis de potenciais clientes. Diante dessa situação, o problema que foi atribuído ao profissional que faz a preparação de dados é o de coletar dados de redes sociais e de bases externas que auxiliem a execução do projeto de mineração de dados.

Após uma exploração inicial, o preparador de dados define que serão coletados os dados das redes sociais Twitter e YouTube, e serão coletados de portais de notícias, pois essas fontes possuem dados mais relacionados com o domínio do problema que se pretende resolver. Além disso, o preparador de dados define o seguinte plano de ação: utilizar as APIs existentes das redes sociais, utilizar *Web Crawlers* para explorar os portais de notícias e utilizar *Web Scrapers* para coletar o conteúdo das páginas web. A seguir, vamos conhecer cada uma das ferramentas que esse profissional pode utilizar e, também, que você pode utilizar para resolver problemas semelhantes.

A API do Twitter (dev.twitter.com) possibilita coletar tweets publicados em tempo real, obter o histórico de tweets de um usuário (*timeline*), coletar dados de perfis de usuários e coletar a rede de contatos de usuários (*friends* e *followers*). A API possui restrições de tempo de coleta e de tamanho de dados que podem ser consultadas em: developer.twitter.com/en/docs/basics/rate-limiting. Um exemplo de restrição é o da coleta da *timeline* dos usuários, permitindo, no máximo, 200 *tweets* por requisição.

Podem ser coletados dados pela API do Twitter de várias formas. Podem ser feitas requisições web diretamente à API do Twitter ou, então, utilizar bibliotecas que implementam a requisição web por chamada de métodos. As bibliotecas *tweepy* e *twython* do Python são opções para quem deseja utilizar o Python.

A API do YouTube (developers.google.com/youtube) permite fazer a coleta de comentários dos vídeos, fazer busca de vídeos por palavra-chave e, também, coletar o perfil do usuário que comentou o vídeo. Diferentemente do Twitter, o YouTube faz cobrança após uma certa taxa de utilização mensal da API.

A coleta em portais de notícias pode ser utilizada para coletar as notícias (texto e imagem) e os comentários. As bibliotecas *scrapy* e *selenium* do Python podem ser utilizadas para fazer o processamento. A biblioteca *selenium* é uma implementação para Python da ferramenta Selenium (seleniumhq.org), majoritariamente utilizada para testes unitários e automação de browsers. Dessa forma, é possível fazer a simulação do comportamento humano (cliques de botão, *scroll-down/scroll-up* etc.) para lidar com páginas responsivas.

RESUMO DO TÓPICO 2

Neste tópico, você aprendeu que:

- O processo de coleta de dados é uma tarefa desafiadora e envolve muitos problemas que devem ser abordados antes que os dados sejam coletados e usados.
- Os principais problemas no processo de coleta e utilização de dados são: um trabalho tedioso e consome um tempo considerável, variando de semanas a meses; é invasivo e envolve questões de privacidade do usuário, entre outros problemas; dados coletados podem não estar no formato utilizável imediatamente e podem exigir esforços adicionais.
- Somente poderemos resolver o problema do cliente se, primeiramente, compreendermos o domínio do problema.
- O domínio do problema precisa ser amplamente identificado para que existam informações precisas, oportunas e úteis sobre os problemas estratégicos.
- Uma das maneiras de identificar o domínio do problema é adicionar detalhes à declaração. Portanto, pense em resultados específicos, mensuráveis, atingíveis, realistas e oportunos que você pode anexar a essa afirmação.
- Determinar os objetivos da coleta de dados é o primeiro passo de todo o processo de avaliação.
- Uma das maneiras do preparador de dados identificar o domínio do problema e determinar adequadamente os seus objetivos é realizando o processo em cinco fases: definir o problema, identificar os *stakeholders*, definir solução esperada, identificar as fontes de dados e elaborar um plano de ação.
- É fundamental que o preparador de dados saiba definir e reconhecer os objetivos.
- A linguagem utilizada na definição dos objetivos precisa ser clara, específica, mensurável, alcançável, relevante e temporal.
- É fundamental que o preparador de dados tenha o processo *Extract, Transform e Load* (ETL) bem definido.
- As fontes de dados comumente encontradas nas empresas são: Banco de Dados (BD), *Data Warehouse* (DW), *Data Mart* (DM) e outras fontes de dados.
- Os bancos de dados podem ser do tipo relacional ou não relacional.

- Os dados podem ser estruturados, semiestruturados e não estruturados.
- Os dados estruturados são compostos por tipos de dados claramente definidos, cujo padrão os torna facilmente pesquisáveis, podendo ser gerados pelo homem ou por computador.
- Os bancos de dados relacionais geralmente contêm dados estruturados.
- Os dados não estruturados são compostos por dados que, geralmente, não são tão facilmente pesquisáveis, incluindo formatos, como postagens de áudio, vídeo e mídia social.
- Os dados não estruturados são, geralmente, classificados como dados qualitativos e não podem ser processados e analisados usando ferramentas e métodos convencionais, gerados pelo homem ou por computador.
- Os bancos de dados não relacionais ou NoSQL são mais adequados para gerenciar dados não estruturados.
- Os dados semiestruturados apresentam uma representação heterogênea, ou seja, possuem estrutura, de forma flexível.
- Em um banco de dados relacional, a estrutura de registros é predefinida, os registros são atômicos e os formatos de dados são únicos.
- Em um banco de dados não relacional, a estrutura de registros é flexível, os registros podem ser alinhados e os formatos de dados são flexíveis.
- *Data Warehouse* (DW) é uma arquitetura que deve ser construída sob uma metodologia de desenvolvimento própria, para armazenar dados atuais e históricos oriundos de uma ou mais fontes de dados, de forma integrada, orientada ao assunto, não volátil, voltada para a inteligência do negócio.
- *Extract, Transform and Load* (ETL) é o principal processo de condução dos dados até o armazenamento definitivo no DW. É responsável por todas as tarefas de extração, tratamento e limpeza dos dados, além da inserção na base do DW.
- *Data Mart* é uma estrutura similar à do DW, contudo, com uma proporção menor de informações, pois trata de um subconjunto de informações do DW.
- *Staging Area* é uma área de armazenamento intermediário situada dentro do processo de ETL.
- *Data Lakes* podem ser utilizados para armazenar e gerenciar os dados.
- O enriquecimento de dados é qualquer coisa que refine e melhore a qualidade dos dados do cliente, preenchendo lacunas e corrigindo informações "ruins".

- O enriquecimento de dados, normalmente, é obtido usando fontes de dados externas e, quando as fontes de dados são internas, alguns autores chamam de aprimoramento de dados.
- Aprimoramento significa embelezar ou expandir o conjunto de dados existente sem adicionar fontes externas.
- O enriquecimento de dados pode ser definido como a fusão de dados de terceiros (fonte externa).
- Existem vários tipos de enriquecimentos de dados e fontes para obter dados, sendo o enriquecimento de dados demográficos e o enriquecimento de dados geográficos os dois tipos mais comuns.
- Enriquecimento de dados demográficos envolve a aquisição de novos dados demográficos, como o estado civil e o nível de renda, e a inclusão, em um conjunto de dados, de clientes.
- Enriquecimento de dados geográficos envolve a adição de dados postais ou latitude e longitude a um conjunto de dados existente, incluindo endereços de clientes.
- Usos de dados internos, de APIs, de bases abertas e de ferramentas são algumas das fontes de enriquecimento de dados.
- *Web Crawler* é um algoritmo utilizado para realizar uma varredura na web, para analisar sites e coletar informações.
- *Web Scraper* é um sistema para realizar o processo de extração de dados de forma automática, simulando a navegação humana e copiando os dados que são requeridos. Estes são disponibilizados no fim da navegação em formato de planilha.



1 Para converter um problema de negócios em uma solução, você precisa entender o problema, as metas e métricas de análise de dados e o mapeamento para um ou mais padrões de negócios. Mais importante, você precisa entender o que a empresa espera obter com a análise de dados e como os resultados da análise serão usados. No contexto, analise as sentenças a seguir e indique a afirmativa com a ordem CORRETA:

- I- Definir o problema.
- II- Identificar os *stakeholders*.
- III- Identificar as fontes de dados.
- IV- Elaborar plano de ação.
- V- Definir a solução esperada.

- a) () I - II - V - III - IV.
- b) () I - II - III - IV - V.
- c) () V - IV - III - II - I.
- d) () IV - III - V - II - I.

2 As fontes de dados comumente encontradas nas empresas são: Banco de Dados (BD), *Data Warehouse* (DW), *Data Mart* (DM) e outras fontes de dados. A forma de armazenamento desses locais pode ser tanto relacional como não relacional e, nos dois tipos, é encontrada uma estrutura mínima. Referente aos bancos de dados não relacionais, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Os dados manipulados estão organizados em documentos que pertencem a uma coleção. Os documentos não possuem uma estrutura predefinida e os dados podem ser armazenados de diversas maneiras.
- () Os dados manipulados estão organizados em tabelas que pertencem a uma base de dados.
- () Os documentos possuem uma estrutura predefinida e os dados podem ser armazenados somente de algumas formas.
- () Assim como bancos de dados relacionais, os bancos de dados não relacionais possuem chaves primárias e estrangeiras para fazer o relacionamento entre as entidades (tabelas).

Assinale a alternativa com a sequência CORRETA:

- a) () V - F - F - F.
- b) () V - F - V - F.
- c) () F - V - V - F.
- d) () F - F - V - V.

3 Os dados estruturados são compostos por tipos de dados claramente definidos, cujo padrão os torna facilmente pesquisáveis. Já os dados não estruturados são compostos por dados que, geralmente, não são tão facilmente pesquisáveis, incluindo formatos, como postagens de áudio, vídeo e mídia social. Por fim, os dados semiestruturados apresentam uma representação heterogênea, ou seja, possuem estrutura, uma forma flexível. Referente aos dados estruturados, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Um texto contendo uma sequência de letras (com ou sem espaços em branco), podendo ou não conter símbolos ou números, e com um número máximo definido, é um exemplo de campo de dados semiestruturado.
- () Banco de dados é um exemplo de dado estruturado.
- () Um formulário cadastral, quando armazenado em um arquivo, é considerado um dado estruturado.
- () Os dados estruturados do tipo relacional somente podem ser pesquisados por pessoas.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

4 Os dados não estruturados são, geralmente, classificados como dados qualitativos e não podem ser processados e analisados usando ferramentas e métodos convencionais. Os dados não estruturados têm estrutura interna, mas não são estruturados por meio de modelos ou esquemas de dados predefinidos. Referente aos dados não estruturados, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Os dados não estruturados podem ser de formato textual ou não textual e gerados somente por um humano.
- () É fácil construir o dado não estruturado porque não possui um modelo predefinido, não podendo ser organizado em bancos de dados relacionais.
- () O campo de mensagens não é estruturado e as ferramentas analíticas tradicionais não podem analisá-lo.
- () Os dados não estruturados podem ser armazenados em um banco de dados não relacional, o NoSQL.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

5 O enriquecimento de dados descreve uma abordagem mais ampla que pode envolver a limpeza e o acréscimo de conjuntos de dados existentes, além da conexão com dados externos de mídias sociais, listas de contatos e outras fontes de terceiros. Portanto, pode-se dizer que a atividade de enriquecimento de dados é qualquer coisa que refine e melhore a qualidade dos dados do cliente, preenchendo lacunas e corrigindo informações "ruins". Referente a fontes que podem ser utilizadas para enriquecer os dados, analise as sentenças a seguir:

- I- Há um algoritmo utilizado para realizar uma varredura na web, para analisar sites e coletar informações. O algoritmo coleta informações do código do site, página por página. Ainda, segue cada um dos links, internos e externos, que estiverem na página.
- II- Redes sociais e de *web services*.
- III- Há um sistema para realizar o processo de extração de dados de forma automática, simulando a navegação humana e copiando os dados que são requeridos. Estes são disponibilizados no fim da navegação em formato de planilha
- IV- Bases governamentais ou de plataformas especializadas.

Assinale a alternativa com a sequência CORRETA:


- a) () Web Crawler – Uso de APIs - Web Scraper – Base abertas.
- b) () Web Scraper – Uso de APIs - Web Crawler – Base abertas.
- c) () Web Crawler – Base abertas - Web Scraper – Uso de APIs.
- d) () Web Scraper – Base abertas - Web Crawler – Uso de APIs.

FERRAMENTAS DE PREPARAÇÃO DE DADOS, *DATA LAKES* E *DATA PONDS*

1 FERRAMENTAS PARA PREPARAÇÃO DE DADOS

Existe uma ampla variedade de ferramentas de preparação de dados disponíveis, utilizadas para descobrir, processar, mesclar, refinar, enriquecer e transformar dados, possibilitando uma melhor integração, uso e análise de conjuntos de dados, além de linguagens utilizadas no processo.


FIGURA 20 – LINGUAGENS MAIS UTILIZADAS (KAGGLE)



FONTE: Adaptado de Kaggle (2017)


AI Multiple (2019) traz outras fontes, como os resultados da pesquisa KDNuggets, trazendo um resultado similar. A seguir, é possível perceber o crescimento do uso da Linguagem Python, dado que se consolida quanto à linguagem que os cientistas de dados recomendariam como primeira linguagem de aprendizado.

GRÁFICO 2 – LINGUAGENS MAIS UTILIZADAS (OUTRAS FONTES)



FONTE: Adaptado de AI Multiple (2019)

FIGURA 21 – LINGUAGEM RECOMENDADA COMO PRIMEIRA LINGUAGEM



FONTE: Adaptado de Kaggle (2017)

Embora esteja claro que o Python é a ferramenta mais popular entre os cientistas de dados, estando em primeiro lugar e, o R, em segundo, existe todo um ecossistema de ferramentas de ciências de dados.

FIGURA 22 – FERRAMENTAS NA PREPARAÇÃO DE DADOS



FONTE: Adaptado de AI Multiple (2019)



Para que você esteja preparado para o mercado de trabalho, é importante conhecer as principais ferramentas referentes ao ecossistema da preparação de dados. Dessa forma, a seguir, elencamos algumas ferramentas que todos precisam conhecer e a leitura 50, disponível no link <https://limeproxies.com/blog/50-reporting-tools-data-scientists-2019-experts/#data>.

QUADRO 12 – FERRAMENTAS QUE TODOS PRECISAM CONHECER

FERRAMENTA	DESCRIÇÃO
Alteryx	É utilizada para descobrir, preparar os dados, realizar a análise e permitir compartilhar analytics e implantar (ALTERYX, 2020). Saiba mais: https://youtu.be/8kUPNSBHCxo .
DataRobot	Pode ser utilizada para “[...] desenvolver e testar centenas de soluções que combinam preparação de dados em nível especializado com algoritmos de Machine Learning de R, Python, Spark, H20, TensorFlow etc.” (DATAROBOT, 2020, p. 1).
Lumen Data	É uma plataforma de gerenciamento de informações que adota uma abordagem em fases por meio de sua metodologia específica para <i>Master Data Management</i> (MDM). Os principais recursos são: experiência em gerenciamento de dados corporativos, governança e qualidade dos dados, integrações construídas e especialização em nuvem (CHAPMAN, 2019). Saiba mais: https://youtu.be/9i05kf0AxoE .
Paxata	É utilizada para combinar dados de diferentes fontes e, posteriormente, verificar problemas de qualidade de dados, como redundância e <i>outliers</i> . O processo de preparação de dados é, até certo ponto, automatizado por algoritmos e aprendizado de máquina, e os usuários trabalham com o software por meio de uma interface de usuário semelhante às planilhas do Excel.
Qubole	É uma plataforma baseada na nuvem que gerencia, otimiza e aprende a melhorar seus dados de forma automática. Segundo Amazon Web Services (2020, p. 1): O QDS é uma plataforma de ativação de dados nativa da nuvem que ajuda a operacionalizar o Data Lake, reduzindo os custos e as complexidades do gerenciamento de Big Data. O Qubole autogerencia, analisa e aprende o uso da plataforma por meio de heurística e Machine Learning. Ele provisiona insights e recomendações para otimizar a confiabilidade, performance e custos. O Qubole trabalha em conjunto com os serviços da AWS, como o Amazon Simple Storage Service (Amazon S3) e o Amazon Elastic Compute Cloud (Amazon EC2). Acesse o site do Qubole e o guia de implantação, com instruções passo a passo, tanto para configurar como para configurar um ambiente Qubole Data Service (QDS) pelo link https://aws.amazon.com/pt/quickstart/architecture/qubole-on-data-lake-foundation/.

RapidMiner	A plataforma permite obter visibilidade do trabalho em equipe e da governança de ciência de dados. O RapidMiner Radoop remove a complexidade da preparação de dados e do aprendizado de máquina no Hadoop e Spark. A plataforma é usada em muitos setores com diferentes tipos de soluções. Segundo Wikipedia (2019, p. 1): é uma plataforma de software de ciência de dados desenvolvida pela empresa de mesmo nome, fornecendo um ambiente integrado para preparação de dados, aprendizado de máquina, aprendizado profundo, mineração de texto e análise preditiva. Ela é usada para aplicativos comerciais, pesquisa, educação, treinamento, prototipagem rápida e desenvolvimento de aplicativos e suporta todas as etapas do processo de aprendizado de máquina, incluindo preparação de dados, visualização de resultados, validação e otimização de modelos.
Trifacta	É utilizada para explorar, transformar e enriquecer dados brutos em formatos limpos e estruturados. A Trifacta utiliza técnicas de aprendizado de máquina, visualização de dados, interação homem-computador e processamento paralelo para usuários finais, a fim de preparar dados para uma variedade de processos de negócios, como análises. O principal produto da ferramenta Trifacta é o Wrangler, responsável por auxiliar na organização e estruturação dos seus dados, chegando a fazer sugestões de transformações e agregações por meio de algoritmos e aprendizado de máquina. Saiba mais: https://youtu.be/akChvnnl7SI.

Fonte: A Autora

2 LINGUAGEM R E LINGUAGEM PYTHON

A linguagem R é uma linguagem para manipulação de dados e análises estatísticas, de código aberto “[...] para computação estatística e construção de gráficos que pode ser baixada e distribuída gratuitamente, de acordo com a licença GNU. O R está disponível para as plataformas UNIX, Windows e MacOS” (LANDEIRO, 2011, p. 1). Landeiro (2011) também coloca os passos necessários para Windows, sendo:

- Entrar no site do R www.r-project.org.
- Clicar em *Comprehensive R Archive Network* (CRAN).
- Escolher o espelho de sua preferência (CRAN *mirrors*).
- Clicar em Windows 95 ou superior.
- Clicar em base e salvar o arquivo do R para Windows. Posteriormente, basta executar o arquivo.


Caetano (2018b, p. 16) complementa que ela:

[...] possui um amplo conjunto de bibliotecas para análise e visualização de dados. Além disso, a linguagem R é amigável para pessoas de todas as áreas (computação, biologia, sociologia, estatística etc.). A linguagem R também é um conjunto de facilitadores para manipulação de dados. Ela possui bibliotecas de manipulação e armazenamento de dados (arquivos de texto, bancos de dados etc.). A linguagem apresenta alto desempenho na manipulação de dados, pois ela tem uma estrutura vetorial (operações em arrays e matrizes são mais rápidas). Suas bibliotecas possibilitam gerar gráficos de excelente qualidade. Dessa forma, é possível gerar gráficos que podem ser exportados diretamente para relatórios que serão apresentados para a gerência ou clientes.

Assim como a linguagem R, a linguagem Python é uma linguagem de código aberto, possuindo compatibilidade multiplataforma e sintaxe simples. Além disso, a linguagem Python é uma linguagem orientada a objetos, de alto nível, e interpretada de script, servindo para diferentes fins, como de computação gráfica e estatística.

Tanto as funcionalidades da linguagem Python quanto as funcionalidades da linguagem R são adicionadas por meio de bibliotecas (*package*). A codificação para realizar a instalação e a carga das bibliotecas pode ser observada a seguir.


FIGURA 23 – INSTALAÇÃO E CARGA DE BIBLIOTECA



FONTE: Adaptado de Caetano (2018b)

As duas linguagens permitem a integração com bancos de dados, como MongoDB, PostgreSQL e Oracle, por meio de bibliotecas. Ainda, elas permitem que sejam manipulados arquivos, como TeXTo (.TXT), *JavaScript Object Notation* (.JSON), *Comma-Separated Values* (.CSV), *eXtensible Markup Language* (.XML) etc. A codificação para leitura de dados de um arquivo .csv das duas linguagens (R e Python) pode ser observada a seguir.


FIGURA 24 – LEITURA DE ARQUIVO DE DADOS DO TIPO .CSV



FONTE: Adaptado de Caetano (2018b)

As duas linguagens utilizam a função estatística *built-in* para explorar os dados, de maneira embutida. A seguir, há a codificação da função `head` para visualizar as primeiras linhas dos dados que foram importados. Ainda, a função `summary` do R e `describe` do Python, para visualizar as informações estatísticas dos dados.


FIGURA 25 – EXPLORAÇÃO INICIAL DE DADOS NO ARQUIVO DO TIPO .CSV



FONTE: Adaptado de Caetano (2018b)

De acordo com Caetano (2018b, p. 17), “para fazer a manipulação de dados, as duas linguagens apresentam diversos recursos para selecionar colunas, linhas e valores, de acordo com um filtro”. A codificação se refere a “[...] selecionar a linha 10 e todas as colunas da tabela de dados (DataFrame), selecionar as colunas A e B e todas as linhas, e filtrar os dados em que os valores da coluna A são maiores de 10” (CAETANO, 2018b, p. 17).

FIGURA 26 – MANIPULAÇÃO DE DADOS



FONTE: Adaptado de Caetano (2018b)

A visualização de dados é realizada de forma diferente nas duas linguagens, ou seja, elas utilizam bibliotecas diferentes. A linguagem R conta com as bibliotecas ggplot2 e a rgl, enquanto a linguagem Python utiliza as bibliotecas matplotlib e searborn.

FIGURA 27 – VISUALIZAÇÃO DE DADOS



```
ggplot(dataset, aes(x=A)) +  
  geom_histogram(binwidth=.5, colour="black", fill="white")
```



```
import matplotlib.pyplot as plt  
plt.hist(dataset.B, normed=True, bins=30)
```

FONTE: Adaptado de Caetano (2018b)

LEITURA COMPLEMENTAR

DATA LAKES E DATA PONDS

Considere a seguinte situação: uma organização possui diversas fontes de dados: bancos de dados, dados não estruturados (como planilhas, e-mails e arquivos de mídia), dados de redes sociais que foram coletados em projetos de mineração de dados, dados de sensores de equipamentos do maquinário da empresa e dados de páginas web (tanto da intranet quanto da web).

EXEMPLO DE CONJUNTO DE DADOS CORPORATIVOS




FONTE: Adaptado de Caetano (2018b)

Todos esses dados fazem parte do conjunto de dados corporativos que a empresa tem, a princípio, para extrair informações. Contudo, vários fatores podem facilitar ou dificultar a extração das informações. Um fator de grande importância menciona como esses dados podem ser acessados. Eles estão descentralizados (em bancos, *Data Marts* ou diretórios espalhados nos servidores da empresa)? Existem dados na nuvem? Os dados estão em um *Data Warehouse*?

A análise de dados, utilizando como fonte um *Data Warehouse*, é uma abordagem recorrente nas empresas. Os dados de um *Data Warehouse* estão limpos e consistentes. A limpeza, formatação e integração são executadas antes do carregamento. Esses dados são não voláteis e estão em tabelas que podem ser manipuladas por comandos SQL.

ANÁLISE DE DADOS UTILIZANDO UM DATA WAREHOUSE



FONTE: Adaptado de Caetano (2018b)

Apesar dessas características descreverem um conjunto de dados preparado para as análises do preparador de dados, existe a seguinte ressalva: o processo de *Extraction, Transformation e Load* (ETL) pode ser, na maioria das situações, dispendioso. Assim, há mais burocracia para executar projetos de análise.


O conceito de *Data Warehouse*, por não ser recente, e dependendo do negócio da empresa, pode não condizer com a realidade atual. O conceito refletia um contexto da internet e do *Big Data*. Na época (década de 1970), o armazenamento e processamento de dados eram caros. Além disso, havia pouca variedade, além do baixo volume de dados.

Sabemos que o cenário atual é completamente diferente. Por isso, um conceito de gerenciamento de dados que tem tido popularidade é o *Data Lake*. Esse conceito possibilita suportar soluções de *Big Data*, suporta grande variedade e alto volume de dados, e aproveita da seguinte realidade atual: o armazenamento e processamento de dados são baratos.

Um *Data Lake* pode ser definido da seguinte maneira: conceito que inclui uma coleção de instâncias de armazenamento de vários ativos de dados armazenados em seu formato original. Além disso, é uma alternativa aos *Data Marts* e *Data Warehouses* em processos de análise de dados.

A seguir, há três diferentes tipos de *Data Lake* que uma empresa pode ter. Os dois primeiros (*Data Swamp* e *Data Pond*) não são *Data Lakes* de verdade, mas uma versão degenerada e limitada. Um *Data Lake* se torna um *Data Swamp* ao coletar e armazenar dados em seu formato original e deixar para analistas encontrarem sentido nos dados quando precisarem. Dessa forma, há gasto de tempo com exploração dos dados e, o *Data Lake*, ao invés de ser uma solução para empresa, se torna um problema.

DATA LAKE E SEU VALOR PARA O NEGÓCIO



FONTE: Adaptado de Caetano (2018b)

Um *Data Pond* é um mini *Data Lake*. Ele possui um escopo e valor limitado, é voltado para a resolução de problemas específicos da empresa, e somente uma pequena equipe tem acesso. Percebe-se que um *Data Pond* não permite ter uma visão holística dos dados da empresa e, dessa forma, oferece um valor limitado para o negócio.

Existem vários benefícios ao utilizar um *Data Lake*. Por exemplo, os tipos de dados para extração de valor são ilimitados. Não é necessário ter todas as respostas de imediato, não existem limites de como os dados são manipulados e há centralização dos dados para análises. Contudo, também existem vários desafios na utilização de um *Data Lake*, por exemplo, a visibilidade de onde estão os dados de interesse, decisões de governança de TI e a complexidade de implementação do projeto.


Implementação de *Data Lake*

Um *Data Lake* é um conceito e, portanto, pode ser implementado de diversas maneiras. As decisões mais comuns de implementação envolvem a utilização de bancos NoSQL e da tecnologia de armazenamento Hadoop Distributed File System (HDFS). Contudo, um *Data Lake* pode ser baseado em *Hadoop* e relacional. A decisão de como implementar o *Data Lake* dependerá da estratégia e do orçamento da empresa.

O mais importante aspecto é o valor que o *Data Lake* oferece para o negócio da empresa. A seguir, há os serviços que devem ser suportados em um *Data Lake*, divididos em quatro categorias: (i) aquisição de dados – diz respeito aos serviços de coletar e armazenar os dados; (ii) gestão de dados – diz respeito aos serviços de processamento e integração dos dados de um *Data Lake*; (iii) acesso aos dados – diz respeito aos serviços de entrega e utilização dos dados; (iv) armazenamento de dados – diz respeito a como os dados serão armazenados e gerenciados no *Data Lake*.

Todos esses serviços devem oferecer suporte para operação em diversas latências: em tempo real, incremental, em lote (*batch*) e em cópia única.

SERVIÇOS SUPORTADOS EM DATA LAKES




FONTE: Adaptado de Caetano (2018b)

Existem duas principais abordagens de implementação e utilização de *Data Lakes* em uma organização. A primeira define o *Data Lake* como um substituto do *Data Warehouse* e, a segunda, define que o *Data Lake* e o *Data Warehouse* coexistem e se complementam. A primeira abordagem requisita uma análise de custo e benefício cuidadosa, pois o investimento em equipamentos, softwares, processos e serviços relacionados com o *Data Warehouse* poderá ser descartado ou sofrer grandes transformações.

A implementação da abordagem pode ser desafiadora, porém, existem distribuições de plataformas facilitadoras, como a Hortonworks, Cloudera e MapR. A segunda abordagem de implementação é, geralmente, o caminho mais fácil, pois valoriza o investimento feito no *Data Warehouse* da organização e aumenta as capacidades.

Organização de um *Data Lake*

A organização arquitetural de um *Data Lake* é um aspecto que transcende a abordagem de implementação. Recomenda-se que existam, a princípio, quatro áreas em um *Data Lake*: (i) área temporária, (ii) área de *sandbox*, (iii) área de dados brutos e (iv) área dos dados confiáveis.

ORGANIZAÇÃO DE UM *DATA LAKE*

FONTE: Adaptado de Caetano (2018b)

Na área temporária, o consumidor principal dos dados é o setor de TI. A área é especialmente necessária quando existe a necessidade de que algum controle de qualidade seja executado nos dados. Por exemplo, os dados devem ser analisados e criados seus metadados.

Na área de dados brutos, os dados são armazenados nos formatos originais e estão prontos para o consumo. Os consumidores principais são os responsáveis pelo ETL, engenheiros de dados e alguns cientistas de dados.

Na área de *Sandbox*, ocorrem a execução de mineração de dados e atividades exploratórias. Ainda, existe uma mínima governança dos dados e os resultados obtidos nas análises e procedimentos podem ser promovidos para a Área de Dados Confiáveis.

Na área de dados confiáveis, os dados estão limpos, organizados e prontos para o consumo por todas as áreas da organização. Os consumidores principais são analistas de negócios e processos de análise de dados da empresa. Aqui, existe a preocupação de observar a aplicação de governança e segurança dos dados.

A organização dessas quatro áreas do *Data Lake* está sustentada pelos processos “pilares”: segurança – quem pode acessar e como ocorrerá o acesso, governança – gerenciamento, controle e fluxos de dados, e gestão da informação – quais dados devem permanecer em cada área e quando um dado se torna obsoleto.

Manutenção *Data Lake*

Considere a seguinte situação: um banco deseja criar um *Data Lake* especialmente para auxiliar na criação de uma plataforma de relatórios de risco, que será utilizada em tomadas de decisão da instituição em relação a investimentos e empréstimos. Os dados são provenientes de bases de dados de riscos e agregam

registros de diversas origens e de diversos tipos, como relatórios governamentais, pesquisas de mercado, dados de instituições financeiras etc. Além disso, o banco utilizará os próprios dados para complementar essas bases de dados de riscos.

Diante dessa situação, percebe-se a alta necessidade de o banco ver seus dados como um valioso ativo para o negócio. Esses dados devem ser, acima de tudo, confiáveis, e devem ser úteis para as tomadas de decisões da organização. Contudo, devido ao alto número de fontes de dados, tipos e volume, a chance de que a utilização do *Data Lake* se degenera para um *Data Swamp* é alta.

Algumas práticas, em um *Data Lake* (DL), devem ser seguidas para evitar essa degeneração. Um DL deve ter dados de alta qualidade (pelo menos, na Área de Dados Confiáveis), boa linhagem dos dados, escalabilidade e deve ser gerenciado por administradores por meio de uma plataforma. Essa plataforma de gerenciamento é composta por ferramentas e processos.

Existem várias ferramentas no mercado que ajudam no gerenciamento dos dados. A maioria delas pertence ao ecossistema Hadoop. Entretanto, um ponto essencial do gerenciamento do DL é o conjunto de processos que a empresa define. Exemplos desses processos de gerenciamento são a atribuição de administradores, definição de um conselho corporativo e gerenciamento integrado.

Gerenciamento integrado de um *Data Lake*

O gerenciamento integrado é um importante processo na manutenção de DLs. No processo, estão definidas decisões importantes, por exemplo, como serão a qualidade e consistência dos dados do DL, políticas e padrões que devem ser observados, segurança, privacidade e conformidade do DL e o gerenciamento do ciclo de vida dos dados.

As partes interessadas no projeto do DL devem definir o que é necessário para que os dados tenham qualidade e consistência suficientes para serem úteis para analistas de negócios e cientistas de dados, quais são as políticas e os padrões para inserir, transformar e utilizar dados e se esses aspectos são observados uniformemente em toda a organização.

Além disso, as partes interessadas devem definir como ocorrerá o acesso aos dados confidenciais e em qual momento os dados sigilosos serão tratados. Por fim, as partes interessadas devem participar juntamente com a TI com relação a como ocorrerá o gerenciamento do ciclo de vida dos dados, além da promoção dos dados dentro do DL.

Quanto à governança de dados, vários aspectos devem ser observados, como a criptografia, procedência, linhagem, utilização de metadados e limpeza. A inserção de dados deve ser gerenciada, isto é, associar o dado com seu metadado para evitar o desaparecimento dentro do DL.

A inserção gerenciada pode ocorrer de duas formas. Na primeira, o metadado é previamente conhecido e, então, dado e metadado são inseridos no DL ao mesmo tempo. Na segunda forma, o metadado é atribuído posteriormente por um administrador do DL, que define o que está armazenado em uma determinada célula do DL. A segunda forma possibilita maior flexibilidade do uso do DL, porém, devem ser definidas regras que limitam o tempo que um dado pode ficar sem metadados ou o tamanho máximo permitido de dados sem metadados no DL.

A seguir, há uma classificação dos metadados em três tipos: técnico, operacional e negócio. Cada um desses tipos de metadados possui suas finalidades e aplicações. Um dado pode ter um arquivo de metadados e/ou vários arquivos.

TIPOS DE METADADOS

Tipo de metadado	Descrição	Exemplo
Técnico	Forma e estrutura do dado	Tipo e estrutura interna
Operacional	Linhagem, qualidade e procedência	Fontes e locais chave e linhagem
Negócio	Importância para o usuário	Nomes de produtos e serviços, tags

FONTE: Adaptado de Caetano (2018b)

Uma abordagem para manter a linhagem dos dados é o uso do catálogo de dados. Esse recurso é um aspecto fundamental para um bom projeto de *Data Lake*, pois suporta os usuários para encontrar dados prontos para o consumo. Tanto os usuários técnicos quanto os usuários do negócio podem utilizar o catálogo.

Quanto à privacidade dos dados no DL, deve-se ter, como regra básica, que o *Data Lake* deve estar disponível para todos os usuários da empresa, porém, o acesso deve respeitar as restrições de permissões e devem ser decididas regras de como dados sensíveis serão disponibilizados.

O gerenciamento do ciclo de dados deve definir como os dados serão armazenados e gerenciados, como ocorrerá a compressão de dados (se houver), e como será mantido o Acordo de Nível de Serviço (ANS) com as diferentes áreas da organização. Por isso, devem ser definidos locais, no DL, que suportem altos números de requisições e locais de baixa prioridade, nos quais os dados podem ser armazenados.


A preparação de dados deve ser executada antes de eles serem promovidos para a Área de Dados Confiáveis. As principais atividades que devem ser executadas são a correção de erros e inconsistências, conversão de formatos para facilitar a pesquisa, atribuição de marca d'água (linhagem dos dados) e atribuição de identificadores únicos nos registros.

O processo integrado possui vários benefícios. Ele facilita o entendimento da procedência e contexto dos dados, permite fazer a identificação de atualizações e modificações nos dados dentro do *Data Lake* e suporta a execução de transformações nos dados sem que eles percam sua identidade e finalidade dentro do DL. Esses benefícios são, em grande parte, alcançados com o gerenciamento de metadados.

Estudo de caso: projetando um *Data Lake*


Considere o seguinte problema: uma empresa deseja melhorar os processos de ETL, pois eles são, atualmente, os principais gargalos no processo de análise de dados. O objetivo é aumentar a competitividade da empresa a curto/médio prazo com investimentos em infraestrutura, corpo técnico e remodelagem de processos. Cabe, ao engenheiro de dados da organização, projetar uma solução de *Data Lake* que tenha uma boa relação custo e benefício e atenda às expectativas das partes interessadas.

Como vimos anteriormente, existem duas principais abordagens de implementação de um *Data Lake*: (i) *Data Lake* como substituto do *Data Warehouse* e (ii) *Data Lake* e *Data Warehouse* coexistem e se complementam. No presente caso de uso, o engenheiro de dados optou pela coexistência que pode seguir duas estratégias: (i) *Data Lake* como área de preparação para o DW e (ii) *Data Lake* para arquivamento ativo. O engenheiro de dados do presente estudo de caso deverá escolher.



FONTE: Adaptado de Caetano (2018b)

DATA LAKE PARA ARQUIVAMENTO ATIVO




FONTE: Adaptado de Caetano (2018b)

Na primeira estratégia, há uma redução das necessidades de armazenamento no *Data Warehouse*, facilitação do uso dos dados armazenados no *Data Lake*, e o *Data Lake* substitui os bancos de dados relacionais. Na segunda estratégia, ocorre o arquivamento de dados que podem ser manipulados por comandos SQL. Assim, são definidas políticas de retenção de dados (tanto no *Data Warehouse* quanto no *Data Lake*). Além disso, com a utilização do *Data Warehouse* e do *Data Lake* para a análise de dados, torna-se mais fácil fazer a recuperação de dados ativos e históricos.

A figura a seguir apresenta o padrão interativo geralmente observado em um *Data Lake*. Os dados são inseridos em seu formato original indefinidamente, ocasionando uma aquisição de dados com baixo custo. Em seguida, os dados são analisados no local onde são inseridos para determinação do valor. Geralmente, essa análise envolve o processamento paralelo e distribuído. Por fim, os dados valiosos para a organização são integrados com o *Data Warehouse*. Esses dados podem ser utilizados em novas análises que, por sua vez, também produzirão dados que terão seu valor determinado no local.

PADRÃO INTERATIVO DO DATA LAKE



FONTE: Adaptado de Caetano (2018b)

A coexistência entre *Data Lake* e *Data Warehouse* permite o aproveitamento dos pontos fortes de cada conceito. Dessa forma, o uso correto de um *Data Lake* gera maiores agilidade, flexibilidade e entrega rápida de projetos de análise de dados, facilitando a exploração dos dados em seu formato original (não há perda de informação). O uso de um *Data Warehouse* ocasiona governança dos dados, confiabilidade, padronização e segurança.

Além do engenheiro de dados no presente estudo de caso decidir qual abordagem e estratégia de coexistência deverão ser implementadas, entre *Data Lake* e *Data Warehouse*, o profissional terá que tomar decisões a respeito de como ocorrerá a integração com o *Data Warehouse* (seletiva, total etc.). Ainda, ele deverá elaborar um modelo que forneça suporte aos experimentos dos cientistas de dados, análises dos analistas e, também, aos engenheiros responsáveis pela preparação.

Para isso, torna-se altamente recomendável que a Área de *Sandbox* do *Data Lake* seja destinada para a preparação de dados e para condução de projetos de mineração de dados.

Na Área de *Sandbox*, deverá ser o ambiente para a execução de scripts e algoritmos e uma estação de trabalho local. Quando os dados estiverem preparados e prontos para o consumo de analistas de dados e demais pessoas da empresa, devem ser promovidos para a Área dos Dados Confiáveis, em que rotinas estáveis de análise e processamento são executadas. Portanto, quando o projeto termina, há, então a descontinuação do local onde estavam armazenados os dados na Área de *Sandbox* e o conjunto de dados é promovido.

Existem inúmeras ferramentas facilitadoras do projeto de *Data Lake*. Assim, os profissionais responsáveis devem decidir qual (ou quais) utilizar. As mais famosas são a Apache Drill, Impala, Pig, Hive e Apache Spark.

FONTE: CAETANO, J. A. **Preparação de dados**. 2018b. Disponível em: <https://rapido.igti.com.br/products/pdd-class>. Acesso em: 11 fev. 2020.

RESUMO DO TÓPICO 3

Neste tópico, você aprendeu que:

- Existe uma ampla variedade de ferramentas de preparação de dados disponíveis.
- As ferramentas para preparação de dados são utilizadas para descobrir, processar, mesclar, refinar, enriquecer e transformar dados.
- As ferramentas para preparação de dados possibilitam uma melhor integração, uso e análise de conjuntos de dados.
- A linguagem R e a linguagem Python são as linguagens mais utilizadas pelos preparadores de dados.
- Os cientistas de dados recomendam a linguagem Python como primeira linguagem de aprendizado.
- Embora esteja claro que o Python é a ferramenta mais popular entre os cientistas de dados, estando em primeiro lugar e, o R, em segundo, existe todo um ecossistema de ferramentas de ciências de dados.
- A ferramenta Alteryx é utilizada para descobrir, preparar os dados, realizar a análise, além de compartilhar analytics e implantar.
- A ferramenta DataRobot é para criar, implantar e manter a Inteligência Artificial (IA) em escala, automatizando todo o processo, ou seja, de ponta a ponta, utilizando algoritmos de código aberto.
- A ferramenta Lumen Data é uma plataforma de gerenciamento de informações que adota uma abordagem em fases por meio de sua metodologia específica para Master Data Management (MDM).
- A ferramenta *Paxata* é utilizada para combinar dados de diferentes fontes e, posteriormente, verificar problemas de qualidade de dados, como redundância e *outliers*.
- A ferramenta Qubole é uma plataforma baseada na nuvem que gerencia, otimiza e aprende a melhorar seus dados de forma automática.
- A ferramenta RapidMiner permite obter visibilidade do trabalho em equipe e governança de ciência de dados. O RapidMiner Radoop remove a complexidade da preparação de dados e do aprendizado de máquina no Hadoop e Spark.

- A ferramenta Trifacta é utilizada para explorar, transformar e enriquecer dados brutos em formatos limpos e estruturados. A Trifacta utiliza técnicas de aprendizado de máquina, visualização de dados, interação homem-computador e processamento paralelo para usuários finais, preparando dados para uma variedade de processos de negócios, como análises.
- A linguagem R é uma linguagem para manipulação de dados e análises estatísticas, de código aberto, servindo para finalidades, como as computações gráfica e estatística.
- A linguagem Python é uma linguagem de código aberto, possuindo compatibilidade multiplataforma e sintaxe simples.
- A linguagem Python é uma linguagem orientada a objetos, de alto nível e interpretada de script, servindo para diferentes fins, como de computação gráfica e estatísticas.
- As funcionalidades da linguagem Python e as da linguagem R são adicionadas por meio de bibliotecas (*package*).
- A codificação para instalar bibliotecas em R é `install.Packaes ("<nome da biblioteca>")`.
- A codificação para instalar bibliotecas em Python é `pip instale <nome da biblioteca>`.
- A codificação para carregar bibliotecas em R é `library (<nome da biblioteca>)`.
- A codificação para carregar bibliotecas em Python é `import <nome da biblioteca> as <nome do alias>`.
- A linguagem R e a Python permitem a integração com bancos de dados, como MongoDB, PostgreSQL, Oracle etc., por meio de bibliotecas. Ainda, elas permitem que sejam manipulados arquivos.
- A codificação para realizar a leitura de arquivos de dados do tipo .csv em R é `dataset <- read.csv("<nome do arquivo.csv>")`.
- A codificação para realizar a leitura de arquivos de dados do tipo .csv em Python é `dataset = <nome do alias>.read_csv('<nome do arquivo.csv>')`.
- A linguagem R e a linguagem Python utilizam a função estatística *built-in* para explorar os dados.
- A codificação para visualizar as primeiras linhas dos dados que foram importados da biblioteca em R é `head(dataset) summary(dataset)`.

- A codificação para visualizar as primeiras linhas dos dados que foram importados da biblioteca em Python é `dataset.head()` `dataset.describe()`.
- A linguagem R e a linguagem Python apresentam vários recursos para trabalhar com colunas, linhas e valores de acordo com um filtro.
- A linguagem R utiliza as bibliotecas `ggplot2` e `rgl` para realizar a visualização de dados.
- A linguagem Python utiliza as bibliotecas `matplotlib` e `seaborn` para realizar a visualização de dados.
- O *Data Lake* pode ser uma alternativa aos *Data Marts* e *Data Warehouse* em processos de análise de dados.
- *Data Lake* pode ser definido como uma coleção de instâncias de armazenamentos de diversos ativos de dados armazenados em seu formato original.
- *Data Lakes* podem ser apresentados de três formas: *Data Swamp*, *Data Pond* e *Data Lake*.
- *Data Swamp* e *Data Ponds* não são *Data Lakes*, mas uma versão limitada de um *Data Lake*.
- Um *Data Pond* é um mini *Data Lake*, voltado para projetos com equipe pequena e escopo e valor limitados.
- *Data Lake* é um conceito. Envolve, na sua implementação, utilizar banco de dados NoSQL e tecnologia de armazenamento Hadoop Distributed File System (HDFS).
- *Data Lakes* devem suportar serviços, e esses serviços podem ser divididos em quatro categorias: aquisição de dados, gestão de dados, acesso aos dados e armazenamento de dados.
- Aquisição de dados se refere aos serviços de coleta e armazenamento dos dados.
- Gestão de dados se refere aos serviços de processar e integrar os dados de um *Data Lake*.
- Acesso aos dados se refere aos serviços de entregar e utilizar os dados.
- Armazenamento de dados se refere à forma que o *Data Lake* (DL) armazena e gerencia os dados.

- A área temporária de um DL é especialmente necessária quando existe a necessidade de que algum controle de qualidade seja executado nos dados.
- Na área de dados brutos de um DL, os dados estão armazenados em sua forma original e prontos para serem utilizados.
- Na área de *Sandbox* de um DL, é realizada a execução da mineração de dados, além das atividades relacionadas à exploração.
- Na área de confiáveis de um DL, os dados estão limpos, assim como estão organizados e prontos para serem utilizados.



Ficou alguma dúvida? Construímos uma trilha de aprendizagem pensando em facilitar sua compreensão. Acesse o QR Code, que levará ao AVA, e veja as novidades que preparamos para seu estudo.





1 Existe uma ampla variedade de ferramentas de preparação de dados disponíveis, utilizadas para descobrir, processar, mesclar, refinar, enriquecer e transformar dados, possibilitando uma melhor integração, uso e análise de conjuntos de dados, além das linguagens utilizadas no processo. As linguagens R e Python são as duas linguagens mais utilizadas. Com relação à linguagem R, analise as sentenças a seguir, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () É uma linguagem para manipulação de dados e análises estatísticas.
- () Possui um amplo conjunto de bibliotecas para análise e visualização de dados.
- () É uma linguagem de código privado.
- () Possibilita integração apenas com o banco de dados MongoDB.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

2 Assim como a linguagem R, a linguagem Python é uma linguagem de código aberto, possuindo compatibilidade multiplataforma e sintaxe simples. Além disso, a linguagem Python é uma linguagem orientada a objetos, de alto nível, e interpretada de script, servindo para diferentes fins, como de computação gráfica e estatística, assim como o R. Tanto as funcionalidades da linguagem Python quanto as funcionalidades da linguagem R são adicionadas por meio de bibliotecas (*package*). Escolha a codificação para instalar bibliotecas na linguagem Python.

- a) () `install.Packaes("<nome da biblioteca>")`.
- b) () `pip install <nome da biblioteca>`.
- c) () `library(<nome da biblioteca>)`.
- d) () `import <nome da biblioteca> as <nome do alias>`.

3 As linguagens R e Python permitem a integração com bancos de dados, como MongoDB, PostgreSQL, Oracle etc., por meio de bibliotecas. Ainda, elas permitem que sejam manipulados arquivos, como TeXTo (.TXT), JavaScript Object Notation (.JSON), Comma-Separated Values (.CSV), eXtensible Markup Language (.XML) etc. Diante disso, escolha a alternativa com a codificação para leitura de dados de um arquivo .csv na linguagem R.

- a) () `dataset = <nome do alias>.read_csv("<nome do arquivo.csv>")`.
- b) () `head(dataset) summary(dataset)`.
- c) () `dataset.head() dataset.describe()`.
- d) () `dataset <- read.csv("<nome do arquivo.csv>")`.

4 As linguagens R e Python servem para diferentes fins, como de computação gráfica e estatística. Tanto a linguagem R quanto a linguagem Python utilizam a função estatística *built-in* para explorar os dados. Diante disso, escolha a alternativa com a codificação para visualizar as informações estatísticas na linguagem Python.

- a) ☐ `head(dataset) summary(dataset).`
- b) ☐ `dataset <- read.csv("<nome do arquivo.csv>").`
- c) ☐ `dataset.head() dataset.describe().`
- d) ☐ `dataset <- read.csv("<nome do arquivo.csv>").`

5 *Data Warehouse* (DW) é uma arquitetura que deve ser construída sob uma metodologia de desenvolvimento própria, para armazenar dados atuais e históricos oriundos de uma ou mais fontes de dados, de forma integrada, orientada ao assunto, não volátil, voltada para a inteligência de negócio. Um conceito de gerenciamento de dados que tem tido popularidade é o *Data Lake*. Referente aos *Data Lakes*, analise as sentenças a seguir e escolha a sentença INCORRETA:

- a) ☐ *Data Lake* é uma tecnologia cuja implementação deve utilizar banco de dados relacional e tecnologia de armazenamento Hadoop Distributed File System (HDFS).
- b) ☐ *Data Lake* é uma tecnologia cuja implementação deve utilizar banco de dados relacional e tecnologia de armazenamento Hadoop Distributed File System (HDFS).
- c) ☐ *Data Lakes* podem ser apresentados de três formas: *Data Swamp*, *Data Pond* e *Data Lake*.
- d) ☐ *Data Swamp* é um mini *Data* e *Data Ponds* não são *Data Lakes* de verdade, mas uma versão limitada de um *Data Lake*.

LIMPEZA, TRANSFORMAÇÃO E REDUÇÃO DE DADOS

OBJETIVOS DE APRENDIZAGEM

A partir do estudo desta unidade, você deverá ser capaz de:

- compreender os impactos ao resolver problemas nos dados;
- identificar as atividades relacionadas com a limpeza de dados;
- analisar e aplicar corretamente diferentes métodos para preencher dados ausentes;
- identificar características redundantes e outliers;
- como estruturar um conjunto de características;
- identificar se a qualidade dos dados é suficiente para executar as análises propostas;
- transformar dados categóricos em representações numéricas;
- discretizar dados contínuos e compreender suas aplicações;
- normalizar dados para que todos atributos tenham a mesma grandeza, e como a disparidade entre os atributos pode afetar a representação numérica das amostras.

PLANO DE ESTUDOS

Esta unidade está dividida em três tópicos. No decorrer da unidade, você encontrará autoatividades com o objetivo de reforçar o conteúdo apresentado.

TÓPICO 1 – LIMPEZA E PREENCHIMENTO DE DADOS

TÓPICO 2 – TRANSFORMAÇÃO DE DADOS

TÓPICO 3 – REDUÇÃO DE DADOS E ANÁLISE POR COMPONENTES PRINCIPAIS



Preparado para ampliar seus conhecimentos? Respire e vamos em frente! Procure um ambiente que facilite a concentração, assim absorverá melhor as informações.



LIMPEZA E PREENCHIMENTO DE DADOS

1 INTRODUÇÃO

A preparação de dados é uma das etapas mais demoradas, envolvendo atividades como a limpeza de dados, que veremos neste tópico; a transformação dos dados (por exemplo, alterações na escala de variáveis), que veremos no Tópico 2 desta unidade ou, até mesmo, a criação de novas variáveis que podem trazer informações úteis para as etapas da análise.

Goldschmidt e Passos (2005, p. 37) colocam que “[...] é comum que os dados estejam incompletos, ruidosos ou inconsistentes. Os dados são considerados incompletos se há informação ausente para determinados atributos ou, ainda, se há dados pouco detalhados”. Torgo (2017) enfatiza a questão de trabalharmos os dados. Pode-se dizer que dados ruidosos se referem a dados errôneos ou que possuam valores divergentes do padrão normal esperado, considerados *outliers*, enquanto dados inconsistentes se referem aos dados que possuem alguma discrepância semântica.

As atividades da fase de limpeza dos dados dizem respeito a realizar “[...] uma verificação da consistência das informações, a correção de possíveis erros e o preenchimento ou a eliminação de valores desconhecidos e redundantes, além da eliminação de valores não pertencentes ao domínio” (GOLDSCHMIDT; PASSOS, 2005, p. 37). Tanto Wickham (2014) quanto Torgo (2017) colocam a importância dessas atividades. Assim, pode-se dizer que o objetivo da fase é arrumar a base de dados, suprimindo consultas dispensáveis que poderiam ser executadas no futuro.

Essas atividades são necessárias. Ao trabalhar com diferentes fontes de dados, geralmente, encontrarmos problemas nos dados pela falta de padronização. Conforme vimos na Unidade 1, é comum trabalharmos com fontes de dados externas e, nesses casos, na grande maioria das vezes, elas não terem relação com o nosso negócio, a inexistência de padronização e a existência de redundâncias. Ainda, existem erros de inserção e possíveis falhas humanas, causadas de maneira acidental ou, até mesmo, propositalmente.


Os métodos que são utilizados na limpeza de dados dependem do contexto da aplicação e pressupõem a caracterização dos domínios envolvidos. Ainda, a verificação da consistência das informações, possíveis erros e preenchimento

ou eliminação de valores nulos e redundantes. Podemos exemplificar a limpeza de dados, com a definição de um intervalo de possíveis domínios, valores (GOLDSCHMIDT; PASSOS, 2005; TORGO, 2017).

No Tópico 3 da Unidade 1, também vimos a importância do enriquecimento dos dados, contudo, não aprofundamos o assunto quanto aos desafios que o enriquecimento pode contribuir ou causar no conjunto de dados. Assim, Caetano (2018b, p. 65) considera que:

As revisões do serviço serão utilizadas para enriquecer um conjunto de dados. Essas revisões vão ser escritas somente por clientes que contrataram o serviço. Entretanto, os clientes que reincidiram o contrato poderiam ter informações até mesmo mais valiosas para o problema que se pretende resolver. Portanto, a abrangência do enriquecimento deve ser conhecida e levada em consideração. Além disso, o enriquecimento de dados pode ter viés. Voltando ao exemplo anterior, os usuários que escreveram as revisões podem ter diferentes perfis e esses perfis levam a diferentes comportamentos (heavy users utilizam muito o serviço, enquanto light users não utilizam tanto). Portanto, o enriquecimento deve considerar como os dados foram gerados.

Outro fator que pode causar poluição com o uso de enriquecimento de dados é que eventos do mundo real podem ter uma relação causal (não explícita) nos dados obtidos no enriquecimento. Por exemplo, se um usuário influente de uma rede social faz um post sobre uma organização ou um serviço, então, é possível ocorrer uma alteração do comportamento de clientes e de fornecedores, refletindo nos dados da empresa naquele período. Isso pode ser um problema caso análises sejam feitas considerando somente esse período onde ocorreu um comportamento atípico.



Heavy users é um termo usado para indicar pessoas que usam frequentemente um serviço ou projeto e *light users* é um termo usado para indicar pessoas que não usam com tanta frequência um serviço ou produto.

Outra atividade da limpeza de dados é referente aos valores ausentes. Para Caetano (2018b, p. 66), “valor ausente é um valor que não foi coletado, porém, ele existe no mundo real. Valor ausente é diferente de valor vazio, pois vazio diz respeito a um valor que não existe no mundo real”. As linguagens R e Python representam os valores ausentes ou vazios pelo *valor null*. De forma geral, os valores ausentes podem ser tratados de três formas:

- Remover os valores ausentes: “[...] consiste em remover atributos ou instâncias do conjunto de dados, porém, isso impõe restrições ao valor dos dados (perda de informação)” (CAETANO, 2018b, p. 66).
- Recuperar os valores ausentes: “[...] consiste em substituir os valores ausentes por valores padrões ou médios, porém, isso pode introduzir informações distorcidas, que não estão contidas no evento e nas circunstâncias” (CAETANO, 2018b, p. 66).
- Restringir a execução de algoritmos de *Machine Learning*: “[...] limitar as análises e algoritmos que podem ser aplicados nos dados [...], técnica de K vizinhos mais próximos (KNN), classificadores bayesianos e diversas técnicas estatísticas não conseguem lidar com valores ausentes, porém, o algoritmo de árvore de decisão consegue” (CAETANO, 2018b, p. 66).

Diante desse cenário, é comum termos um conjunto de dados bagunçado, ou seja, termos dados inconsistentes. Wickham (2014) faz uma analogia com as famílias, colocando que conjuntos de dados organizados são todos iguais, mas todos os conjuntos de dados bagunçados são confusos. Assim, primeiramente, precisamos compreender a definição de dados organizados.

2 ORGANIZANDO OS DADOS

Dados organizados (estruturados) fornecem uma maneira padronizada de vincular a estrutura de dados (seu layout físico) com sua semântica (seu significado). Para Wickham (2014), conjuntos de dados organizados são fáceis de manipular, modelar e visualizar, possuindo uma estrutura específica: por exemplo, cada variável é uma coluna, cada observação é uma linha e cada tipo de unidade de observação é uma tabela. Dessa forma, é fundamental entendermos a estrutura e a sua semântica, além da importância de termos os dados organizados.

Estrutura de dados

A maioria dos conjuntos de dados estatísticos são tabelas retangulares compostas de linhas e colunas. As colunas são quase sempre rotuladas e, as linhas, às vezes, são rotuladas.

TABELA 1 – CONJUNTO DE DADOS ATÍPICO

	Tratamento a	Tratamento b
João Smith	NA	2
Jane Doe	16	11
Maria Johnson	3	1

FONTE: Adaptado de Wickham (2014)

Existem várias maneiras de estruturar os mesmos dados. Por exemplo, a tabela a seguir apresenta os mesmos dados apresentados na tabela anterior, contudo, as linhas e colunas foram transpostas. Os dados são os mesmos, mas o layout é diferente. Wickham (2014) coloca que nosso vocabulário de linhas e colunas não é rico o suficiente para descrever por que as duas tabelas representam os mesmos dados. Além da aparência, precisamos de uma maneira de descrever a semântica subjacente, ou seja, o significado dos valores exibidos na tabela (WICKHAM, 2014).

TABELA 2 – O MESMO CONJUNTO DE DADOS COM UMA ESTRUTURA DIFERENTE

	João Smith	Jane Doe	Maria Johnson
Tratamento a	NA	16	3
Tratamento b	2	11	1

FONTE: Adaptado de Wickham (2014)

Semântica de dados

Um conjunto de dados é uma coleção de valores, geralmente números (se quantitativos) ou sequências de caracteres (se qualitativas).

Os valores são organizados de duas maneiras. Todo valor pertence a uma variável e a uma observação. Uma variável contém todos os valores que medem o mesmo atributo subjacente (como altura, temperatura, duração) nas unidades. Uma observação contém todos os valores medidos na mesma unidade (como uma pessoa, um dia ou uma corrida).

TABELA 3 – CONJUNTO DE DADOS ATÍPICO

Nome	Tratamento	Resultado
Jane Doe	a	16
Jane Doe	b	11
João Smith	a	NA
João Smith	b	2
Maria Johnson	a	3
Maria Johnson	b	1

FONTE: Adaptado de Wickham (2014)

Dessa forma, os valores, as variáveis e as observações ficam mais claras, em que o conjunto de dados contém 18 valores que representam três variáveis e seis observações. As variáveis são (WICKHAM, 2014):

- **Nome:** com três valores possíveis (Jane Doe, João Smith e Maria Johnson).
- **Tratamento:** com dois valores possíveis (a e b).
- **Resultado:** com cinco ou seis valores, dependendo de como você pensa no valor ausente (NA, 16,3, 2, 11, 1).

No exemplo, conseguimos entender a estrutura das observações, sendo possível verificar as possíveis combinações de nome e tratamento, além de determinar se os valores ausentes podem ou não ser eliminados com segurança.



O valor ausente representa uma observação que deveria ter sido feita, mas não foi, por isso, é importante mantê-lo. Os valores ausentes estruturais, que representam medidas que não podem ser feitas (por exemplo, a contagem de homens no estado de gravidez), podem ser removidos com segurança.

Para um determinado conjunto de dados, na maioria das vezes, é fácil descobrir o que são observações e o que são variáveis, contudo, é complicado definir as variáveis e as observações de forma precisa. Wickham (2014) observa que, se as colunas na Tabela 1 fossem altura e peso, seria fácil chamar de variáveis. Agora, se as colunas tivessem altura e largura, seria menos claro, pois poderíamos pensar em altura e largura como valores de uma variável de dimensão. Se as colunas fossem telefones residencial e comercial, poderíamos tratá-las como duas variáveis. Contudo, em um ambiente de detecção de fraude, o uso de um número de telefone para várias pessoas pode indicar fraude, dessa forma, podemos querer variáveis número de telefone e tipo de número.

Dessa forma, pode-se dizer que é mais fácil descrever relações funcionais entre colunas do que entre linhas, e é mais fácil fazer comparações entre grupos de observações (por exemplo, média do grupo a vs. média do grupo b) do que entre grupos de colunas. Em uma determinada análise, podem existir vários níveis de observação. Por exemplo, em um teste com novos medicamentos para alergia, podemos ter três tipos de observação: dados demográficos coletados de cada pessoa (idade, sexo, raça), dados médicos coletados de cada pessoa em cada dia (número de espirros, vermelhidão dos olhos) e dados meteorológicos coletados em cada dia (temperatura, contagem de pólen) (WICKHAM, 2014).

Dados organizados

Wickham (2014) coloca que devemos ter dados organizados como um objetivo geral em função de facilitar nossa análise posterior. As principais propriedades dos dados organizados são:

- Cada valor pertence a uma variável e a uma observação (instância).
- Cada variável contém todos os valores de uma determinada propriedade medidos em todas as observações.
- Cada observação contém todos os valores das variáveis medidas para o respectivo caso.

Essas propriedades são as mesmas que a terceira forma normal de Codd, só que voltadas para a linguagem estatística e o foco está em um único conjunto de dados.

Cada linha representa uma observação, o resultado de um tratamento em uma pessoa e cada coluna é uma variável. Os dados organizados facilitam a extração de variáveis necessárias para um analista ou um computador, fornecendo uma maneira padrão de estruturar um conjunto de dados. Compare a Tabela 3 com a Tabela 1: na Tabela 1, você precisa usar estratégias diferentes para extrair variáveis diferentes. Isso atrasa a análise e convida erros. Se você considerar quantas operações de análise de dados envolvem todos os valores em uma variável (todas as funções de agregação), poderá ver como é importante extrair esses valores de uma maneira simples e de maneira padronizada (WICKHAM, 2014).

Dados estruturados são particularmente adequados para linguagens de programação vetorizadas como na linguagem R, porque o layout garante que valores de variáveis diferentes da mesma observação sejam sempre pareados. Embora a ordem das variáveis e das observações não afete a análise, uma boa ordem facilita a verificação dos valores brutos. Uma maneira de organizar as variáveis é por seu papel na análise (WICKHAM, 2014; TORGO, 2017).

Organizando conjuntos de características

Como vimos, tanto os valores do conjunto de dados precisam ser trabalhados para que estejam limpos como a estrutura também é fundamental nesse processo, devido que a boa estruturação dos dados facilita as análises. Frequentemente, os dados não são fornecidos em um formato tão organizado. Segundo Torgo (2017), é exigido pela maioria das ferramentas de modelagem disponíveis no R. Package *tidyr* pode ser usado para limpar os dados, tornando-os mais padronizados. De acordo com Wickham (2014), são cinco os principais problemas encontrados em conjuntos de dados.

- 1- Cabeçalhos de coluna são valores, não nomes de variáveis.
- 2- Múltiplas variáveis são armazenadas em uma coluna.
- 3- As variáveis são armazenadas tanto em linhas quanto em colunas.
- 4- Múltiplos tipos de observação são armazenados na mesma tabela.
- 5- Um único tipo de observação é armazenado em várias tabelas.

QUADRO 1 – CINCO PRINCIPAIS PROBLEMAS NA ESTRUTURA DE DADOS

TIPO

DESCRIÇÃO

1

Na maioria das vezes, o problema está relacionado com conjuntos de dados que foram criados por usuários não técnicos, ou seja, usuários finais. As variáveis fazem parte tanto das linhas como das colunas. Para resolver esse problema deve-se transformar as colunas em linhas. Esse processo é conhecido como *melting* (WICKHAM, 2014; TORGO, 2017). A figura a seguir exemplifica o conjunto de dados não estruturado, à direita está o conjunto, além dos dados, após as colunas serem transformadas em linhas. Em primeiro lugar é criada a variável Renda, que conterà os valores dos cabeçalhos, posteriormente estão os valores das linhas que se referem aos antigos cabeçalhos que são inseridos na variável Freq.

EXEMPLO DO PRIMEIRO PROBLEMA ESTRUTURAL

Área	<\$10k	\$10-20k
TI	27	34
Construção	12	27



Área	Renda	Freq.
TI	<\$10k	27
Construção	<\$10k	12
TI	\$10-20k	34
Construção	\$10-20k	27

FONTE: Adaptado de Caetano (2018b)

2

Para solucionar esse problema deve-se fazer *melting* e depois realizar a separação das variáveis das colunas (WICKHAM, 2014; TORGO, 2017). A seguir, há o processo para solucionar o problema em duas etapas. Primeiro, as colunas são transformadas em linhas, criando-se a variável Valor, que recebe os valores das linhas e a variável Faixa, que recebe os cabeçalhos do conjunto de dados original. Depois, a coluna Faixa é dividida nas colunas Sexo e Idade.

EXEMPLO DO SEGUNDO PROBLEMA ESTRUTURAL

País	m014	f014
US	52	228
BR	2	152



País	Faixa	Valor
US	m014	52
BR	m014	2
US	f014	228
BR	f014	152

País	Faixa	Valor
US	m014	52
BR	m014	2
US	f014	228
BR	f014	152



País	Sexo	Idade	Valor
US	m	0-14	52
BR	m	0-14	2
US	f	0-14	228
BR	f	0-14	152

FONTE: Adaptado de Caetano (2018b)

3

O problema estrutural de ter as variáveis armazenadas tanto em linhas quanto em colunas é um dos problemas mais complexos de se resolver. Para solucionar esse problema é necessário fazer o *melting* e depois aplicar o processo inverso do *melting*, transformando em linhas e colunas (WICKHAM, 2014; TORGO, 2017). A seguir, é possível perceber o conjunto sobre um *melting*. Dessa forma, as colunas Ano, Mês, Dia 1 e Dia 2 são transformadas na coluna Data, ou seja, é realizado um *melting* e um merge dessas colunas; bem como a coluna Valor é criada com o objetivo de se ter os valores das linhas. Depois, é feito o processo inverso do *melting* no conjunto de dados, sendo os valores da coluna Tipo transformados em cabeçalhos de colunas, assim como a coluna Valor é transformada em linhas dos cabeçalhos relacionadas à coluna Tipo.

EXEMPLO DO TERCEIRO PROBLEMA ESTRUTURAL

Ano	Mês	Tipo	Dia 1	Dia2
2000	1	Tmax	27	24
2000	1	Tmin	22	20

Data	Tipo	Valor
01/01/2000	Tmax	27
01/01/2000	Tmin	22
02/01/2000	Tmax	24
02/01/2000	Tmin	20

Data	Tipo	Valor
01/01/2000	Tmax	27
01/01/2000	Tmin	22
02/01/2000	Tmax	24
02/01/2000	Tmin	20

Data	Tmax	Tmin
01/01/2000	27	22
02/01/2000	24	20

FONTE: Adaptado de Caetano (2018b)

4

Múltiplos tipos de observação são armazenados. É o típico problema estrutural de se ter um conjunto de dados não normalizado (WICKHAM, 2014; TORGO, 2017). A seguir, há dois assuntos do conjunto, existindo a Observação 1, referente aos dados das músicas e a Observação 2, referente aos dados sobre a posição daquela música em um ranking. Para solucionar esse problema, Torgo (2017) coloca que se deve dividir o conjunto em tabelas (ou conjuntos), conforme a observação.

EXEMPLO DO SEGUNDO PROBLEMA ESTRUTURAL

Artista	Música	Data	Semana	Posição
A	TRACK1	26/02/2000	1	10
A	TRACK1	04/03/2000	2	8

Observação 1Observação 2

Artista	Música	Data	Semana	Posição
A	TRACK1	26/02/2000	1	10
A	TRACK1	04/03/2000	2	8

IDArtistaMúsicaIDDataSemanaPosiçãoA1A TRACK1A126/02/2000110A2A TRACK1A204/03/200028

FONTE: Adaptado de Caetano (2018b)

98

5	O problema de se ter um único tipo de observação armazenado em várias tabelas é inverso ao problema de se ter múltiplos tipos de observação armazenados na mesma tabela (WICKHAM, 2014; TORGO, 2017). Segundo Caetano (2018b, p. 72), “a solução é simples, basta carregar os arquivos em uma lista de tabelas e para cada uma dessas tabelas adicionar uma coluna de identificação no arquivo unificado. Por fim, deve ser feita a combinação (join) de todas as tabelas no arquivo unificado. Dessa forma, ao final desse processo, existirá uma única tabela com os dados de todas as outras”.
---	---

Fonte: A Autora

Conjunto de dados fictício de clientes de uma financeira

Agora que já temos conhecimento tanto da estrutura dos dados quanto da semântica, vamos utilizar o conjunto fictício de dados de clientes de uma financeira.

TABELA 4 – ESTRUTURA DO CONJUNTO DE DADOS DE CLIENTES DE UMA FINANCEIRA

Atributo	Tipo de Dado	Descrição do domínio
CPF	Char(11)	Número do Cadastro de Pessoa Física do Cliente. Formato: XXX.XXX.XXX-XX
Nome	VarChar(40)	Nome completo do Cliente
Sexo	Char(1)	M – Masculino F – Feminino
Data_Nasc	Date	Data de nascimento do Cliente. Formato: DD/MM/AAAA
Est_Civil Johnson	Char(1)	Estado civil do Cliente: C – Casado S – Solteiro V – Viúvo D – Divorciado O – Outro
Num_Dep	Integer	Quantidade de pessoas que dependem financeiramente do Cliente.
Renda	Real	Total dos rendimentos
Despesa	Real	Total das despesas
Tp_Res	Char(1)	Tipo da residência do Cliente: P – Própria A – Alugada E – Parentes F – Funcional O – Outro
Bairro_Res	VarChar(50)	Nome do Bairro em que o Cliente reside
Result	Char(1)	Resultado do crédito concedido anteriormente ao cliente: A – Adimplente I – Inadimplente

FONTE: Adaptado de Goldschmidt e Passos (2005)

TABELA 5 – EXEMPLOS DE INSTÂNCIAS DE CLIENTES DE UMA FINANCEIRA

CPF	Nome	Sexo	Data_Nasc	Est_Civil	Num_Dep	Renda	Despesa	Tp_Res	Bairro_Res	Result
99999999999	José	M	05/05/1989	C	1	Null	1000	X	Centro	A
11111111111	Maria	F	10/07/1985	S	5	3000	2000	P	Urca	A
33333333333	Ana	F	15/08/1981	S	4	5000	3000	P	Leblon	A
55555555555	Pedro	M	10/09/1975	C	3	1500	1500	A	Centro	I
22222222222	Mário	M	20/02/1960	C	5	2500	1500	P	Leblon	A
00000000000	Manoel	M	13/10/1954	S	1	Null	1000	E	Barra	I
88888888888	Liza	F	27/04/1980	S	2	4500	3000	F	Urca	A
77777777777	Marisa	F	14/07/1980	C	3	1000	500	A	Recreio	I
66666666666	Carlos	M	06/11/1963	V	7	4300	4000	F	Leblon	A
44444444444	Paula	F	15/12/1982	C	3	1400	1000	A	Centro	I

FONTE: Adaptado de Goldschmidt e Passos (2005)

Cabe destacar aqui o tema que vimos no item 3 do Tópico 1 na Unidade 1, referente que os atributos, nossas variáveis do problema, ainda podem ser classificadas em duas categorias: quanto ao tipo de dados (representação de seus valores) e quanto ao tipo de variável (natureza da informação). Também vimos a classificação de Pyle (1999) quanto ao tipo de dado e quanto ao tipo de variável.

O tipo da variável pode ser chamado de nominal, ou ainda comumente chamado de categórica, para o tipo de dado for qualitativo; e discreta ou contínua, para o tipo de dado quantitativo.

TABELA 6 – ESTRUTURA DO CONJUNTO DE DADOS DE CLIENTES DE UMA FINANCEIRA

Atributo	Tipo de Variável	Descrição do domínio
CPF	Nominal	Não possui relação de ordem entre seus valores.
Nome	Nominal	Não possui relação de ordem entre seus valores.
Sexo	Nominal	Não possui relação de ordem entre seus valores.
Data_Nasc	Discreto	Uma variável do tipo data pode ser representada pelo número de dias transcorridos a partir de um determinado marco temporal. Envolve, portanto, uma relação de ordem entre seus valores. O conjunto de valores possíveis é finito.
Est_Civil	Nominal	Não possui relação de ordem entre seus valores.
Num_Dep	Discreto	Envolve uma relação de ordem entre os seus valores. O conjunto de valores desta variável é finito.
Renda	Contínuo	O conjunto de valores deste atributo, embora seja limitado, é teoricamente infinito, uma vez que sejam admitidas variações no número de casas decimais.

Despesa	Contínuo	Idêntico à variável Renda.
Tp_Res	Nominal	Não possui relação de ordem entre seus valores.
Bairro_Res	Nominal	Não possui relação de ordem entre seus valores.
Result	Nominal	Não possui relação de ordem entre seus valores.

FONTE: Adaptado de Goldschmidt e Passos (2005)

3 LIMPEZA E PREENCHIMENTO DE VALORES AUSENTES

Como falamos no início desta unidade, a limpeza se refere a todo e qualquer tipo de tratamento que se realize sobre os dados escolhidos de maneira que garanta a qualidade, ou seja, que se assegure a completude, veracidade e integridade dos fatos que aqueles dados representem. Portanto, de acordo com Caetano (2018b) e ressaltado por Goldschmidt e Passos (2005, p. 12) :

Informações ausentes, errôneas ou inconsistentes nas bases de dados devem ser corrigidas de forma a não comprometer a qualidade dos modelos de conhecimento a serem extraídos [...]. Um exemplo simples de limpeza de dados seria a definição de um intervalo de possíveis valores para um determinado atributo. Caso surgisse qualquer valor diferente dos definidos no intervalo, o registro contendo esse dado poderia ser removido.

Valores com informações ausentes surgem em quase todas as análises estatísticas sérias. Primeiramente, para podermos lidar com valores ausentes é importante sabermos o motivo deles estarem ausentes. Em R, por exemplo, os valores ausentes são indicados pelos NAs. Por exemplo, para vermos alguns dos dados de cinco entrevistados no arquivo de dados da Pesquisa de Indicadores Sociais (escolhendo arbitrariamente as linhas 91–95), digitamos o código no R: `cbind (sexo, raça, educação, idade, renda, segurança) [91:95]`.

TABELA 7 – CONJUNTO DE DADOS DE CINCO ENTREVISTADOS NO ARQUIVO DE PESQUISA DE INDICADORES SOCIAIS

	sexo	raça	educação	idade	renda	segurança
[91,]	1	3	3	31	NA	0
[92,]	2	1	2	37	135,00	1
[93,]	2	3	2	40	NA	1
[94,]	1	1	3	42	3,00	1
[95,]	1	3	1	24	0,00	NA

FONTE: Adaptado de Gelman e Hill (2006)

Na regressão clássica ou regressão linear simples, bem como na maioria dos outros modelos, R exclui de maneira automática todos os casos em que alguma das entradas estiver ausente. Entretanto, isso pode limitar a quantidade de informações disponíveis na análise, especialmente se o modelo incluir muitas entradas que estiverem propensas a estarem ausentes. As coisas ficam mais complicadas quando os preditores tiverem valores ausentes (GELMAN; HILL, 2006).



A regressão linear simples é definida como a relação linear entre uma variável dependente (Y) e a variável independente (X). A variável independente é a variável conhecida como explicativas, devido ela explicar a variação de Y. O adjetivo simples refere-se ao fato de que a regressão é uma das mais simples na estatística. O declive da linha reta é igual à correlação entre y e x seja corrigida pela relação de desvios padrão destas variáveis. Cabe lembrar que a intercepção da linha reta é tal que passa pelo centro de massa (x,y) dos pontos de dados.



Variáveis de repostas ou dependentes são as variáveis de interesse em um experimento, ou seja, aquelas variáveis que são observados. Já as variáveis preditoras ou ainda variáveis independentes ou explicativas são as demais variáveis no experimento que afetam a resposta, bem como podem ser medidas ou definidas pelo experimentador, ou seja, por aquele que está realizando a análise.

Por exemplo, se quisermos modelar atitudes com relação à segurança, de acordo com a renda e os preditores demográficos, o modelo não contabiliza de maneira automática os valores ausentes da renda. Dessa forma, teríamos que remover os valores ausentes, preenchê-los ou modelá-los. Para decidir como lidar com dados ausentes, é útil saber por que eles estão ausentes. Gelman e Hill (2006) colocam quatro mecanismos de ausência, passando do mais simples para o mais complexo. Esses mecanismos são referenciados por Caetano (2018b).

QUADRO 2 – MECANISMOS DE VALORES AUSENTES

TIPO	DESCRIÇÃO
Ausência totalmente aleatória	Uma variável não existe de fato se a probabilidade da ausência for igual para todas as unidades. Por exemplo, em uma pesquisa, os participantes jogam um dado para responder uma determinada pergunta, exceto se o número que aparecer no dado que foi jogado for seis, ou seja, se for seis todos os participantes recusam a responder. Dessa forma, pode-se dizer que se os dados estiverem faltando completamente ao acaso, a eliminação de casos com dados ausentes não influencia suas inferências.
Ausência aleatória	A maioria das ausências não é totalmente aleatória como explicado no caso anterior. Por exemplo, em uma pesquisa, a quantidade de participantes brancos e negros que não respondem às perguntas indicam que a pergunta renda na Pesquisa de Indicadores Sociais não está ausente totalmente ao acaso. De maneira geral, uma ausência aleatória depende somente das informações disponíveis. Assim, se sexo, raça, educação e idade são registrados para todos os participantes da pesquisa, renda tem sua ausência aleatória se a probabilidade de não ter a resposta dessa pergunta, depender apenas das outras variáveis que estão registradas. Muitas vezes, é razoável modelar esse processo como uma regressão logística, na qual a variável resultante é igual a 1 para os casos observados e 0 para quando eles não existirem. Quando uma variável resultante tem sua ausência aleatória é plausível excluir os casos ausentes (ou seja, tratá-los como NA), desde que a regressão controle todas as variáveis que afetam a probabilidade da ausência. Dessa forma, qualquer modelo de renda teria que incluir preditores de etnia, para evitar viés de não resposta. Essa suposição que o valor faltante é aleatório na estrutura de dados ausentes é basicamente o mesmo tipo de suposição que a ignorabilidade na estrutura causal. Ambos exigem que as informações tenham sido coletadas para que possamos “ignorar” o mecanismo de atribuição (atribuição ao tratamento, atribuição à não resposta).
Ausência que depende de preditores não observados	A falta de informação não é mais "aleatória" se depender de informações que não foram registradas e essas informações também predizerem os valores ausentes. Por exemplo, vamos supor que as pessoas intratáveis têm uma menor probabilidade de responder à questão da renda, a segurança é preditiva da renda e a segurança não é observada. Ainda podemos supor que as pessoas com diploma universitário tenham uma probabilidade menor de revelar sua renda, pois, ter um diploma universitário é preditivo de renda e existe alguma resposta à pergunta referente educação. Então, mais uma vez, não faltam renda de forma aleatória. Um exemplo de estudos médicos é que, se um tratamento em particular causa desconforto, é mais provável que o paciente abandone o estudo. Essa falta não é aleatória, exceto que o desconforto seja medido e observado em todos os pacientes. Se a falta não é aleatória, ela deve ser explicitamente modelada, ou então você deve aceitar algum viés em suas inferências.
Ausência que depende do valor faltante	Finalmente, surge uma situação particularmente difícil quando a probabilidade de ausência depende da própria variável (potencialmente ausente). Por exemplo, vamos supor que pessoas com maior renda têm menos probabilidade de revelá-las. Em contrapartida, todas as pessoas que ganham mais de R\$ 100.000 se recusam a responder, isso é chamado de censura.

FONTE: Adaptado de Gelman e Hill (2006)



Não é possível provar que os dados faltam aleatoriamente.

Como discutido, a falta aleatória é relativamente fácil de lidar, devido que basta incluir como entradas de regressão todas as variáveis que afetam a probabilidade de ausência. Infelizmente, geralmente não podemos ter certeza se os dados realmente estão faltando aleatoriamente ou se a ausência depende de preditores não observados ou dos próprios dados ausentes. A questão é que essas “variáveis ocultas” em potencial não são observadas e, portanto, nunca podemos descartá-las.

3.1 LIMPEZA DE INFORMAÇÕES AUSENTES

A função de limpeza de informações ausentes, compreende a eliminação de valores ausentes em conjunto de dados. Muitas abordagens de dados ausentes simplificam o problema jogando fora os dados, ou seja, removendo os valores. Contudo, discutimos aqui como essas abordagens podem levar a estimativas tendenciosas. Além disso, jogar fora os dados pode levar a estimativas errôneas devido ao tamanho reduzido da amostra. Dessa forma, demonstraremos alguns métodos, que podem ser utilizados para atribuir valores.

QUADRO 3 – MÉTODOS PARA TRATAR OS VALORES AUSENTES

TIPO	DESCRIÇÃO
Exclusão de Casos	Para Goldschmidt e Passos (2005, p. 37), “esse é o método mais simples para limpeza de informações ausentes. Consiste em excluir do conjunto de dados as tuplas que possuam pelo menos um atributo não preenchido. Em geral, esse método não é o mais adequado, a menos que a tupla a ser excluída contenha diversos atributos com valores ausentes. Quando a percentagem de valores ausentes por atributo varia significativamente na mesma base, esse método deve ser evitado, sob o risco de restarem poucos registros com todas as informações preenchidas”. Portanto, esse método é utilizado quando não existir conteúdo na variável, ou seja, possuir valor null. Essa abordagem não é efetiva, exceto se existirem muitos atributos com valores ausentes. Quando o percentual de valores ausentes variar muito é um método considerado consideravelmente pobre (HAN; KAMBER, 2001; TORGO, 2017; CAETANO, 2018b).

Preenchimento (imputar) manual de valores	Para Goldschmidt e Passos (2005, p. 37), “em geral, essa abordagem demanda alto consumo de tempo e recursos, sendo muitas vezes inviável na prática (nos casos em que grandes volumes de dados possuam informações desconhecidas). Esse método pode ser implementado por meio de pesquisas junto às fontes de dados originais que procurem captar as informações ausentes. Nesse método, os dados pesquisados devem ser complementados via digitação”. Esse método não é indicado quando a base de dados for muito grande e possuir muitos valores ausentes. Outro ponto é que essa abordagem consome muito tempo (TORGO, 2017; CAETANO, 2018b).
Preenchimento com valores globais constantes	No método se atualizam “[...] todos os valores ausentes com um único valor constante, tal qual “desconhecido” ou – high values. Embora simples, não é muito recomendado (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 25). Portanto, o valor atribuído pode não ser correto. Segundo Goldschmidt e Passos (2005, p. 37), “esse método consiste em substituir todos os valores ausentes de um atributo por um valor padrão tal como “desconhecido” ou “null”. Esse valor padrão pode e deve ser especificado pelo especialista no domínio da aplicação. Cabe ressaltar, no entanto, que determinados algoritmos de mineração de dados podem assumir constantes padrões como valores recorrentes importantes”. Outros autores (TORGO, 2017; CAETANO, 2018b) também colocam, que apesar de simples, esse método não está entre os mais indicados.
Preenchimento com medidas estatísticas	Para Goldschmidt e Passos (2005, p. 37), “medidas estatísticas podem ser empregadas como alternativa à utilização de constantes padrões no processo de preenchimento de valores ausentes. Como exemplos de medidas estatísticas para preenchimento de informações ausentes podem ser citados: média para atributos numéricos e moda para atributos categóricos. Uma variação desse método pode ser utilizada em problemas de classificação. Nesse caso, em vez de considerar todo o conjunto de dados, o preenchimento com medidas estatísticas fica restrito aos registros de cada classe. Assim sendo, o cálculo da medida estatística a ser utilizada no preenchimento de informações ausentes fica restrito aos registros que pertencem a cada classe”. No exemplo, colocada, as informações de renda ausentes poderiam ser alteradas por: R\$ 3860,00 na classe A e R\$ 1300,00 na classe I.
Preenchimento com métodos de mineração de dados	Conforme Goldschmidt e Passos (2005, p. 37), “[...] modelos preditivos podem ser construídos de forma a sugerir os valores mais prováveis a serem utilizados no preenchimento dos valores ausentes. Algoritmos de Mineração de Dados tais como Redes Neurais, Estatística (Modelos Bayesianos) e Árvores de Decisão são alternativas na construção destes modelos”. Cabe destacar, que mesmo durante a fase de pré-processamento, os algoritmos de mineração de dados podem ser usados para preenchimento de valores ausentes (TORGO, 2017; CAETANO, 2018b).

Fonte: A Autora

Cabe destacar, que os quatro primeiros métodos podem tornar tendenciosos determinados atributos, enquanto a abordagem de utilizar o preenchimento com métodos de mineração de dados é a abordagem mais popular quando comparada com as outras abordagens. Isso ocorre devido esta abordagem considerar mais informações referente aos dados para predizer valores ausentes. Portanto, ao utilizar outros atributos ao estimar valores ausentes, se tem uma chance considerável na preservação da relação entre o atributo estimado e os outros atributos usados no processo de estimação (HAN; KAMBER, 2001; DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002; TORGO, 2017; CAETANO, 2018b).

3.2 LIMPEZA DE INCONSISTÊNCIA

A função de limpeza de inconsistências compreende identificar e eliminar valores inconsistentes em conjuntos de dados. Uma inconsistência pode estar relacionada a um único registro (tupla) ou se referir a um conjunto de registros. A inconsistência em somente uma única tupla acontece quando os valores desta tupla forem divergentes (TORGO, 2017). Han e Kamber (2001, p. 27) colocam que “ferramentas de software de engenharia de conhecimento podem também ser utilizadas para detectar violações nas restrições de integridades dos dados, tais como funções de dependência entre atributos”.

Além disso, Torgo (2017) afirma que podem existir inconsistências causadas por integrações de dados, em que um atributo pode ter nomes distintos em seus bancos de dados. Consequentemente, podem existir dados redundantes.

Em nosso exemplo, o primeiro registro (tupla) possui uma inconsistência, devido que foi aprovado um crédito para um cliente com idade inferior a 21 anos. Portanto, conseguimos observar que é de fundamental relevância contar com especialista no domínio da aplicação na identificação de inconsistências. Podemos afirmar que esse processo demanda conhecimento prévio referente ao problema. Dessa forma, tabulamos alguns métodos para limpeza de valores não pertencente ao domínio dos atributos do problema.

QUADRO 4 – MÉTODOS PARA TRATAR OS VALORES INCONSISTENTES

TIPO	DESCRIÇÃO
Exclusão de Casos	Esse método é considerado o mais simples. Para Goldschmidt e Passos (2005, p. 39), “consiste em excluir, do conjunto de dados original, as tuplas que possuem, pelo menos, uma inconsistência”. A identificação dos casos com inconsistência pode ser obtida por meio de consultas em SQL cujas restrições especifiquem o tipo de inconsistência a ser verificada. Exemplo: Obtenha os clientes com menos de 21 anos para os quais tenha sido concedido crédito. <pre>SELECT * FROM CLIENTE WHERE (YEAR(SYSDATE) – YEAR(DT_NC)) < 21 AND RESULT=A”; SYSDATE = “01/05/2005” (Data do dia).</pre>
Correção de erros	Para Goldschmidt e Passos (2005, p. 39), “esse método consiste em substituir valores errôneos ou inconsistentes identificados no conjunto de dados. Pode envolver desde a correção manual até a atualização desses valores em um lote predeterminado de registros, utilizando comandos de atualização de dados em ambientes relacionais”. Segundo Torgo (2017), essa abordagem consome muito tempo.

Fonte: A Autora

3.3 LIMPEZA DE VALORES NÃO PERTENCENTES AO DOMÍNIO

A função de limpeza de valores não pertencente ao domínio dos atributos do problema é considerada muitas vezes como um caso em particular da limpeza de inconsistências, demandando conhecimento do domínio do problema de cada atributo. Em nosso exemplo, o valor “X” se refere ao domínio do atributo Tipo de Residência e o primeiro registro contém um valor inválido. Dessa forma, tabulamos alguns métodos para limpeza de inconsistência a seguir.

QUADRO 5 – MÉTODOS PARA TRATAR DE VALORES NÃO PERTENCENTES AO DOMÍNIO

TIPO	DESCRIÇÃO
Exclusão de Casos	O método é considerado o mais simples para tratar de valores não pertencentes ao domínio do atributo do problema (CAETANO, 2018b). Para Goldschmidt e Passos (2005, p. 40), “consiste em excluir do conjunto de dados original, as tuplas que possuem, pelo menos, um valor fora do conjunto de valores válidos de cada atributo. Exemplo: obtenha os clientes com número de dependentes abaixo de zero. SELECT * FROM CLIENTE WHERE QTDE_DEP < 0;”.
Correção de erros	Para Goldschmidt e Passos (2005, p. 40), “o método consiste em substituir os valores inválidos identificados no conjunto de dados”. Caetano (2018b) complementa que pode envolver a correção manual, além da atualização, em um lote predeterminado, de registros por meio de comandos SQL.


Fonte: A Autora

3.4 LIMPEZA DE VALORES REDUNDANTES

Em um conjunto de dados a redundância ocorre quando diferentes características estão representando o mesmo fato, exigindo maior esforço computacional para realizar o processamento do conjunto, bem como causando ruído para modelar o problema. Caetano (2018b, p. 66) coloca que “um exemplo clássico de redundância é a duplicação de características, onde características do conjunto são obtidas com o processamento de outras características”.

Dessa forma, pode-se dizer que um atributo pode ser considerado redundante se ele puder ser derivado de outra tabela, ou seja, de outro armazenamento. Frequentemente, pode-se ter redundância em conjunto de dados devido a inconsistências em atributos ou nome de dimensões. Uma técnica muito interessante para verificar redundância em conjunto de dados é a utilização da análise de correlação, a qual medirá o quanto dois atributos são correlatos. A redundância a nível de atributo também pode ser identificada por meio da geração de registros (tuplas) idênticas geradas em uma mesma entrada de dados (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002; TORGO, 2017; CAETANO, 2018b).

FIGURA 1 – TIPOS DE CORRELAÇÕES



FONTE: Adaptado de Caetano (2018b)

De acordo com Caetano (2018b, p. 66):

[...] há uma correlação linear negativa entre duas características quando se observa que conforme os valores de uma característica crescem, os valores da outra diminuem. Existe uma correlação linear positiva entre duas características, quando se observa que conforme os valores de uma característica crescem, os valores da outra característica também crescem. Outro tipo de correlação é a correlação não linear, onde a correlação de duas características é não linear (logarítmica, exponencial etc.). Quando os valores não apresentam relação alguma, podemos então dizer que não há correlação observável entre as duas características.

Em cada par de características do conjunto a correlação deve ser aplicada. Ao aplicar a técnica de correlação será retornado um índice de correlação e caso o índice retornado seja igual a zero, não existe correlação entre as duas características. Agora, caso o índice de correlação linear esteja entre -1 e 1, existe uma correlação. De acordo com Caetano (2018b, p. 67), “considera-se alta correlação um índice de no mínimo 70% (índice maior ou igual a 0,7, ou índice menor ou igual a -0,7)”.



Deve-se tomar cuidado com correlações falsas, devido que pode ocorrer de características aparentarem correlações e não passarem de uma simples coincidência. O discernimento entre uma correlação verdadeira e uma correlação falsa é trabalho do preparador de dados diferenciar.

4 DADOS FORA DO PADRÃO (OUTLIERS)

Pode-se dizer que *outliers* são instâncias ou valores de um atributo que são significativamente inconsistentes ou diferentes, ou seja, valores fora do padrão de um determinado conjunto de dados. Portanto, detectar desvios objetiva identificar mudanças em padrões que já foram percebidos. A identificação de *outliers*, ou detecção de desvios, pode ajudar a solucionar problemas da empresa. Para Goldschmidt e Passos (2005, p. 37), “dados ruidosos são dados errados ou que contenham valores considerados divergentes, denominados outliers, do padrão normal esperado”.



Algumas atividades para o tratamento de *outliers* também são encontradas na redução de valores, que será visto em nosso Tópico 3 desta unidade.


O conceito de distância é também utilizado na detecção de desvios. Em geral, são especificados limiares de tolerância, de tal forma que, sempre que a distância entre o registro em análise e o padrão médio representativo da base de dados excede um destes limiares, tal registro é considerado como um desvio.

Para ilustração desta tarefa, considere um banco de dados de cartão de crédito que contenha os valores médios das compras realizadas pelos clientes em meses anteriores. Assim sendo, a ocorrência de compras cujo valor seja significativamente superior ao comportamento médio de consumo dos clientes pode ser um indicativo de roubo ou fraude, merecendo uma investigação específica.

A detecção de desvios pode ser on-line ou off-line. Na detecção de desvios on-line, mecanismos computacionais ativos devem monitorar a base de dados a fim de identificar a entrada de novos valores que sejam espúrios ou outliers. Somente novos dados são analisados. A tecnologia de Agentes Inteligentes é muito utilizada na detecção de desvios on-line. Na detecção de desvios off-line, o banco de dados é integralmente analisado na busca por outliers. Durante o processo de análise, não são incluídos novos dados na base (GOLDSCHMIDT; PASSOS, 2005).

Ao fazer uso da análise, é possível determinar valores muito distantes da tendência central do conjunto.

QUADRO 6 – ALGUNS MÉTODOS DE CORREÇÃO

TIPO	DESCRIÇÃO
Binning	É usada quando não existir conteúdo na variável – <i>null</i> (assume que o processo de mineração envolverá descrição ou classificação), não sendo efetivo, exceto se existirem muitos atributos com valores ausentes. Quando o percentual de valores ausentes variar muito é um método considerado pobre.
Agrupamento (Clustering)	“Outliers podem ser detectados quando valores similares são organizados em grupos ou clusters” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 26). Caetano (2018b) coloca que, de maneira intuitiva, valores que estão fora dos <i>clusters</i> podem ser considerados como <i>outliers</i>. DETECTANDO <i>OUTLIERS</i> COM A TÉCNICA DE ANÁLISE DE AGRUPAMENTO (<i>CLUSTERING</i>)  FONTE: Adaptado de Han e Kamber (2001) A clusterização pode ser vista de duas formas: Clusterização – Classificação; e Clusterização – Sumarização (CAETANO, 2018b). Goldschmidt e Passos (2005, p. 80) colocam que “a tarefa referenciada por “Clusterização – Classificação” [...] encadeia as tarefas primárias de Clusterização e de Classificação. Aplicável em situações em que os registros de dados não estejam enquadrados em classes predefinidas, esta tarefa consiste em: a) Agrupar os dados em função de sua similaridade. Utiliza-se, para tanto, algum método de clusterização de dados. Em geral, os métodos de clusterização incluem um novo atributo no conjunto de dados original, de forma que este novo atributo indique a qual <i>cluster</i> cada registro pertence. b) Cada rótulo de cluster passa a ser considerado como uma classe. No novo conjunto de dados, os registros estão enquadrados em classes. A partir de então, algoritmos de classificação podem ser aplicados de forma a gerar modelos de conhecimento que possam prever a classificação de novos registros a partir das características dos dados”. A tarefa referente à Clusterização – Sumarização, segundo Caetano (2018b), é do tipo composto e, para Goldschmidt e Passos (2005, p. 81), “[...] encadeia as tarefas primárias de Clusterização e de Sumarização. Aplicável em situações nas quais o conjunto completo de registros do banco de dados disponha de pouca similaridade entre seus elementos, esta tarefa consiste em: a) Agrupar os dados em função de sua similaridade. Utiliza-se, para tanto, algum método de clusterização de dados. Cada cluster passa a ser considerado isoladamente como um novo conjunto de dados. Para tanto, o conjunto de dados original é segmentado em tantos conjuntos quantos forem os clusters gerados. b) Cada novo conjunto de dados é então apresentado a um algoritmo de sumarização que descreve as principais características dos registros envolvidos naquele conjunto”.

Combinação de inspeção humana e computador	Para Caetano (2018b), <i>outliers</i> podem ser identificados por meio da combinação do uso de computador e de inspeção humana. “Em uma aplicação, uma medida teórica pode ser utilizada para ajudar a identificar padrões de outliers. Uma vez identificados os padrões de outliers e sendo estes considerados lixo, podem ser excluídos da utilização na etapa de mineração de dados” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 26).
Regressão	“[...] dados podem ser ajustados (smoothed) por funções de ajustamentos de dados, tais como funções de regressão. Regressão linear busca encontrar a melhor linha de ajustamento para duas variáveis, desde que uma possa ser estimada (predita) pela outra. Regressão linear múltipla é uma extensão da regressão linear, onde duas ou mais variáveis são envolvidas e os dados são combinados em uma superfície (plano) multidimensional” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 26).

Fonte: A Autora

Os valores extremos (*noisy data*) “[...] são um erro aleatório ou uma variação acentuada na medição de uma variável. Ocorre em variáveis numéricas do tipo rendimento, faturamento etc. e que precisam ser aplainadas (*smooth*), retirando-se esse erro de medição” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 25). Caetano (2018b, p. 68) ainda acrescenta que “outliers podem ser identificados visualmente com o uso de gráficos de caixas e com análise estatística. A análise estatística utiliza a métrica Z-score, que leva em consideração a média e o desvio padrão do conjunto”.

• **Boxplot – identificação visual**


Como falamos uma maneira relativamente simples de identificar os *outliers* é por meio da inspeção visual utilizando gráficos do tipo boxplot. Desta forma, ao fazer uso de uma ferramenta gráfica é possível encontrar os dados incomuns no conjunto de dados. Para Galarnyk (2018), esse tipo de gráfico boxplot organiza os dados em grupos por quartis, bem como traça a variabilidade abaixo ou acima dos quartis inferiores e superiores, respectivamente. Além disso, coloca os *outliers* como pontos fora da caixa (GALARNYK, 2018).



Quartil é o termo utilizado sempre que se dividir uma área de uma distribuição de frequência em quatro domínios de áreas iguais.

Para entender melhor como os dados estão distribuídos deve-se organizar os dados de maneira crescente e encontrar os quartis. Inicialmente, espera-se que os dados estejam em sua maioria distribuídos dentro do próprio interquartil, como InterQuartile Range (IQR), ou seja, o (intervalo interquartil). Os dados que estão fora do interquartil, mas estão na região entre mínimo (Minimum) e máximo (Maximum), que são entendidos como variabilidade da distribuição. Os dados que estão fora da variabilidade são compreendidos como *outliers* (GALARNYK, 2018).

FIGURA 2 – DETALHES SOBRE BOXPLOT



FONTE: Adaptado de Galarnyk (2018)

Tanto o mínimo quanto o máximo do boxplot é calculado a partir do IQR, o qual considera o quartil 1 (Q1) e 3 (Q3). A linha amarela apresentada e apontada na literatura como Q2 indica a mediana, representando qual é o valor do dado que fica exatamente no centro da distribuição.

- **Z-Score**

A abordagem por boxplot utiliza gráfico e desta forma o entendimento é mais direto, enquanto a abordagem de identificação por Z-Score é mais matemática. Você deve lembrar de como se calcula a média e o desvio padrão, certo? Ao se falar em Z-Score estamos nos referindo a um número de vezes que um determinado valor se distancia das outras amostras com relação ao desvio padrão e a média do atributo.

Segundo Haslwanter (2016), a identificação de *outliers* por meio do Z-Score consiste em centralizar os dados em torno da média 0 e desvio padrão 1, e a partir dos novos dados, identificar aqueles que estão muito distantes de 0. A partir dos dados centralizados, à medida que um ponto aparece muito longe desse centro, podemos entender que é um valor atípico.

• K-Means


O algoritmo k-means é um método popular da tarefa de clusterização. Toma-se, randomicamente, k pontos de dados (dados numéricos) como sendo os centroides (elementos centrais) dos *clusters*. Em seguida, cada ponto (ou registro da base de dados) é atribuído ao *cluster* cuja distância deste ponto em relação ao centroide de cada *cluster* é a menor dentre todas as distâncias calculadas. Um novo centroide para cada *cluster* é computado pela média dos pontos do *cluster*, caracterizando a configuração dos *clusters* para a iteração seguinte. O processo termina quando os centroides dos *clusters* param de se modificar, ou após um número limitado de iterações que tenha sido especificado pelo usuário.

O algoritmo k-means toma um parâmetro de entrada, k , e divide um conjunto de n objetos em k *clusters* tal que a similaridade intracluster resultante seja alta, mas a similaridade intercluster seja baixa. A similaridade em um *cluster* é medida em respeito ao valor médio dos objetos nesse *cluster* (centro de gravidade do *cluster*).

A execução do algoritmo k-means consiste em primeiro, selecionar aleatoriamente k objetos, que inicialmente representam cada um a média de um *cluster*. Para cada um dos objetos remanescentes, é feita a atribuição ao *cluster* ao qual o objeto é mais similar, baseado na distância entre o objeto e a média do *cluster*. A partir de então, o algoritmo computa as novas médias para cada *cluster*. Este processo se repete até que uma condição de parada seja atingida (GOLDSCHMIDT; PASSOS, 2005).


As figuras a seguir ilustram a aplicação do algoritmo k-means em um arquivo com 20 registros de dados, considerando-se $k = 3$. O algoritmo k-means é inicializado com os centros (médias) colocados em posições aleatórias. A busca pelo centro comum se faz de forma iterativa. Após essa inicialização, os objetos restantes são agrupados conforme a distância em que se encontram das médias (GOLDSCHMIDT; PASSOS, 2005).

FIGURA 3 – PRIMEIROS PASSOS DO ALGORITMO



FONTE: Adaptado de Goldschmidt e Passos (2005)

FIGURA 4 – PASSOS SUBSEQUENTES DO ALGORITMO



FONTE: Adaptado de Goldschmidt e Passos (2005)

• K-Modes

Esse algoritmo é uma variação do método k-means, só que usado para clusterização de dados categóricos, ou seja, dados nominais. Goldschmidt e Passos (2005, p. 103) colocam que, de maneira geral, “[...] no lugar do cálculo da média, calcula-se a moda (valor que aparece com maior frequência) dos objetos, usando medidas de similaridade para tratar objetos categóricos, e usando métodos baseados em frequência para atualizar as modas dos clusters” (GOLDSCHMIDT; PASSOS, 2005, p. 103).

• K-Prototypes

Segundo Goldschmidt e Passos (2005, p. 103), “o método k-prototypes é a integração dos métodos k-means e k-modes. Esse método pode ser aplicado a bases de dados que contenham tanto atributos numéricos quanto atributos categóricos”.

• K-Medoids

Segundo Goldschmidt e Passos (2005, p. 104), “o algoritmo k-medoids baseia-se, primeiramente, em encontrar o medoid (objeto mais centralmente localizado em um cluster). Os objetos restantes são então clusterizados com o medoid ao qual ele é mais similar”. Existe uma troca iterativa, de um medoid por um não medoid, que visa à melhoria da clusterização. “A qualidade é estimada usando uma função custo que mede a similaridade média entre os objetos e o medoid de seu cluster” (GOLDSCHMIDT; PASSOS, 2005, p. 104).

Basicamente, a diferença entre K-Means e K-Medoids é que, em K-Medoids, cada cluster tem sua representação por um dos registros do *cluster* e, em K-Means, a média dos registros do *cluster* é o elemento representante de cada *cluster*.

RESUMO DO TÓPICO 1

Neste tópico, você aprendeu que:

- Os métodos utilizados na limpeza de dados dizem respeito a verificar a consistência das informações, corrigir possíveis erros e preencher ou eliminar valores nulos e redundantes.
- Os métodos utilizados na limpeza de dados dependem do contexto da aplicação e pressupõe-se a caracterização dos domínios envolvidos.
- Dados ruidosos se referem a dados errôneos ou que possuam valores divergentes do padrão normal esperado, considerados *outliers*.
- Dados inconsistentes se referem aos dados que possuem alguma discrepância semântica entre si.
- “Valor ausente é um valor que não foi coletado, porém, ele existe no mundo real. Valor ausente é diferente de valor vazio, pois vazio diz respeito a um valor que não existe no mundo real” (CAETANO, 2018b, p. 66).
- As linguagens R e Python representam os valores ausentes ou vazios pelo valor *null*.
- Dados organizados (estruturados) fornecem uma maneira padronizada de vincular a estrutura de dados (seu layout físico) com sua semântica (seu significado).
- Para um determinado conjunto de dados, na maioria das vezes é fácil descobrir o que são observações e o que são variáveis, contudo, é complicado definir as variáveis e as observações em geral de forma precisa.
- São cinco os principais problemas encontrados em conjuntos de dados: cabeçalhos de coluna são valores, não nomes de variáveis; múltiplas variáveis são armazenadas em uma coluna; as variáveis são armazenadas tanto em linhas quanto em colunas; múltiplos tipos de observação são armazenados na mesma tabela; um único tipo de observação é armazenado em várias tabelas.
- Para podermos lidar com valores ausentes é importante sabermos o motivo deles estarem ausentes.
- Existem alguns mecanismos de ausência, enumeramos quatro: falta completamente aleatória; desaparecimento aleatório; desaparecimento que depende de preditores não observados; falta que depende do valor que falta.

- Não é possível provar que os dados faltam aleatoriamente.
- A limpeza se refere a todo e qualquer tipo de tratamento que se realize sobre os dados escolhidos de maneira que garanta a qualidade, ou seja, que se assegure a completude, veracidade e integridade dos fatos que aqueles dados representem.
- A função de limpeza de informações ausentes compreende a eliminação de valores ausentes em conjunto de dados.
- O método exclusão de casos para tratar os valores ausentes é o método mais simples: consistindo em excluir do conjunto de dados as tuplas que possuam pelo menos um atributo não preenchido.
- O método preenchimento (imputar) manual de valores de casos para tratar os valores ausentes “[...] demanda alto consumo de tempo e recursos, sendo muitas vezes inviável na prática (nos casos em que grandes volumes de dados possuam informações desconhecidas)” (GOLDSCHMIDT; PASSOS, 2005, p. 37).
- O método preenchimento com valores globais constantes para tratar os valores ausentes “[...] todos os valores ausentes com um único valor constante, tal qual “desconhecido” ou – high values. Embora simples, não é muito recomendado (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 25).
- O método preenchimento com medidas estatísticas para tratar os valores ausentes “[...] estatísticas podem ser empregadas como alternativa à utilização de constantes padrões no processo de preenchimento de valores ausentes” (GOLDSCHMIDT; PASSOS, 2005, p. 37).
- O método preenchimento com métodos de mineração de dados para tratar os valores ausentes “[...] podem ser construídos de forma a sugerir os valores mais prováveis a serem utilizados no preenchimento dos valores ausentes” (GOLDSCHMIDT; PASSOS, 2005, p. 37).
- A função de limpeza de inconsistências compreende identificar e eliminar valores inconsistentes em conjuntos de dados.
- Uma inconsistência pode estar relacionada a uma única tupla ou se referir a um conjunto de tuplas.
- Exclusão de casos e correção de erros são métodos para tratar os valores inconsistentes.
- A função de limpeza de valores não pertencente ao domínio dos atributos do problema é considerada muitas vezes como um caso em particular da limpeza de inconsistências, demandando conhecimento do domínio do problema de cada atributo.

- Em um conjunto de dados a redundância ocorre quando diferentes características estão representando o mesmo fato, exigindo maior esforço computacional para realizar o processamento do conjunto, bem como causando ruído para modelar o problema.
- A redundância a nível de atributo também pode ser identificada por meio da geração de registros (tuplas) idênticas geradas em uma mesma entrada de dados.
- Deve-se tomar cuidado com correlações falsas, devido que pode ocorrer de características aparentarem correlações e não passarem de uma simples coincidência.
- Pode-se dizer que *outliers* são instâncias ou valores de um atributo que são significativamente inconsistentes ou diferentes, ou seja, valores fora do padrão de um determinado conjunto de dados.
- A identificação de *outliers*, ou detecção de desvios, pode ajudar a solucionar problemas da empresa.
- *Binning* é um método para detectar o desvio de padrão, *outliers*, que pode ser utilizado quando não existir conteúdo na variável – *null* (assume que o processo de mineração envolverá descrição ou classificação), não sendo efetivo, exceto se existirem muitos atributos com valores ausentes.
- Agrupamento ou clusterização é um método para detectar o desvio de padrão, *outliers*, que “[...] podem ser detectados quando valores similares são organizados em grupos ou clusters. Intuitivamente, valores que estão fora dos clusters podem ser considerados como outliers” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 26).
- A Clusterização pode ser vista de duas formas: Clusterização – Classificação; e Clusterização – Sumarização.
- Combinação de inspeção humana e computador é um método para detectar o desvio de padrão, *outliers*, por meio da combinação de inspeção humana e do uso do computador.
- Regressão é um método para detectar o desvio de padrão, *outliers*, na qual “[...] dados podem ser ajustados (smoothed) por funções de ajustamentos de dados, tais como funções de regressão” (DA COSTA CÔRTEZ; PORCARO; LIFSCHITZ, 2002, p. 26).
- *Outliers* podem ser identificados por análise estática ou de forma visual com o uso de gráficos de caixas.

- A análise estatística pode fazer uso da métrica Z-score, que leva em consideração a média e o desvio padrão do conjunto.
- Gráfico boxplot organiza os dados em grupos por quartis, bem como traça a variabilidade abaixo ou acima dos quartis inferiores e superiores, respectivamente. Além disso, coloca os *outliers* como pontos fora da caixa.
- A abordagem por boxplot utiliza gráfico e desta forma o entendimento é mais direto, enquanto a abordagem de identificação por Z-Score é mais matemática.
- Ao se falar em Z-Score, estamos nos referindo a um número de vezes que um determinado valor se distancia das outras amostras com relação ao desvio padrão e a média do atributo.
- A identificação de *outliers* por meio do Z-Score consiste em centralizar os dados em torno da média 0 e desvio padrão 1, e a partir dos novos dados, identificar aqueles que estão muito distantes de 0.
- O algoritmo k-means é um método popular da tarefa de clusterização. Toma-se, randomicamente, k pontos de dados (dados numéricos) como sendo os centroides (elementos centrais) dos clusters.
- O algoritmo K-modes é uma variação do método k-means, só que usado para clusterização de dados categóricos, ou seja, dados nominais.
- “O método k-prototypes é a integração dos métodos k-means e k-modes” (GOLDSCHMIDT; PASSOS, 2005, p. 103).
- O método k-prototypes “[...] pode ser aplicado a bases de dados que contenham tanto atributos numéricos quanto atributos categóricos” (GOLDSCHMIDT; PASSOS, 2005, p. 103).
- “O algoritmo k-medoids baseia-se, primeiramente, em encontrar o medoid (objeto mais centralmente localizado em um cluster). Os objetos restantes são então clusterizados com o medoid ao qual ele é mais similar” (GOLDSCHMIDT; PASSOS, 2005, p. 104).



1 O objetivo geral de se ter os dados (estruturados) é para facilitar nossa análise posterior. Dados estruturados são particularmente adequados para linguagens de programação vetorizadas como na linguagem R, porque o layout garante que valores de variáveis diferentes da mesma observação sejam sempre pareados. No contexto, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () São três as principais propriedades dos dados organizados.
- () Uma das propriedades de se ter dados organizados é referente cada valor pertence a uma variável e a uma observação (instância).
- () Uma das propriedades de se ter dados organizados diz respeito a cada variável conter todos os valores de uma determinada propriedade medidos em todas as observações.
- () Uma das propriedades de se ter dados organizados diz respeito a cada observação conter todos os valores das variáveis medidas para o respectivo caso.

Assinale a alternativa CORRETA:

- a) () F – F – V – V.
- b) () V – F – V – F.
- c) () F – V – F – V.
- d) () V – V – V – V.

2 São cinco os principais problemas encontrados em conjuntos de dados, sendo: cabeçalhos de coluna são valores, não nomes de variáveis, múltiplas variáveis são armazenadas em uma coluna, as variáveis são armazenadas tanto em linhas quanto em colunas, múltiplos tipos de observação são armazenados na mesma tabela e um único tipo de observação é armazenado em várias tabelas. Referente a esses cinco principais problemas encontrados em conjuntos de dados, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () O problema de se ter cabeçalhos de coluna são valores, não nomes de variáveis está relacionado com conjuntos de dados que foram criados por usuários não técnicos, ou seja, usuários finais.
- () O problema estrutural de ter as variáveis armazenadas tanto em linhas quanto em colunas é um dos problemas mais complexos de se resolver.
- () O problema de se ter múltiplas variáveis são armazenadas em uma coluna é o típico problema estrutural de se ter um conjunto de dados não normalizado.
- () O problema de se ter múltiplos tipos de observação é simples. Para solucionar, é suficiente carregar os arquivos em uma lista de tabelas e para cada uma dessas tabelas adicionar uma coluna de identificação no arquivo unificado.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

3 A limpeza se refere a todo e qualquer tipo de tratamento que se realize sobre os dados escolhidos de maneira que garanta a qualidade, ou seja, que se assegure a completude, veracidade e integridade dos fatos que aqueles dados representem. Nesse sentido, está a limpeza e preenchimento de informações ausentes, que compreende a eliminação de valores ausentes em conjunto de dados. Exclusão de casos, preenchimento (imputar) manual de valores, preenchimento com valores globais constantes, preenchimento com medidas estatísticas e preenchimento com métodos de mineração de dados são métodos para tratar os valores ausentes. Referente aos métodos para tratar os valores ausentes, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Exclusão de casos é considerado o método mais simples para limpeza de informações ausentes.
- () O método de preenchimento (imputar) manual de valores demanda alto consumo de tempo e recursos, sendo muitas vezes inviável na prática (nos casos em que grandes volumes de dados possuam informações desconhecidas).
- () O método de preenchimento com medidas estatísticas pode ser utilizado como maneira de sugerir os valores mais prováveis a serem utilizados no preenchimento dos valores ausentes.
- () O método de preenchimento com métodos de mineração de dados pode ser usado como alternativa à utilização de constantes padrões no processo de preenchimento de valores ausentes.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

4 A função de limpeza de inconsistências compreende identificar e eliminar valores inconsistentes em conjuntos de dados. Uma inconsistência pode estar relacionada a uma única tupla ou se referir a um conjunto de tuplas. Já a função de limpeza de valores não pertencente ao domínio dos atributos do problema é considerada muitas vezes como um caso em particular da limpeza de inconsistências, demandando conhecimento do domínio do problema de cada atributo. Referente a essas duas funções, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () O método de exclusão de casos consiste em excluir do conjunto de dados original, as tuplas que possuem, pelo menos, uma inconsistência.
- () O método de correção de erros consiste em substituir valores errôneos ou inconsistentes identificados no conjunto de dados.
- () Os métodos de exclusão de casos e de correção de erros são utilizados tanto para limpeza de inconsistências quanto para limpeza de valores não pertencentes ao domínio do problema.
- () O método de exclusão de casos pode envolver desde a correção manual até a atualização desses valores em um lote predeterminado de registros, utilizando comandos de atualização de dados em ambientes relacionais.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – V.
- d) () V – V – V – F.

5 *Outliers* são instâncias ou valores de um atributo que são significativamente inconsistentes ou diferentes, ou seja, valores fora do padrão de um determinado conjunto de dados. Portanto, detectar desvios objetiva identificar mudanças em padrões que já foram percebidos. A identificação de *outliers*, ou detecção de desvios, pode ajudar a solucionar problemas da empresa. No contexto, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () O conceito de distância é também utilizado na detecção de desvios.
- () *Outliers* podem ser detectados quando valores similares são organizados em grupos ou clusters.
- () A clusterização ou agrupamento é um dos métodos para detectar desvios (*outliers*).
- () A Clusterização pode ser vista de duas formas: Clusterização → Classificação e Clusterização → Sumarização.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – V – V.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.



TRANSFORMAÇÃO DE DADOS

1 INTRODUÇÃO

Transformações de dados objetivam melhorar a utilidade de uma característica adicionando, modificando ou eliminando informações, bem como cada tipo de característica possui um detalhamento específico, favorecendo ou desfavorecendo a extração de valor. A etapa de transformação de dados envolve também a consolidação em formatos adequados para que a mineração possa ser realizada. Segundo Da Costa Côrtes, Porcaro e Lifschitz (2002), a transformação de dados envolve:

- *Smooting* (aplainamento): o *smooting* remove os dados corrompidos (*noisy data*), usando técnicas de *binning*, agrupamento e regressão, conforme visto no Tópico 1 desta unidade.
- Agregação: aplica operações de sumarização e agregação nos dados. Por exemplo, vendas diárias são agregadas em vendas semanais, quinzenais e mensais. Tipicamente utilizada para geração de dados no formato multidimensional em dados com alta granularidade (muitos detalhes).
- Generalização: a generalização dos dados é a etapa que possibilita transformar os dados primitivos (como linhas de tabelas) em hierarquias de mais alto nível. Por exemplo, em como criar categorias de bairro, cidade e estado a partir do atributo logradouro; ou criança, adolescente, adultos e idade a partir do atributo idade.
- Normalização: a normalização dos dados possibilita atribuir uma nova escala a um atributo de maneira que os valores desse atributo possam cair na nova escala em um intervalo especificado, tal como entre -1.0 a 1.0 ou de 0.0 a 1.0 etc.
- Construção de atributos: na construção de atributos novos atributos podem ser construídos a partir dos atributos existentes, no sentido de apoiar o processo de análise. Podemos, por exemplo, gerar um novo atributo levando-se em conta os atributos idade, peso e altura de uma pessoa ou a aplicação de uma fórmula específica.

Os dados devem ser codificados para ficarem em uma maneira que possam ser utilizados como entrada dos algoritmos de Mineração de Dados. Goldschmidt e Passos (2005, p. 40) colocam que a “codificação de dados é operação de pré-processamento responsável pela forma como os dados serão representados durante o processo de KDD. Trata-se de uma atividade criativa que deve ser realizada repetidas vezes em busca melhores representações”.

Goldschmidt e Passos (2005) ressaltam que a forma como a informação é codificada tem grande influência sobre o tipo de conhecimento a ser encontrado. Basicamente, para Goldschmidt e Passos (2005, p. 40) “[...] a codificação pode ser: numérica-categórica, que divide valores de atributos contínuos em intervalos codificados ou categórica-numérica, que representa valores de atributos categóricos por códigos numéricos”.

Caetano (2018b, p. 78) exemplifica que “[...] valores numéricos possuem mais detalhes do que os valores categóricos que, por sua vez, possuem mais valores do que booleanos (que pode fazer parte dos dados categóricos ou pode ser uma categoria isolada)”.



Destacamos que é necessário realizar as transformações em conformidade com o domínio do problema. “Por exemplo, certos tipos de análises e algoritmos apresentam melhores resultados quando são utilizados valores transformados. Portanto, cabe ao preparador de dados definir se há ou não a necessidade de transformar as características do conjunto” (CAETANO, 2018b, p. 78).

2 TRANSFORMAÇÕES BÁSICAS DE CARACTERÍSTICAS

A seguir, há as possíveis transformações de dados e as do tipo binarização, desordenação, ordenação, agrupamento e *thresholding*, objetivando seu aprendizado.

TABELA 8 – POSSÍVEIS TRANSFORMAÇÕES DE DADOS

De \ Para	Numérica	Ordinal	Nominal	Booleana
Numérica	Normalização	Discretização	Discretização	<i>Thresholding</i>
Ordinal	Calibração	Ordenação	Desordenação	<i>Thresholding</i>
Nominal	Calibração	Ordenação	Agrupamento	Binarização
Booleana	Calibração	Ordenação		

FONTE: Adaptado de Caetano (2018b)

QUADRO 7 – BINARIZAÇÃO, DESORDENAÇÃO, AGRUPAMENTO, ORDENAÇÃO E *THRESHOLDING*

TIPO	DESCRIÇÃO
Binarização	Transformar valores nominais em um conjunto de valores booleanos. Caetano (2018b, p. 79) exemplifica com “[...] uma característica que contém as cores Red, Green e Blue. Com a binarização, essa característica será transformada no conjunto (IS_RED, IS_GREEN e IS_BLUE), sendo que cada uma dessas características pode receber o valor true ou false”.
Desordenação	Basicamente é para tirar o sendo de ordem dos valores. Caetano (2018b, p. 79) exemplifica com “[...] uma característica que contém os valores 1º, 2º e 3º, então, com a desordenação, esses valores serão transformados em valores nominais que não carregam explicitamente um senso de ordem, por exemplo: primeiro, segundo e terceiro”.
Agrupamento	Refere-se em juntar valores nominais em somente uma classe nominal.
Ordenação	Basicamente se adiciona informação em um valor para o organizar. Caetano (2018b, p. 79) exemplifica com “[...] uma característica com valores de cores: red, green, blue é ordenada para se transformar em: 1ª cor, 2ª cor, 3ª cor”.
Thresholding	Consiste em transformar valores do tipo numéricos ou ordinais em conjuntos de valores booleanos. Caetano (2018b, p. 79) exemplifica com “[...] um conjunto X que contenha valores inteiros. Considere também que se definiu que a função de thresholding é a média do conjunto X. Dessa forma, o critério de thresholding separará valores maiores ou iguais à média e valores menores do que a média. Portanto, o conjunto resultante da transformação levará em consideração um desses critérios, e para cada valor comparado com o critério será definido um valor booleano”.

Fonte: A Autora


2.1 DISCRETIZAÇÃO, NORMALIZAÇÃO E CALIBRAÇÃO

Observamos as possíveis transformações de dados e as transformações do tipo binarização, desordenação, agrupamento, ordenação e *thresholding*. Agora, veremos as transformações de dados do tipo normalização, discretização e calibração.

2.2 DISCRETIZAÇÃO

A discretização também é denominada de mapeamento em intervalos. Ela é baseada em transformar valores numéricos em faixas de valores, categorias, classes ou valores ordinais. De acordo com Goldschmidt e Passos (2005, p. 41), “[...] a representação em intervalos pode ser obtida a partir de métodos que dividam o domínio de uma variável numérica em intervalos”. Esses autores ainda colocam que “alguns autores consideram o processo de Discretização como pertencente ao conjunto de operações voltadas à redução de valores das variáveis (Redução de Valores Contínuos)”.

Vamos dar alguns exemplos para facilitar seu entendimento. Considere as idades dos clientes com uma característica do conjunto e para que possamos realizar a discretização desses valores, precisamos definir pontos de corte. “Esses pontos de corte delimitam faixas de valores que no exemplo poderiam ser períodos de vida das pessoas. Por exemplo, crianças teriam idade de 0 aos 12 anos, adultos teriam idade dos 18 aos 35 anos e assim por diante” (CAETANO, 2018b, p. 80).



FONTE: Adaptado de Caetano (2018b)

Entretanto, existem diversos desafios referentes a discretização. Nesse sentido, Caetano (2018b, p. 80) coloca que “o primeiro deles é que transformar valores numéricos em atributos categóricos implica em perda de informação”. Dessa forma, devemos ter cuidado ao discretizar, pois ela deve ser utilizada com a menor perda de informação. Outro desafio diz respeito a representação das categorias, devido que algumas delas podem não ser representativas. Segundo Caetano (2018b, p. 80), “a solução para esse problema é definir a raiz quadrada do número de instâncias como o valor inicial (ou ponto de partida) do número de faixas de valores da discretização”.

Existem algumas técnicas para discretização. Vamos exemplificar algumas delas. Considere os seguintes valores: 1000, 1400, 1500, 1700, 2500, 3000, 3700, 4300, 4500, 5000, já organizados em ordem crescente.

QUADRO 8 – TÉCNICAS DE DISCRETIZAÇÃO

TIPO	DESCRIÇÃO																						
Divisão em intervalos com comprimentos definidos pelo usuário	Aqui o usuário define o número de intervalos e escolhe o tamanho de cada um deles. Na referida tabela, temos três intervalos de comprimento 1600, 2800 e 1000. Observe que cada intervalo está representado pelo Limite Inferior (LI) – Limite Superior (LS), compreendendo todos os valores reais desde o intervalo do LI até o intervalo do LS, não incluso. Em termos matemáticos, intervalo fechado em LI e aberto em LS. EXEMPLO DE DIVISÃO EM INTERVALOS COM COMPRIMENTOS DEFINIDOS PELO USUÁRIO <table><tr><th>Intervalo</th><th>Frequência (número de valores no intervalo)</th></tr><tr><td>1000 –1600</td><td>3</td></tr><tr><td>1600 –4400</td><td>5</td></tr><tr><td>4400 –5400</td><td>2</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005)	Intervalo	Frequência (número de valores no intervalo)	1000 –1600	3	1600 –4400	5	4400 –5400	2														
Intervalo	Frequência (número de valores no intervalo)																						
1000 –1600	3																						
1600 –4400	5																						
4400 –5400	2																						
Divisão em intervalos de igual comprimento	Nesta técnica, é definido apenas o número de intervalos, sendo o comprimento calculado a partir do maior valor do domínio do atributo e do menor valor do domínio do atributo. A tabela apresenta quatro intervalos, indo de 1000 a 5000, tendo $R = 5000 - 1000 = 4000$. Dessa forma, cada intervalo terá um comprimento de 1000 ($4000/4$). EXEMPLO DE DIVISÃO EM INTERVALOS DE IGUAL COMPRIMENTO <table><tr><th>Intervalo</th><th>Frequência (número de valores no intervalo)</th></tr><tr><td>1000 –2000</td><td>4</td></tr><tr><td>2000 –3000</td><td>1</td></tr><tr><td>3000 –4000</td><td>2</td></tr><tr><td>4000 –5000</td><td>3</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005) Goldschmidt e Passos (2005, p. 42) ainda colocam que “uma variação comum a este procedimento consiste em utilizar um critério para definir a quantidade de intervalos. Em geral, estes critérios envolvem o número de elementos do domínio, incluindo as repetições de valores. Exemplo de critério: o número de intervalos (k) é 5 se o número de amostras for inferior ou igual a 25. Nos demais casos, o número de intervalos é aproximadamente a raiz quadrada do número de amostras. A amplitude é expressa por $R = X_{\max} - X_{\min}$ ($R = 5000 - 1000 = 4000$). O comprimento de cada intervalo é obtido por $h = R/k$ ($h = 4000/5 = 800$)”. EXEMPLO DA VARIAÇÃO DE DIVISÃO EM INTERVALOS DE IGUAL COMPRIMENTO <table><tr><th>Intervalo</th><th>Frequência (número de valores no intervalo)</th></tr><tr><td>1000 –1800</td><td>4</td></tr><tr><td>1800 –2600</td><td>1</td></tr><tr><td>2600 –3400</td><td>1</td></tr><tr><td>3400 –4200</td><td>1</td></tr><tr><td>4200 –5000</td><td>2</td></tr></table> FONTE: adaptado de Goldschmidt e Passos (2005)	Intervalo	Frequência (número de valores no intervalo)	1000 –2000	4	2000 –3000	1	3000 –4000	2	4000 –5000	3	Intervalo	Frequência (número de valores no intervalo)	1000 –1800	4	1800 –2600	1	2600 –3400	1	3400 –4200	1	4200 –5000	2
Intervalo	Frequência (número de valores no intervalo)																						
1000 –2000	4																						
2000 –3000	1																						
3000 –4000	2																						
4000 –5000	3																						
Intervalo	Frequência (número de valores no intervalo)																						
1000 –1800	4																						
1800 –2600	1																						
2600 –3400	1																						
3400 –4200	1																						
4200 –5000	2																						

Linear (Min-Max)	A normalização linear Min-Max consiste basicamente em uma interpolação linear que leva em consideração os valores mínimo e máximos dos atributos, preservando o relacionamento entre os valores dos dados. Contudo, seu uso é recomendado somente quando é sabido de fato que o atributo está entre os valores mínimo e máximo. FÓRMULA DA TÉCNICA MAX-MIN $x' = \frac{x - Min_A}{Max_A - Min_A} \cdot (novo_Max_A - novo_Min_A) + novo_Min_A, \text{ onde:}$ x' valor normalizado x valor do atributo a ser normalizado Min_A valor mínimo do atributo A Max_A valor máximo do atributo A $novo_Min_A$ novo valor mínimo do atributo A $novo_Max_A$ novo valor máximo do atributo A FONTE: Adaptado de Gonçalves e Lima (2013)
Divisão em intervalos de igual comprimento	Esta técnica utiliza o valor máximo do conjunto e o valor mínimo. É uma generalização da normalização Linear Min-Max. FÓRMULA DA TÉCNICA DA GENERALIZAÇÃO DA NORMALIZAÇÃO LINEAR MIN-MAX $x' = \frac{x - Min_A}{Max_A - Min_A}$ FONTE: Adaptado de Caetano (2018b)
Soma de Elementos	A normalização da soma de elementos consiste basicamente em normalizar o valor de cada atributo, dividindo seu valor original pela soma de todos os valores do atributo. O método apresenta uma desvantagem com relação aos demais, pois alguns de seus registros podem apresentar valores muito pequenos. FÓRMULA DA TÉCNICA NORMALIZAÇÃO POR SOMA DE ELEMENTOS $x' = \frac{x}{K}, \text{ onde:}$ x' valor normalizado x valor do atributo a ser normalizado K valor total da soma de todos os atributos FONTE: Adaptado de Gonçalves e Lima (2013)

Valor Máximo de Elementos	A normalização valor máximo de elementos consiste basicamente em normalizar o valor do atributo, dividindo seu valor pelo maior. FÓRMULA DA TÉCNICA NORMALIZAÇÃO VALOR MÁXIMO DE ELEMENTOS $x' = \frac{x}{Max_A}, \text{ onde:}$ x' valor normalizado x valor do atributo a ser normalizado Max_A valor máximo do atributo A FONTE: Adaptado de Gonçalves e Lima (2013)
Escala Decimal	A normalização escala decimal consiste basicamente em deslocar o ponto decimal dos valores do atributo que se quer normalizar, baseando-se no número de casas decimais do atributo que tiver o maior valor. FÓRMULA DA TÉCNICA NORMALIZAÇÃO POR SOMA DE ELEMENTOS $x' = \frac{x}{10^j}, \text{ onde:}$ x' valor normalizado x valor do atributo a ser normalizado j menor valor inteiro tal que $Max(x') < 1$ FONTE: Adaptado de Gonçalves e Lima (2013)

2.4 CALIBRAÇÃO

A técnica de transformação de dados calibração é utilizada na extração de informações preditivas, comumente usada em bases de dados de instituições financeiras para fazer previsões. Na técnica de calibração dois tipos de variáveis são produzidos: do tipo preditoras e do tipo alvo. A calibração produz dois tipos de variáveis: preditoras e alvo. As variáveis do tipo preditoras definem a variável do tipo alvo a partir de uma função preditora, dependendo das regras de negócio envolvidas e dos dados envolvidos que são observados (CAETANO, 2018b).

Caetano (2018b) exemplifica a calibração, referente a um banco contendo dados financeiros sobre o perfil dos clientes. O foco aqui é fazer uma previsão da probabilidade de o cliente ser um bom pagador com base nas características Idade e Situação. Dessa forma, uma função preditora própria do negócio da empresa e fundamentada nas observações atuais, utilizando essas duas características como variáveis preditoras. A função preditora tem como resultado a variável alvo bom pagador (CAETANO, 2018b).

FIGURA 6 – EXEMPLO DE CALIBRAÇÃO

Idade	Situação		Idade	Situação	Bom Pagador
46	T		46	T	0.80
37	F		37	F	0.18
23	T		23	T	0.40
52	F		52	F	0.30

FONTE: Adaptado de Caetano (2018b)

3 CODIFICAÇÃO DE DADOS CATEGÓRICOS

Já falamos das codificações existentes, contudo, ainda queremos explanar um pouco mais sobre as codificações de dados categóricos, especialmente, do tipo one hot encoding. O One Hot Encoder é utilizado para transformar atributos categóricos que estão representados como números, contudo, a ordem não possui relevância. As variáveis binárias são criadas para evitar que os modelos interpretem esses atributos como sendo numéricos. Dessa forma, é criada uma variável binária para cada valor possível que o atributo pode assumir. Assim, dentre essas novas variáveis binárias, a única de valor 1 será aquela que corresponde à categoria do atributo na instância. Primeiramente, colocaremos, a seguir, técnicas de codificação categórica – numérica e, em seguida, exemplificaremos com o tratamento dos dados categóricos e de diferentes métodos para tratá-los.

QUADRO 10 – TÉCNICAS DE CODIFICAÇÃO CATEGÓRICA – NUMÉRICA

TÉCNICA	DESCRIÇÃO												
Representação Binária Padrão (Econômica)	Na representação binária padrão (econômica) cada valor categórico é associado a um valor de 1 até N, bem como é representado por uma cadeia de dígitos binários. A seguir, há a seguinte situação: se tivermos cinco possíveis valores, podemos representá-los com cadeias binárias de comprimento três.												
	EXEMPLO DE REPRESENTAÇÃO BINÁRIA PADRÃO (ECONÔMICA)												
	<table><tr><th>Valores originais</th><th>Representação binária padrão</th></tr><tr><td>Casado</td><td>001</td></tr><tr><td>Solteiro</td><td>010</td></tr><tr><td>Viúvo</td><td>100</td></tr><tr><td>Divorciado</td><td>011</td></tr><tr><td>Outro</td><td>110</td></tr></table>	Valores originais	Representação binária padrão	Casado	001	Solteiro	010	Viúvo	100	Divorciado	011	Outro	110
	Valores originais	Representação binária padrão											
	Casado	001											
Solteiro	010												
Viúvo	100												
Divorciado	011												
Outro	110												
	FONTE: Adaptado de Goldschmidt e Passos (2005)												

Representação Binária 1-de-N	Na representação binária 1-de-N, o código 1-N possui um comprimento igual ao número de categorias discretas que são possíveis para a variável, na qual cada elemento na cadeia de bits é 0, exceto para um único elemento, aquele elemento que representa o valor da categoria.																								
	EXEMPLO DE REPRESENTAÇÃO BINÁRIA 1-DE-N																								
	<table><tr><th>Valores originais</th><th>Representação Binária 1-de-N</th></tr><tr><td>Casado</td><td>00001</td></tr><tr><td>Solteiro</td><td>00010</td></tr><tr><td>Viúvo</td><td>00100</td></tr><tr><td>Divorciado</td><td>01000</td></tr><tr><td>Outro</td><td>10000</td></tr></table>	Valores originais	Representação Binária 1-de-N	Casado	00001	Solteiro	00010	Viúvo	00100	Divorciado	01000	Outro	10000												
	Valores originais	Representação Binária 1-de-N																							
	Casado	00001																							
Solteiro	00010																								
Viúvo	00100																								
Divorciado	01000																								
Outro	10000																								
FONTE: Adaptado de Goldschmidt e Passos (2005)																									
Representação Binária por Temperatura	A representação binária por temperatura é usada mais usualmente quando os valores discretos estão relacionados de algum modo. Goldschmidt e Passos (2005, p. 43) exemplificam com “[...] uma variável discreta que pode ter um dos seguintes valores: fraco, regular, bom e ótimo. Nesse caso, existe uma graduação entre os valores. O valor ótimo é o melhor caso e o valor fraco, o pior”. Dessa forma, a diferença entre os conceitos fraco e ótimo deve ser a maior possível entre os valores. Em contrapartida, as diferenças entre valores adjacentes na escala devem ser iguais à menor diferença possível. Cada valor corresponde a um acréscimo de um bit igual a 1 na representação.																								
	EXEMPLO DE REPRESENTAÇÃO BINÁRIA POR TEMPERATURA																								
	<table><tr><th>Valores originais</th><th>Representação Binária por Temperatura</th></tr><tr><td>Casado</td><td>00001</td></tr><tr><td>Solteiro</td><td>00010</td></tr><tr><td>Viúvo</td><td>00100</td></tr><tr><td>Divorciado</td><td>01000</td></tr><tr><td>Outro</td><td>10000</td></tr></table>	Valores originais	Representação Binária por Temperatura	Casado	00001	Solteiro	00010	Viúvo	00100	Divorciado	01000	Outro	10000												
	Valores originais	Representação Binária por Temperatura																							
	Casado	00001																							
Solteiro	00010																								
Viúvo	00100																								
Divorciado	01000																								
Outro	10000																								
FONTE: Adaptado de Goldschmidt e Passos (2005)																									
Uma medida de distância frequentemente usada em conjunto a esta representação é a distância de Hamming (DH), também chamada CityBlock. Segundo Goldschmidt e Passos (2005, p. 44), “essa distância expressa a diferença entre duas cadeias de bits, adicionando uma unidade sempre que bits de mesma posição possuem valores distintos”.																									
EXEMPLO DA DISTÂNCIA DE HAMMING ENTRE OS CONCEITOS																									
<table><tr><th>DH</th><th>Fraco</th><th>Regular</th><th>Bom</th><th>Ótimo</th></tr><tr><td>Fraco</td><td>0</td><td>1</td><td>2</td><td>3</td></tr><tr><td>Regular</td><td>1</td><td>0</td><td>1</td><td>2</td></tr><tr><td>Bom</td><td>2</td><td>1</td><td>0</td><td>1</td></tr><tr><td>Ótimo</td><td>3</td><td>2</td><td>1</td><td>0</td></tr></table>	DH	Fraco	Regular	Bom	Ótimo	Fraco	0	1	2	3	Regular	1	0	1	2	Bom	2	1	0	1	Ótimo	3	2	1	0
DH	Fraco	Regular	Bom	Ótimo																					
Fraco	0	1	2	3																					
Regular	1	0	1	2																					
Bom	2	1	0	1																					
Ótimo	3	2	1	0																					
FONTE: Adaptado de Goldschmidt e Passos (2005)																									

Fonte: A Autora

3.1 EXEMPLIFICAÇÃO DA CODIFICAÇÃO DE DADOS CATEGÓRICOS EM PYTHON

O utilitário `LabelEncoder` da biblioteca `scikit-learn` basicamente converte os valores categóricos em valores numéricos. Por exemplo, imagine que temos uma variável intitulada `cor` que recebe a lista de possíveis valores: ("branco", "preto", "amarelo", "vermelho").

Este conjunto deve nos retornar: [0,1,2,3], ou seja, o valor amarelo foi transformado em 0, o valor branco foi transformado em 1, o valor preto transformado em 2 e por fim o valor vermelho foi transformado em 3. Agora, vamos aplicar o `LabelEncoder` na lista de valores, veja:

```
cor=['branco','preto','amarelo','amarelo','vermelho','branco','preto','preto']
```

Podemos ver que a lista de tamanhos tem vários valores repetidos, vamos ver os valores únicos, para isso: `set(cor)`. O comando `set` elimina valores repetidos da lista, podemos ver que temos quatro valores distintos de cores.

Em seguida, use o `LabelEncoder` para fazer a codificação e transformar isso em inteiro. O primeiro a fazer é importar o módulo de pré-processamento:

```
from sklearn.preprocessing import LabelEncoder
```

Após isso, instancie um objeto do tipo `LabelEncoder`:

```
label_encoder = LabelEncoder()
```

Agora, vamos fazer a transformação dos dados com o método `fit_transform()`, veja:

```
valores_numericos = label_encoder.fit_transform(cor)
```

A variável `valores_numericos` recebe a lista de valores já codificados:

```
valores_numericos
```

FIGURA 7 – EXEMPLIFICANDO DADOS CATEGÓRICOS

```
In [17]: valores_numericos
Out[17]: array([1, 2, 0, 0, 3, 1, 2, 2])
```

FONTE: Santana (2018, p. 1)

Note que, para os quatro valores distintos na lista `cor`, `LabelEncoder` atribuiu um valor (0,1,2,3).

```
set(valores_numericos)
```

É possível inverter a codificação, para isso, vamos usar o método `inverse_transform()` e passar o valor codificado, veja:

```
valor_real = label_encoder.inverse_transform(2)
print(valor_real)
```

Esse método é importante, pois, às vezes, precisamos retornar o valor na sua forma real. No exemplo, foi passado o valor 2 e o retorno foi o valor preto.

- *One Hot Encoding*

O que fizemos com o `LabelEncoder` foi transformar valores categóricos em valores inteiros, contudo, conforme vimos isso pode ser perigoso. De acordo com Santana (2018, p. 1), “alguns algoritmos de Machine Learning podem aprender uma informação que não é verdadeira nos valores gerados”. Se os valores da variável `valores_numericos` fossem features para um classificador, este poderia aprender que 4 é maior que 3 e isso poderia inferir no processo de aprendizado.

Além disso, “[...] o algoritmo poderia calcular a média desses valores de alguma forma e dar pesos específicos para essa feature” (SANTANA, 2018, p. 1). Portanto, esses valores prejudicariam a eficiência do algoritmo.

Vamos utilizar o `One Hot Encoding` para solucionar esse problema, devido que ele vai gerar vetores binários para cada valor inteiro, ou seja, os valores inteiros [0,1,2] podem ser transformados em vetores como: [1, 0, 0] [0, 1, 0] [0, 0, 1]. Assim, o problema criado pelo `LabelEncoder` é resolvido, devido que os vetores binários nada significam. Agora, cada valor inteiro é representado por um vetor binário único.

Para implementar o `One Hot Encoding`, em primeiro lugar vamos criar um objeto chamado `onehot_encoder` do tipo `OneHotEncoding`, para tal, façamos:

```
onehot_encoder = OneHotEncoder(sparse=False)
```

O parâmetro `sparse=False` é utilizado para gerar a matriz de vetores. Em seguida, vamos transformar a lista de valores em uma lista de uma única dimensão, para então passar para o `onehot_encoder`. Assim, vamos fazer:

```
inteiros = valores_numericos.reshape(len(valores_numericos),1)
```

Agora, passamos os valores para o objeto `onehot_encoder` para realizar a transformação.

```
vetores_binarios = onehot_encoder.fit_transform(inteiros)
```

Por fim, podemos ver como ficaram dados transformados pelo One Hot Encoding.

FIGURA 8 – EXEMPLIFICANDO DADOS CATEGÓRICOS COM ONE HOT ENCODING

```
In [21]: vetores_binarios
Out[21]: array([[ 0.,  1.,  0.,  0.],
 [ 0.,  0.,  1.,  0.],
 [ 1.,  0.,  0.,  0.],
 [ 1.,  0.,  0.,  0.],
 [ 0.,  0.,  0.,  1.],
 [ 0.,  1.,  0.,  0.],
 [ 0.,  0.,  1.,  0.],
 [ 0.,  0.,  1.,  0.]])
```

FONTE: Santana (2018, p. 1)

3.2 EXEMPLIFICAÇÃO DA CODIFICAÇÃO DE DADOS CATEGÓRICOS PELO DATASET DO TITANIC DA KAGGLE

Aqui, exemplificamos com o tratamento dos dados categóricos e métodos diferentes para tratá-los, pelo dataset do Titanic do Kaggle e a codificação apresentada é de Alegeorgelustosa (2018). A seguir, poderemos ver a importação do pandas e numpy (In [108]) e em In [66] e Out [66] a importação do conjunto de dados do Titanic do Kaggle.

FIGURA 9 – CODIFICAÇÃO DE IMPORTAÇÃO DO PANDAS E DO NUMPY E LEITURA DO ARQUIVO

```
In [108]: import pandas as pd
import numpy as np

import re

from sklearn.model_selection import train_test_split

from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import AdaBoostClassifier
from sklearn.ensemble import RandomForestClassifier

from sklearn.metrics import roc_auc_score

import warnings
warnings.filterwarnings('ignore')

In [66]: data = pd.read_csv('titanic/train.csv')
data.head()
```

Out[66]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cunings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Häkkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

FONTE: Adaptado de Alegeorgelustosa (2018)

A seguir, será possível verificar quais são os tipos de dados que temos em nosso Dataset.

FIGURA 10 – CODIFICAÇÃO PARA VERIFICAR OS TIPOS DE DADOS DO DATASET

```
In [67]: data.dtypes

Out[67]: PassengerId      int64
Survived                int64
Pclass                  int64
Name                    object
Sex                     object
Age                     float64
SibSp                   int64
Parch                   int64
Ticket                  object
Fare                    float64
Cabin                   object
Embarked                object
dtype: object
```

FONTE: Adaptado de Alegeorgelustosa (2018)

As colunas ['PassengerId','Ticket','Name'] não possuem informações relevantes para o nosso estudo referentes aos dados categóricos. Dessa forma, vamos removê-las do nosso Dataframe.

FIGURA 11 – CODIFICAÇÃO PARA REMOÇÃO

```
In [69]: data.drop(['PassengerId', 'Ticket', 'Name'], axis=1, inplace=True)
```

FONTE: Adaptado de Alegeorgelustosa (2018)

A seguir, observaremos a codificação para os dados faltantes em colunas categóricas como Cabin e Embarked. Os iremos preenchê-los como Missing (In [70]), apenas por praticidade, bem como poderíamos substituir pela Moda, por grupo etc. Em In [71] podemos verificar a codificação para extrair a primeira letra da variável Cabin e em In [72] a codificação data.head() com a saída em Out [72].

FIGURA 12 – CODIFICAÇÃO PARA PREENCHIMENTO

```
In [70]: data.Cabin.fillna('Missing', inplace=True)
data.Embarked.fillna('Missing', inplace=True)

In [71]: ### Extraindo a primeira letra da variavel Cabin
data['Cabin'] = data['Cabin'].astype(str).str[0]

In [72]: data.head()
```

Out[72]:

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
0	0	3	male	22.0	1	0	7.2500	M	S
1	1	1	female	38.0	1	0	71.2833	C	C
2	1	3	female	26.0	0	0	7.9250	M	S
3	1	1	female	35.0	1	0	53.1000	C	S
4	0	3	male	35.0	0	0	8.0500	M	S

FONTE: Adaptado de Alegeorgelustosa (2018)

A seguir, veremos a codificação do train_test_split, utilizado para dividirmos os dados em Treino e Teste.

FIGURA 13 – CODIFICAÇÃO PARA DIVIDIR OS DADOS EM TREINO E TESTE

```
In [73]: X_train, X_test, y_train, y_test = train_test_split(data, data.Survived,
                                                         test_size=0.3,
                                                         random_state=0)

X_train.shape, X_test.shape

Out[73]: ((623, 9), (268, 9))
```

FONTE: Adaptado de Alegeorgelustosa (2018)

Ainda, a codificação para substituir os valores faltantes da coluna Age pelos valores da parte direita da distribuição.

FIGURA 14 – CODIFICAÇÃO PARA SUBSTITUIR OS VALORES FALTANTES DA COLUNA AGE PELOS VALORES DA PARTE DIREITA DA DISTRIBUIÇÃO

```
In [74]: def impute_na(df, variable, extreme):
          df[variable].fillna(extreme, inplace = True)

          impute_na(X_train, 'Age', X_train.Age.mean()+3*X_train.Age.std())
          impute_na(X_test, 'Age', X_test.Age.mean()+3*X_test.Age.std())

In [75]: X_train.isnull().sum(), X_test.isnull().sum()

Out[75]: (Survived      0
          Pclass      0
          Sex         0
          Age         0
          SibSp      0
          Parch      0
          Fare       0
          Cabin      0
          Embarked   0
          dtype: int64, Survived      0
          Pclass      0
          Sex         0
          Age         0
          SibSp      0
          Parch      0
          Fare       0
          Cabin      0
          Embarked   0
          dtype: int64)
```

FONTE: Adaptado de Alegeorgelustosa (2018)

Agora, temos os dados prontos para efetuarmos os tratamentos específicos de dados categóricos.

- *One Hot Encoding*

Pelo que será exposto a seguir, será possível verificar que tanto os Shapes dos dados de Treino como os de Teste estão diferentes, devido à existência dos dados raros na base de treino.

FIGURA 15 – CODIFICAÇÃO ONE HOT ENCODING (PARTE 1)

```

In [76]: def get_OHE(df):
         df_OHE = pd.concat([df[['Age', 'Fare', 'Pclass']],
                             pd.get_dummies(df[['Sex', 'Cabin', 'Embarked']], drop_first=True)], axis=1)
         return df_OHE

In [77]: X_train_OHE = get_OHE(X_train)
         X_test_OHE = get_OHE(X_test)
         X_train_OHE.head()

Out[77]:
   Age  Fare  Pclass  Sex_male  Cabin_B  Cabin_C  Cabin_D  Cabin_E  Cabin_F  Cabin_G  Cabin_M  Cabin_T  Embarked_Missing  Embarked_Q
857  51.00000  26.5500  1         1         0         0         0         1         0         0         0         0         0         0
52   49.00000  76.7292  1         0         0         0         1         0         0         0         0         0         0         0
386   1.00000  46.9000  3         1         0         0         0         0         0         0         0         1         0         0
124  54.00000  77.2875  1         1         0         0         1         0         0         0         0         0         0         0
578  73.43632  14.4583  3         0         0         0         0         0         0         0         1         0         0         0

In [78]: X_train_OHE.shape, X_test_OHE.shape
Out[78]: ((623, 15), (268, 13))

```

FONTE: Adaptado de Alegeorgelustosa (2018)

FIGURA 16 – CODIFICAÇÃO ONE HOT ENCODING (PARTE 2)

```

In [79]: X_train.Cabin.nunique()
Out[79]: 9

In [80]: X_test.Cabin.nunique()
Out[80]: 8

In [81]: ##### Por enquanto podemos criar as colunas na base de teste e preenche-las com zeros
         X_test_OHE.loc[:, 'Cabin_Y'] = 0
         X_test_OHE.loc[:, 'Embarked_Missing'] = 0

In [82]: X_train_OHE.shape, X_test_OHE.shape
Out[82]: ((623, 15), (268, 15))

```

FONTE: Adaptado de Alegeorgelustosa (2018)

• Método de Contagem da frequência de dados

A seguir, será possível observar a codificação do método de contagem da frequência dos dados.

FIGURA 17 – CODIFICAÇÃO DO MÉTODO DE CONTAGEM DA FREQUÊNCIA DOS DADOS

```

In [83]: def categorical_to_count(df_train, df_test):
         # Realizamos uma copia temporária do Dataframe Original
         df_train_temp = df_train.copy()
         df_test_temp = df_test.copy()

         # Criação de um dicionário para mapear as observações
         for col in ['Sex', 'Cabin', 'Embarked']:
             X_frequency_map = df_train_temp[col].value_counts().to_dict()

             # Substituímos os valores reais das observações pela contagem dos dados
             df_train_temp[col] = df_train_temp[col].map(X_frequency_map)
             df_test_temp[col] = df_test_temp[col].map(X_frequency_map)

         # Agora retiramos do Dataframe nosso Target
         df_train_temp.drop(['Survived'], axis=1, inplace=True)
         df_test_temp.drop(['Survived'], axis=1, inplace=True)

         return df_train_temp, df_test_temp

```

FONTE: Adaptado de Alegeorgelustosa (2018)

Além disso, há a codificação para executar nossa função para ambas bases. Poderemos observar o preenchimento com as colunas Sex, Cabin, Embarked, com a quantidade de vezes que a observação apareceu no Dataset.

FIGURA 18 – CODIFICAÇÃO PARA EXECUTAR A FUNÇÃO EM AMBAS AS BASES

```
In [84]: # Vamos agora executar nossa função para ambas as bases
X_train_count, X_test_count = categorical_to_count(X_train, X_test)
X_train_count.head()
```

```
Out[84]:
```

	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
857	1	408	51.00000	0	0	26.5500	27	457
52	1	215	49.00000	1	0	78.7292	26	108
386	3	408	1.00000	5	2	46.9000	471	457
124	1	408	54.00000	0	1	77.2875	26	457
578	3	215	73.43632	1	0	14.4583	471	108

FONTE: Adaptado de Alegeorgelustosa (2018)

Outra maneira de transformar variáveis do tipo categórico é considerar o Target como referência.

FIGURA 19 – CODIFICAÇÃO PARA TRANSFORMAR VARIÁVEIS CATEGÓRICAS UTILIZANDO TARGET COMO REFERÊNCIA

```
In [85]: def categorical_to_ordered(df_train, df_test):
# Realizamos uma copia temporária do Dataframe Original
df_train_temp = df_train.copy()
df_test_temp = df_test.copy()

# Iremos ordenar as observações de acordo com a média de Sobreviventes
for col in ['Sex', 'Cabin', 'Embarked']:
    ordered_labels = df_train.groupby([col])['Survived'].mean().sort_values().index

    # O Dicionário será preenchido com valores ordinais de acordo com as observações
    ordinal_label = {k:i for i, k in enumerate(ordered_labels, 0)}

    # Aplicando os valores encontrados acima nos Datasets de Treino e Test
    df_train_temp[col] = df_train[col].map(ordinal_label)
    df_test_temp[col] = df_test[col].map(ordinal_label)

# Agora retiramos do Dataframe nosso Target
df_train_temp.drop(['Survived'], axis=1, inplace=True)
df_test_temp.drop(['Survived'], axis=1, inplace=True)

return df_train_temp, df_test_temp
```

FONTE: Adaptado de Alegeorgelustosa (2018)

A seguir, a codificação para executar nossa função para ambas as bases.

FIGURA 20 – CODIFICAÇÃO PARA EXECUTAR NOSSA FUNÇÃO PARA AMBAS AS BASES

```
In [86]: # Vamos agora executar nossa função para ambas as bases
X_train_ordered, X_test_ordered = categorical_to_ordered(X_train, X_test)
X_train_ordered.head()
```

```
Out[86]:
```

	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
857	1	0	51.00000	0	0	26.5500	7	0
82	1	1	49.00000	1	0	78.7292	6	2
386	3	0	1.00000	5	2	46.9000	1	0
124	1	0	54.00000	0	1	77.2875	6	0
678	3	1	73.43632	1	0	14.4583	1	2

FONTE: Adaptado de Alegeorgelustosa (2018)

Ainda, a codificação que exemplifica o resultado da nossa função de preenchimento para a coluna Cabin. Para isso, utilizaremos a função unique, que pode ser vista em In [88].

FIGURA 21 – CODIFICAÇÃO EXEMPLIFICANDO O RESULTADO

```
In [87]: X_train_ordered.Cabin.unique()
```

```
Out[87]: array([7, 6, 1, 8, 4, 2, 5, 3, 0], dtype=int64)
```

FONTE: Adaptado de Alegeorgelustosa (2018)

• Técnica de fator de riscos para dados categóricos

A seguir, será apresentada a técnica de fator de risco para dados categóricos. In [88] contém a codificação da técnica e, em Out [88], está a execução do resultado da codificação.

FIGURA 22 – CODIFICAÇÃO DA TÉCNICA DE FATOR DE RISCO PARA DADOS CATEGÓRICOS

```
In [88]: def categorical_to_risk(df_train, df_test):
# Realizamos uma copia temporária do Dataframe Original
df_train_temp = df_train.copy()
df_test_temp = df_test.copy()

# Iremos ordenar as observações de acordo com a média de Sobreviventes
for col in ['Sex', 'Cabin', 'Embarked']:
    risk_dict = df_train.groupby([col])['Survived'].mean().to_dict()

    # Aplicação do dicionário criado!
    df_train_temp[col] = df_train[col].map(risk_dict)
    df_test_temp[col] = df_test[col].map(risk_dict)

# Remoção da coluna Target
df_train_temp.drop(['Survived'], axis=1, inplace=True)
df_test_temp.drop(['Survived'], axis=1, inplace=True)
return df_train_temp, df_test_temp

X_train_risk, X_test_risk = categorical_to_risk(X_train, X_test)
X_train_risk.head()
```

```
Out[88]:
```

	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
857	1	0.196078	51.00000	0	0	26.5500	0.740741	0.341357
52	1	0.753488	49.00000	1	0	76.7292	0.692308	0.564815
386	3	0.196078	1.00000	5	2	46.9000	0.303609	0.341357
124	1	0.196078	54.00000	0	1	77.2875	0.692308	0.341357
578	3	0.753488	73.43633	4	0	44.4593	0.303609	0.564815

FONTE: Adaptado de Alegeorgelustosa (2018)

O peso de evidência (Weight of Evidence – WoE) e o valor da informação (Information Value - IV) são técnicas simples, porém poderosas para realizar a transformação e para selecionar variáveis. Esses conceitos têm enorme conexão com a técnica de modelagem de regressão logística. A seguir, em In [89], poderá ser verificada a codificação e, em Out [89], a execução do resultado da codificação.

FIGURA 23 – TÉCNICA DO PESO DE EVIDÊNCIA

```
In [89]: def categorical_to_woe(df_train, df_test):
# Realizamos uma copia temporária do Dataframe Original
df_train_temp = df_train.copy()
df_test_temp = df_test.copy()

# Criação de DF contemplando diferentes partes da equação WoE
for col in ['Sex', 'Cabin', 'Embarked']:
    prob_df = X_train.groupby([col])['Survived'].mean()
    prob_df = pd.DataFrame(prob_df)
    prob_df['Died'] = 1 - prob_df['Survived']

    # Como não existe log de Zero, iremos substituí-los por valores aproximados de Zeros
    prob_df.loc[prob_df.Died == 0, 'Died'] = 0.00001
    prob_df.loc[prob_df.Survived == 0, 'Survived'] = 0.00001

    # Calculando a equação WoE
    prob_df['woe'] = np.log(prob_df.Survived / prob_df.Died)
    woe = prob_df['woe'].to_dict()

    # Aplicando o dicionário criado com a equação WoE
    df_train_temp[col] = df_train[col].map(woe)
    df_test_temp[col] = df_test[col].map(woe)

# Remoção da Variável Target
df_train_temp.drop(['Survived'], axis=1, inplace=True)
df_test_temp.drop(['Survived'], axis=1, inplace=True)
return df_train_temp, df_test_temp

X_train_woe, X_test_woe = categorical_to_woe(X_train, X_test)
X_train_woe.head()
```

Out[89]:

	Pclass	Sex	Age	SibSp	Parch	Fare	Cabin	Embarked
857	1	-1.410987	51.00000	0	0	26.5500	1.049822	-0.657254
52	1	1.117304	49.00000	1	0	76.7292	0.810930	0.260726
386	3	-1.410987	1.00000	5	2	46.9000	-0.830169	-0.657254
124	1	-1.410987	54.00000	0	1	77.2875	0.810930	-0.657254
578	3	1.117304	73.43632	1	0	14.4563	-0.830169	0.260726

FONTE: Adaptado de Alegeorgelustosa (2018)

Agora, compararemos diferentes algoritmos: Logistic Regression, Random Forest, Gradient Boosting Trees. É interessante estudar o comportamento de cada método de Machine Learning nos dados tratados de maneiras diferentes na etapa de preparação.

Com a utilização da regressão logística, o método de preenchimento com dados ordinais obteve o melhor resultado na base de testes, conforme apresentado. Já quando utilizamos o algoritmo Random Forest, podemos identificar uma melhor performance para os datasets que forma tratados com alguma forma inteligente de preencher os dados (WoE, Risco, Ordinal). Por fim, ao utilizar o algoritmo Xgboost obtivemos o melhor resultado com o método One Hot Encoding.

• Algoritmo de Logistic Regression

FIGURA 24 – CODIFICAÇÃO DO ALGORITMO *LOGISTIC REGRESSION*

```
In [90]: def run_logistic(X_train, X_test, y_train, y_test):

    logit = LogisticRegression(random_state=44)
    logit.fit(X_train, y_train)
    print('Fase de Treinamento')
    pred = logit.predict_proba(X_train)
    print('Logistic Regression roc-auc: {}'.format(roc_auc_score(y_train, pred[:,1])))
    print('Fase de Teste')
    pred = logit.predict_proba(X_test)
    print('Logistic Regression roc-auc: {}'.format(roc_auc_score(y_test, pred[:,1])))

In [91]: # One Hot Encoding
run_logistic(X_train_OHE, X_test_OHE, y_train, y_test)

Fase de Treinamento
Logistic Regression roc-auc: 0.851852454393614
Fase de Teste
Logistic Regression roc-auc: 0.8501785714285715
```

```
In [92]: # Método counts
run_logistic(X_train_count, X_test_count, y_train, y_test)

Fase de Treinamento
Logistic Regression roc-auc: 0.8543090171579792
Fase de Teste
Logistic Regression roc-auc: 0.8521428571428572
```

```
In [93]: # Método de (ordered) - Preenchimento com dados ordinais
run_logistic(X_train_ordered, X_test_ordered, y_train, y_test)

Fase de Treinamento
Logistic Regression roc-auc: 0.856141948198499
Fase de Teste
Logistic Regression roc-auc: 0.8549404761904763
```

```
In [94]: # Método de fator de Risco
run_logistic(X_train_risk, X_test_risk, y_train, y_test)

Fase de Treinamento
Logistic Regression roc-auc: 0.8531919047709169
Fase de Teste
Logistic Regression roc-auc: 0.853452380952381
```

```
In [95]: # Método WOE
run_logistic(X_train_woe, X_test_woe, y_train, y_test)

Fase de Treinamento
Logistic Regression roc-auc: 0.8555996616125463
Fase de Teste
Logistic Regression roc-auc: 0.8545833333333333
```

FONTE: Adaptado de Alegeorgelustosa (2018)

- Algoritmo Random Forest

FIGURA 25 – CODIFICAÇÃO DO ALGORITMO RANDOM FOREST

```
In [96]: def run_randomForests(X_train, X_test, y_train, y_test):
         rf = RandomForestClassifier(n_estimators=200, random_state=39, max_depth=4)
         rf.fit(X_train, y_train)
         print('Fase de Treinamento')
         pred = rf.predict_proba(X_train)
         print('Random Forests roc-auc: {}'.format(roc_auc_score(y_train, pred[:,1])))
         print('Fase de Teste')
         pred = rf.predict_proba(X_test)
         print('Random Forests roc-auc: {}'.format(roc_auc_score(y_test, pred[:,1])))

In [97]: # One Hot Encoding
         run_randomForests(X_train_OHE, X_test_OHE, y_train, y_test)

Fase de Treinamento
Random Forests roc-auc: 0.8823669768551659
Fase de Teste
Random Forests roc-auc: 0.8705059523809523

In [98]: # Método counts
         run_randomForests(X_train_count, X_test_count, y_train, y_test)

Fase de Treinamento
Random Forests roc-auc: 0.8935435240016485
Fase de Teste
Random Forests roc-auc: 0.8832142857142856

In [99]: # Método de (ordered) - Preenchimento com dados ordinais
         run_randomForests(X_train_ordered, X_test_ordered, y_train, y_test)

Fase de Treinamento
Random Forests roc-auc: 0.8931530769397626
Fase de Teste
Random Forests roc-auc: 0.8834821428571429

In [100]: # Método de Fator de Risco
          run_randomForests(X_train_risk, X_test_risk, y_train, y_test)

Fase de Treinamento
Random Forests roc-auc: 0.8931422311880436
Fase de Teste
Random Forests roc-auc: 0.8834226190476191

In [101]: # Método MDE
          run_randomForests(X_train_woe, X_test_woe, y_train, y_test)

Fase de Treinamento
Random Forests roc-auc: 0.8931422311880436
Fase de Teste
Random Forests roc-auc: 0.8834226190476191
```

FONTE: Adaptado de Alegeorgelustosa (2018)

• Algoritmo Gradient Boosting Trees

FIGURA 26 – CODIFICAÇÃO DO ALGORITMO GRADIENT BOOSTING TREES

```
In [102]: from xgboost import XGBClassifier

def run_xgb(X_train, X_test, y_train, y_test):
    # function to train and test gradient boosting trees
    # using the xgboost package

    xgb_model = XGBClassifier(random_state=44, max_depth=2)
    xgb_model.fit(X_train, y_train)
    print('Fase de Treino')
    pred = xgb_model.predict_proba(X_train)
    print('Xgboost roc-auc: {}'.format(roc_auc_score(y_train, pred[:,1])))
    print('Fase de Teste')
    pred = xgb_model.predict_proba(X_test)
    print('Xgboost roc-auc: {}'.format(roc_auc_score(y_test, pred[:,1])))

In [103]: # One Hot Encoding
run_xgb(X_train_OHE[X_train_OHE.columns], X_test_OHE[X_test_OHE.columns], y_train, y_test)

Fase de Treino
Xgboost roc-auc: 0.9084414220949655
Fase de Teste
Xgboost roc-auc: 0.8898214285714285

In [104]: # Método counts
run_xgb(X_train_count, X_test_count, y_train, y_test)

Fase de Treino
Xgboost roc-auc: 0.9082503633326826
Fase de Teste
Xgboost roc-auc: 0.885297619047619
```

```
In [105]: # Método de (ordered) - Preenchimento com dados ordinais
run_xgb(X_train_ordered, X_test_ordered, y_train, y_test)

Fase de Treino
Xgboost roc-auc: 0.9063198195266915
Fase de Teste
Xgboost roc-auc: 0.8844642857142858

In [106]: # Método de Fator de Risco
run_xgb(X_train_risk, X_test_risk, y_train, y_test)

Fase de Treino
Xgboost roc-auc: 0.9063198195266915
Fase de Teste
Xgboost roc-auc: 0.8844642857142858

In [107]: # Método WOE
run_xgb(X_train_woe, X_test_woe, y_train, y_test)

Fase de Treino
Xgboost roc-auc: 0.9063198195266915
Fase de Teste
Xgboost roc-auc: 0.8844642857142858
```

FONTE: Adaptado de Alegeorgelustosa (2018)



Não existe um melhor algoritmo ou mesmo uma receita de bolo. Então, o que existe? Há existência de métodos estatísticos unida a sua criatividade! Elas possibilitam a melhora considerável de cada resultado nos seus modelos.



Aprofunde seu aprendizado com a exemplificação em Python, apresentada em <https://www.quora.com/What-is-one-hot-encoding-and-when-is-it-used-in-data-science>. O exemplo está planejado em mundo em que as pessoas bebem café ou chá.

RESUMO DO TÓPICO 2

Neste tópico, você aprendeu que:

- A transformação de dados objetiva melhorar a utilidade de uma característica adicionando, modificando ou eliminando informações.
- Na transformação de dados cada tipo de característica possui um detalhamento específico, favorecendo ou desfavorecendo a extração de valor.
- A etapa de transformação de dados envolve também a consolidação em formatos adequados para que a mineração possa ser realizada.
- A transformação de dados envolve atividades de *smoothing* (aplainamento), agregação, generalização, normalização e construção de atributos.
- *Smoothing* remove os *noisy data*, usando técnicas de *binning*, agrupamento e regressão.
- Agregação aplica operações de sumarização e agregação nos dados.
- A generalização dos dados é a etapa que possibilita transformar os dados primitivos (como linhas de tabelas) em hierarquias de mais alto nível.
- A normalização dos dados possibilita atribuir uma nova escala a um atributo de maneira que os valores desse atributo possam cair na nova escala em um intervalo especificado.
- Na construção de atributos, novos atributos podem ser construídos a partir dos atributos existentes, no sentido de apoiar o processo de análise.
- Os dados devem ser codificados para ficarem em uma maneira que possam ser utilizados como entrada dos algoritmos de Mineração de Dados.
- A forma como a informação é codificada tem grande influência sobre o tipo de conhecimento a ser encontrado.
- De forma abrangente a codificação pode ser numérica → categórica ou categoria → numérica.
- A codificação Numérica → Categórica, divide valores de atributos contínuos em intervalos codificados.

- A codificação Categórica → Numérica, representa valores de atributos categóricos por códigos numéricos.
- A transformação dos dados deve ser realizada de acordo com o domínio do problema.
- As possíveis transformações dos dados são: Binarização, Desordenação, Agrupamento, Ordenação, *Thresholding*, Discretização, Normalização e Calibração.
- Binarização se refere em transformar valores nominais em um conjunto de valores booleanos.
- Ordenação se adiciona informação em um valor para organizá-los.
- *Thresholding* consiste em transformar valores do tipo numéricos ou ordinais em conjuntos de valores booleanos.
- A discretização também é denominada de mapeamento em intervalos.
- A discretização baseada em transformar valores numéricos em faixas de valores, categorias, classes ou valores ordinais.
- Divisão em intervalos com comprimentos definidos pelo usuário é uma técnica de discretização, em que o usuário define o número de intervalos e escolhe o tamanho de cada um deles.
- Divisão em intervalos de igual comprimento é uma técnica de discretização, em que é definido apenas o número de intervalos, sendo o comprimento calculado a partir do maior valor do domínio do atributo e do menor valor do domínio do atributo.
- Divisão em intervalos por meio de clusterização é uma técnica de discretização que consiste em agrupar os valores de um atributo em *clusters* (grupos), levando em consideração a similaridade existente entre tais valores.
- A normalização é usada para neutralizar os efeitos de operação de valores em escalas diferentes.
- A Métrica Z-score também é uma técnica de normalização, que utiliza o desvio padrão e a média dos valores para normalizar.
- Divisão em intervalos de igual comprimento é uma técnica utilizada na normalização, que utiliza o valor máximo do conjunto e do valor mínimo do conjunto.

- “A calibração é uma técnica de transformação de dados utilizada para extrair informações preditivas. Essa técnica é geralmente utilizada em bases de dados de instituições financeiras para fazer previsões sobre investimentos” (CAETANO, 2018b, p. 1).
- O One Hot Encoder é utilizado para transformar atributos categóricos que estão representados como números, contudo, a ordem não possui relevância.
- A Representação Binária Padrão (Econômica) é uma técnica de codificação Categórica – Numérica, que utiliza representação binária padrão (econômica), em que cada valor categórico é associado a um valor de 1 até N, bem como é representado por uma cadeia de dígitos binários.
- A Representação Binária 1-de-N é uma técnica de codificação Categórica – Numérica, que utiliza a representação binária 1-de-N, na qual o código 1-N possui um comprimento igual ao número de categorias discretas que são possíveis para a variável, na qual cada elemento na cadeia de bits é 0, exceto para um único elemento, aquele elemento que representa o valor da categoria em questão.
- A representação Binária por temperatura é uma técnica de codificação Categórica – Numérica, que utiliza a representação binária por temperatura e é usada mais usualmente quando os valores discretos estão relacionados de algum modo.



1 A transformação de dados objetiva melhorar a utilidade de uma característica adicionando, modificando ou eliminando informações, bem como cada tipo de característica possui um detalhamento específico, favorecendo ou desfavorecendo a extração de valor. A transformação de dados envolve: Smoothing (aplainamento, agregação, generalização, normalização e a construção de atributos. Nesse contexto, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () A agregação aplica operações de sumarização e agregação nos dados.
- () A normalização é a etapa que possibilita transformar os dados primitivos (como linhas de tabelas) em hierarquias de mais alto nível.
- () O *smoothing* remove os *noisy data*, usando técnicas de *binning*, agrupamento e regressão.
- () A generalização possibilita atribuir uma nova escala a um atributo de maneira que os valores desse atributo possam cair na nova escala em um intervalo especificado.

Assinale a alternativa com a sequência CORRETA:

- a) () V – F – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () F – F – V – V.

2 A forma como a informação é codificada tem grande influência sobre o tipo de conhecimento a ser encontrado. Basicamente, para Goldschmidt e Passos (2005, p. 40), “[...] a codificação pode ser Numérica – Categórica, que divide valores de atributos contínuos em intervalos codificados ou Categórica – Numérica, que representa valores de atributos categóricos por códigos numéricos”. Referente às técnicas codificação numérica categórica, ou discretização, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () A técnica de divisão em intervalos com comprimentos definidos pelo usuário é o próprio usuário que define o número de intervalos e escolhe o tamanho de cada um deles.
- () A técnica de divisão em intervalos por meio de clusterização é definido apenas o número de intervalos, sendo o comprimento calculado a partir do maior valor do domínio do atributo e do menor valor do domínio do atributo.
- () A técnica de divisão em intervalos de igual comprimento consiste em agrupar os valores de um atributo em *clusters* (grupos) levando em consideração a similaridade existente entre tais valores.
- () A técnica de divisão em intervalos por meio de clusterização requer que o usuário especifique previamente o número de *clusters* a ser considerado.

Assinale a alternativa com a sequência CORRETA:

- a) () V – F – F – V.
- b) () V – V – V – F.
- c) () F – F – V – F.
- d) () F – F – V – V.

3 A Codificação de dados Categórica – Numérica representam valores de atributos categóricos por códigos numéricos categóricos. A representação Binária Padrão (Econômica), Representação Binária 1-de-N e a representação Binária por Temperatura são técnicas de codificação de dados categóricos → numérica. Assim, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () A técnica de representação Binária por Temperatura é comumente usada quando os valores discretos estão relacionados de algum modo.
- () A medida de distância de Hamming (DH), também chamada CityBlock é uma medida de distância frequentemente usada em conjunto com a representação Binária por Temperatura.
- () A técnica de representação Binária 1-de-N cada valor categórico é associado a um valor de 1 até N, bem como é representado por uma cadeia de dígitos binários.
- () A técnica de Representação Binária Padrão (Econômica) o código 1-N possui um comprimento igual ao número de categorias discretas que são possíveis para a variável, na qual cada elemento na cadeia de bits é 0, exceto para um único elemento, aquele elemento que representa o valor da categoria em questão.

Assinale a alternativa com a sequência CORRETA:

- a) () V – F – V – F.
- b) () F – V – V – F.
- c) () V – V – F – F.
- d) () F – F – V – V.

4 O One Hot Encoder é utilizado para transformar atributos categóricos que estão representados como números, mas a ordem não possui relevância. Assim, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () As variáveis binárias são criadas para evitar que os modelos interpretem os atributos como sendo numéricos.
- () É criada uma variável binária para cada valor possível que o atributo pode assumir
- () Dentre essas novas variáveis binárias, a única variável de valor 1 será aquela que corresponde à categoria do atributo na instância.
- () É utilizado para transformar atributos categóricos que estão representados como números.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F – F.
- b) () V – F – V – F.
- c) () F – V – V – F.
- d) () V – V – V – V.

5 A forma como a informação é codificada tem grande influência sobre o tipo de conhecimento a ser encontrado. Basicamente, para Goldschmidt e Passos (2005, p. 40), “[...] a codificação pode ser Numérica – Categórica, que divide valores de atributos contínuos em intervalos codificados ou Categórica – Numérica, que representa valores de atributos categóricos por códigos numéricos”. Referente às técnicas codificação categórica → numérica, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Na representação binária padrão (econômica) cada valor categórico é associado a um valor de 1 até N, bem como é representado por uma cadeia de dígitos binários.
- () Na representação Binária por Temperatura o código 1-N possui um comprimento igual ao número de categorias discretas que são possíveis para a variável.
- () A representação binária 1-de-N é usada mais usualmente quando os valores discretos estão relacionados de algum modo.
- () A medida de distância frequentemente usada em conjunto da representação Binária por Temperatura é a distância de Hamming (DH), também chamada CityBlock.

- a) () V – F – F – V.
- b) () F – V – V – F.
- c) () V – V – V – V.
- d) () F – F – F – F.



REDUÇÃO DE DADOS E ANÁLISE POR COMPONENTES PRINCIPAIS

1 INTRODUÇÃO

Existem problemas na análise de dados em que o conjunto de dados é muito grande. Nesses casos, a dimensão é justamente relacionada a quantidade de características existentes no conjunto de dados. Pode-se dizer que quanto maior for o número de características, maior será a dimensão do problema. “Grandes dimensões implicam em um alto custo para executar algoritmos de Machine Learning” (CAETANO, 2018b p. 83).

Nesse contexto, Goldschmidt e Passos (2005) colocam que a redução de dados, também é conhecida como seleção de dados, compreendendo basicamente, identificar quais informações, dentre as existentes, devem de fato ser consideradas durante o processo. Os autores (GOLDSCHMIDT; PASSOS, 2005) ainda colocam que podem existir dois possíveis cenários: escolher atributos ou escolher registros. Caetano (2018b, p. 83) complementa o cenário com o exemplo seguinte:

Considere a situação em que uma pessoa deseja encontrar uma nota de R\$100,00 na calçada de uma rua. A solução que ela deve seguir é simples, basta percorrer a reta (1 dimensão) e procurar pela nota. Talvez em apenas alguns minutos ela irá encontrar a nota. Considere outra situação onde a mesma pessoa perde uma nota de R\$100,00 em um quintal. A solução que ela deve seguir não é tão simples quanto a anterior, pois ela terá que vasculhar a área (2 dimensões) do quintal. Dessa forma, ela poderá demorar algumas horas para encontrar essa nota dependendo do tamanho da área. Agora considere que essa pessoa perdeu uma nota de R\$100,00 em um prédio (e ela não sabe nem em que andar perdeu). Podemos perceber que ela terá uma dificuldade enorme em encontrar essa nota pois a dimensão do problema é alta. Dependendo da dificuldade o custo de encontrar a nota de R\$100,00 não compensa o esforço que ela terá que fazer.

Dessa forma, podemos dizer que a redução de dados é uma transformação com o intuito de reduzir os tempos necessários para realizar análises, facilitar tanto a manutenção dos dados quanto a análise dos dados. Além disso, a redução de dados visa reduzir os custos computacionais. Segundo Caetano (2018b) dentre as abordagens mais conhecidas para reduzir os dados estão: Principal Component Analysis (PCA), também conhecida como redução de dados vertical e pela Seleção das melhores características.

2 PRINCIPAIS ABORDAGENS DA REDUÇÃO DE DADOS

Dentre as abordagens mais conhecidas para reduzir os dados estão: Principal Component Analysis (PCA), também conhecida como redução de dados vertical, e Seleção das melhores características (CAETANO, 2018b).

QUADRO 11 – PRINCIPAIS ABORDAGENS NA REDUÇÃO DE DADOS

TIPO	DESCRIÇÃO
Seleção das melhores características	Essa abordagem pode ser executada com: eliminação de valores ausentes, análise da variância e análise de correlação. A eliminação de valores ausentes, tem como objetivo a eliminação das características que contém valores ausentes, enquanto a análise de variância de uma característica, conforme Caetano (2018b, p. 84): [...] é utilizada para identificar características cujos valores não se alteram muito (baixa variância). Dessa forma, o valor das informações dessas características é baixo. A solução é remover as características com baixa variância. Porém, as características devem ser normalizadas antes de se fazer a análise da variância, para que o preparador tenha mais facilidade em determinar o que constitui um valor alto de variância e o que constitui um valor baixo de variância. Portanto, definir o threshold da variância é um desafio dessa análise, pois isso depende da intuição e experiência do preparador de dados. Por fim, a análise de correlação, segundo Caetano (2018b, p. 84), “[...] as características altamente correlatas são identificadas e se escolhe uma característica de cada par de características correlatas”.
PCA ou redução de dados vertical	Nessa técnica são realizadas combinações lineares das n características de um conjunto de dados, resultando em um novo conjunto de dados criado diferente do conjunto original. Os principais benefícios para Caetano (2018b, p. 84) são: “[...] redução da dimensão pela seleção de k ($k < n$) componentes principais. Estes k componentes principais podem ser utilizados para substituir o conjunto dos n atributos originais”. Além disso, Caetano (2018b) coloca que aqui há perda de informação, devido que é utilizada uma quantidade de dados menor na representação de um mesmo problema. Outro fator, para Caetano (2018b, p. 84-85), é que “[...] os dados são descaracterizados (não ficam em seu estado original). Isso torna a análise difícil, pois não há uma clareza do que realmente significa os valores. Uma regra de ouro para selecionar os k componentes principais é selecionando os componentes cuja variância total acumulada esteja entre 70% a 95% da variância do conjunto”. GRÁFICO SCREE-PLOT FONTE: Adaptado de Caetano (2018)

Fonte: A Autora

3 ANÁLISE POR COMPONENTES PRINCIPAIS PARA IDENTIFICAÇÃO DE GRUPOS

Conforme vimos anteriormente a análise por componentes principais ajuda a identificar grupo com custo computacional baixo, podendo ser aplicada em qualquer conjunto de dados numéricos que tenha mais de duas dimensões. Ela também é conhecida como Karhunen-Loeve ou Método K-L. Haykin (1999) apresenta uma ampla literatura referente ao tema (GOLDSCHMIDT; PASSOS, 2005; CAETANO, 2018b).

Vamos exemplificar essa situação. Goldschmidt e Passos (2005) colocam que, se tivermos um conjunto de dados em análise que possua N vetores de dados (tuplas) e K atributos (dimensões). A PCA busca por c tuplas ortonormais de dimensão k , que possam ser usadas na melhor representação dos dados ($c \leq k$). Dessa forma, os dados originais são projetados em um espaço com menor dimensão, resultante da redução dos dados. Portanto, PCA combina [...] a essência dos atributos originais, criando um e menor conjunto de variáveis para representar os dados. Assim sendo, os dados iniciais são, então, projetados sobre as novas variáveis” (GOLDSCHMIDT; PASSOS, 2005, p. 32).

QUADRO 12 – PROCEDIMENTOS BÁSICOS DA PCA

PROCEDIMENTO	DESCRIÇÃO
Dados de entrada são normalizados	Os dados de entrada são normalizados de maneira que os valores de todos os atributos fazem parte da mesma faixa de valores. Este passo auxilia a manter que atributos que tem domínios mais amplos não sejam privilegiados de acordo com os atributos com domínios menores.
PCA computa c vetores ortonormais que forneçam uma base para os dados de entrada normalizados	Os c vetores ortonormais computados pela análise de componentes principais são unitários, norma igual a 1, cujo rumo é perpendicular referente aos demais. Esses vetores são chamados componentes principais. Os dados de entrada conseguem representar a combinação linear dos componentes principais.
Os componentes principais são ordenados em ordem decrescente de variância	Basicamente os componentes principais ajudam como um novo conjunto de eixos para os dados, dando informações relevantes referente a variância dos dados.
Redução dos componentes mais fracos	Primeiro os componentes são ordenados de maneira decrescente relacionado à variância, o tamanho do conjunto de dados tem a possibilidade de ser reduzido a partir da eliminação dos componentes mais fracos, ou seja, daqueles que tiverem menor variância. Isto é, utilizando os componentes principais mais fortes em relação à variância, consegue-se realizar a reconstrução aproximando-se bem dos dados originais.

FONTE: Adaptado de Goldschmidt e Passos (2005)

A redução de valores é vista como uma alternativa viável frente a alternativa de corte de atributos que acontece pela redução de valores vertical, ou comumente chamada de PCA (CAETANO, 2018b). Para Goldschmidt e Passos (2005, p. 33):

Essa operação consiste em reduzir o número de valores distintos em determinados atributos, o que pode proporcionar um melhor desempenho a diversos algoritmos de Mineração de Dados, sobretudo àqueles que envolvem manipulações simbólicas e comparações lógicas dos dados. Com menos valores, menos comparações são feitas, reduzindo o tempo de processamento de tais algoritmos. Existem métodos de redução de valores contínuos e métodos de redução de valores nominais.

O método de redução de valores nominais pode ser utilizado apenas em variáveis nominais, enquanto o método de redução de valores contínuos (ou discretos) podem ser aplicados somente em variáveis contínuas ou discretas. Como vimos na Unidade 1, uma variável nominal tem um número finito, possivelmente grande, de diferentes valores e esses valores não possuem ordenação. Já uma variável contínua ou discreta tem um relacionamento de ordenação entre os seus valores.

QUADRO 13 – MÉTODOS DE REDUÇÃO DE VALORES

TIPO	MÉTODO	DESCRIÇÃO																				
Nominal	Identificação de Hierarquia entre atributos	Os dados de entrada são normalizados de maneira que os valores de todos os atributos fazem parte da mesma faixa de valores. Este passo auxilia a manter que atributos que tem domínios mais amplos não sejam privilegiados de acordo com os atributos com domínios menores.																				
	Identificação de Hierarquia entre valores	Os c vetores ortonormais computados pela análise de componentes principais são unitários, norma igual a 1, cujo rumo é perpendicular referente aos demais. Esses vetores são chamados componentes principais. Os dados de entrada conseguem representar a combinação linear dos componentes principais.																				
	Particionamento em Células (Bins) de mesma Cardinalidade (“Equidepth Bins”)	Os valores são agrupados em células com o mesmo número de elementos em cada uma delas. A última célula pode conter mais valores em função de um número de valores que não seja múltiplo do número de células. Os valores originais são substituídos pela identificação de cada célula, gerando um novo conjunto de dados (CAETANO, 2018b). O quadro a seguir traz o resultado deste método quando aplicado à variável número de dependentes do nosso conjunto de dados de exemplo. A terceira célula possui quatro valores, enquanto as demais somente três. PARTICIONAMENTO EM CÉLULAS DE MESMA CARDINALIDADE <table><tr><td>1</td><td>1</td><td>2</td><td>3</td><td>3</td><td>3</td><td>4</td><td>5</td><td>5</td><td>7</td></tr><tr><td>Bin1</td><td>Bin1</td><td>Bin1</td><td>Bin2</td><td>Bin2</td><td>Bin2</td><td>Bin3</td><td>Bin3</td><td>Bin3</td><td>Bin3</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005)	1	1	2	3	3	3	4	5	5	7	Bin1	Bin1	Bin1	Bin2	Bin2	Bin2	Bin3	Bin3	Bin3	Bin3
1	1	2	3	3	3	4	5	5	7													
Bin1	Bin1	Bin1	Bin2	Bin2	Bin2	Bin3	Bin3	Bin3	Bin3													

Contínuo ou Discreto	Redução de valores pelas medianas das células (“Bin Medians”)	Nesse método o procedimento é igual ao descrito para o método anterior (CAETANO, 2018b). Depois, é calculada a mediana de cada uma das células. Os valores originais são substituídos pela mediana associada a cada célula, gerando um novo conjunto de dados. O quadro a seguir traz o resultado desse método quando aplicado à variável número de dependentes do nosso conjunto de dados de exemplo. REDUÇÃO DE VALORES PELAS MEDIANAS DAS CÉLULAS <table><tr><td>1</td><td>1</td><td>2</td><td>3</td><td>3</td><td>3</td><td>4</td><td>5</td><td>5</td><td>7</td></tr><tr><td>1</td><td>1</td><td>1</td><td>3</td><td>3</td><td>3</td><td>5</td><td>5</td><td>5</td><td>5</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005)	1	1	2	3	3	3	4	5	5	7	1	1	1	3	3	3	5	5	5	5
	1	1	2	3	3	3	4	5	5	7												
	1	1	1	3	3	3	5	5	5	5												
Redução de valores pelas médias das células (“Bin Means”)	Nesse método o procedimento é parecido ao descrito para o método anterior. Aqui, é calculada a média dos valores em cada uma das células. Os valores originais são substituídos pela média associada a cada célula, gerando um novo conjunto de dados. O quadro a seguir traz o resultado deste método quando aplicado à variável número de dependentes do nosso conjunto de dados de exemplo. REDUÇÃO DE VALORES PELAS MEDIANAS DAS CÉLULAS <table><tr><td>1</td><td>1</td><td>2</td><td>3</td><td>3</td><td>3</td><td>4</td><td>5</td><td>5</td><td>7</td></tr><tr><td>1,3</td><td>1,3</td><td>1,3</td><td>3</td><td>3</td><td>3</td><td>5,3</td><td>5,3</td><td>5,3</td><td>5,3</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005)	1	1	2	3	3	3	4	5	5	7	1,3	1,3	1,3	3	3	3	5,3	5,3	5,3	5,3	
1	1	2	3	3	3	4	5	5	7													
1,3	1,3	1,3	3	3	3	5,3	5,3	5,3	5,3													
Redução de valores pelos limites das células (“Bin Boundaries”)	Aqui, é realizado o mesmo procedimento descrito para o primeiro método. Depois disso, os valores nos extremos das células são considerados. O procedimento calcula a distância de cada valor em relação aos extremos de cada célula. O valor original é substituído pelo valor do extremo mais próximo, gerando um novo conjunto de dados. O quadro a seguir traz o resultado do método quando aplicado à variável número de dependentes do nosso conjunto de dados de exemplo. REDUÇÃO DE VALORES PELAS MÉDIAS DAS CÉLULAS <table><tr><td>1</td><td>1</td><td>2</td><td>3</td><td>3</td><td>3</td><td>4</td><td>5</td><td>5</td><td>7</td></tr><tr><td>1</td><td>1</td><td>2</td><td>3</td><td>3</td><td>3</td><td>4</td><td>4</td><td>4</td><td>7</td></tr></table> FONTE: Adaptado de Goldschmidt e Passos (2005)	1	1	2	3	3	3	4	5	5	7	1	1	2	3	3	3	4	4	4	7	
1	1	2	3	3	3	4	5	5	7													
1	1	2	3	3	3	4	4	4	7													

	Arredondamento de valores	O arredondamento de valores, também chamado de aproximação de valores, sendo uma função comum do nosso cotidiano. A figura a seguir mostra uma alternativa para a noção elementar de arredondamento de valores em números inteiros. ALTERNATIVA PARA A NOÇÃO ELEMENTAR DE ARREDONDAMENTO DE VALORES EM NÚMEROS INTEIROS $y = \text{int}(x/10^k)$ $\text{if } (\text{mod}(x,10^k) \geq (10k/2)) \text{ then } y = y + 1$ $x = y * 10^k$ Considere como exemplos: (i) $x = 145, K=2$ <i>Primeiro passo:</i> $y = \text{int}(145/10^2) = \text{int}(1,45)=1$ <i>Segundo passo:</i> não é executado <i>Terceiro passo:</i> $x = 1 * 10^2 = 100$ (ii) $x = 145, K=1$ <i>Primeiro passo:</i> $y = \text{int}(145/10^1) = \text{int}(14,5)=14$ <i>Segundo passo:</i> $y = y + 1 = 14 + 1 =15$ <i>Terceiro passo:</i> $x = 15 * 10^1 = 150$ FONTE: Adaptado de Goldschmidt e Passos (2005) A variável x indica o valor original, que deve ser arredondado. A variável y recebe o resultado intermediário do procedimento de arredondamento. O parâmetro k é o número de casas decimais à direita a ser considerado no arredondamento.
	Agrupamento de valores (“Clusterização”)	Esse método consiste em realizar o agrupamento de valores de um atributo em grupos (<i>clusters</i>), considerando a similaridade que existe entre os valores. Esse processo basicamente tenta minimizar a similaridade dos dados pertencentes ao mesmo cluster e maximizar a similaridade dos dados em clusters diferentes. Uma vez concluído o processo de clusterização, cada cluster pode passar a ter sua representação pela média dos valores a ele atribuídos. Cabe destacar, que o problema da redução de valores pode ser interpretado como um problema de otimização.

Fonte: A Autora

LEITURA COMPLEMENTAR

ESTUDO DE CASO

LIMPEZA DE DADOS NO R

Existem bibliotecas no R que facilitam a atividade de manipulação e estruturação de dados. Por exemplo, a biblioteca *tidyr* ajuda a resolver problemas de estruturação e a biblioteca *tidyr* ajuda a manipular dados com comandos familiares aos do padrão SQL (*join*, *selects* etc.). Nessa seção vamos utilizar a biblioteca *tidyr* para resolver os dois primeiros casos de problemas de estrutura dos dados.

Ainda, há a implementação em R da solução do primeiro problema estrutural (cabeçalhos de coluna são valores, não nomes de variáveis). Primeiramente, o script lê o arquivo *caso1.csv* e carrega os dados no dataframe *caso1_messy*.

CODIFICAÇÃO DE SOLUÇÃO DO PRIMEIRO PROBLEMA ESTRUTURAL

```
> # CASO 1
> caso1_messy <- read.csv("caso1.csv",
+                          stringsAsFactors = FALSE,
+                          check.names = FALSE, sep=";")
> caso1_messy
  area <$10k $10-20k
1    TI      27    34
2 Construção  12    27
>
> caso1_tidy <- gather(caso1_messy, renda, freq, -area)
> caso1_tidy
  area  renda freq
1    TI  <$10k  27
2 Construção <$10k  12
3    TI  $10-20k  34
4 Construção $10-20k  27
>
```

FONTE: Adaptado de Caetano (2018b)

Em seguida, a função *gather* da biblioteca *tidyr* é utilizada para fazer o *melting*. Essa função recebe como parâmetros os dados, coluna com cabeçalhos que são valores, coluna com os valores (que será criada) e o escopo do *melting*, que no caso será todas as colunas do dataframe *caso1_messy*, exceto a coluna área. O dataframe *caso1_tidy* recebe os dados estruturados.

A seguir, apresentaremos a implementação em R da solução do segundo problema estrutural (Múltiplas variáveis são armazenadas em uma coluna). Primeiramente, o script lê o arquivo *caso2.csv* e carrega os dados no dataframe *caso2_messy*.

CODIFICAÇÃO DE SOLUÇÃO DO SEGUNDO PROBLEMA ESTRUTURAL

```

> # CASO 2
> caso2_messy <- read.csv("caso2.csv",
+                          stringsAsFactors = FALSE,
+                          check.names = FALSE, sep=";")
> caso2_messy
  país m0-14 f0-14
1  US    52   228
2  BR     2   152
>
> caso2_molten <- gather(caso2_messy, faixa, valor, -país)
> caso2_molten
  país faixa valor
1  US m0-14    52
2  BR m0-14     2
3  US f0-14   228
4  BR f0-14   152
> caso2_tidy <- separate(caso2_molten, faixa, c("sexo", "idade"), 1)
> caso2_tidy
  país sexo idade valor
1  US    m  0-14    52
2  BR    m  0-14     2
3  US    f  0-14   228
4  BR    f  0-14   152
>

```

FONTE: Adaptado de Caetano (2018b)

Em seguida, aplica-se o melting no dataframe `caso2_messy`. O dataframe `caso2_molten` recebe o resultado do melting. Por fim, a função `separate` da biblioteca `tidyr` é utilizada para fazer a separação de colunas. Essa função recebe como parâmetros os dados, uma coluna com as múltiplas variáveis, uma lista com os nomes das colunas derivadas (`sexo` e `idade`) e o critério de separação da coluna (no exemplo, considera-se até o primeiro caractere dos valores da coluna `faixa`. O dataframe `caso2_tidy` recebe os dados estruturados).

Para consultar a documentação de funções e bibliotecas no R, basta executar um comando com o caractere `?` antes de uma função ou biblioteca. Por exemplo, se executarmos o comando `?gather`, então o R irá retornar para nós uma descrição do que faz o método, como utilizá-lo, quais são os argumentos do método e outras informações de interesse.

A identificação de valores ausentes no R é facilitada por recursos built-in da linguagem. A seguir, haverá a definição da lista `x` com um dos valores ausentes (NA). A função `is.na` retorna um booleano dizendo se o valor é nulo ou se não é. Em seguida, a função `mean` é aplicada no conjunto `x`, porém a média de um valor nulo não existe, por isso o R retorna o valor NA (que indica erro ou que o conjunto solução é vazio). Para contornar esse problema, podemos utilizar o parâmetro `na.rm=TRUE` que diz para a função `mean` que devem ser removidos primeiro os valores ausentes para depois aplicar o cálculo da média. Esse parâmetro é comum em diversas funções do R.

IDENTIFICAÇÃO DOS VALORES AUSENTES

```

> # Valores ausentes
> x <- c(1,2,3,NA)
> is.na(x)
[1] FALSE FALSE FALSE TRUE
>
> mean(x)
[1] NA
> mean(x, na.rm=TRUE)
[1] 2
>

```

FONTE: Adaptado de Caetano (2018b)

Para fazer a análise de correlação das características de um dataframe, basta utilizar a função `cor` do R. Essa função retorna uma correlação entre as características do dataframe. A seguir, haverá um exemplo de correlação entre as características numéricas da base de dados Iris (quatro primeiras colunas). Por padrão, o método `cor` faz o cálculo de correlação linear utilizando a métrica de Pearson.

EXEMPLO DE CORRELAÇÃO NO R

```

> matriz_correlacao <- cor(iris[,1:4])
> matriz_correlacao

```

	Sepal.Length	Sepal.width	Petal.Length	Petal.width
Sepal.Length	1.0000000	-0.1175698	0.8717538	0.8179411
Sepal.width	-0.1175698	1.0000000	-0.4284401	-0.3661259
Petal.Length	0.8717538	-0.4284401	1.0000000	0.9628654
Petal.width	0.8179411	-0.3661259	0.9628654	1.0000000

```


>

```

FONTE: Adaptado de Caetano (2018b)

Traremos um exemplo de uso da biblioteca `corrplot` para a visualização da matriz de correlação. O método `corrplot` é utilizado recebendo como parâmetros os dados (`matriz_correlacao`) e o método de visualização, que no exemplo é `number`, ou seja, a matriz de correlação mostrará os índices de correlação entre as características. Consulte a documentação da biblioteca para mais detalhes.

EXEMPLO DE GRÁFICO DE CORRELAÇÃO NO R



FONTE: Adaptado de Caetano (2018b)

TRANSFORMAÇÃO E REDUÇÃO DE DADOS NO R

A seguir, poderemos notar a leitura de um arquivo e atribuição ao Dataframe myData. Esse dataframe possui três características (Idade, Valor_A, Valor_B).

CODIFICAÇÃO DA LEITURA DE ARQUIVO E CRIAÇÃO DE UM DATAFRAME

```
> # CARREGA OS DADOS
> myData <- read.csv("data_estudo_de_caso_6_4.csv",
+                     stringsAsFactors = FALSE,
+                     check.names = FALSE, sep=";")
>
> myData
  Idade valor_A valor_B
1    87   19.04    2.26
2    29   29.62   19.59
3    72   17.85   24.13
4    57   27.65   -9.30
5    85   54.81   42.78
6    76  -17.01  -29.21
7    13   13.89    0.03
8     9   16.63   13.79
9    40   48.21   47.88
10   25   42.13   50.56
11   75   19.34  -15.56
12   62   23.03  -28.46
13   17    2.63   19.68
14   74  -19.51  -11.65
15    9    8.13   39.80
16   88  -15.20   48.92
17   17   23.89   11.32
18   14   51.58   41.28
19    8   28.31    7.16
20   88   37.31  -17.86
>
```

FONTE: Adaptado de Caetano (2018b)

Para fazer a discretização de dados no R, vamos utilizar a biblioteca infotheo e a sugestão sobre a definição do número de faixas de valores de discretização. A seguir, mostraremos a instalação e carregamento da biblioteca infotheo e o cálculo da quantidade de bins (divisões). A função sqrt do R calcula a raiz quadrada e a função NROW retorna o número de linhas de um dataframe.

CODIFICAÇÃO DA INICIALIZAÇÃO DA DISCRETIZAÇÃO

```
# DISCRETIZAÇÃO
# ----- CARREGA BIBLIOTECAS
install.packages("infotheo")
library(infotheo)

> # ----- CALCULA NÚMERO DE CATEGORIAS
> nbins <- sqrt(NROW(myData))
> nbins
[1] 4.472136
>
```

FONTE: Adaptado de Caetano (2018b)

Mostraremos como executar a discretização utilizando as duas técnicas clássicas: divisão em intervalos de mesmo tamanho e divisão em intervalos de mesma frequência. A função `discretize` da biblioteca `infotheo` recebe como parâmetros o conjunto de valores, o método de discretização (no exemplo `equalwidth` ou `equalfreq`) e a quantidade de classes da discretização. Os resultados das duas técnicas são atribuídos as colunas `Idade_D1` e `Idade_D2`.

CODIFICAÇÃO DA UTILIZAÇÃO DAS DUAS TÉCNICAS CLÁSSICAS DE DISCRETIZAÇÃO NO R

```
> # EXECUTA DISCRETIZAÇÃO: INTERVALOS DO MESMO TAMANHO
> myData['Idade_D1'] <- discretize( myData$Idade, disc="equalwidth", nbins=nbins)
> myData$Idade_D1
[1] 4 2 4 3 4 4 1 1 2 1 4 3 1 4 1 4 1 1 1 4
>
Técnica utilizada

> # EXECUTA DISCRETIZAÇÃO: INTERVALOS DE MESMA FREQUÊNCIA
> myData['Idade_D2'] <- discretize( myData$Idade, disc="equalfreq", nbins=nbins)
> myData$Idade_D2
[1] 4 2 3 3 4 4 1 1 2 2 3 3 2 3 1 4 2 1 1 4
>
```

FONTE: Adaptado de Caetano (2018b)

A implementação da função `maxMinNormalization` referente à métrica max-min de normalização.

CODIFICAÇÃO DA IMPLEMENTAÇÃO DA MÉTRICA MAX-MIN NO R

```
> # NORMALIZAÇÃO
> # ----- DECLARA FUNÇÃO MAX-MIN
> maxMinNormalization <- function(x) {
+   ((x - min(x))/(max(x) - min(x)))
+ }
>
```

FONTE: Adaptado de Caetano (2018b)

Observaremos a execução da normalização em todas as colunas do Dataframe `myData`, com o uso da função `lapply` do R. O resultado da normalização é convertido para o formato dataframe e atribuído ao Dataframe `myDataNorm`. Em seguida, os valores normalizados são arredondados com até duas casas decimais com o uso da função `round` do R.

CODIFICAÇÃO DA EXEMPLIFICAÇÃO DE NORMALIZAÇÃO NO R

```
> # ----- NORMALIZA OS DADOS
> myDataNorm <- as.data.frame(lapply(myData, maxMinNormalization))
> myDataNorm <-round(x = myDataNorm ,digits=2)
> myDataNorm
```

	Idade	Valor_A	Valor_B	Idade_D1	Idade_D2
1	0.99	0.52	0.39	1.00	1.00
2	0.26	0.66	0.61	0.33	0.33
3	0.80	0.50	0.67	1.00	0.67
4	0.61	0.63	0.25	0.67	0.67
5	0.96	1.00	0.90	1.00	1.00
6	0.85	0.03	0.00	1.00	1.00
7	0.06	0.45	0.37	0.00	0.00
8	0.01	0.49	0.54	0.00	0.00
9	0.40	0.91	0.97	0.33	0.33
10	0.21	0.83	1.00	0.00	0.33
11	0.84	0.52	0.17	1.00	0.67
12	0.68	0.57	0.01	0.67	0.67
13	0.11	0.30	0.61	0.00	0.33
14	0.82	0.00	0.22	1.00	0.67
15	0.01	0.37	0.87	0.00	0.00
16	1.00	0.06	0.98	1.00	1.00
17	0.11	0.58	0.51	0.00	0.33
18	0.08	0.96	0.88	0.00	0.00
19	0.00	0.64	0.46	0.00	0.00
20	1.00	0.76	0.14	1.00	1.00

```
>
```

FONTE: Adaptado de Caetano (2018b)

A seguir, faremos a análise da variância de uma característica e como executar a análise da variância no dataframe inteiro com o uso da função `apply` do R. Essa função recebe como parâmetros os dados, um indicador de qual dimensão será analisada (linha ou coluna) e qual a função será executada nos dados (no exemplo, a função `var` do R).

CODIFICAÇÃO DA ANÁLISE DE VARIÂNCIA NO R

```
> # ANÁLISE DA VARIÂNCIA
> var(myDataNorm$Idade)
[1] 0.1568842
> apply(myDataNorm, 2, var)
```

	Idade	Valor_A	Valor_B	Idade_D1	Idade_D2
0.15688421	0.08284105	0.10959868	0.21661053	0.14678947	

```
>
```

FONTE: Adaptado de Caetano (2018b)

O exposto a seguir apresentará como executar a técnica Principal Component Analysis (PCA) no R. Para isso, vamos utilizar a biblioteca `factorextra`. O método `prcomp` faz as transformações do PCA e o método `fviz_eig` gera um `scree-plot` dos dados.


CODIFICAÇÃO DA ANÁLISE DOS COMPONENTES PRINCIPAIS NO R

```
# ANÁLISE DOS COMPONENTES PRINCIPAIS (PCA)
# ----- CARREGA BIBLIOTECAS
install.packages("factoextra")
library(factoextra)

> # ----- EXECUTA PCA
> myPCA <- prcomp(myDataNorm)
>
> # ----- GRÁFICO SCREE-PLOT
> fviz_eig(myPCA)
>
```

FONTE: Adaptado de Caetano (2018b)

EXEMPLO DE SCREE-PLOT NO R



FONTE: Adaptado de Caetano (2018b)

Por fim, a execução do comando `summary`. Esse comando retorna o sumário do resultado da técnica PCA. Nesse sumário é possível identificar o campo `Cumulative Proportion` que indica a variância acumulada dos componentes. Portanto, podemos escolher os três primeiros componentes, pois eles representam 98% da variância dos dados.

CODIFICAÇÃO DO SUMÁRIO DO RESULTADO DO PCA

```
> # ----- ANÁLISE DA VARIÂNCIA ACUMULADA
> summary(myPCA)
Importance of components:
      PC1      PC2      PC3      PC4      PC5
Standard deviation 0.7267 0.3336 0.24323 0.11463 0.03316
Proportion of Variance 0.7409 0.1561 0.08301 0.01844 0.00154
Cumulative Proportion 0.7409 0.8970 0.98002 0.99846 1.00000
>
```

Os k componentes principais

FONTE: Adaptado de Caetano (2018b)

FONTE: CAETANO, J. A. Preparação de dados. 2018b. Disponível em: <https://rapido.igti.com.br/products/pdd-class>. Acesso em: 11 fev. 2020.

RESUMO DO TÓPICO 3

Neste tópico, você aprendeu que:

- Quanto maior for o número de características, maior será a dimensão do problema.
- Conjunto de dados com grandes dimensões geram um custo alto na execução dos algoritmos de *Machine Learning*.
- A redução de dados, também é conhecida como seleção de dados, compreendendo basicamente, identificar quais informações, dentre as existentes, devem de fato ser consideradas durante o processo.
- A redução de dados é uma transformação com o intuito de reduzir os tempos necessários para realizar análises, facilitar tanto a manutenção dos dados quanto a análise dos dados.
- A abordagem de seleção de melhores características pode ser executada com: eliminação de valores ausentes, análise da variância e análise de correlação.
- A eliminação de valores ausentes tem como objetivo a eliminação das características que contém valores ausentes.
- A análise de variância de uma característica “[...] é utilizada para identificar características cujos valores não se alteram muito (baixa variância)” (CAETANO, 2018b, p. 84).
- Na análise de correlação, “[...] as características altamente correlatas são identificadas e se escolhe uma característica de cada par de características correlatas” (CAETANO, 2018b, p. 84).
- Na PCA ou redução de dados vertical são realizadas combinações lineares das n características de um conjunto de dados, resultando em um novo conjunto de dados criado diferente do conjunto original.
- Na PCA ou redução de dados vertical a regra de ouro para escolher os k componentes principais é escolher os componentes em que a variância total acumulada esteja entre 70% a 95% da variância do próprio conjunto.
- A análise por componentes principais ajuda a identificar grupo com custo computacional baixo, podendo ser aplicada em qualquer conjunto de dados numéricos que tenha mais de duas dimensões.

- A PCA também é chamada de Karhunen-Loeve ou Método K-L.
- Se tivermos um conjunto de dados em análise que possua N vetores de dados (tuplas) e K atributos (dimensões). A PCA busca por c tuplas ortonormais de dimensão k , que possam ser usadas na melhor representação dos dados ($c \leq k$). Dessa forma, os dados originais são projetados em um espaço com menor dimensão, resultante da redução dos dados.
- Os procedimentos básicos realizados na PCA são: os dados de entrada são normalizados; PCA computa c vetores ortonormais que forneçam uma base para os dados de entrada normalizados; os componentes principais são ordenados em ordem decrescente de variância e é realizado a redução dos componentes mais fracos.
- A redução de valores é vista como uma alternativa viável frente a alternativa de corte de atributos que ocorre na PCA, podendo ser nominal ou contínuo (discreto).
- O método de redução de valores nominais pode ser utilizado apenas em variáveis nominais.
- O método de redução de valores contínuos (ou discretos) podem ser aplicados somente em variáveis contínuas ou discretas.
- Uma variável nominal tem um número finito, possivelmente grande, de diferentes valores e esses valores não possuem ordenação.
- Uma variável contínua ou discreta tem um relacionamento de ordenação entre os seus valores.
- Dois métodos na redução de valores nominal: a identificação de hierarquia entre atributos e a identificação de hierarquia entre valores.
- Na identificação de hierarquia entre atributos os dados de entrada são normalizados de maneira que os valores de todos os atributos fazem parte da mesma faixa de valores.
- Na identificação de hierarquia entre valores os c vetores ortonormais computados pela análise de componentes principais são unitários, norma igual a 1, cujo rumo é perpendicular referente aos demais, cujos vetores são chamados componentes principais.
- Na identificação de hierarquia entre valores, os dados de entrada conseguem representar a combinação linear dos componentes principais.

- Seis métodos na redução de valores contínuo ou discreto: particionamento em células da mesma cardinalidade, redução de valores pelas medianas das células, redução de valores pelas médias das células, redução de valores pelos limites das células, arredondamento de valores e o agrupamento de valores.
- No particionamento em células da mesma cardinalidade, os valores são agrupados em células com o mesmo número de elementos em cada uma delas.
- No particionamento em células da mesma cardinalidade, a última célula pode conter mais valores em função de um número de valores que não seja múltiplo do número de células.
- No particionamento em células da mesma cardinalidade, os valores originais são substituídos pela identificação de cada célula, gerando um novo conjunto de dados.
- Na redução de valores pelas medianas das células o procedimento é igual ao descrito para o método de particionamento em células da mesma cardinalidade, porém, depois, é calculada a mediana de cada uma das células.
- Na redução de valores pelas medianas das células, os valores originais são substituídos pela mediana associada a cada célula, gerando um novo conjunto de dados.
- Na redução de valores pela média das células, o procedimento é parecido com o procedimento na redução de valores pela mediana das células.
- Na redução de valores pela média das células, os valores originais são substituídos pela média associada a cada célula, gerando um novo conjunto de dados.
- Na redução de valores pelos limites das células, é realizado o mesmo procedimento em que ao descrito para o método de particionamento em células da mesma cardinalidade, porém, em seguida, os valores nos extremos das células são considerados.
- Na redução de valores pelos limites das células o procedimento ainda calcula a distância de cada valor em relação aos extremos de cada célula.
- Na redução de valores pelos limites das células, o valor original é substituído pelo valor do extremo mais próximo, gerando um novo conjunto de dados.
- O arredondamento de valores também é chamado de aproximação de valores, sendo uma função comum do nosso cotidiano.

- O agrupamento de valores (ou clusterização) consiste em realizar o agrupamento de valores de um atributo em grupos (*clusters*), considerando a similaridade que existe entre os valores.
- O processo de agrupamento de valores (ou clusterização) basicamente tenta minimizar a similaridade dos dados pertencentes ao mesmo *cluster* e maximizar a similaridade dos dados em *clusters* diferentes.
- Uma vez que o concluído o processo de agrupamento de valores (ou clusterização), cada *cluster* pode passar a ter sua representação pela média dos valores a ele atribuídos.



Ficou alguma dúvida? Construímos uma trilha de aprendizagem pensando em facilitar sua compreensão. Acesse o QR Code, que levará ao AVA, e veja as novidades que preparamos para seu estudo.





1 Existem problemas na análise de dados em que o conjunto de dados é muito grande. Nesses casos, a dimensão é justamente relacionada a quantidade de características existentes no conjunto de dados. Pode-se dizer que quanto maior for o número de características, maior será a dimensão do problema. Nesse sentido, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () Grandes dimensões implicam em um baixo custo para executar algoritmos de *Machine Learning*.
- () A redução de dados também é conhecida como exclusão de dados.
- () A redução de dados compreende identificar quais informações, dentre as existentes, devem de fato ser consideradas durante o processo.

Assinale a alternativa com a sequência CORRETA:

- a) () V – F – V.
- b) () V – V – V.
- c) () F – F – F.
- d) () F – F – V.

2 A redução de dados é uma transformação com o intuito de reduzir os tempos necessários para realizar análises, facilitar tanto a manutenção dos dados quanto a análise dos dados. Além disso, a redução de dados visa reduzir os custos computacionais. Segundo Caetano (2018b), dentre as abordagens mais conhecidas para reduzir os dados, estão: Principal Component Analysis (PCA), também conhecida como redução de dados vertical e pela Seleção das melhores características. Referente à seleção das melhores características, analise as sentenças, classificando com V as sentenças verdadeiras e com F as sentenças falsas:

- () A seleção das melhores características pode ser executada com: eliminação de valores ausentes, análise da variância e análise de correlação.
- () A eliminação de valores ausentes tem como objetivo a eliminação das características que contém valores ausentes.
- () Na análise de variância de uma característica as características altamente correlatas são identificadas e se escolhe uma característica de cada par de características correlatas.

Assinale a alternativa com a sequência CORRETA:

- a) () V – F – V.
- b) () V – V – V.
- c) () F – F – F.
- d) () F – F – V.

3 Na abordagem PCA ou redução de dados vertical são realizadas combinações lineares das n características de um conjunto de dados, resultando em um novo conjunto de dados criado diferente do conjunto original. Referente à PCA, escolha a alternativa CORRETA:

- a) () Existe ganho de informação, devido que é utilizada uma quantidade de dados menor na representação de um mesmo problema.
- b) () Os dados são caracterizados, ficando em seu estado original.
- c) () A análise é fácil devido que os dados ficam em seu estado original.
- d) () A seleção dos k componentes principais devem ser realizadas pelos componentes cuja variância total acumulada esteja entre 70% a 95% da variância do conjunto.

4 Podemos exemplificar a PCA da seguinte forma: se tivermos um conjunto de dados em análise que possua N vetores de dados (tuplas) e K atributos (dimensões). A PCA busca por c tuplas ortonormais de dimensão k , que possam ser usadas na melhor representação dos dados ($c \leq k$). Dessa forma, os dados originais são projetados em um espaço com menor dimensão, resultante da redução dos dados. A PCA, devido a essas características, também é conhecida como:

- a) () Identificação de Hierarquia entre atributos.
- b) () Identificação de Hierarquia entre valores.
- c) () Karhunen-Loeve ou Método K-L.
- d) () Redução de valores pelos limites das células.

5 A redução de valores é uma alternativa viável frente a alternativa de corte de atributos que acontece pela redução de valores vertical ou PCA, podendo ser do tipo nominal ou do contínuo (discreto) O método de redução de valores nominais pode ser utilizado apenas em variáveis nominais, enquanto o método de redução de valores contínuos (ou discretos) podem ser aplicados somente em variáveis contínuas ou discretas. Referente aos métodos de redução de valores é INCORRETO apenas a sentença:

- a) () Na identificação de hierarquia entre atributos os dados de entrada são normalizados de maneira que os valores de todos os atributos fazem parte da mesma faixa de valores.
- b) () No particionamento em células da mesma cardinalidade os valores originais são substituídos pela mediana associada a cada célula, gerando um novo conjunto de dados.
- c) () Na identificação de hierarquia entre valores os dados de entrada conseguem representar a combinação linear dos componentes principais.
- d) () Na redução de valores pelos limites das células o valor original é substituído pelo valor do extremo mais próximo, gerando um novo conjunto de dados.

ANÁLISE EXPLORATÓRIA DE DADOS

OBJETIVOS DE APRENDIZAGEM

A partir do estudo desta unidade, você deverá ser capaz de:

- compreender a história da análise exploratória de dados;
- conhecer técnicas de análise exploratória de dados;
- conhecer a atividade de construção do conjunto de características;
- realizar a análise da distribuição dos valores do conjunto de características;
- visualizar e explorar dados do conjunto;
- visualizar a análise da distribuição dos valores;
- codificar a caracterização de dados no R;
- compreender bibliotecas de gráficos;
- entender os descritores estatísticos com pandas, a representação gráfica com matplotlib e conhecer gráficos de pares com seaborn.

PLANO DE ESTUDOS

Esta unidade está dividida em três tópicos. No decorrer da unidade, você encontrará autoatividades com o objetivo de reforçar o conteúdo apresentado.

TÓPICO 1 – EXPLORAÇÃO DE DADOS

TÓPICO 2 – VISUALIZAÇÃO DE DADOS

TÓPICO 3 – DESCRITORES ESTATÍSTICOS COM PANDAS, A REPRESENTAÇÃO GRÁFICA COM MATPLOB LIB EOS GRÁFICOS DE PARES COM SEABORN



Preparado para ampliar seus conhecimentos? Respire e vamos em frente! Procure um ambiente que facilite a concentração, assim absorverá melhor as informações.



EXPLORAÇÃO DE DADOS

1 INTRODUÇÃO

John W. Tukey foi quem definiu a expressão Exploratory Data Analysis (EDA) e fez contribuições significativas tanto para as ciências físicas quanto para as ciências sociais. Referente especificamente à análise exploratória de dados, de acordo com Kenneth, Trinity e Dublin (2011), suas contribuições inovadoras incluíram o algoritmo de transformação rápida de Fourier e a EDA, mudando o uso da estatística descritiva por meio da EDA, assim como a linguagem e o paradigma da estatística ao fazê-lo.

Curiosamente, é difícil, se não impossível, encontrar uma definição precisa da EDA nos escritos de Tukey (1977). Ele introduziu a EDA ao descrever suas características e ao criar ferramentas. Nas suas descrições Kenneth, Trinity e Dublin (2011) enumeram as seguintes características, como sendo que:

- Três das principais características da análise de dados se referem: (i) apresentação gráfica; (ii) flexibilidade no ponto de vista e nas instalações; (iii) busca intensiva de parcimônia e simplicidade (JONES, 1986).
- Na análise exploratória de dados, não se pode substituir a flexibilidade para se adaptar ao que é calculado, e o que esperamos traçar. Isso vale tanto para as necessidades da situação quanto para os dados que já foram fornecidos (JONES, 1986).
- Histograma deve ser visto como antiquado (JONES, 1986).
- A análise exploratória de dados não precisa de probabilidade, significância ou confiança (JONES, 1986).
- A análise exploratória de dados é ativamente incisiva e não passivamente descritiva, com ênfase real na descoberta do inesperado.
- Análise exploratória de dados é uma atitude, um estado de flexibilidade, uma disposição para procurarmos as coisas que acreditamos que não existem, bem como aquelas que acreditamos que estejam lá.
- A análise exploratória de dados isola padrões e características dos dados e os revela com força ao analista (HOAGLIN; MOSTELLER; TUKEY, 1983).
- Jones (1986) coloca que, se precisarmos de uma breve sugestão referente o que é a EDA, seria: atitude flexibilidade e algum papel de gráfico ou transparências, ou ainda ambos.



Segundo Muniz (2017), a análise exploratória de dados tem como objetivo controlar a qualidade dos dados, descobrir padrões e formular hipóteses (para estudos futuros), avaliar premissas dos testes estatísticos planejados e “sentir o jeitão” dos dados.

Neste tópico, vamos apresentar uma seleção de técnicas de EDA, incluindo tabelas, resumos de cinco números, exibições de caule e folhas, matrizes de dispersão, plotagens de caixas, plotagens residuais, outliers, plotagens de bolsas, *smoothers*, reexpressões e polimento mediano.

2 TÉCNICAS DE ANÁLISE EXPLORATÓRIA DE DADOS

O uso dessas ferramentas objetiva procurar os dados para a estrutura ou a falta dela. Algumas dessas ferramentas da EDA serão ilustradas aqui, empregando dados das eleições presidenciais dos EUA de 1952 a 2008. A Tabela 1 mostra a porcentagem de votos que os democratas receberam nos estados da Califórnia, Oregon e Washington naqueles anos. As porcentagens dos candidatos republicanos e de terceiros não são uma preocupação atual. Na EDA, procura-se displays e quantidades que forneçam insights, compreensão e surpresas. Essas informações estão baseadas em Kenneth, Trinity e Dublin (2011).

Tabela

Uma tabela é o objeto mais simples da EDA. A tabela serve simplesmente para organizar os dados de uma maneira conveniente, conforme estudamos na Unidade 2.

TABELA 1 – PORCENTAGENS DOS VOTOS EXPRESSOS PARA O CANDIDATO DEMOCRATA NAS ELEIÇÕES PRESIDENCIAIS DOS ESTADOS UNIDOS NO PERÍODO DE 1952 A 2008

Table 1	Percentages of the Votes Cast for the Democratic Candidate in the Presidential Years 1952–2008														
	Year														
State	1952	1956	1960	1964	1968	1972	1976	1980	1984	1988	1992	1996	2000	2004	2008
California	42.7	44.3	49.6	59.1	44.7	41.5	47.6	35.9	41.3	47.6	46.0	51.1	53.4	54.3	61.0
Oregon	38.9	44.8	44.7	63.7	43.8	42.3	47.6	38.7	43.7	51.3	42.5	47.2	47.0	51.3	56.7
Washington	44.7	45.4	45.4	62.0	47.2	38.6	46.1	37.3	42.8	50.1	45.1	49.8	50.2	52.8	57.7

Source: Statistical Abstracts of the U.S. Census Bureau.

FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

2.1 SUMÁRIO DE CINCO-NÚMEROS (FIVE-NUMBER)

Dado um conjunto de números, o resumo de cinco números consiste nos quartis maior, menor, mediano e superior e inferior. Esses números são úteis para auditar um conjunto de dados e ter uma ideia dos dados. Algumas ferramentas de maior complexidade da análise exploratória de dados podem ser fundamentadas nelas.

QUADRO 1 – RESUMO DE CINCO NÚMEROS PARA AS PORCENTAGENS DE DEMOCRATAS DA CALIFÓRNIA				
Minimum	Lower Quartile	Median	Upper Quartile	Maximum
35.9	43.50	47.6	52.25	61.0

FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

2.2 EXIBIÇÃO DE CAULE E FOLHAS (STEM-AND-LEAF)

Ao exibir determinado conjunto de dados, algumas vezes, exibirmos somente as informações condensadas. É mais adequado do que mostrarmos todas as informações em uma tabela.

FIGURA 1 – EXIBE CAULES E FOLHAS, COM ESCALAS DE 1 E 2, PARA OS DADOS DEMOCRÁTICOS DA CALIFÓRNIA




FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

Como podemos ver, existem caules e folhas. A haste é uma linha com um valor. Veja os números à esquerda do |. As folhas são números em uma haste, as partes à direita dos valores exibidos. Ao usarmos esta exibição, podemos ler, em vários quartis, o resumo de cinco números aproximadamente; veja indicações de assimetria; e inferir vários modos (KENNETH; TRINITY; DUBLIN, 2011).

2.3 EXIBIÇÃO SCATTERPLOT MATRIX

A seguir, apresentaremos gráficos de dispersão individuais para os pares de estados. Os estados considerados são Califórnia (CA), Oregon (OR); Washington (WA). Os pares de estados são: (CA, OR), (CA, WA) e (OR, WA).

FIGURA 2 – DISPERSÃO DE PORCENTAGENS PARA OS ESTADOS VERSUS PORCENTAGENS PARA OS ESTADOS EM PARES



FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

Dessa forma, está se utilizando gráficos de dispersão de porcentagens para os estados versus a porcentagem para cada par de estados. Uma linha de mínimos quadrados foi adicionada em cada exibição para fornecer uma referência. Pela referida figura, é possível perceber os valores x e y permanecendo juntos. Uma vantagem dessa figura em relação aos três gráficos de dispersão individuais é que os gráficos podem ser vistos simultaneamente.




2.4 EXIBIÇÃO POR *OUTLIERS*

Exploramos os *outliers* na Unidade 2. Como vimos, um *outlier* é uma observação surpreendentemente longe de algum valor central, ou seja, é um valor incomum referente a maioria dos dados. Quantidades comumente calculadas, como médias e linhas de mínimos quadrados, podem ser afetadas por esses valores. Portanto, são necessários métodos para detectar as discrepâncias existentes e moderar os efeitos causados.

Até o momento, não foi encontrado nenhum *outlier* claro nas ferramentas vistas anteriormente. Por exemplo, um gráfico de caixa consiste em um retângulo com os lados superior e inferior nos níveis dos quartis, uma linha horizontal adicionada ao nível da mediana e bigodes, com comprimento 1,5 vezes o intervalo interquartil, adicionado nas partes superior e inferior. Esse tipo é baseado em valores numéricos e os pontos fora desses limites são plotados, sendo possível verificar os valores que são discrepantes.

GRÁFICO 1 – CAIXAS PARALELAS PARA AS PORCENTAGENS, UMA PARA CADA ESTADO




FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

Quando mais de um gráfico de caixa estiver presente em uma figura, eles são chamados de gráficos de caixa paralelos. O referido gráfico é de caixa paralela para os dados presidenciais, no qual os valores da Califórnia tendem a ser mais altos que os valores de Oregon e Washington, mostrando um único *outlier* cada e um desvio para valores mais altos. Os valores extremos em ambos casos são para a eleição de 1964 (KENNETH; TRINITY; DUBLIN, 2011).

2.5 RESIDUAL PLOTS

Esse tipo de exibição é outra ferramenta para detectar discrepâncias e observar padrões fora do comum. Considere que haja um ajuste nos dados, digamos, uma linha de mínimos quadrados. Os resíduos são as diferenças entre os dados e seus valores correspondentes ajustados.


GRÁFICO 2 – PORCENTAGENS INDIVIDUAIS DOS DEMOCRATAS ESTADUAIS VERSUS OS ANOS ELEITORAIS



FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

A série temporal dos três estados rastreia cada um ao outro, existindo uma sugestão de um *outlier* em cada parcela. O gráfico anterior apresenta os resíduos para os três estados.

GRÁFICO 3 – RESÍDUOS DA LINHA DOS MÍNIMOS QUADRADOS VERSUS ANO COM ADIÇÃO DE 0 LINHAS




FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

Cada exibição apresentada mostra um *outlier* próximo ao topo, no qual cada um deles correspondendo ao ano de 1964, para os estados da Califórnia (CA), de Oregon (OR) e Washington (WA). Cabe voltarmos na história e lembrarmos que este foi o primeiro ano após o assassinato de John Kennedy e Lyndon Johnson recebeu um voto de simpatia significativa. Outro fato que cabe destacar, é que existem sugestões de dependência temporal. Além disso, com os grandes conjuntos de dados de hoje, deseja-se lidar com *outliers* e outros valores incomuns. Fala-se de métodos resistentes, sendo os métodos resistentes os que não são excessivamente sensíveis à presença de *outliers* e os robustos sendo os que não são fortemente afetados por caudas longas na distribuição. No caso de dados bivariados, pode-se considerar *bag plot* (KENNETH; TRINITY; DUBLIN, 2011).

2.6 BAG PLOTS

Pode-se dizer que a visualização *bag plots* é uma generalização da visualização por box plots. Comumente, é uma forma conveniente de estudar a dispersão dos dados bivariados. Na construção de um *bag plot* é necessária uma mediana bivariada, análoga dos quartis e *whiskers*, desenvolvido por Tukey (1977). O centro do *bag plots* é a mediana de Tukey (1977). A “bolsa” (*bag*) circunda o centro e contém 50% das observações com a maior profundidade. A “cerca” (*fence*) separa *inliers* de *outliers*. As linhas conhecidas como *whiskers* marcam observações entre a *bag* and the *fence*. A *fence* é obtida inflando a *bag*, do centro, pelo fator três.

GRÁFICO 4 – BAG PLOTS POR PAR DE ESTADOS, PORCENTAGENS VERSUS PORCENTAGENS



FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)


Observa-se uma aparente discrepância nos casos Califórnia versus Oregon e Califórnia versus Washington. Curiosamente, não existe um caso para Oregon versus Washington. Na inspeção, vê-se que os valores extremos correspondem às eleições de 1964. Ainda, é possível verificar que os pontos vagamente cercam uma linha. Devido à resistência da plotagem de malas a outliers, o ponto incomum não afeta sua localização e forma.

2.7 SMOOTHER

Smoother tem como objetivo substituir a dispersão de pontos por uma *smooth curve*. Às vezes, o efeito de suavização é meio drástico e ocorre uma sinalização. A curva resultante da suavização pode ser uma linha reta, na qual muitas vezes, um ajuste de mínimos quadrados local pode ser empregado com as curvas locais, $y = f(x)$, um quadrático. O caractere local é frequentemente introduzido empregando um kernel. Um segundo kernel pode ser introduzido para tornar a operação robusta/resistente. Desta forma, se reduz o impacto de pontos com grandes resíduos.

O gráfico a seguir trará o resultado da suavização local das percentagens democratas em função do ano eleitoral. O procedimento empregado foi o loess. As curvas têm uma aparência geral semelhante, no qual eles são puxados pelo *outlier* no ponto do ano de 1964.

GRÁFICO 5 – PORCENTAGENS VERSUS ANO COM UMA CURVA DE LOESS SOBREPOSTA




FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

2.8 ROBUST VARIANT

Até certo ponto, podemos dizer que o comportamento das eleições do ano de 1964 é compreensível. Contudo, gostaríamos de ter uma forma automática de obter uma curva não tão fortemente afetada por esse erro. O procedimento loess possui uma variante robusta/resistente e os resultados serão apresentados a seguir.

GRÁFICO 6 – AS CURVAS TRAÇADAS AGORA SÃO RESISTENTES A VALORES DISCREPANTES



FONTE: Adaptado de Kenneth, Trinity e Dublin (2011)

Após termos a compreensão que as eleições do ano de 1964 foi um caso incomum, pode-se usar uma curva robusta para entendermos melhor outros valores. As parcelas têm formas semelhantes. Pode-se observar que existe um crescimento geral nas percentagens democratas a partir de 1980. Neste procedimento de duas etapas, é importante estudar tanto a curva externa quanto a robusta/resistente (KENNETH; TRINITY; DUBLIN, 2011).


2.9 REEXPRESSION

A *reexpression* refere-se a se ter uma expressão de mesma informação por números diferentes. Por exemplo, utilizando $\text{logit} = \log(p/(1-p))$ ao invés da proporção p . O objetivo pode ser tanto a aditividade quanto obter retidão ou simetria ou ainda tornar a variabilidade mais uniforme. Esse método é uma ferramenta para se trabalhar com tabelas bidirecionais (KENNETH; TRINITY; DUBLIN, 2011).

2.10 MEDIAN POLISH

O *median polish* é um processo que visa encontrar e subtrair medianas de linhas e colunas alternadamente. Esse processo deve ser realizado até o momento que o seu resultado não mudar muito. Um dos objetivos aqui é buscar um modelo aditivo para uma tabela bidirecional, quando existirem dados discrepantes. As porcentagens de estado apresentadas a seguir formam o exposto 3×15 e um forte candidato a ser a *median polish*.

GRÁFICO 7 – EXEMPLIFICAÇÃO DE VISUALIZAÇÃO POR *MEDIAN POLISH*



FONTE: Kenneth, Trinity e Dublin (2011)

Esse resultado não deve ser fortemente afetado pelos valores discrepantes.

RESUMO DO TÓPICO 1

Neste tópico, você aprendeu que:

- John W. Tukey foi quem definiu a expressão Exploratory Data Analysis (EDA).
- John W. Tukey fez contribuições significativas tanto para as ciências físicas quanto para as ciências sociais.
- John W. Tukey fez contribuições inovadoras, incluindo o algoritmo de transformação rápida de Fourier e a EDA.
- John W. Tukey mudou o uso da estatística descritiva por meio da EDA, bem como mudou a linguagem e o paradigma da estatística ao fazê-lo.
- Três das principais características da análise de dados se referem: apresentação gráfica; flexibilidade no ponto de vista e nas instalações; busca intensiva de parcimônia e simplicidade.
- Na análise exploratória de dados, não se pode substituir a flexibilidade para se adaptar ao que é calculado, e o que esperamos traçar. Isso vale tanto para as necessidades da situação, quanto para os dados que já foram fornecidos.
- A análise exploratória de dados é ativamente incisiva e não passivamente descritiva, com ênfase real na descoberta do inesperado.
- Análise exploratória de dados é uma atitude, um estado de flexibilidade, uma disposição para procurarmos as coisas que acreditamos que não existem, bem como aquelas que acreditamos que estejam lá.
- A análise exploratória de dados isola padrões e características dos dados e os revela com força ao analista.
- Se precisarmos de uma breve sugestão referente o que é a EDA, seria: atitude flexibilidade e algum papel de gráfico ou transparências, ou ainda ambos.
- Dado um conjunto de números, o resumo de cinco números consiste nos quartis maior, menor, mediano e superior e inferior. Esses números são úteis para auditar um conjunto de dados e ter uma ideia dos dados.
- Ao exibir determinado conjunto de dados, algumas vezes, exibirmos somente as informações condensadas é mais adequado do que mostrarmos todas as informações em uma tabela, como a exibição de caule e folhas (*stem-and-leaf*).

- Uma vantagem da exibição *scatterplot matrix* em relação aos gráficos de dispersão individuais é que os gráficos podem ser vistos simultaneamente.
- Um *outlier* é uma observação surpreendentemente longe de algum valor central, ou seja, é um valor incomum referente a maioria dos dados.
- Quando mais de um gráfico de caixa estiver presente em uma figura, eles são chamados de gráficos de caixa paralelos.
- *Residual plots* é outra ferramenta para detectar discrepâncias e observar padrões fora do comum.
- A visualização *bag plots* é uma generalização da visualização por *box plots*.
- Na construção de um *bag plot* é necessária uma mediana bivariada, análoga dos quartis e *whiskers*, desenvolvido por Tukey (1977) e seus colaboradores.
- O centro do *bag plots* é a mediana de Tukey (1977).
- Smoother têm como objetivo substituir a dispersão de pontos por uma *smooth curve*.
- A curva resultante da suavização pode ser uma linha reta, na qual muitas vezes, um ajuste de mínimos quadrados local pode ser empregado com as curvas locais, $y = f(x)$, um quadrático. O caractere local é frequentemente introduzido empregando um kernel. Um segundo kernel pode ser introduzido para tornar a operação robusta/resistente. Desta forma, se reduz o impacto de pontos com grandes resíduos.
- A *reexpression* refere-se a se ter uma expressão de mesma informação por números diferentes. Por exemplo, utilizando $\text{logit} = \log(p/(1-p))$ ao invés da proporção p .
- O objetivo da *reexpression* pode ser tanto a aditividade quanto obter retidão ou simetria ou ainda tornar a variabilidade mais uniforme.
- A *reexpression* método é uma ferramenta para se trabalhar com tabelas bidirecionais.
- O *median polish* é um processo de encontrar e subtrair medianas de linhas e colunas alternadamente e, provavelmente, continuar fazendo esse processo até que os resultados não mudem muito.
- Um dos objetivos do *median polish* é buscar um modelo aditivo para uma tabela bidirecional, na presença de dados discrepantes.

- A construção do conjunto de características é o processo de transformar dados brutos em características que melhor representam o modelo definido pelo entendimento do problema.
- Os valores podem ser tanto numéricos quanto categóricos.
- Valores contínuos são valores que representam medidas que podem ter fração (ex.: temperatura).
- Valores discretos são valores que não podem ter fração (ex.: número de clientes).
- Valores ordinais indicam uma organização e hierarquia dos valores (ex.: número de estrelas em uma revisão).
- Se a característica for numérica, podemos fazer várias operações como: análise da tendência central, análise da dispersão e análise visual dos dados.
- Em características categóricas as análises mais comuns são as análises visuais que mostram a distribuição dos valores.
- Estatísticas de tendência central incluem a média, referente ao valor médio do conjunto; a mediana, relacionado ao valor que está no meio do conjunto; e a moda, referente ao valor que mais se repete no conjunto.
- Estatísticas de dispersão incluem a variância e desvio padrão, referente as medidas de distâncias dos valores com a média; alcance, referente ao valor máximo e valor mínimo do conjunto e medidas de posição, referente a identificar os valores até uma determinada posição (0-25%, 25%-50%).
- As análises visuais mais frequentes são a Função de Distribuição Acumulada, também conhecida pelo seu termo em inglês Cumulative Distribution Function (CDF) e os histogramas.
- Na Função de Distribuição Acumulada a visualização é de como as probabilidades estão associadas aos valores.
- Apesar do histograma ser uma das análises visuais mais frequentes, cabe lembrar que Jones (1986) coloca, que devemos o ver como antiquado.



1 John W. Tukey foi quem definiu a expressão Exploratory Data Analysis (EDA) e fez contribuições significativas tanto para as ciências físicas quanto para as ciências sociais. Referente especificamente a análise exploratória de dados. Diante do contexto, analise as sentenças e classifique com V para as sentenças verdadeiras e com F para as sentenças falsas:

- () As contribuições inovadoras incluíram o algoritmo de transformação rápida de Fourier e a EDA.
- () Pode-se dizer que ele mudou o uso da estatística descritiva por meio da EDA.
- () Elo também mudou a linguagem e o paradigma da estatística ao ter mudado o uso da estatística descritiva por meio da EDA.

Assinale a alternativa com a sequência CORRETA:

- a) () V – V – F.
- b) () F – F – V.
- c) () F – V – F.
- d) () V – V – V.

2 Curiosamente, é difícil, se não impossível, encontrar uma definição precisa da EDA nos escritos de Tukey (1977). Ele introduziu a EDA ao descrever suas características e ao criar ferramentas. Nas suas descrições Kenneth, Trinity e Dublin (2011) enumeram as seguintes características, como sendo que:

- a) () Três das principais características da análise de dados se referem: (i) apresentação gráfica; (ii) flexibilidade no ponto de vista e nas instalações; (iii) busca intensiva de parcimônia e simplicidade.
- b) () Na análise exploratória de dados, é possível substituir a flexibilidade para se adaptar o que o que é calculado, e o que esperamos traçar.
- c) () Os histogramas devem ser vistos como inovadores.
- d) () Análise exploratória de dados é passivamente descritiva, com ênfase real na descoberta do esperado.



3 Dado um conjunto de números, o resumo de cinco números consiste nos quartis maior, menor, mediano e superior e inferior. Esses números são úteis para auditar um conjunto de dados e ter uma ideia dos dados. Algumas ferramentas de maior complexidade da análise exploratória de dados podem ser fundamentadas nelas. Qual sentença está ilustrando o sumário de cinco números?

a) ()

Minimum	Lower Quartile	Median	Upper Quartile	Maximum
35.9	43.50	47.6	52.25	61.0

b) ()

3 6	3 6
4 12345688	4 1234
5 01349	4 5688
6 1	5 0134
	5 9
	6 1



4 *Residual Plots* é outra ferramenta para detectar discrepâncias e observar padrões fora do comum. Considere que haja um ajuste nos dados, digamos, uma linha de mínimos quadrados. Os resíduos são as diferenças entre os dados e seus valores correspondentes ajustados. Qual alternativa exemplifica a exibição de gráficos das porcentagens individuais dos democratas estaduais versus os anos eleitorais?


a) ()

Minimum	Lower Quartile	Median	Upper Quartile	Maximum
35.9	43.50	47.6	52.25	61.0


b) ()

3 6	3 6
4 12345688	4 1234
5 01349	4 5688
6 1	5 0134
	5 9
	6 1

c) ()



d) ()



5 Ao exibir determinado conjunto de dados, algumas vezes, somente as informações condensadas é mais adequado do que mostrarmos todas as informações em uma tabela. Qual alternativa apresenta a exibição de tronco e folha, ou seja, traz a exibição *stem-and-leaf*?


a) ()

Minimum	Lower Quartile	Median	Upper Quartile	Maximum
35.9	43.50	47.6	52.25	61.0


b) ()

3 6	3 6
4 12345688	4 1234
5 01349	4 5688
6 1	5 0134
	5 9
	6 1

c) ()



d) ()





VISUALIZAÇÃO DE DADOS

1 INTRODUÇÃO

O objetivo básico da visualização de dados é fornecer uma exibição gráfica eficiente para resumir e raciocinar sobre as informações quantitativas. A visualização de dados deve ser diferenciada de outros tipos de visualização usados na ciência política, sendo elas: (i) visualização de informações e conhecimentos mais gerais, (ii) visualização de conceitos, (iii) visualização de estratégias e fluxos de trabalho, (iv) visualização de metáforas etc., pois é mais específico para a representação de dados quantitativos existentes na forma de tabelas numéricas.

As abordagens de visualização de dados podem ser classificadas em vários grupos, começando com a criação de gráficos e diagramas informativos, como os gráficos e infográficos estatísticos, até métodos estatísticos avançados para visualizar tabelas multidimensionais, que contenham informações categóricas como de informações numéricas.

Nesse sentido, Priceconomics (2016) coloca que a visualização de dados está relacionada a como “digerimos” as informações. Nas últimas décadas, houve uma explosão no uso de gráficos e um reconhecimento de como a mente humana conhecer processar dados de maneira visual. Temos até um provérbio que uma imagem fale mais que mil palavras. A ascensão da visualização coincidiu, provavelmente não por coincidência, com uma formalização e uma consideração mais profunda do que funciona melhor ao tentar transmitir informações de maneira gráfica.

É domínio geral, que o estatístico William Cleveland possivelmente é a pessoa que seja mais responsável por dar à visualização de dados uma base científica. Seus estudos sobre percepção gráfica, bem como referente aos processos cognitivos utilizados pelas pessoas para compreender um gráfico estão entre as primeiras tentativas de estudar a visualização e desenvolver uma teoria de como ela deve ser melhor executada. Portanto, William Cleveland é pioneiro em visualização de dados.

Praticamente, os gráficos de maior clareza e minimalistas devem na sua grande maioria, muito ao trabalho realizado por William Cleveland. Sua pesquisa também é a principal razão pela qual a maioria dos visualizadores de dados gostam de gráficos de barras e gráficos de dispersão, bem como tendem a não utilizar gráficos de pizza e barras empilhadas.

Como estatístico que trabalhava no início dos anos 1980, William Cleveland estava profundamente preocupado com a forma amplamente não científica pela qual estatísticos e outros cientistas estavam visualizando dados. Embora os gráficos tenham sido utilizados para representar dados desde o século XVIII, havia muito pouca teoria ou pesquisa referente como isso deveria ser feito. Na visão de Cleveland, a maioria das ideias contemporâneas sobre a visualização adequada era basicamente uma sabedoria não estruturada. Cleveland acreditava que as convenções e as melhores práticas de visualização de dados deveriam ser ferramentas amplamente utilizadas por cientistas e engenheiros (PRICEONOMICS, 2016).

É importante conhecermos um pouco da história da visualização de dados, para termos uma melhor compreensão do uso.

2 CONHECENDO UM POUCO MAIS SOBRE A VISUALIZAÇÃO DE DADOS E SUA IMPORTÂNCIA

Cleveland e McGill (1984) são referenciados até hoje. Eles (CLEVELAND; MCGILL, 1984) detalharam as tarefas cognitivas comuns que acontecem quando alguém lê um gráfico e avaliavam quão bem os sujeitos do estudo executavam essas tarefas, dependendo dos recursos do gráfico. Por exemplo: quando as pessoas olham para um gráfico de barras, alegam que a tarefa principal é julgar a “posição em uma escala comum”, ou seja, avaliar qual barra aumenta mais na escala, quanto maior etc. Quando as pessoas olham para um mapa em quais estados são saturados por uma determinada variável, a tarefa principal é avaliar a “saturação de cores”, ou seja, avaliar qual maneira é mais saturada e quanto mais ela está saturada.

Cleveland e McGill (1984) acreditavam que existem algumas “tarefas perceptivas elementares”, que as pessoas realizam ao realizarem alguma consulta gráfica. Por exemplo, a “saturação da cor”, que muitas vezes não são ilustradas para evitar aquela reprodução de cores inconveniente.

Depois de estabelecer esse paradigma de “tarefa” para pensar em gráficos, o restante da Percepção Gráfica concentra-se em compreender como as pessoas estão qualificadas em cada uma dessas tarefas. Cleveland e McGill (1984) realizaram vários ensaios clínicos randomizados para avaliar com que precisão as pessoas percebem as informações em um gráfico de barras (posição em escala comum), gráfico de setores circulares (ângulo), gráfico de barras empilhadas (área), mapas coloridos e mapas sombreados (saturação de cores e sombreamento) entre outros.

Cleveland e McGill (1984) colocam que as pessoas observam os gráficos de barras com mais precisão do que observam os gráficos de pizza, ou seja, as pessoas têm melhor percepção das informações quando estão vendo as informações em gráficos de barras, quando comparamos com as informações dispostas em gráficos de pizza. Ainda, fornecem uma hierarquia geral para os tipos de dados:

- Posição ao longo de uma escala comum (gráfico de barras, gráficos de pontos).
- Posições em escalas idênticas não alinhadas (múltiplos pequenos).
- Comprimento, direção, ângulo (gráfico de pizza).
- Área (mapa da árvore).
- Volume, curvatura (gráficos de barras de 3 Dimensões (3D), gráficos de área).
- Sombreamento, saturação de cores.

Posteriormente, Cleveland (1985) detalha, de maneira completa, sua teoria e suas crenças sobre a visualização adequada e modelado com base no clássico guia de estilo de escrita de *Strunk and White, The Elements of Style*. Cleveland (1985) teve como objetivo colocar boas práticas de visualização no mesmo nível de importância para os pesquisadores que a gramática correta.


Cleveland (1985) enfatiza a remoção de gráficos de elementos desnecessários e os elementos do gráfico que impossibilitam o destaque dos dados. Além disso, Cleveland (1985) enfatiza que as legendas devem ser mantidas fora da região de dados, as marcas de escala devem ser mantidas minimamente e os rótulos de dados não devem confundir o gráfico. Essas dicas são como os conselhos de escrita de *Strunk and White*, que se concentram em “omitir palavras desnecessárias” e usar a voz ativa.

Cleveland (1985) também aprofundou sua discussão sobre a percepção das pessoas referente aos gráficos e quais representações visuais são melhores para quais dados. Cleveland (1985) recomenda que os pontos de dados sejam colocados o mais próximo possível, porque as pessoas comparam com mais precisão os elementos que estão mais próximos. Os gráficos de pizza não fornecem detecção eficiente de objetos geométricos que transmitem informações referentes a diferenças de valores. De acordo com a pesquisa de Cleveland, a maioria das pessoas compreenderá as informações com mais rapidez e precisão se as informações estiverem dispostas em um gráfico de barras.

Segundo Cleveland (1985), as pessoas entendem os gráficos de barras alinhados substancialmente melhor do que os gráficos de barra empilhados. As pessoas cometem muito mais erros, em estimar os tamanhos relativos de uma categoria, em um gráfico de barras empilhadas do que em gráficos de barras alinhados.



À medida que a visualização de dados se torna mais criativa e interativa, ela permanece fundamentada na base científica fornecida por William Cleveland.



Convidamos você a fazer uma jornada sobre a visualização de dados e indicamos livros e *papers*.

LIVROS E PAPERS SOBRE VISUALIZAÇÃO DE DADOS

TÍTULO E LINK (QUANDO POSSÍVEL)	INFORMAÇÕES
An Approach to Providing Mathematical Annotation in Plots	Paul Murrell and Ross Ihaka, Journal of Computational and Graphical Statistics 9(3):582-599, 2000.
Creating More Effective Graphs	Naomi B. Robbins (WILEY-INTERSCIENCE, 2005).
The Elements of Graphing Data	Revised Edition by William S. Cleveland (HOBART PRESS, 1994).
The Grammar of Graphics	Leland Wilkinson (SPRINGER, 2005).
Graphics of Large Datasets	Antony Unwin, Martin Theus, Heike Hofmann (SPRINGER, 2006).
How to Display Data Badly	Howard Wainer, The American Statistician 38(2), 1984.
Interactive and Dynamic Graphics for Data Analysis: With R and GGobi	Dianne Cook and Deborah F. Swayne (Springer, 2007).
Lattice Multivariate Data Visualization with R	Deepayan Sarkar (SPRINGER, 2008).
Maps for Advocacy	Tactical Technology Collective (2008).
R Graphics	Paul Murrell (CHAPMAN; HALL/CRC, 2005).
S-PLUS Trellis Graphics User's Manual	Richard A. Becker and William S. Cleveland.
The Visual Display of Quantitative Information, 2nd Edition	Edward R. Tufte (GRAPHICS PRESS, 2001).
Visualizing Data	William S. Cleveland (HOBART PRESS, 1993).
Visualizing Data	Ben Fry (O'Reilly, 2007).
Visualizing Information for Advocacy	Tactical Technology Collective (2008).

Fonte: A Autora

3 PRINCIPAIS GRÁFICOS PARA REPRESENTAR VALORES NUMÉRICOS

Os principais gráficos para representar valores numéricos são: (i) gráfico de pontos (ou de dispersão), (ii) gráfico de caixas, (ii) histograma, (iv) gráfico de densidade, (v) gráfico violino. Para visualizar esses gráficos, vamos utilizar a base de dados Iris, disponível em archive.ics.uci.edu/ml/datasets/iris. A base de dados Iris contém características de comprimento da pétala, largura da pétala e sépala dessas flores, ou seja, contém as três espécies de flores da família.

QUADRO 2 – REPRESENTAÇÃO DE VALORES NUMÉRICOS



TIPO	DESCRIÇÃO
Gráfico de pontos ou de dispersão	Os diagramas de dispersão ou gráficos de dispersão são representações de dados de duas (tipicamente) ou mais variáveis que são organizadas em um gráfico. O gráfico de dispersão utiliza coordenadas cartesianas para exibir valores de um conjunto de dados. Os dados são exibidos como uma coleção de pontos, cada um com o valor de uma variável determinando a posição no eixo horizontal e o valor da outra variável determinando a posição no eixo vertical (em caso de duas variáveis). A seguir, observaremos o gráfico de pontos das características de Sepal Length (eixo x) e de Sepal Width (eixo y). Esse gráfico, segundo Caetano (2018b, p. 51), “[...] mostra como estão distribuídos os valores do comprimento e largura da sépala das três espécies. Com esse gráfico, é possível identificar correlações e grupos de valores”. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO PELO GRÁFICO DE PONTOS  FONTE: Adaptado de Caetano (2018b)

Gráfico de caixas ou *boxplot*

Em estatística descritiva, diagrama de caixa, diagrama de extremos e quartis, *boxplot* ou *box plot* é uma ferramenta gráfica para representar a variação de dados observados de uma variável numérica por meio de quartis. O *boxplot* tem uma reta (*whisker* ou fio de bigode) que estende-se verticalmente ou horizontalmente a partir da caixa, indicando a variabilidade fora do quartil superior e do quartil inferior. Os valores discrepantes (*outliers* ou valores atípicos), podem ser plotados como pontos individuais. O diagrama de caixa não é paramétrico, pois apresenta variação em amostras de uma população estatística sem realizar qualquer suposição da distribuição estatística subjacente. Os espaços entre as diferentes partes da caixa indicam o grau de dispersão, a obliquidade nos dados e os *outliers*. O *boxplot* também permite estimar visualmente vários L-estimadores como amplitude interquartil, *midhinge*, *range*, *midrange*, e *trimean*. Resumindo, o *boxplot* identifica em que local estão 50% dos valores mais prováveis, a mediana e os valores extremos. Essa ferramenta é usada frequentemente para analisar e comparar a variação de uma variável entre diferentes grupos de dados. A seguir, será possível visualizar o gráfico de caixas das características de Species (eixo x) e Sepal Length (eixo y), mostrando a distribuição dos valores da largura da sépala das três espécies. “Esse tipo gráfico apresenta várias informações. Por exemplo, é possível identificar o alcance dos valores, o quartil superior (medida de posição em 75%) e o quartil inferior (medida de posição em 25%), a mediana dos valores e os outliers do conjunto” (CAETANO, 2018b, p. 51-52).

EXEMPLIFICAÇÃO DA REPRESENTAÇÃO PELO GRÁFICO DE CAIXAS



FONTE: Adaptado de Caetano (2018b)







Histograma	Histograma ou distribuição de frequências é a representação gráfica em colunas ou em barras (retângulos) de um conjunto de dados previamente tabulado e dividido em classes uniformes ou não uniformes. A base de cada retângulo representa uma classe. A altura de cada retângulo representa a quantidade ou a frequência absoluta com que o valor da classe ocorre no conjunto de dados para classes uniformes ou a densidade de frequência para classes não uniformes. Quando o volume de dados aumenta indefinidamente dentro do conjunto de dados e o intervalo de classes tende a zero (o que torna os retângulos cada vez mais finos e altos), a distribuição de frequência torna-se uma distribuição de densidade de probabilidades. A construção de histogramas tem caráter preliminar em qualquer estudo e é um importante indicador da distribuição de dados. Os histogramas podem indicar se uma distribuição se aproxima de uma função normal, assim como também podem indicar a mistura de populações quando se apresentam bimodais. A seguir, poderemos observar o histograma das características de Sepal Width (eixo x) e agrupado pela característica Species. No gráfico, o eixo y está representando a frequência de valores que são observados frente a um comprimento de sépala, para uma espécie específica (CAETANO, 2018b). EXEMPLIFICAÇÃO PELA REPRESENTAÇÃO POR HISTOGRAMA DA CARACTERÍSTICA SEPAL WIDTH (EIXO X) PELA CARACTERÍSTICA SPECIES  The histogram shows the frequency of Sepal Width (x-axis, ranging from 2 to 4) for three species: setosa (red), versicolor (green), and virginica (blue). The y-axis represents Frequency, ranging from 0 to 30. The virginica species shows the highest frequency, peaking around 3.5. The versicolor species peaks around 3.0, and the setosa species peaks around 3.5. FONTE: Adaptado de Caetano (2018b)
Stacked dot plot	A representação por <i>stacked dot plot</i> é uma alternativa ao histograma quando a variável é discreta. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR STACKED DOT PLOT  The stacked dot plot shows the count of individuals (y-axis, ranging from 0.00 to 1.00) for a discrete variable (x-axis, ranging from 40 to 90). The plot shows three distinct clusters of dots, representing the distribution of the variable. The first cluster is around 50, the second around 60, and the third around 80. FONTE: Adaptado de Zeviani (2018)

Gráfico de densidade	“O gráfico de densidade é gerado como se fosse um histograma com uma classe móvel, isto é, a classe que tem uma certa amplitude, se move da esquerda para direita e em cada ponto estima a densidade probabilística da variável” (ECO R, 2016, p. 1). Tibco (2019, p. 1) ainda coloca que “o gráfico de densidade mostra como os dados numéricos, agrupados em intervalos, são distribuídos entre os eixos X e Y. Para visualizar a densidade, isto é, visualizar em que medida os marcadores se sobrepõem totalmente, a configuração Por cor é usada”. De acordo com Caetano (2018b, p. 52), “esse gráfico é semelhante ao histograma, porém ele suaviza as divisões dos bins (colunas) do histograma”. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO PELO GRÁFICO DE DENSIDADE  Fonte: Adaptado de Caetano (2018b)
Gráfico de violino ou violin plot	O violin plot é “uma representação que mistura o boxplot com o density para acomodar várias densidades conforme muda os níveis de um fator” (ZEVIANI, 2018, p. 1). A seguir, traremos o gráfico de violino com as características Sepal Length (eixo y) segundo a característica Species. De acordo com (Caetano, 2018b, p. 52), “o eixo x do gráfico mostra uma medida de densidade dos valores da característica Sepal Length. Esse gráfico mostra como estão concentrados os valores de tamanho da sépala. Por esse gráfico, é possível identificar áreas de maior e menor densidade de valores”. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR VIOLIN PLOT  Fonte: Adaptado de Caetano (2018b) A codificação é em R <code>gplot:geom_violin()</code>. EXEMPLIFICAÇÃO DO VIOLIN PLOT  Fonte: Adaptado de Zeviani (2018)

Beeswarm plot

Beeswarm plot “é uma alternativa para representar a distribuição de dados discretos” (ZEVIANI, 2018, p. 1). Pacote R beeswarm é utilizado para realizar a representação.

EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR BEESWARM PLOT




FONTE: Adaptado de Zeviani (2018)

Joyplot

O joyplot é uma “alternativa ao violin plot para representar a distribuição de uma variável conforme os níveis de outra” (ZEVIANI, 2018, p. 1).

EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR JOYLOT




FONTE: Adaptado de Zeviani (2018)

Circular plot

A representação por circular *plot* é indicada quando queremos representar a distribuição de dados cíclicos ou direcionais.

EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR JOYPLLOT



FONTE: Adaptado de Zeviani (2018)

Fonte: A Autora

4 PRINCIPAIS GRÁFICOS PARA REPRESENTAR VALORES CATEGÓRICOS



Referente à representação de valores categóricos, os principais gráficos são: (i) gráficos de balões, (ii) gráfico de mosaicos, (iii) mapa de calor, (iv) análise de série de dados temporais (ou *time series*), (v) *word cloud*, (vi) mapa em árvore (ou *treemap*), entre outros. Para essa visualização, usaremos a base de dados da kaggle, relacionado aos sobreviventes do acidente da embarcação Titanic, disponível em [kaggle.com/c/titanic](https://www.kaggle.com/c/titanic). Essa base contém dados referente a idade, ao gênero e a classe de viagem dos sobreviventes.

QUADRO 3 – REPRESENTAÇÃO VALORES CATEGÓRICOS

TIPO	DESCRIÇÃO																																																																																										
Gráfico de balões	O exposto a seguir trará a exemplificação do gráfico de balões. No gráfico, é possível perceber a relação entre a classe idade, gênero, viagem e se o passageiro sobreviveu ou morreu no naufrágio. O tamanho da área indica o número naquela posição, ou seja, quanto maior for o tamanho da área, maior é a indicação que a posição daquele número é alta. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO PELO GRÁFICO DE BALÕES Tamanho da área indica quantidade de dados <table><tr><th>Survived</th><th>Age</th><th>Sex</th><th>Class</th><th>1st</th><th>2nd</th><th>3rd</th><th>Crew</th><th>Total</th></tr><tr><td>No</td><td>Child</td><td>Male</td><td></td><td></td><td></td><td>35</td><td></td><td>35</td></tr><tr><td></td><td></td><td>Female</td><td></td><td></td><td></td><td>17</td><td></td><td>17</td></tr><tr><td></td><td>Adult</td><td>Male</td><td></td><td>158</td><td>154</td><td>587</td><td>570</td><td>1329</td></tr><tr><td></td><td></td><td>Female</td><td></td><td>4</td><td>13</td><td>89</td><td>3</td><td>109</td></tr><tr><td>Yes</td><td>Child</td><td>Male</td><td></td><td>5</td><td>11</td><td>13</td><td></td><td>29</td></tr><tr><td></td><td></td><td>Female</td><td></td><td>1</td><td>13</td><td>14</td><td></td><td>28</td></tr><tr><td></td><td>Adult</td><td>Male</td><td></td><td>57</td><td>14</td><td>75</td><td>192</td><td>338</td></tr><tr><td></td><td></td><td>Female</td><td></td><td>140</td><td>80</td><td>76</td><td>20</td><td>316</td></tr><tr><td></td><td></td><td></td><td></td><td>325</td><td>285</td><td>766</td><td>685</td><td>2201</td></tr></table>	Survived	Age	Sex	Class	1st	2nd	3rd	Crew	Total	No	Child	Male				35		35			Female				17		17		Adult	Male		158	154	587	570	1329			Female		4	13	89	3	109	Yes	Child	Male		5	11	13		29			Female		1	13	14		28		Adult	Male		57	14	75	192	338			Female		140	80	76	20	316					325	285	766	685	2201
Survived	Age	Sex	Class	1st	2nd	3rd	Crew	Total																																																																																			
No	Child	Male				35		35																																																																																			
		Female				17		17																																																																																			
	Adult	Male		158	154	587	570	1329																																																																																			
		Female		4	13	89	3	109																																																																																			
Yes	Child	Male		5	11	13		29																																																																																			
		Female		1	13	14		28																																																																																			
	Adult	Male		57	14	75	192	338																																																																																			
		Female		140	80	76	20	316																																																																																			
				325	285	766	685	2201																																																																																			
Gráfico de mosaico	A seguir, será possível observar a exemplificação do gráfico de mosaico. Nesse gráfico, é possível perceber a relação existente entre a classe tipo de pessoa: criança, mulher, homem e classe viagem. Além disso, nesta visualização podemos identificar a quantidade de pessoas pertencentes a determinada classe conforme seu tipo de pessoa. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO PELO GRÁFICO DE MOSAICOS <table><tr><th>Classe</th><th>Crianças</th><th>Mulheres</th><th>Homens</th><th>Total</th></tr><tr><td>Tripulação</td><td>20</td><td>192</td><td></td><td>212</td></tr><tr><td>3ª Classe</td><td>27</td><td>76</td><td>75</td><td>178</td></tr><tr><td>2ª Classe</td><td>24</td><td>80</td><td>14</td><td>118</td></tr><tr><td>1ª Classe</td><td>8</td><td>140</td><td>57</td><td>205</td></tr></table>	Classe	Crianças	Mulheres	Homens	Total	Tripulação	20	192		212	3ª Classe	27	76	75	178	2ª Classe	24	80	14	118	1ª Classe	8	140	57	205																																																																	
Classe	Crianças	Mulheres	Homens	Total																																																																																							
Tripulação	20	192		212																																																																																							
3ª Classe	27	76	75	178																																																																																							
2ª Classe	24	80	14	118																																																																																							
1ª Classe	8	140	57	205																																																																																							

FONTE: Adaptado de Caetano (2018b)


FONTE: Caetano (2018b, p. 55)

Mapa de calor	O mapa de calor permite que seja realizado a identificação de pontos de menor e de maior concentração de eventos, de pessoas, entre outros. O importante nesse tipo de visualização é conseguirmos identificar algum tipo de concentração. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR MAPA DE CALOR  Fonte: Adaptado de Caetano (2018b)
Análise de série de dados temporais (time series)	O exposto a seguir demonstrará a exemplificação de <i>time series</i>. Essa representação é utilizada análise de série de dados temporais. A exibição por <i>time series</i> permite que seja realizado a identificação de padrões de comportamentos em determinado período, bem como possibilita realizar várias caracterizações. Podemos citar dentre elas, tendência, determinado comportamento observado, a análise aleatória ou residual dos dados, a periodicidade dos valores. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR TIME SERIES  Fonte: Adaptado de Caetano (2018b)
Nuvem de palavras (world cloud)	A seguir, visualizaremos a exemplificação de world cloud, ou comumente conhecida como nuvem de palavras em português. A exibição de world cloud permite que seja realizado a identificação de maneira visual das palavras mais frequentes em um determinado texto, devido que quanto maior for incidência de determinadas palavras, maior será o tamanho da fonte da palavra. EXEMPLIFICAÇÃO DA REPRESENTAÇÃO POR WORLD CLOUD  Fonte: Adaptado de Caetano (2018b)

Mapa em
árvore
(*treemap*)

O exposto a seguir trará a exemplificação do *treemap*, ou como é chamado em português, do mapa em árvore. Segundo Caetano (2018b, p. 55), “esse tipo de gráfico é útil para visualizar de várias maneiras os valores, pois é possível determinar os conjuntos com mais registros e os com menos registros apenas analisando o tamanho do retângulo”. Além disso, ainda segundo Caetano (2018b, p. 55), “esse gráfico também permite analisar uma terceira variável que é a tonalidade da cor do retângulo. Essa tonalidade pode indicar maior ou menor valor relacionado ao grupo, conjunto representado pelo retângulo”.

EXEMPLIFICAÇÃO DE TREEMAP



FONTE: Caetano (2018b, p. 57)

Fonte: A Autora

RESUMO DO TÓPICO 2

Neste tópico, você aprendeu que:

- O objetivo básico da visualização de dados é fornecer uma exibição gráfica eficiente para resumir e raciocinar sobre as informações quantitativas.
- A visualização de dados deve ser diferenciada de outros tipos de visualização usados na ciência política, sendo elas: visualização de informações e conhecimentos mais gerais, visualização de conceitos, visualização de estratégias e fluxos de trabalho, visualização de metáforas etc.
- As abordagens de visualização de dados podem ser classificadas em vários grupos, começando com a criação de gráficos e diagramas informativos, como os gráficos e infográficos estatísticos, até métodos estatísticos avançados para visualizar tabelas multidimensionais, que contenham informações categóricas como de informações numéricas.
- A visualização de dados está relacionada a como “digerimos” as informações.
- Nas últimas décadas, houve uma explosão no uso de gráficos e um reconhecimento de como a mente humana conhecer processar dados de maneira visual.
- O estatístico William Cleveland possivelmente é a pessoa que seja mais responsável por dar à visualização de dados uma base científica.
- William Cleveland é pioneiro em visualização de dados.
- A pesquisa de William Cleveland é a principal razão pela qual a maioria dos visualizadores de dados gostam de gráficos de barras e gráficos de dispersão, bem como tendem a não utilizar gráficos de pizza e barras empilhadas.
- Os gráficos de maior clareza e minimalistas devem na sua grande maioria, muito ao trabalho realizado por William Cleveland.
- William Cleveland acreditava que as convenções e as melhores práticas de visualização de dados deveriam ser ferramentas amplamente utilizadas por cientistas e engenheiros.
- Existem algumas “tarefas perceptivas elementares”, que as pessoas realizam ao realizarem alguma consulta gráfica.
- Depois de estabelecer o paradigma de “tarefa” para pensar em gráficos, o restante da percepção gráfica concentra-se em compreender como as pessoas estão qualificadas em cada uma dessas tarefas.


- A hierarquia geral para os tipos de dados são: posição ao longo de uma escala comum (gráfico de barras, gráficos de pontos); posições em escalas idênticas não alinhadas (múltiplos pequenos); comprimento, direção, ângulo (gráfico de pizza); área (mapa da árvore); volume, curvatura (gráficos de barras de 3 Dimensões (3D), gráficos de área); e sombreamento, saturação de cores (mapas de calor, mapas de coropletas).
- Legendas devem ser mantidas fora da região de dados, as marcas de escala devem ser mantidas minimamente e os rótulos de dados não devem confundir o gráfico.
- Os pontos de dados devem ser colocados o mais próximo possível, porque as pessoas comparam com mais precisão os elementos que estão mais próximos.
- Os gráficos de pizza não fornecem detecção eficiente de objetos geométricos que transmitem informações referentes a diferenças de valores.
- A maioria das pessoas compreende de forma mais rápida e precisa quando as informações são exibidas em um gráfico de barras.
- As pessoas entendem os gráficos de barras alinhados substancialmente melhor do que os gráficos de barra empilhados.
- As pessoas cometem muito mais erros em estimar os tamanhos relativos de uma categoria, em um gráfico de barras empilhadas do que em gráficos de barras alinhados.
- À medida que a visualização de dados se torna mais criativa e interativa, ela permanece fundamentada na base científica fornecida por William Cleveland.
- Os principais gráficos para representar valores numéricos são: gráfico de pontos (ou de dispersão); gráfico de caixas; histograma; gráfico de densidade; gráfico violino.
- O gráfico de pontos (ou dispersão) é possível identificar correlações e grupos de valores.
- O gráfico de densidade é semelhante ao histograma, porém ele suaviza as divisões dos *bins* (colunas) do histograma.
- Pelo gráfico de violino é possível identificar áreas de maior e menor densidade de valores.
- Os principais gráficos para representar valores categóricos são: gráficos de balões, gráfico de mosaicos, mapa de calor, análise de série de dados temporais (ou *time series*), *word cloud*, mapa em árvore (*treemap*).

AUTOATIVIDADE




1 Em estatística descritiva, diagrama de caixa, diagrama de extremos e quartis, *boxplot* ou *box plot* é uma ferramenta gráfica para representar a variação de dados observados de uma variável numérica por meio de quartis. Diante disso, qual sentença ilustra o diagrama de caixa?


a) ()




b) ()



c) ()




d) ()




2 Os diagramas de dispersão ou gráficos de dispersão são representações de dados de duas (tipicamente) ou mais variáveis que são organizadas em um gráfico. O gráfico de dispersão utiliza coordenadas cartesianas para exibir valores de um conjunto de dados. Os dados são exibidos como uma coleção de pontos, cada um com o valor de uma variável determinando a posição no eixo horizontal e o valor da outra variável determinando a posição no eixo vertical (em caso de duas variáveis). Diante disso, qual sentença ilustra o gráfico de dispersão?


a) ()




b) ()



c) ()




d) ()




3 Histograma ou distribuição de frequências é a representação gráfica em colunas ou em barras (retângulos) de um conjunto de dados previamente tabulado e dividido em classes uniformes ou não uniformes. A base de cada retângulo representa uma classe. A altura de cada retângulo representa a quantidade ou a frequência absoluta com que o valor da classe ocorre no conjunto de dados para classes uniformes ou a densidade de frequência para classes não uniformes. Diante disso, qual sentença ilustra o histograma?


a) ()




b) ()



c) ()




d) ()




4 O gráfico de densidade é gerado como se fosse um histograma com uma classe móvel, isto é, a classe que tem uma certa amplitude se move da esquerda para direita e em cada ponto estima a densidade probabilística da variável. Diante disso, qual sentença ilustra a representação do gráfico de densidade?


a) ()




b) ()



c) ()




d) ()




5 O *violin plot* é uma representação que mistura o boxplot com o density para acomodar várias densidades conforme muda os níveis de um fator. No gráfico, é possível identificar áreas de maior e menor densidade de valores. Diante disso, qual sentença ilustra o *violin plot*?


a) ()




b) ()



c) ()



d) ()





DESCRITORES ESTATÍSTICOS COM PANDAS, A REPRESENTAÇÃO GRÁFICA COM MATPLOB LIB E OS GRÁFICOS DE PARES COM SEABORN

1 INTRODUÇÃO

Conforme vimos nas unidades anteriores um conjunto de dados é composto por um ou mais atributos, que o definem e são chamados de descritores. Por exemplo, ao falarmos de imagens, há vários atributos genéricos que podem ser utilizados como descritores, ou seja, que podem ser aplicados em qualquer tipo de imagem, bem como podem ser definidos ao domínio da imagem usada. Para Gonzalez *et al.* (2018, p. 75-76):

Os termos pixel e voxel são utilizados de forma intercambiável, representando a utilização de imagens 2D ou 3D. Quando utilizado o termo valor do pixel, este refere-se à intensidade no caso de imagens representadas em tons de cinza; ou à cor, no caso de imagens coloridas. Muitos atributos são calculados em função de uma série de pixels próximos, aqui denominados região de interesse. Uma região de interesse pode representar uma parte de uma imagem ou mesmo uma imagem completa.

Agora vamos ver o que é pandas. Segundo Wangenheim (2019, p. 1), "pandas é uma biblioteca em Python que permite trabalhar com grandes quantidades de dados de uma forma muito fácil: é possível carregar planilhas e tabelas, trabalhando-as do mesmo jeito que você trabalharia em um banco de dados SQL [...]". O Autor (WANGENHEIM, 2019, p. 1) ainda coloca que "[...] é possível realizar todo tipo de análise estatística, inclusive produzindo belos gráficos e é possível realizar atividades de geoprocessamento, trabalhando com dados georreferenciados, plotando mapas e realizando análises estatísticas em mapas".

Pandas (2020a, p. 1, tradução nossa) complementa que "o pandas é uma ferramenta de análise e manipulação de dados de código aberto, rápida, poderosa, flexível e fácil de usar, construída sobre a linguagem de programação Python". Para que você possa trabalhar com o pandas, sugerimos que você o instale em seu computador ou o utilize no Google Colab. Para realizar a instalação você pode utilizar o link https://pandas.pydata.org/getting_started.html disponibilizado no site do Pandas.



Nunca usou o Pandas? Confira o guia de introdução, disponível em: https://pandas.pydata.org/docs/getting_started/index.:html#getting-started. Ele contém os principais conceitos do pandas e links tutoriais adicionais. Acesse também o guia de usuário, disponível em: https://pandas.pydata.org/docs/user_guide/index.:html#user-guide, ele traz informações detalhadas sobre os principais conceitos de pandas, bem como informações e explicações úteis; o guia de referência, disponível em: <https://pandas.pydata.org/docs/reference/index.:html#api>, que contém uma descrição detalhada da API do pandas; e, por fim, o guia do desenvolvedor, disponível em: <https://pandas.pydata.org/docs/development/index.:html#development>.



Cabe destacar que o tipo de dado mais elementar em pandas é o DataFrame. O DataFrame é uma tabela. Dessa forma, em Pandas você pode fazer a mesma coisa que você faz com tabelas em sistemas de estatísticas, como por exemplo o Statistica.

Quando falamos em estatística, pode-se dizer que a área da matemática que envolve coleta, análise, interpretação e apresentação de grandes conjuntos de dados numéricos. Portanto, a estatística é relevante para a ciência de dados, usada para análise de série de situações e problemas por meio de diferentes conceitos. Agora, vamos focar em conceitos e aplicações referente a estatística descrita.

De acordo com Galvão (2016, p. 1), a estatística descritiva “[...] é a parte da Estatística que visa descrever e sumarizar um conjunto de dados. Para isso, são usadas uma série de medidas, como a famosa média”. Para exemplificar, vamos utilizar o Dataset do Titanic em conjunto com uma série mais simples do Pandas, para que possamos validar. “As medidas da Estatística Descritiva se dividem entre medidas de tendência central e medidas de dispersão” (GALVÃO, 2016, p. 1).

2 MEDIDAS DE TENDÊNCIA CENTRAL

Os valores significativos para um conjunto de dados são definidos pelas medidas de tendência central. Além disso, as medidas de tendência central definem valores que são adequados e representativos nesse conjunto, que depende do que se quer analisar. As medidas de tendência central podem ser classificadas como média, mediana, quantis e a moda apenas para que se possa conferir que está tudo sendo calculado corretamente (GALVÃO, 2016).

Média

A média é uma das medidas de tendência central utilizada para indicar o valor no qual estão centralizados (concentrados) os dados de um determinado conjunto de valores, que representam um valor importante para esse mesmo conjunto. A média no caso dos Dataframes do Pandas é calculada por meio da função `mean()` dos Dataframes, presente também nas Series do Pandas. O Quadro 4 traz a codificação para criar uma Series e o cálculo da sua média, bem como o cálculo da idade média dos passageiros do Titanic (GALVÃO, 2016).

QUADRO 4 – CODIFICAÇÃO DA MÉDIA COM O PANDAS

```
import pandas as pd
import numpy as np

train_df = pd.read_csv('train.csv')
example_series = pd.Series([1,5,10,30,50,30,15,40,45])

print(train_df['Age'].mean())
29.69911764705882

print(example_series.mean())
25.11111111111111
```

FONTE: Adaptado de Galvão (2016)

Mediana

De acordo com Galvão (2016, p. 1), “a mediana é o valor que separa a metade superior da metade inferior de uma distribuição de dados, ou o valor no centro da distribuição”. Portanto, com Galvão (2016, p. 1), “[...] se o número de observações na distribuição é ímpar, ele é o valor central, e se o número de observações é par, ele será a média das duas observações mais centrais”. O Quadro 5 traz a codificação da mediana.

QUADRO 5 – CODIFICAÇÃO DA MEDIANA COM O PANDAS

```
print(train_df['Age'].median())
28.0

print(example_series.median())
30.0
```

FONTE: Adaptado de Galvão (2016)

Pelo Quadro 5 é possível perceber que “a mediana é um conceito menos suscetível a grandes valores discrepantes do que a média” (GALVÃO, 2016, p. 1). Pelo referido quadro também é possível perceber que “se o número de observações não é muito grande e você tem uma observação que é muito maior do que os outros, a sua média pode começar a ficar menos representativa com relação à maioria do seu grupo” (GALVÃO, 2016, p. 1).

Quantil

O quantil pode ser visto como uma generalização da mediana. Assim, podemos dizer que o valor que estiver abaixo do valor que conter um determinado percentual é o quantil. A codificação do quantil pode ser vista no Quadro 6. Para tal, usamos a função `quantile()`. A função `quantile()` utiliza o percentual de 50% por default, que é representado por meio do parâmetro `q`. Portanto, podemos dizer que é uma mediana por default. Cabe destacar, que você pode configurar outros percentuais por meio deste parâmetro.

QUADRO 6 – CODIFICAÇÃO DO QUANTIL COM O PANDAS

```
print(train_df['Age'].quantile())
28.0

print(example_series.quantile())
30.0

print(train_df['Age'].quantile(q=0.25))
20.125

print(example_series.quantile(q=0.25))
10.0
```

FONTE: Adaptado de Galvão (2016)

Moda

A moda é uma medida central simples, devido ser o valor que aparece com mais frequência dentro de um conjunto de dados. No Pandas, calculamos a moda por meio da função `mode()`.

QUADRO 7 – CODIFICAÇÃO DA MODA COM O PANDAS

```
print(train_df['Age'].mode())
0 24
dtype: float64

print(example_series.mode())
0 30
dtype: int64
```

FONTE: Adaptado de Galvão (2016)

A função `mode()` do pandas traz esse retorno ou retorna todos, quando existirem dois valores distintos para a moda.

QUADRO 8 – CODIFICAÇÃO DA MODA COM O PANDAS – DOIS VALORES DISTINTOS PARA A MODA

```
example_series_2 = pd.Series([1,5,10,30,50,30,15,40,45,45])
print(example_series_2.mode())

0    30
1    45
dtype: int64
```

FONTE: Adaptado de Galvão (2016)

2.1 MEDIDAS DE DISPERSÃO

Segundo Galvão (2016, p. 1), “as medidas de dispersão são medidas que indicam o quão espalhados os dados estão, ou como eles variam. São elas a amplitude, a variância, o desvio padrão e o desvio absoluto”.

Amplitude

A amplitude é a diferença entre o maior valor de um conjunto de dados e o menor valor desse mesmo conjunto de dados. No pandas, podemos usar a função `max()`, que retorna o maior valor de um conjunto de dados e a função `min()`, que retorna o menor valor de um conjunto de dados. Desta forma, para realizar o cálculo da diferença basta diminuirmos o valor máximo do valor mínimo.

QUADRO 9 – CODIFICAÇÃO DA AMPLITUDE NO PANDAS

```
print(train_df['Age'].max() - train_df['Age'].min())
79.58

print(example_series.max() - example_series.min())
49
```

FONTE: Adaptado de Galvão (2016)

Variância

A variância no pandas é calculada por meio da função `var()`. Essa medida mostra o quanto os dados de um conjunto de dados estão distantes de seu valor esperado.

QUADRO 10 – CODIFICAÇÃO DA VARIÂNCIA NO PANDAS

```
print(train_df['Age'].var())  
211.0191247463081  
  
print(example_series.var())  
325.1111111111111
```

FONTE: Adaptado de Galvão (2016)

Desvio padrão

Outra medida de dispersão é o desvio padrão, também é uma medida de dispersão, que demonstra o quanto os dados estão distanciados da média. Segundo Galvão (2016), se o valor do desvio padrão for alto demonstra que os valores estão mais distanciados, ou seja, estão mais afastados da média, enquanto um desvio padrão baixo demonstra que os valores estão mais perto da média. No Pandas o cálculo é realizado por meio da função `std()`.

QUADRO 11 – CODIFICAÇÃO DO DESVIO PADRÃO NO PANDAS

```
print(train_df['Age'].std())  
14.526497332334044  
  
print(example_series.std())  
18.03083778173136
```

FONTE: Adaptado de Galvão (2016)

Desvio absoluto

Para realizar o cálculo do desvio absoluto primeiro precisamos encontrar a média dos valores; posteriormente, devemos calcular a distância de cada ponto desta média; depois devemos somar as distâncias e dividir o resultado pela média destas distâncias (GALVÃO, 2016). O cálculo no pandas é realizado por meio da função `mad()`.

QUADRO 12 – CODIFICAÇÃO DO DESVIO ABSOLUTO NO PANDAS

```
print(train_df['Age'].mad())  
11.322944471906405  
  
print(example_series.mad())  
15.432098765432098
```

FONTE: Adaptado de Galvão (2016)

Covariância e Correlação

A correlação e a variância devem ser utilizadas nos casos que se queira ter conhecimento se duas variáveis contenham alguma relação mútua dentro de um conjunto de dados. De acordo com Galvão (2016, p. 1), “a covariância é uma medida numérica que indica a interdependência entre duas variáveis. A covariância indica como duas variáveis se comportam conjuntamente em relação às suas médias”. Galvão (2016, p. 1) ainda coloca que “uma covariância igual a 0 indica que as duas variáveis são totalmente independentes, enquanto uma covariância alta e positiva indica que uma variável é grande quando a outra é grande”. De forma análoga, “[...] uma covariância negativa e com valor absoluto alto indica que uma variável é pequena quando a outra é grande” (GALVÃO, 2016, p. 1). No pandas, a covariância pode ser calculada por meio da função `cov()`, retornando uma matriz demonstrando a covariância de cada coluna com outra.

QUADRO 13 – CODIFICAÇÃO DA COVARIÂNCIA NO PANDAS

```
print(train_df.cov())
```

	PassengerId	Survived	Pclass	Age	SibSp
PassengerId	66231.000000	-0.626966	-7.561798	138.696504	-16.325843
Survived	-0.626966	0.236772	-0.137703	-0.551296	-0.018954
Pclass	-7.561798	-0.137703	0.699015	-4.496004	0.076599
Age	138.696504	-0.551296	-4.496004	211.019125	-4.163334
SibSp	-16.325843	-0.018954	0.076599	-4.163334	1.216043
Parch	-0.342697	0.032017	0.012429	-2.344191	0.368739
Fare	161.883369	6.221787	-22.830196	73.849030	8.748734

	Parch	Fare
PassengerId	-0.342697	161.883369
Survived	0.032017	6.221787
Pclass	0.012429	-22.830196
Age	-2.344191	73.849030
SibSp	0.368739	8.748734
Parch	0.649728	8.661052
Fare	8.661052	2469.436846

FONTE: Adaptado de Galvão (2016)

Contudo, a covariância pode ser difícil comparação e compreensão, devido que ela nos retorna valores em escalas que serão distintas em detrimento às variáveis mudarem. Galvão (2016) normalizou a covariância para termos um valor que sempre estará entre 1 e -1. Esse valor é a correlação. Portanto, da mesma forma que covariância, a correlação também é usada quando queremos indicar que duas variáveis estão relacionadas. Segundo Galvão (2016, p. 1), “seu valor fica sempre entre -1, que indica uma anticorrelação perfeita, e 1, que indica uma correlação perfeita”.

No Pandas, a correlação é calculada por meio da função `corr()`. A função `corr()`, da mesma forma que a função `cov()`, retorna uma matriz com a respectiva correlação para cada coluna correspondente com as outras colunas do Dataframe.

QUADRO 14 – CODIFICAÇÃO DA CORRELAÇÃO NO PANDAS

```
print(train_df.corr())
```

	PassengerId	Survived	Pclass	Age	SibSp	Parch \
PassengerId	1.000000	-0.005007	-0.035144	0.036847	-0.057527	-0.001652
Survived	-0.005007	1.000000	-0.338481	-0.077221	-0.035322	0.081629
Pclass	-0.035144	-0.338481	1.000000	-0.369226	0.083081	0.018443
Age	0.036847	-0.077221	-0.369226	1.000000	-0.308247	-0.189119
SibSp	-0.057527	-0.035322	0.083081	-0.308247	1.000000	0.414838
Parch	-0.001652	0.081629	0.018443	-0.189119	0.414838	1.000000
Fare	0.012658	0.257307	-0.549500	0.096067	0.159651	0.216225

	Fare
PassengerId	0.012658
Survived	0.257307
Pclass	-0.549500
Age	0.096067
SibSp	0.159651
Parch	0.216225
Fare	1.000000

FONTE: Adaptado de Galvão (2016)

Galvão (2016, p. 1) coloca que devemos tomar cuidado com ao avaliar as correlações, devido que “alguns dados podem indicar uma correlação que não existe de fato, e é apenas obra do acaso, o que é possível em certos casos onde variáveis apresentam algum tipo de padrão que pode levar a este valor de correlação”. Cabe destacar ainda, que ao se ter uma correlação isso não nos indica causalidade. Dessa forma, podemos dizer, que:

[...] quando duas variáveis apresentam um alto valor de correlação, pode ser que a primeira variável cause este comportamento na segunda, que a segunda causa este comportamento na primeira, que ambas causam o comportamento na outra ou isso também pode não dizer nada, como nos casos que mencionamos. O segredo para não cair nesta armadilha é conhecer bem os dados, para que se possa fazer sempre uma avaliação criteriosa, caso a caso (GALVÃO, 2016, p. 1).




Recomendamos que você aprofunde seus conhecimentos, verificando a função `dropna` do pandas, que encontra-se disponível em <https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.dropna.html> e a função `fillna`, disponível em <https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.fillna.html>.

3 REPRESENTAÇÃO GRÁFICA COM MATPLOB LIB

O Matplotlib é uma biblioteca de plotagem 2 Dimensões (2D) da linguagem Python que produz números de qualidade de publicação em formatos variados tanto de cópia impressa quanto em ambientes interativos entre plataformas. O Matplotlib pode ser utilizado em scripts Python, em shell Python e IPython, no notebook Jupyter, em servidores de aplicativos da web e em quatro kits de ferramentas da interface gráfica do usuário (HUNTER *et al.*, 2020a).

FIGURA 3 – QUATRO KITS DE FERRAMENTAS GRÁFICAS



Fonte: A Autora


Além disso, existem kits de ferramentas complementares, incluindo plotagem 3 Dimensões (3D) com mplot3d, eixos auxiliares `axes_grid1` e eixos auxiliares `axisartist`. Os pacotes de terceiros objetivam estender a ferramenta. Nesses pacotes está incluído o Seaborn que veremos no item 3 deste tópico. Além dele, temos holoviews, ggplot entre outros e dois conjuntos de ferramentas utilizadas para projeção e mapeamento, que são BaseMap e cartopy.

O Matplotlib visa apoiar as atividades fáceis e difíceis, podendo ser utilizado na geração de gráficos, histogramas, espectros de potência, gráficos de barras, gráficos de erros, gráficos de dispersão etc. com apenas algumas linhas de código. Para plotagem simples o módulo pyplot fornece uma interface semelhante ao MATLAB, principalmente quando utilizada em conjunto com o IPython. Quando você tiver mais familiarizado, você pode usar recursos que lhe darão controle total dos estilos de linha, propriedades da fonte, propriedades dos eixos etc., por meio de uma interface orientada a objetos ou fazendo uso de um conjunto de funções similares do MATLAB (HUNTER *et al.*, 2020a). Neste contexto, vamos colocar algumas exemplificações para facilitar sua compreensão.

Gráfico de barras empilhado

O exposto a seguir trará o exemplo do gráfico de barras empilhado e o Quadro 15 a codificação. Pelo referido quadro, é possível observar o parâmetro `yerr` utilizado para barras de erro e o parâmetro `bottom` para empilhar as barras femininas em cima das barras masculinas.

GRÁFICO 8 – BARRAS EMPILHADAS



FONTE: Adaptado de Hunter *et al.* (2020b)

QUADRO 15 – CODIFICAÇÃO EM MATPLOTLIB DO GRÁFICO DE BARRAS EMPILHADO

```
import numpy as np
import matplotlib.pyplot as plt

N = 5
menMeans = (20, 35, 30, 35, 27)
womenMeans = (25, 32, 34, 20, 25)
menStd = (2, 3, 4, 1, 2)
womenStd = (3, 5, 2, 3, 3)
ind = np.arange(N) # the x locations for the groups
width = 0.35 # the width of the bars: can also be len(x) sequence

p1 = plt.bar(ind, menMeans, width, yerr=menStd)
p2 = plt.bar(ind, womenMeans, width,
             bottom=menMeans, yerr=womenStd)

plt.ylabel('Scores')
plt.title('Scores by group and gender')
plt.xticks(ind, ('G1', 'G2', 'G3', 'G4', 'G5'))
plt.yticks(np.arange(0, 81, 10))
plt.legend((p1[0], p2[0]), ('Men', 'Women'))


plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020b)

Gráfico de barras agrupado com etiquetas

A seguir, observaremos o exemplo do gráfico de barras agrupado com etiquetas e o Quadro 16 traz a codificação. Pelo referido quadro, é possível observar o uso das funções, métodos e classes utilizados, como: `matplotlib.axes.Axes.bar`, `matplotlib.pyplot.bar`, `matplotlib.axes.Axes.annotate` e `matplotlib.pyplot.annotate`.

GRÁFICO 9 – DE BARRAS AGRUPADO COM ETIQUETA



FONTE: Adaptado de Hunter *et al.* (2020b)

QUADRO 16 – CODIFICAÇÃO EM MATPLOTLIB DO GRÁFICO DE BARRAS AGRUPADO COM ETIQUETA

```

import matplotlib
import matplotlib.pyplot as plt
import numpy as np

labels = ['G1', 'G2', 'G3', 'G4', 'G5']
men_means = [20, 34, 30, 35, 27]
women_means = [25, 32, 34, 20, 25]
x = np.arange(len(labels)) # the label locations
width = 0.35 # the width of the bars

fig, ax = plt.subplots()
rects1 = ax.bar(x - width/2, men_means, width, label='Men')
rects2 = ax.bar(x + width/2, women_means, width, label='Women')

# Add some text for labels, title and custom x-axis tick labels etc.
ax.set_ylabel('Scores')
ax.set_title('Scores by group and gender')
ax.set_xticks(x)
ax.set_xticklabels(labels)
ax.legend()

def autolabel(rects):
    """Attach a text label above each bar in *rects*, displaying its height."""
    for rect in rects:
        height = rect.get_height()
        ax.annotate('{}' .format(height),
                    xy=(rect.get_x() + rect.get_width() / 2, height),
                    xytext=(0, 3), # 3 points vertical offset
                    textcoords="offset points",
                    ha='center', va='bottom')

autolabel(rects1)
autolabel(rects2)

fig.tight_layout()

plt.show()


```

FONTE: Adaptado de Hunter *et al.* (2020b)

Gráfico de barras horizontais

A seguir, o exemplo do gráfico de barras horizontal simples e o Quadro 17 traz a codificação correspondente para a plotagem.

GRÁFICO 10 – DE BARRAS HORIZONTAL



FONTE: Adaptado de Hunter *et al.* (2020b)

QUADRO 17 – CODIFICAÇÃO EM MATPLOTLIB DO GRÁFICO DE BARRAS HORIZONTAL

```
import matplotlib.pyplot as plt
import numpy as np

# Fixing random state for reproducibility
np.random.seed(19680801)

plt.rcParams()
fig, ax = plt.subplots()

# Example data
people = ('Tom', 'Dick', 'Harry', 'Slim', 'Jim')
y_pos = np.arange(len(people))
performance = 3 + 10 * np.random.rand(len(people))
error = np.random.rand(len(people))

ax.barh(y_pos, performance, xerr=error, align='center')
ax.set_yticks(y_pos)
ax.set_yticklabels(people)
ax.invert_yaxis() # labels read top-to-bottom
ax.set_xlabel('Performance')
ax.set_title('How fast do you want to go today?')


plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020c)

Plotagem de variáveis categóricas

Frequentemente, precisamos usar variáveis categóricas no Matplotlib, sendo possível passar variáveis categóricas diretamente para muitas outras funções de plotagem. Observaremos a exemplificação de plotagem de variáveis categóricas e o Quadro 18 traz a codificação correspondente.

GRÁFICO 11 – PLOTAGEM DE VARIÁVEIS CATEGÓRICAS



FONTE: Adaptado de Hunter et al. (2020d)

QUADRO 18 – CODIFICAÇÃO EM MATPLOTLIB DE VARIÁVEIS CATEGÓRICAS


```
import matplotlib.pyplot as plt

data = {'apples': 10, 'oranges': 15, 'lemons': 5, 'limes': 20}
names = list(data.keys())
values = list(data.values())

fig, axs = plt.subplots(1, 3, figsize=(9, 3), sharey=True)
axs[0].bar(names, values)
axs[1].scatter(names, values)
axs[2].plot(names, values)
fig.suptitle('Categorical Plotting')
```

FONTE: Adaptado de Hunter et al. (2020d)

GRÁFICO 12 – PLOTAGEM DE VARIÁVEIS CATEGÓRICAS NOS DOIS EIXOS



FONTE: Adaptado de Hunter *et al.* (2020d)

QUADRO 19 – CODIFICAÇÃO EM MATPLOTLIB DE VARIÁVEIS CATEGÓRICAS EM DOIS EIXOS

```
cat = ["bored", "happy", "bored", "bored", "happy", "bored"]
dog = ["happy", "happy", "happy", "happy", "bored", "bored"]
activity = ["combing", "drinking", "feeding", "napping", "playing", "washing"]

fig, ax = plt.subplots()
ax.plot(activity, dog, label="dog")
ax.plot(activity, cat, label="cat")
ax.legend()


plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020d)

Traçando a coerência de dois sinais

A seguir, demonstraremos como plotar a coerência de dois sinais e o Quadro 20 traz a codificação correspondente.

GRÁFICO 13 – PLOTAGEM PARA TRAÇAR A COERÊNCIA DE DOIS SINAIS

FONTE: Adaptado de Hunter *et al.* (2020e)

QUADRO 20 – CODIFICAÇÃO EM MATPLOTLIB PARA TRAÇAR A COERÊNCIA DE DOIS SINAIS

```
import numpy as np
import matplotlib.pyplot as plt

# Fixing random state for reproducibility
np.random.seed(19680801)

dt = 0.01
t = np.arange(0, 30, dt)
nse1 = np.random.randn(len(t))           # white noise 1
nse2 = np.random.randn(len(t))           # white noise 2

# Two signals with a coherent part at 10Hz and a random part
s1 = np.sin(2 * np.pi * 10 * t) + nse1
s2 = np.sin(2 * np.pi * 10 * t) + nse2

fig, axs = plt.subplots(2, 1)
axs[0].plot(t, s1, t, s2)
axs[0].set_xlim(0, 2)
axs[0].set_xlabel('time')
axs[0].set_ylabel('s1 and s2')
axs[0].grid(True)

cxy, f = axs[1].cohere(s1, s2, 256, 1. / dt)
axs[1].set_ylabel('coherence')


fig.tight_layout()
plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020e)

Gráfico de barras empilhado

Na visualização de distribuição discreta, podemos utilizar plotagem de barras empilhadas. O gráfico a seguir traz essa exemplificação, na qual podemos visualizar o resultado de uma pesquisa em que as pessoas podem avaliar sua concordância com perguntas em uma escala de cinco elementos; e o Quadro 21 traz a sua codificação. Pelo referido quadro é possível verificar a utilização das seguintes funções, métodos, classes e módulos: `import matplotlib, matplotlib.axes, Axes.barh, matplotlib.pyplot.barh, matplotlib.axes.Axes.text, matplotlib.pyplot.text, matplotlib.axes.Axes.legend, matplotlib.pyplot.legend`. O empilhamento horizontal é realizado por meio de `barh()` para cada categoria e passando o ponto de partida como a soma cumulativa dos bares já tiradas por meio do parâmetro `left`.

GRÁFICO 14 – DISTRIBUIÇÃO DISCRETA COM O GRÁFICO DE BARRAS HORIZONTAL



FONTE: Adaptado de Hunter *et al.* (2020f)

QUADRO 21 – CODIFICAÇÃO EM MATPLOTLIB DA DISTRIBUIÇÃO DISCRETA COMO GRÁFICO DE BARRAS HORIZONTAL

```

import numpy as np
import matplotlib.pyplot as plt

category_names = ['Strongly disagree', 'Disagree',
                  'Neither agree nor disagree', 'Agree', 'Strongly agree']
results = {
    'Question 1': [10, 15, 17, 32, 26],
    'Question 2': [26, 22, 29, 10, 13],
    'Question 3': [35, 37, 7, 2, 19],
    'Question 4': [32, 11, 9, 15, 33],
    'Question 5': [21, 29, 5, 5, 40],
    'Question 6': [8, 19, 5, 30, 38]
}

def survey(results, category_names):
    """
    Parameters
    -----
    results : dict
        A mapping from question labels to a list of answers per category.
        It is assumed all lists contain the same number of entries and that
        it matches the length of *category_names*.
    category_names : list of str
        The category labels.
    """
    labels = list(results.keys())
    data = np.array(list(results.values()))
    data_cum = data.cumsum(axis=1)
    category_colors = plt.get_cmap('RdYlGn')(
        np.linspace(0.15, 0.85, data.shape[1]))

    fig, ax = plt.subplots(figsize=(9.2, 5))
    ax.invert_yaxis()
    ax.xaxis.set_visible(False)
    ax.set_xlim(0, np.sum(data, axis=1).max())

    for i, (colname, color) in enumerate(zip(category_names, category_colors)):
        widths = data[:, i]
        starts = data_cum[:, i] - widths
        ax.barh(labels, widths, left=starts, height=0.5,
                label=colname, color=color)
        xcenters = starts + widths / 2

        r, g, b, _ = color
        text_color = 'white' if r * g * b < 0.5 else 'darkgrey'
        for y, (x, c) in enumerate(zip(xcenters, widths)):
            ax.text(x, y, str(int(c)), ha='center', va='center',
                    color=text_color)
        ax.legend(ncol=len(category_names), bbox_to_anchor=(0, 1),
                loc='lower left', fontsize='small')

    return fig, ax

survey(results, category_names)
plt.show()

```


FONTE: Adaptado de Hunter *et al.* (2020f)

Linha do tempo com linhas, datas e texto

O gráfico que segue traz um exemplo de como realizar a plotagem criando uma linha do tempo com linhas, datas e texto e o Quadro 22 e Quadro 23 trazem a codificação correspondente desta plotagem. A codificação do Quadro 22 foi extraída do GitHub e apresenta como criar uma linha do templo de forma simplificada utilizando as datas das versões recentes do Matplotlib. Já no Quadro 23 foi criado um stem com algumas variações nos níveis para diferenciar eventos próximos. Em contraste com um gráfico de tronco usual, foi mudado os marcadores para a linha de base para dar ênfase visual à natureza unidimensional da linha do tempo. Para cada evento, foi adicionado uma etiqueta de texto via annotate, que é deslocada em unidades de pontos a partir da ponta da linha do evento.

Observe que o Matplotlib plotará automaticamente as entradas de data e hora. O uso das seguintes funções, métodos e classes é mostrado aqui: `import matplotlib, matplotlib.axes.Axes.stem, matplotlib.axes.Axes.annotate, matplotlib.axis.Axis.set_major_locator, matplotlib.axis.Axis.set_major_formatter, matplotlib.dates.MonthLocator` e `matplotlib.dates.DateFormatter`.

GRÁFICO 15 – PLOTAGEM DE UMA LINHA DO TEMPO COM LINHAS, DATAS E TEXTO



FONTE: Adaptado de Hunter et al. (2020g)

QUADRO 22 – CODIFICAÇÃO EM MATPLOTLIB DE UMA LINHA DO TEMPO COM LINHAS, DATAS E TEXTO

```

import matplotlib.pyplot as plt
import numpy as np
import matplotlib.dates as mdates
from datetime import datetime

try:
    # Try to fetch a list of Matplotlib releases and their dates
    # from https://api.github.com/repos/matplotlib/matplotlib/releases
    import urllib.request
    import json
    url = 'https://api.github.com/repos/matplotlib/matplotlib/releases'
    url += '?per_page=100'
    data = json.loads(urllib.request.urlopen(url, timeout=.4).read().decode())

    dates = []
    names = []
    for item in data:
        if 'rc' not in item['tag_name'] and 'b' not in item['tag_name']:
            dates.append(item['published_at'].split("T")[0])
            names.append(item['tag_name'])
    # Convert date strings (e.g. 2014-10-18) to datetime
    dates = [datetime.strptime(d, "%Y-%m-%d") for d in dates]

except Exception:
    # In case the above fails, e.g. because of missing internet connection
    # use the following lists as fallback.
    names = ['v2.2.4', 'v3.0.3', 'v3.0.2', 'v3.0.1', 'v3.0.0', 'v2.2.3',
            'v2.2.2', 'v2.2.1', 'v2.2.0', 'v2.1.2', 'v2.1.1', 'v2.1.0',
            'v2.0.2', 'v2.0.1', 'v2.0.0', 'v1.5.3', 'v1.5.2', 'v1.5.1',
            'v1.5.0', 'v1.4.3', 'v1.4.2', 'v1.4.1', 'v1.4.0']

    dates = ['2019-02-26', '2019-02-26', '2018-11-10', '2018-11-10',
            '2018-09-18', '2018-08-10', '2018-03-17', '2018-03-16',
            '2018-03-06', '2018-01-18', '2017-12-10', '2017-10-07',
            '2017-05-10', '2017-05-02', '2017-01-17', '2016-09-09',
            '2016-07-03', '2016-01-10', '2015-10-29', '2015-02-16',
            '2014-10-26', '2014-10-18', '2014-08-26']

    # Convert date strings (e.g. 2014-10-18) to datetime
    dates = [datetime.strptime(d, "%Y-%m-%d") for d in dates]

```

FONTE: Adaptado de Hunter *et al.* (2020g)

QUADRO 23 – CODIFICAÇÃO EM MATPLOTLIB DO GRÁFICO DE BARRAS EMPILHADO

```
# Choose some nice levels
levels = np.tile([-5, 5, -3, 3, -1, 1],
                 int(np.ceil(len(dates)/6))[:len(dates)])

# Create figure and plot a stem plot with the date
fig, ax = plt.subplots(figsize=(8.8, 4), constrained_layout=True)
ax.set(title="Matplotlib release dates")

markerline, stemline, baseline = ax.stem(dates, levels,
                                          linefmt="C3-", basefmt="k-",
                                          use_line_collection=True)

plt.setp(markerline, mec="k", mfc="w", zorder=3)

# Shift the markers to the baseline by replacing the y-data by zeros.
markerline.set_ydata(np.zeros(len(dates)))

# annotate lines
vert = np.array(['top', 'bottom'])[(levels > 0).astype(int)]
for d, l, r, va in zip(dates, levels, names, vert):
    ax.annotate(r, xy=(d, l), xytext=(-3, np.sign(l)*3),
               textcoords="offset points", va=va, ha="right")
# format xaxis with 4 month intervals
ax.get_xaxis().set_major_locator(mdates.MonthLocator(interval=4))
ax.get_xaxis().set_major_formatter(mdates.DateFormatter("%b %Y"))
plt.setp(ax.get_xticklabels(), rotation=30, ha="right")

# remove y axis and spines
ax.get_yaxis().set_visible(False)
for spine in ["left", "top", "right"]:
    ax.spines[spine].set_visible(False)


ax.margins(y=0.1)
plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020g)

Correlação cruzada e automática

O exposto exemplifica a plotagem de correlação cruzada, por meio de `xcorr` e de correlação automática, por meio de `acorr`, e o Quadro 24 traz a codificação correspondente. Pelo referido quadro, possível observar o uso das seguintes funções, métodos, classes e módulos: `import matplotlib`, `matplotlib.axes.Axes.acorr`, `matplotlib.axes.Axes.xcorr`, `matplotlib.pyplot.acorr` e `matplotlib.pyplot.xcorr`.

GRÁFICO 16 – PLOTAGEM DE CORRELAÇÃO CRUZADA E AUTOMÁTICA



FONTE: Adaptado de Hunter *et al.* (2020h)

QUADRO 24 – CODIFICAÇÃO EM MATPLOTLIB DE PLOTAGEM DE CORRELAÇÃO CRUZADA E AUTOMÁTICA

```
import matplotlib.pyplot as plt
import numpy as np

# Fixing random state for reproducibility
np.random.seed(19680801)

x, y = np.random.randn(2, 100)
fig, [ax1, ax2] = plt.subplots(2, 1, sharex=True)
ax1.xcorr(x, y, usevlines=True, maxlags=50, normed=True, lw=2)
ax1.grid(True)

ax2.acorr(x, usevlines=True, normed=True, maxlags=50, lw=2)
ax2.grid(True)


plt.show()
```

FONTE: Adaptado de Hunter *et al.* (2020h)

Plotagem de transformação afim de imagem

O gráfico exemplifica a plotagem de transformação afim e o Quadro 25 traz a codificação correspondente. Pelo referido quadro, é possível observar o uso das seguintes funções, métodos, classes e módulos: `import matplotlib`, `matplotlib.axes.Axes.imshow`, `matplotlib.pyplot.imshow` e `matplotlib.transforms.Affine2D`.

GRÁFICO 17 – PLOTAGEM DE TRANSFORMAÇÃO AFIM DE IMAGEM



FONTE: Adaptado de Hunter *et al.* (2020i)

Cabe destacar, que anexar uma transformação afim (Affine2D) à transformação de dados de uma imagem possibilita a manipulação e a orientação da imagem. Este é um exemplo do conceito de encadeamento de transformação. Para os back-end que suportam `draw_image` com transformação affine opcional, como por exemplo: agg, ps back-end, a imagem da saída deve ter seu limite correspondente ao retângulo amarelo tracejado.

QUADRO 25 – CODIFICAÇÃO EM MATPLOTLIB DE PLOTAGEM DE TRANSFORMAÇÃO AFIM DE IMAGEM

```

import numpy as np
import matplotlib.pyplot as plt
import matplotlib.transforms as mtransforms

def get_image():
    delta = 0.25
    x = y = np.arange(-3.0, 3.0, delta)
    X, Y = np.meshgrid(x, y)
    Z1 = np.exp(-X**2 - Y**2)
    Z2 = np.exp(-(X - 1)**2 - (Y - 1)**2)
    Z = (Z1 - Z2)
    return Z

def do_plot(ax, Z, transform):
    im = ax.imshow(Z, interpolation='none',
                  origin='lower',
                  extent=[-2, 4, -3, 2], clip_on=True)

    trans_data = transform + ax.transData
    im.set_transform(trans_data)

    # display intended extent of the image
    x1, x2, y1, y2 = im.get_extent()
    ax.plot([x1, x2, x2, x1], [y1, y1, y2, y2], "y--",
            transform=trans_data)
    ax.set_xlim(-5, 5)
    ax.set_ylim(-4, 4)

# prepare image and figure
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2)
Z = get_image()

# image rotation
do_plot(ax1, Z, mtransforms.Affine2D().rotate_deg(30))

# image skew
do_plot(ax2, Z, mtransforms.Affine2D().skew_deg(30, 15))

# scale and reflection
do_plot(ax3, Z, mtransforms.Affine2D().scale(-1, .5))
# everything and a translation
do_plot(ax4, Z, mtransforms.Affine2D().
        rotate_deg(30).skew_deg(30, 15).scale(-1, .5).translate(.5, -1))

plt.show()


```

FONTE: Adaptado de Hunter *et al.* (2020i)

Plotagem de mapas de calor

De acordo com Hunter *et al.* (2020h), existe situação que desejamos apresentar dados que dependem de duas variáveis independentes como um gráfico de imagem com código de cores. Essa situação é chamada de mapa de calor. Quando os dados são categóricos é chamado de mapa de calor categórico. No matplotlib, a função `imshow` facilita a produção de tais parcelas. Vamos apresentar alguns exemplos de como criar um mapa de calor com anotações e começaremos com um exemplo fácil e o expandiremos para ser utilizado como uma função universal.

FIGURA 4 – PLOTAGEM DE CRIAÇÃO DE MAPAS DE CALOR ANOTADOS



FONTE: Adaptado de Hunter *et al.* (2020j)

O que precisamos é de uma lista ou matriz 2D que defina os dados para o código de cores, bem como precisamos de duas listas ou matrizes de categorias. Cabe lembrar que o número de elementos nessas listas precisa corresponder aos dados ao longo dos respectivos eixos. Outro ponto que precisamos lembrar, é que o mapa de calor em si é um gráfico `imshow` com os rótulos definidos para as categorias que temos, assim como é importante definir os locais `set_xticks` dos marcadores (`set_xticklabels`) e os rótulos desses marcadores ().

Caso contrário, eles ficarão fora de sincronia. Já os locais são apenas os números inteiros ascendentes, enquanto os rótulos são os rótulos a serem exibidos. Por fim, podemos rotular os dados em si, criando um `Text` dentro de cada célula, mostrando o valor dessa célula.

QUADRO 26 – CODIFICAÇÃO EM MATPLOTLIB DE PLOTAGEM DE MAPA DE CALOR SIMPLES

```

import numpy as np
import matplotlib
import matplotlib.pyplot as plt
# sphinx_gallery_thumbnail_number = 2

vegetables = ["cucumber", "tomato", "lettuce", "asparagus",
              "potato", "wheat", "barley"]
farmers = ["Farmer Joe", "Upland Bros.", "Smith Gardening",
           "Agrifun", "Organiculture", "BioGoods Ltd.", "Cornylee Corp."]

harvest = np.array([[0.8, 2.4, 2.5, 3.9, 0.0, 4.0, 0.0],
                    [2.4, 0.0, 4.0, 1.0, 2.7, 0.0, 0.0],
                    [1.1, 2.4, 0.8, 4.3, 1.9, 4.4, 0.0],
                    [0.6, 0.0, 0.3, 0.0, 3.1, 0.0, 0.0],
                    [0.7, 1.7, 0.6, 2.6, 2.2, 6.2, 0.0],
                    [1.3, 1.2, 0.0, 0.0, 0.0, 3.2, 5.1],
                    [0.1, 2.0, 0.0, 1.4, 0.0, 1.9, 6.3]])

fig, ax = plt.subplots()
im = ax.imshow(harvest)

# We want to show all ticks...
ax.set_xticks(np.arange(len(farmers)))
ax.set_yticks(np.arange(len(vegetables)))
# ... and label them with the respective list entries
ax.set_xticklabels(farmers)
ax.set_yticklabels(vegetables)

# Rotate the tick labels and set their alignment.
plt.setp(ax.get_xticklabels(), rotation=45, ha="right",
         rotation_mode="anchor")

# Loop over data dimensions and create text annotations.
for i in range(len(vegetables)):
    for j in range(len(farmers)):
        text = ax.text(j, i, harvest[i, j],
                       ha="center", va="center", color="w")


ax.set_title("Harvest of local farmers (in tons/year)")
fig.tight_layout()
plt.show()

```

FONTE: Adaptado de Hunter *et al.* (2020j)

Vamos dar continuidade no exemplo de mapa de calor, utilizando o estilo do código da função auxiliar, e a sua codificação apresentada no Quadro 27. Sempre que possível, devemos reutilizar código para criar algum tipo de mapa de calor, para distintos dados de entrada e/ou em distintos eixos. Criamos uma função que usa os dados e os rótulos de linha e coluna como entrada, permitindo ter argumentos utilizados para personalizar o gráfico.

GRÁFICO 18 – PLOTAGEM DE CRIAÇÃO DE MAPAS DE CALOR UTILIZANDO FUNÇÃO AUXILIAR



FONTE: Adaptado de Hunter *et al.* (2020j)

QUADRO 27 – CODIFICAÇÃO EM MATPLOTLIB DA PLOTAGEM

```
def heatmap(data, row_labels, col_labels, ax=None,
            cbar_kw={}, cbarlabel="", **kwargs):
    """
    Create a heatmap from a numpy array and two lists of labels.

    Parameters
    -----
    data
        A 2D numpy array of shape (N, M).
    row_labels
        A list or array of length N with the labels for the rows.
    col_labels
        A list or array of length M with the labels for the columns.
    ax
        A `matplotlib.axes.Axes` instance to which the heatmap is plotted. If
        not provided, use current axes or create a new one. Optional.
    cbar_kw
        A dictionary with arguments to `matplotlib.figure.colorbar`. Optional.
    cbarlabel
        The label for the colorbar. Optional.
    **kwargs
        All other arguments are forwarded to `imshow`.
    """

    if not ax:
        ax = plt.gca()

    # Plot the heatmap
    im = ax.imshow(data, **kwargs)

    # Create colorbar
    cbar = ax.figure.colorbar(im, ax=ax, **cbar_kw)
    cbar.ax.set_ylabel(cbarlabel, rotation=-90, va="bottom")

    # We want to show all ticks...
    ax.set_xticks(np.arange(data.shape[1]))
    ax.set_yticks(np.arange(data.shape[0]))
    # ... and label them with the respective list entries.
    ax.set_xticklabels(col_labels)
    ax.set_yticklabels(row_labels)

    # Let the horizontal axes labeling appear on top.
    ax.tick_params(top=True, bottom=False,
                  labeltop=True, labelbottom=False)

    # Rotate the tick labels and set their alignment.
    plt.setp(ax.get_xticklabels(), rotation=-30, ha="right",
              rotation_mode="anchor")

    # Turn spines off and create white grid.
    for edge, spine in ax.spines.items():
        spine.set_visible(False)

    ax.set_xticks(np.arange(data.shape[1]+1)-.5, minor=True)
    ax.set_yticks(np.arange(data.shape[0]+1)-.5, minor=True)
    ax.grid(which="minor", color="w", linestyle='-', linewidth=3)
    ax.tick_params(which="minor", bottom=False, left=False)
```

```

return im, cbar

def annotate_heatmap(im, data=None, valfmt="{x:.2f}", textcolors=["black", "white"],
                    threshold=None, **textkw):
    """
    A function to annotate a heatmap.

    Parameters
    -----
    im
        The AxesImage to be labeled.
    data
        Data used to annotate. If None, the image's data is used. Optional.
    valfmt
        The format of the annotations inside the heatmap. This should either
        use the string format method, e.g. "{x:.2f}", or be a
        `matplotlib.ticker.Formatter`. Optional.
    textcolors
        A list or array of two color specifications. The first is used for
        values below a threshold, the second for those above. Optional.
    threshold
        Value in data units according to which the colors from textcolors are
        applied. If None (the default) uses the middle of the colormap as
        separation. Optional.
    **kwargs
        All other arguments are forwarded to each call to `text` used to create
        the text labels.
    """
    if not isinstance(data, (list, np.ndarray)):
        data = im.get_array()

    # Normalize the threshold to the images color range.
    if threshold is not None:
        threshold = im.norm(threshold)
    else:
        threshold = im.norm(data.max())/2.

    # Set default alignment to center, but allow it to be
    # overwritten by textkw.
    kw = dict(horizontalalignment="center",
                verticalalignment="center")
    kw.update(textkw)

    # Get the formatter in case a string is supplied
    if isinstance(valfmt, str):
        valfmt = matplotlib.ticker.StrMethodFormatter(valfmt)

    # Loop over the data and create a `Text` for each "pixel".
    # Change the text's color depending on the data.
    texts = []
    for i in range(data.shape[0]):
        for j in range(data.shape[1]):
            kw.update(color=textcolors[int(im.norm(data[i, j]) > threshold)])
            text = im.axes.text(j, i, valfmt(data[i, j], None), **kw)
            texts.append(text)

    return texts

```

FONTE: Adaptado de Hunter *et al.* (2020j)

É possível perceber que a exemplificação apresentada e codificada contém uma barra de cores e os rótulos estão posicionados acima do mapa de calor em vez de colocar abaixo dele. Além disso, as anotações possuem cores diferentes, dependendo de um limite para melhor contraste com a cor do pixel. Por fim, foi desligado os “espinhos” dos eixos circundantes e criado uma grade de linhas brancas para separar as células. Dito isso, podemos manter a criação de plotagem real bastante compacta.

QUADRO 28 – CODIFICAÇÃO EM MATPLOTLIB DA PLOTAGEM DE FORMA COMPACTA

```
fig, ax = plt.subplots()


im, cbar = heatmap(harvest, vegetables, farmers, ax=ax,
                  cmap="YlGn", cbarlabel="harvest [t/year]")
texts = annotate_heatmap(im, valfmt="{x:.1f} t")

fig.tight_layout()
plt.show()
```

FONTE: Adaptado de Hunter et al. (2020j)

As funções criadas anteriormente possuem uma grande versatilidade, dependendo apenas de aplicá-la em diferentes casos e usando diferentes argumentos. O uso das seguintes funções e métodos é mostrado na exemplificação apresentada no Gráfico 19 e codificada no Quadro 29: `matplotlib.axes.Axes.imshow`, `matplotlib.pyplot.imshow`, `matplotlib.figure.Figure.colorbar` e `matplotlib.pyplot.colorbar`.

GRÁFICO 19 – PLOTAGEM DE MAPA DE CALOR MAIS COMPLEXO



FONTE: Adaptado de Hunter et al. (2020i)

QUADRO 29 – CODIFICAÇÃO EM MATPLOTLIB DA PLOTAGEM

```

np.random.seed(19680801)

fig, ((ax, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(8, 6))

# Replicate the above example with a different font size and colormap.

im, _ = heatmap(harvest, vegetables, farmers, ax=ax,
                 cmap="Wistia", cbarlabel="harvest [t/year]")
annotate_heatmap(im, valfmt="{x:.1f}", size=7)

# Create some new data, give further arguments to imshow (vmin),
# use an integer format on the annotations and provide some colors.

data = np.random.randint(2, 100, size=(7, 7))
y = ["Book {}".format(i) for i in range(1, 8)]
x = ["Store {}".format(i) for i in list("ABCDEFGF")]
im, _ = heatmap(data, y, x, ax=ax2, vmin=0,
                 cmap="magma_r", cbarlabel="weekly sold copies")
annotate_heatmap(im, valfmt="{x:d}", size=7, threshold=20,
                 textcolors=["red", "white"])

# Sometimes even the data itself is categorical. Here we use a
# :class: matplotlib.colors.BoundaryNorm` to get the data into classes
# and use this to colorize the plot, but also to obtain the class
# labels from an array of classes.

data = np.random.randn(6, 6)
y = ["Prod. {}".format(i) for i in range(10, 70, 10)]
x = ["Cycle {}".format(i) for i in range(1, 7)]
qrates = np.array(list("ABCDEFGF"))
norm = matplotlib.colors.BoundaryNorm(np.linspace(-3.5, 3.5, 8), 7)
fmt = matplotlib.ticker.FuncFormatter(lambda x, pos: qrates[-1][norm(x)])

im, _ = heatmap(data, y, x, ax=ax3,
                 cmap=plt.get_cmap("PiYG", 7), norm=norm,
                 cbar_kw=dict(ticks=np.arange(-3, 4), format=fmt),
                 cbarlabel="Quality Rating")

annotate_heatmap(im, valfmt=fmt, size=9, fontweight="bold", threshold=-1,
                 textcolors=["red", "black"])

# We can nicely plot a correlation matrix. Since this is bound by -1 and 1,
# we use those as vmin and vmax. We may also remove leading zeros and hide
# the diagonal elements (which are all 1) by using a
# :class: matplotlib.ticker.FuncFormatter`.

corr_matrix = np.corrcoef(np.random.rand(6, 5))
im, _ = heatmap(corr_matrix, vegetables, vegetables, ax=ax4,
                 cmap="PuOr", vmin=-1, vmax=1,
                 cbarlabel="correlation coeff.")

def func(x, pos):
    return "{:2f}".format(x).replace("0.", ".").replace("1.00", "")

annotate_heatmap(im, valfmt=matplotlib.ticker.FuncFormatter(func), size=7)

plt.tight_layout()
plt.show()

```

FONTE: Adaptado de Hunter *et al.* (2020i)



Sugerimos que você acesse o User's Guide, disponível em <https://matplotlib.org/users/index.html>. Ainda, verifique a galeria de imagens disponibilizada em <https://matplotlib.org/gallery/index.html> ou a lista de comandos de plotagens https://matplotlib.org/api/pyplot_summary.html. Ainda, sugerimos outros recursos externos de aprendizagem em <https://matplotlib.org/resources/index.html>, incluindo material impresso, tutoriais e vídeos.

4 GRÁFICOS DE PARES COM SEABORN

Seaborn é uma biblioteca de visualização de dados na linguagem Python baseada na biblioteca matplotlib e estreitamente integrado às estruturas de dados do pandas. Esta biblioteca fornece uma interface de alto nível para desenhar gráficos estatísticos atraentes e informativos (WASKOM, 2020a). Aqui estão algumas das funcionalidades que o seaborn oferece (WASKOM, 2020b):


- Uma API orientada a conjunto de dados para examinar os relacionamentos entre várias variáveis.
- Suporte especializado para o uso de variáveis categóricas para mostrar observações ou agregar estatísticas.
- Opções para visualizar distribuições univariadas ou bivariadas e as compara entre subconjuntos de dados.
- Estimação e plotagem automáticas de modelos de regressão linear para variáveis dependentes de diferentes tipos.
- Visualizações convenientes da estrutura geral de conjuntos de dados complexos.
- Abstrações de alto nível para estruturar grades de vários gráficos que permitem criar facilmente visualizações complexas.
- Controle conciso sobre o estilo de figuras matplotlib com vários temas internos
- Ferramentas para escolher paletas de cores que revelam fielmente padrões em seus dados.



Sugerimos que você navegue pela galeria de exemplos, para ter uma ideia do que você pode fazer com essa biblioteca. Essa galeria está disponível <https://seaborn.pydata.org/examples/index.html>. Também sugerimos que você visite a página de instalação para baixar o pacote e o instalar, que encontra-se em <https://seaborn.pydata.org/installing.html>.

O Seaborn visa tornar a visualização uma parte central da exploração e uma melhor compreensão dos dados. Suas funções de plotagem orientadas a conjuntos de dados operam em quadros de dados e matrizes, que contém conjuntos de dados inteiros, que executam internamente o mapeamento semântico necessário e a agregação estatística para produzir gráficos informativos.

GRÁFICO 20 – MAPEAMENTO SEMÂNTICO EM SEABORN



FONTE: Adaptado de Waskom (2020b)

QUADRO 30 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 import seaborn as sns
2 sns.set()
tips = sns.load_dataset("tips")
sns.relplot(x="total_bill", y="tip", col="time", hue="smoker", style="smoker", size="size",
            data=tips);
```

FONTE: Adaptado de Waskom (2020b)

Vamos examinar um pouco mais a codificação. Na linha 1, importamos a biblioteca seaborn, que é a única biblioteca necessária neste exemplo. Esta biblioteca usa o matplotlib para desenhar tramas. Muitas tarefas podem ser realizadas apenas com funções disponibilizadas pela biblioteca seaborn, mas uma personalização adicional pode exigir o uso direto do matplotlib.



Para um trabalho interativo, é recomendável usar uma interface Jupyter/ IPython no modo matplotlib, caso contrário você precisará chamar matplotlib.pyplot.show() para visualizar a plotagem.

Na linha 2 foi aplicado o tema, a escala e a paleta de cores padrão. Para isso, foi utilizado o sistema `matplotlib rcParam`, que afeta a aparência de todos os gráficos do `matplotlib`. Além do tema padrão, existem outras opções, que possibilitam alterar o estilo livremente, bem como a escala da plotagem para traduzir rapidamente seu trabalho entre os contextos da apresentação, como por exemplo, criar uma plotagem que tenha fontes legíveis quando projetadas durante uma palestra (WASKOM, 2020b).

Na linha 3 foi carregado um dos conjuntos de dados de exemplo. Na grande maioria das codificações, será utilizado função `load_dataset()`, para obter acesso rápido a um conjunto de dados. Não há nada de especial referente esses conjuntos de dados; eles são apenas quadros de dados de `pandas` (vistos no item 1 deste tópico) e poderíamos carregá-los `pandas.read_csv()` ou ainda os construir manualmente (WASKOM, 2020b).


Na linha 4 desenhamos o gráfico de dispersão com as variáveis semânticas. Esse gráfico em particular mostra o relacionamento entre cinco variáveis no conjunto de dados de dicas, sendo três do tipo numérico e duas do tipo categórico. Duas variáveis numéricas, sendo `total_bill` tip responsável por determinar a posição de cada ponto nos eixos, e a terceira `size` variável determinou o tamanho de cada ponto. Uma variável categórica dividiu o conjunto de dados em dois eixos diferentes (facetas) e a outra que determinou a cor e a forma de cada ponto.

A função `relplot()` `seaborn` é que a responsável por realizar tudo isso. Cabe destacar, que fornecemos apenas os nomes das variáveis no conjunto de dados e os papéis que queríamos que eles desempenhassem no gráfico. Diferentemente do uso direto do `matplotlib`, que não era necessário converter as variáveis em parâmetros da visualização, como por exemplo, a cor ou marcador específico a ser usado para cada categoria. Essa tradução foi feita automaticamente pela biblioteca `seaborn` (WASKOM, 2020b).

4.1 ABSTRAÇÃO DE API ENTRE VISUALIZAÇÕES

Não existe uma única forma para realizar a visualização de dados. Ressaltamos que diferentes perguntas serão mais bem respondidas se utilizarmos diferentes visualizações. A biblioteca `Seaborn` visa auxiliar a alternância entre diferentes representações visuais, que podem ser parametrizadas com a mesma `Application Programming Interface (API)` orientada ao conjunto de dados. A função `relplot()`, apresentada na linha 2 do Quadro 31, é chamada dessa maneira devido ter sido projetada para visualizar muitos relacionamentos estatísticos diferentes. Embora os gráficos de dispersão sejam uma maneira altamente eficaz de realizar esta atividade, os relacionamentos em que uma variável representa uma medida de tempo são melhor representados por uma linha função `relplot()` possui um parâmetro `kind` (linha 4), que permite que se alterne facilmente para a plotagem apresentada a seguir (WASKOM, 2020b).

GRÁFICO 21 – REPRESENTAÇÃO ALTERNATIVA PARA MAPEAMENTO SEMÂNTICO EM SEABORN



FONTE: Adaptado de Waskom (2020b)

QUADRO 31 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 dots = sns.load_dataset("dots")
2 sns.relplot(x="time", y="firing_rate", col="align",
3             hue="choice", size="coherence", style="choice", facet_kws=dict(sharex=False),
4             kind="line", legend="full", data=dots);
```

FONTE: Adaptado de Waskom (2020b)

Na linha 3 do Quadro 31, é possível verificar os parâmetros `size` e `style`, que são compartilhados entre os gráficos de dispersão e linha, que afetam as duas visualizações de maneira diferente, tanto alterando a área do marcador e o símbolo quanto a largura da linha e o traçado.

4.2 ESTIMATIVA ESTATÍSTICA E BARRAS DE FERRO


Outra funcionalidade comum de trabalharmos é com o valor médio de uma variável em função de outras variáveis. Em `seaborn` existem funcionalidades que podem executar automaticamente a estimativa estatística necessária para responder a estas perguntas. A codificação correspondente desta visualização está contida no Quadro 32 e a plotagem da visualização está demonstrada no Gráfico 22 (WASKOM, 2020b).

QUADRO 32 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM A SEGUIR

```
1 fmri = sns.load_dataset("fmri")
2 sns.relplot(x="timepoint", y="signal", col="region", hue="event", style="event",
3             kind="line", data=fmri);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 22 – REPRESENTAÇÃO ESTIMATIVA ESTATÍSTICA EM SEABORN



FONTE: Adaptado de Waskom (2020b)

Quando nos referimos que valores estatísticos são estimados, a biblioteca seaborn usa o bootstrapping para calcular intervalos de confiança e desenhar barras de erro que representam a incerteza da estimativa. A estimativa estatística vai além da estatística descritiva. Por exemplo, também é possível aprimorar um gráfico de dispersão para incluir um modelo de regressão linear (e sua incerteza) usando a função `lmplot()`, utilizada na linha 1 do Quadro 33 (WASKOM, 2020b).

QUADRO 33 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.lmplot(x="total_bill", y="tip", col="time", hue="smoker", data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 23 – REPRESENTAÇÃO ESTIMATIVA ESTATÍSTICA EM SEABORN UTILIZANDO A FUNÇÃO LMPLLOT



FONTE: Adaptado de Waskom (2020b)

4.3 PARCELAS CATEGÓRICAS ESPECIALIZADAS


Os gráficos de dispersão e linha padrão visualizam relacionamentos entre variáveis numéricas, mas muitas análises de dados envolvem variáveis categóricas. Existem plotagens otimizadas na biblioteca seaborn para visualizar esse tipo de dados, por meio de `catplot()`. De maneira semelhante temos `relplot()`. Aqui a ideia ao se utilizar `catplot()`, conforme pode ser observado na linha 1 do Quadro 34, é que ela exponha uma API comum orientada a conjuntos de dados, que generalize sobre diferentes representações do relacionamento entre uma variável numérica e uma (ou mais) variáveis categóricas. Essas representações oferecem diferentes níveis de granularidade na apresentação dos dados subjacentes. Para termos um refinamento maior, convém ver todas as observações desenhando um gráfico de dispersão que ajusta as posições dos pontos ao longo do eixo categórico, para que essas variáveis não se sobreponham (WASKOM, 2020b).

QUADRO 34 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.catplot(x="day", y="total_bill", hue="smoker", kind="swarm", data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 24 – PLOTAGEM DE PARCELAS CATEGÓRICAS EM SEABORN



FONTE: Adaptado de Waskom (2020b)


O Quadro 35 traz uma codificação alternativa para essa visualização, por meio da estimativa de densidade do kernel, representando a distribuição subjacente da qual os pontos são representados.

QUADRO 35 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.catplot(x="day", y="total_bill", hue="smoker", kind="violin", split=True, data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 25 – PLOTAGEM DE PARCELAS CATEGÓRICAS EM SEABORN POR MEIO DA ESTIMATIVA DE DENSIDADE



FONTE: Adaptado de Waskom (2020b)


O Quadro 36 traz uma codificação para representar um único valor médio e seu intervalo de confiança em cada categoria.

QUADRO 36 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.catplot(x="day", y="total_bill", hue="smoker", kind="bar", data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 26 – PLOTAGEM DE UM ÚNICO VALOR MÉDIO E SEU INTERVALO DE CONFIANÇA EM CADA CATEGORIA



FONTE: Adaptado de Waskom (2020b)

4.4 FUNÇÕES DE NÍVEL E DE EIXO


Até agora, vimos plotagens com a biblioteca seaborn a nível, que são otimizadas para análise exploratória, devido à possibilidade de configurar a plotagem do matplotlib. A biblioteca seaborn utiliza FacetGrid para trabalhar com parte de eixo. Cada gráfico de nível combina uma função específica de "nível de eixo" com o objeto FacetGrid. O Quadro 37 traz a codificação para desenhar gráficos de dispersão utilizando a função scatterplot() (linha 4) e os gráficos de barras são desenhados utilizando a função barplot(). As funções são chamadas de "nível de eixos" porque são desenhadas em um único eixo do matplotlib, não afetando o restante. O resultado é que a função no nível precisa controlar onde vive, enquanto as funções no nível dos eixos podem ser combinadas em uma matplotlib mais complexa com outros eixos que podem ou não ter plotagens seaborn para representar um único valor médio e seu intervalo de confiança em cada categoria aninhada (WASKOM, 2020b).

QUADRO 37 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 import matplotlib.pyplot as plt
2 f, axes = plt.subplots(1, 2, sharey=True, figsize=(6, 4))
3 sns.boxplot(x="day", y="tip", data=tips, ax=axes[0])
4 sns.scatterplot(x="total_bill", y="tip", hue="day", data=tips, ax=axes[1]);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 27 – PLOTAGEM EM SEABORN UTILIZANDO A FUNÇÃO SCATTERPLOT



FONTE: Adaptado de Waskom (2020b)


Controlar o tamanho das funções no nível funciona um pouco diferente. Em vez de definir o tamanho geral, as funções no nível são parametrizadas pelo tamanho de cada faceta. E ao invés definir a altura e a largura de cada faceta, devemos controlar a altura e aspecto rácio, ou seja, a relação entre largura e altura. Essa parametrização facilita o controle do tamanho do gráfico sem pensar exatamente em quantas linhas e colunas ele terá compreensão (WASKOM, 2020b). O Quadro 38 traz essa codificação para sua melhor.

QUADRO 38 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.relplot(x="time", y="firing_rate", col="align", hue="choice", size="coherence",
2             style="choice",
3             height=4.5, aspect=2 / 3,
4             facet_kws=dict(sharex=False),
5             kind="line", legend="full", data=dots);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 28 – PLOTAGEM EM SEABORN CONTROLANDO O TAMANHO DAS FUNÇÕES



FONTE: Adaptado de Waskom (2020b)



Para sabermos se uma função é a "nível de figura" ou a "nível de eixo" devemos verificar se ela aceita um parâmetro `ax`. Você também pode distinguir as duas classes pelo tipo de saída: funções no nível de eixos retornam o `matplotlib axes`, enquanto funções no nível de figura retornam o `FacetGrid`.

4.5 VISUALIZAÇÃO DA ESTRUTURA DO CONJUNTO DE DADOS


Existem dois outros tipos de funções na biblioteca `seaborn`, que podem ser utilizados para fazer visualizações com vários gráficos. Cada um deles é orientado para iluminar a estrutura de um conjunto de dados. A função `jointplot()` (linha 2 do Quadro 39) se concentra em um único relacionamento (WASKOM, 2020b).

QUADRO 39 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 iris = sns.load_dataset("iris")
2 sns.jointplot(x="sepal_length", y="petal_length", data=iris);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 29 – PLOTAGEM EM SEABORN UTILIZANDO A FUNÇÃO JOINTPLOT



FONTE: Adaptado de Waskom (2020b)


A outra função `pairplot()` (linha 1 do Quadro 40) é quando precisamos ter uma visão mais ampla, que seja necessário mostrar todos os relacionamentos em pares e as distribuições marginais, e de forma opcional condicionar uma variável categórica (WASKOM, 2020b).

QUADRO 40 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.pairplot(data=iris, hue="species");
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 30 – PLOTAGEM EM SEABORN UTILIZANDO A FUNÇÃO PAIRPLOT



FONTE: Adaptado de Waskom (2020b)

Tanto a função `jointplot()` quanto a função `pairplot()` possuem algumas opções diferentes para a representação visual, e eles são construídos em cima de classes que permitem a personalização, como pela `JointGrid` e `PairGrid`, respectivamente.

4.6 PERSONALIZAÇÃO DA PLOTAGEM


As funções de plotagem de forma geral tentam usar boa estética por padrão, bem como costumam adicionar rótulos informativos para que a saída seja relevante. Contudo, ao se trabalhar com a formatação padrão não conseguimos ir muito longe, diferente de trabalharmos com gráficos personalizados. Uma das possibilidades que temos é utilizar a biblioteca `seaborn` para, por exemplo, definir um tema ou paleta de cores diferentes, fazendo com que seja aplicado a todos os gráficos, conforme pode ser visto na codificação do Quadro 41 (WASKOM, 2020b).

QUADRO 41 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.set(style="ticks", palette="muted")
2 sns.relplot(x="total_bill", y="tip", col="time", Hue="smoker", style="smoker", size="size",
3             data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 31 – PLOTAGEM EM SEABORN DEFININDO UM TEMA E A PALETA DE CORES DE FORMA GERAL



FONTE: Adaptado de Waskom (2020b)


Para realizar a personalização, a biblioteca seaborn conta com parâmetros opcionais, que possibilitam trabalhar com mapeamentos semânticos, ou seja, fora do padrão, como no caso de cores diferentes. Cabe destacar, que o uso apropriado da cor é essencial para uma visualização eficaz dos dados. O Quadro 42 traz a codificação de uma correspondência direta com uma função matplotlib subjacente, como scatterplot() e matplotlib.axes.Axes.scatter() (WASKOM, 2020b).

QUADRO 42 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 sns.relplot(x="total_bill", y="tip", col="time", hue="size", style="smoker", size="size",
2             palette="YlGnBu", markers=["D", "o"], sizes=(10, 125),
3             edgecolor=".2", linewidth=.5, alpha=.75,
4             data=tips);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 32 – PLOTAGEM EM SEABORN DEFININDO UM TEMA E A PALETA DE CORES DE FORMA ESPECÍFICA



FONTE: Adaptado de Waskom (2020b)


No caso de `relplot()` e em outras funções no nível, isso significa que existem alguns níveis de indireção, devido `relplot()` passar seus argumentos de palavra-chave extra para a função subjacente de nível de eixos seaborn, que por conseguinte, passa seus argumentos de palavra-chave extras para a função subjacente matplotlib. Portanto, pode ser necessário algum esforço para encontrar a documentação correta para os parâmetros que você precisará usar, mas, em princípio, é possível um nível de personalização extremamente detalhado. Algumas customizações das funções no nível podem ser realizadas por meio de parâmetros adicionais passados para `FacetGrid`, e você pode usar os métodos nesse objeto para controlar muitas outras propriedades. Para ainda mais ajustes, você pode acessar os objetos matplotlib nos quais o gráfico é desenhado, que são armazenados como atributos (WASKOM, 2020b). O Quadro 43 traz uma codificação personalizada dos parâmetros, contidos na linha 1 e linha 2.

QUADRO 43 – CODIFICAÇÃO EM SEABORN DA PLOTAGEM

```
1 g = sns.catplot(x="total_bill", y="day", hue="time", height=3.5, aspect=1.5,
2               kind="box", legend=False, data=tips);
3 g.add_legend(title="Meal")
4 g.set_axis_labels("Total bill ($) ", "")
5 g.set(xlim=(0, 60), yticklabels=["Thursday", "Friday", "Saturday", "Sunday"])
6 g.despine(trim=True)
7 g.fig.set_size_inches(6.5, 3.5)
8 g.ax.set_xticks([5, 15, 25, 35, 45, 55], minor=True);
9 plt.setp(g.ax.get_yticklabels(), rotation=30);
```

FONTE: Adaptado de Waskom (2020b)

GRÁFICO 33 – PLOTAGEM EM SEABORN UTILIZANDO PARÂMETROS ADICIONAIS



FONTE: Adaptado de Waskom (2020b)

Como as funções no nível são orientadas para uma exploração eficiente, usá-las para gerenciar com precisão pode exigir um esforço além do que configurar diretamente no matplotlib e usar a função correspondente no nível dos eixos da biblioteca seaborn.



Apesar do histograma ser uma das análises visuais mais frequentes, cabe lembrar que Jones (1986) coloca, que devemos ver ele como antiquado.



Um importante aspecto de ser definido na construção do conjunto de características diz respeito a granularidade dos dados. Dados simples (grão fino) são geralmente melhores do que dados compostos (grão grosso), pois eles possuem quantidade de análises disponíveis. O conjunto de características deve ser caracterizado para que seus valores sejam conhecidos e explorados. Recomenda-se que seja necessário determinar o tipo, valores possíveis, linhagem e a classe dos dados. Outras importantes caracterizações são a estatística e visual. Com elas é possível fazer a identificação de padrões e da qualidade dos dados. Essas caracterizações são fundamentais para a seleção das melhores características do conjunto.

LEITURA COMPLEMENTAR

CONSTRUÇÃO DO CONJUNTO DE CARACTERÍSTICAS

A construção do conjunto de características é o processo de transformar dados brutos em características que melhor representam o modelo definido pelo entendimento do problema. Um conjunto de características de qualidade é um dos principais aspectos para o sucesso do projeto e envolve a construção, preparação e seleção das melhores de características. O processo de construção depende de um bom entendimento do problema, da qualidade e da representatividade dos dados. A seleção dos dados relevantes que serão transformados em características deve observar três importantes aspectos: regras de negócios envolvidas, processos que manipulam os dados e o contexto do problema.

Uma importante decisão que o preparador de dados deverá tomar é se ele trabalhará com todos os dados ou com uma amostra. Essa amostra pode ser tanto o objeto de seu trabalho ao longo do projeto quanto pode ser um ponto de partida para primeiro executar análises em uma porção dos dados e depois estender essas análises para todos os dados.

A atividade de amostragem dos dados pode ser executada de várias maneiras. A mais comum é a amostragem aleatória, na qual todos os registros têm igual chance de serem escolhidos. Outra abordagem é a amostragem aleatória estratificada. Nessa abordagem, os elementos são agrupados em estratos de acordo com características em comum e depois os registros de cada estrato são escolhidos aleatoriamente. Uma terceira forma de amostragem é a sistemática. Nessa amostragem, um registro é aleatoriamente escolhido e, logo em seguida, estabelece-se uma regra que define como os demais registros serão escolhidos. Exemplo: selecione todo 3º elemento após o último selecionado. Uma quarta maneira de fazer amostragem é por grupo. Nessa técnica, os registros são agrupados e os grupos são aleatoriamente selecionados para compor a amostra.

Deve-se estar atento ao tamanho da amostra, pois ela deve ser representativa, caso contrário os dados amostrados revelarão um comportamento local dos valores que não representam o comportamento global dos valores. Não há uma regra de ouro que define o tamanho da amostra. Essa escolha depende do domínio do problema. Uma forma de garantir uma boa qualidade da amostra é a repetição da análise em diferentes amostras, a fim de constatar uma constância do comportamento observado nas análises.

Análise da distribuição dos valores

Considere o seguinte cenário: um conjunto de características contém a idade de pessoas e o número das casas dessas pessoas. Podemos perceber que os valores de ambas características são inteiros. Contudo, se calcularmos a média dessas características iremos descobrir que a média do número das casas não faz nenhum sentido.

Esse exemplo mostra que o que importa não é apenas o domínio de uma característica, mas também o conjunto de operações permitidas. Os valores das características devem estar em uma escala significativa. Se analisarmos as características do exemplo, podemos perceber que são valores discretos e os números das casas são valores ordinais, ou seja, as duas características estão em escalas diferentes. Continuando no nosso exemplo, podemos afirmar que os vizinhos da casa 726 são as casas 724 e 728. Mas não podemos afirmar que a distância entre as casas 724 e 726 é a mesma que entre as casas 726 e 728.

Apesar de termos vistos em detalhes a classificação das escalas de valores, trazemos, de forma resumida. Os valores podem ser tanto numéricos quanto categóricos. Valores contínuos são valores que representam medidas que podem ter fração (ex.: temperatura). Valores discretos são valores que não podem ter fração (ex.: número de clientes). Valores ordinais indicam uma organização e hierarquia dos valores (ex.: número de estrelas em uma revisão).



Se a característica for numérica, podemos fazer várias operações como: análise da tendência central, análise da dispersão e análise visual dos dados. Em características categóricas as análises mais comuns são as análises visuais que mostram a distribuição dos valores.

Estatísticas de tendência central incluem a média – valor médio do conjunto; a mediana – valor que está no meio do conjunto e a moda – valor que mais se repete no conjunto. Estatísticas de dispersão incluem a variância e desvio padrão – medidas de distâncias dos valores com a média, alcance – valor máximo e valor mínimo do conjunto e medidas de posição – identificam os valores até uma determinada posição (0-25%, 25%-50%).

As análises visuais mais frequentes são a Função de Distribuição Acumulada, também conhecida pelo seu termo em inglês Cumulative Distribution Function (CDF). Nela a visualização é de como as probabilidades estão associadas aos valores; e o histograma, em que é realizada a representação gráfica da distribuição de frequências dos valores da característica. Anteriormente, abordamos as análises gráficas para serem utilizadas com dados numéricos e com dados categóricos.

Estudo de caso: construção de características

No presente estudo de caso iremos utilizar a base de dados Íris que já vem embutida na linguagem R. A figura que segue apresenta como carregar a base de dados Iris no R e como fazer uma exploração inicial, isto é, como analisar a dimensão do conjunto de dados, os nomes das colunas e a estrutura das características.

EXEMPLIFICAÇÃO DE EXPLORAÇÃO DA ESTRUTURA DAS CARACTERÍSTICAS

```
> # INICIO
> #=====
> data(iris)
>
> df <- iris
>
> # TAMANHO E ESTRUTURA DOS DADOS
> #=====
> dim(df)
[1] 150 5
> names(df)
[1] "Sepal.Length" "Sepal.Width" "Petal.Length" "Petal.Width" "Species"
> str(df)
'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species     : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
```

① Linhas e colunas
② Nomes das colunas
③ Estrutura das características

FONTE: Adaptado de Caetano (2018b)

A figura a seguir mostrará a função `attributes` do R, que permite visualizar as características do conjunto, exemplo de linhas e o tipo do dado.

EXEMPLIFICAÇÃO DE EXPLORAÇÃO DOS ATRIBUTOS

```
> #ATRIBUTOS DOS DADOS
> #=====
> attributes(df)
$names
[1] "Sepal.Length" "Sepal.Width" "Petal.Length" "Petal.Width" "Species"

$row.names
[1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30
[31] 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60
[61] 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90
[91] 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120
[121] 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147 148 149 150

$class
[1] "data.frame"
```

FONTE: Adaptado de Caetano (2018b)

A seguir, visualizaremos como selecionar as três primeiras linhas do dataframe com o uso de seleção de linhas (*slicing*) e com a função `head` do R. Também é apresentada a função `tail` que retorna as últimas linhas do dataframe.

SELEÇÃO DE LINHAS DO DATAFRAME NO R

```

> # PRIMEIRAS LINHAS DOS DADOS
> #=====
> df_slice <- df[1:3, ]
> df_slice
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1          3.5          1.4          0.2  setosa
2          4.9          3.0          1.4          0.2  setosa
3          4.7          3.2          1.3          0.2  setosa
> #=====
> head(df, 3)
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1          3.5          1.4          0.2  setosa
2          4.9          3.0          1.4          0.2  setosa
3          4.7          3.2          1.3          0.2  setosa
> #=====
> tail(df, 3)
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
148          6.5          3.0          5.2          2.0 virginica
149          6.2          3.4          5.4          2.3 virginica
150          5.9          3.0          5.1          1.8 virginica
>

```

FONTE: Adaptado de Caetano (2018b)

A figura que segue apresenta comandos utilizados para fazer a seleção de colunas do dataframe. Para selecionar colunas informamos o(s) nome(s) da(s) coluna(s) que queremos filtrar logo após a vírgula em um comando de slicing. Para selecionar linhas, informamos o valor ou intervalo de valores antes da vírgula no slicing.

SELEÇÃO DE COLUNA DO DATAFRAME NO R

```

> # UMA ÚNICA COLUNA
> #=====
> df_slice <- df[1:10, "Sepal.Width"]
> df_slice
[1] 3.5 3.0 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1
> #=====
> df_slice <- df$Sepal.Width[1:10]
> df_slice
[1] 3.5 3.0 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1
>

```

FONTE: Adaptado de Caetano (2018b)

A seguir, veremos o resultado da função `summary` do R. Essa função retorna estatísticas básicas das características do conjunto (mínimo e máximo, média, mediana e quartis). Outra forma de fazer um sumário dos dados é com o uso da função `describe` da biblioteca `Hmisc`. Essa biblioteca permite fazer outras análises dos dados, inclusive identificar valores ausentes e valores distintos.

MÉTODO SUMMARY DO R

```
> # SUMARIZAÇÃO DOS DADOS
> #=====
> summary(df)
  Sepal.Length  Sepal.Width  Petal.Length  Petal.Width      Species
Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100   setosa    :50
1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300   versicolor:50
Median :5.800   Median :3.000   Median :4.350   Median :1.300   virginica :50
Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
>
```

FONTE: Adaptado de Caetano (2018b)

A figura que segue traz as funções do R para calcular medidas de centralidade e de dispersão dos valores de características.

MEDIDAS DE CENTRALIDADE E DISPERSÃO NO R

```
> # ESTATÍSTICA BÁSICA
> #=====
> mean(df$Petal.Length)
[1] 3.758
> median(df$Petal.Length)
[1] 4.35
> var(df$Petal.Length)
[1] 3.116278
> sd(df$Petal.Length)
[1] 1.765298
> range(df$Petal.Length)
[1] 1.0 6.9
> #=====
> quantile(df$Petal.Length)
 0% 25% 50% 75% 100%
1.00 1.60 4.35 5.10 6.90
> #=====
> quantile(df$Petal.Length, c(0.1, 0.3, 0.65))
10% 30% 65%
1.4 1.7 4.8
>
```

FONTE: Adaptado de Caetano (2018b)

Para fazermos a visualização dos dados no R, vamos utilizar a biblioteca ggplot2. Essa biblioteca é uma implementação de uma gramática de gráficos, tem implementação em Python e é popular entre usuários que utilizam o R para visualização de dados. Uma gramática nos diz que um gráfico estatístico é um mapeamento de dados para atributos estéticos (cor, forma e tamanho) de objetos geométricos (pontos, linhas e barras).

A seguir, notaremos a sintaxe de camadas utilizadas em comandos do ggplot2. Em um comando de geração de gráficos, deve-se na primeira camada especificar os dados que serão utilizados e o mapeamento estético (definição de eixos). Em seguida, com a utilização do sinal +, torna-se possível agregar mais camadas que vão definindo as formas, tema e opções do gráfico.

SINTAXE DE CAMADAS DO GGPLOT2



FONTE: Adaptado de Caetano (2018b)

As figuras a seguir representam códigos utilizados para gerar alguns gráficos, que são apresentadas no tópico 2 desta unidade. Poderemos ver que o parâmetro data da primeira camada sempre recebe a base de dados da Iris, em seguida, são definidos os eixos e depois são definidos aspectos estatísticos (tipo do gráfico e como será gerado) e de tema (legenda dos eixos).

EXEMPLIFICAÇÃO DO GRÁFICO DE DISPERSÃO NO GGPLOT2

```
library(ggplot2)

scatter <- ggplot(data=df, aes(x = Sepal.Length, y = Sepal.width))
scatter + geom_point(aes(color=Species, shape=Species)) +
  xlab("Sepal Length") + ylab("Sepal width")
```

FONTE: Adaptado de Caetano (2018b)

EXEMPLIFICAÇÃO DO GRÁFICO DE CAIXAS NO GGPLOT2

```
box <- ggplot(data=iris, aes(x=Species, y=Sepal.Length))
box + geom_boxplot(aes(fill=Species)) +
  ylab("Sepal Length") +
  stat_summary(fun.y=mean, geom="point", shape=5, size=4)
```

FONTE: Adaptado de Caetano (2018b)

EXEMPLIFICAÇÃO DO GRÁFICO HISTOGRAMA NO GGPLOT2

```
histogram <- ggplot(data=iris, aes(x=Sepal.width))
histogram + geom_histogram(binwidth=0.2, color="black", aes(fill=Species)) +
  xlab("Sepal width") + ylab("Frequency")
```

FONTE: Adaptado de Caetano (2018b)

EXEMPLIFICAÇÃO DO GRÁFICO DE DENSIDADE NO GGLOT2

```
density2 <- ggplot(data=iris, aes(x=Sepal.Width, fill=Species))  
density2 + geom_density(stat="density", alpha=I(0.2)) +  
  xlab("Sepal width") + ylab("Density")
```

FONTE: Adaptado de Caetano (2018b)

Além da biblioteca ggplot2 do R, existem outras plataformas e ferramentas que permitem a realização da exploração de dados. Dentre as mais conhecidas estão: scikit-learn, TensorFlow e NumPy, todas do Python. Além dessas, temos também ferramentas bem conhecidas, como: Plotly, matplotlib, pandas e Google Maps APIs.

FONTE: CAETANO, J. A. **Preparação de dados**. 2018b. Disponível em: <https://rapido.igti.com.br/products/pdd-class>. Acesso em: 11 fev. 2020.

RESUMO DO TÓPICO 3

Neste tópico, você aprendeu que:

- Um conjunto de dados é composto por um ou mais atributos, que o definem e são chamados de descritores.
- Os termos pixel e voxel são usados de maneira, representando a utilização de imagens 2D ou 3D.
- Quando utilizamos o termo valor do pixel, se refere à intensidade no caso de imagens representadas em tons de cinza; ou à cor, no caso de imagens coloridas.
- Atributos podem ser calculados em função de uma série de pixels próximos, ou seja, a região de interesse.
- Uma região de interesse pode representar uma parte de uma imagem ou até mesmo de uma imagem completa.
- "Pandas é uma biblioteca em Python que permite trabalhar com grandes quantidades de dados de uma forma muito fácil: é possível carregar planilhas e tabelas, trabalhando-as do mesmo jeito que você trabalharia em um banco de dados SQL [...]" (WANGENHEIM, 2019, p. 1).
- "O pandas é uma ferramenta de análise e manipulação de dados de código aberto, rápida, poderosa, flexível e fácil de usar, construída sobre a linguagem de programação Python" (PANDAS, 2020a, p. 1, tradução nossa).
- O tipo de dado mais elementar em pandas é o DataFrame.
- Quando falamos em estatística, pode-se dizer que a área da matemática que envolve coleta, análise, interpretação e apresentação de grandes conjuntos de dados numéricos.
- A estatística descritiva "[...] é a parte da Estatística que visa descrever e sumarizar um conjunto de dados. Para isso, são usadas uma série de medidas, como a famosa média" (GALVÃO, 2016, p. 1).
- "As medidas da Estatística Descritiva se dividem entre medidas de tendência central e medidas de dispersão" (GALVÃO, 2016, p. 1).
- Os valores significativos para um conjunto de dados são definidos pelas medidas de tendência central.

- As medidas de tendência central definem valores que são adequados e representativos nesse conjunto, que depende do que se quer analisar.
- As medidas de tendência central podem ser classificadas como média, mediana, quantis e a moda apenas para que se possa conferir que está tudo sendo calculado corretamente.
- A média é uma das medidas de tendência central utilizada para indicar o valor no qual estão centralizados (concentrados) os dados de um determinado conjunto de valores, que representam um valor importante para esse mesmo conjunto.
- A média no caso dos Dataframes do Pandas é calculada por meio da função `mean()` dos Dataframes, presente também nas Series do Pandas.
- “A mediana é o valor que separa a metade superior da metade inferior de uma distribuição de dados, ou o valor no centro da distribuição” (GALVÃO, 2016, p. 1).
- “A mediana é um conceito menos suscetível a grandes valores discrepantes do que a média” (GALVÃO, 2016, p. 1).
- O quantil pode ser visto como uma generalização da mediana.
- O valor que estiver abaixo do valor que conter um determinado percentual é o quantil.
- A função `quantile()` utiliza o percentual de 50% por default, que é representado por meio do parâmetro `q`.
- A moda é uma medida central simples, devido ser o valor que aparece com mais frequência dentro de um conjunto de dados.
- No Pandas, calculamos a moda por meio da função `mode()`.
- “As medidas de dispersão são medidas que indicam o quão espalhados os dados estão, ou como eles variam. São elas a amplitude, a variância, o desvio padrão e o desvio absoluto” (GALVÃO, 2016, p. 1).
- A amplitude é a diferença entre o maior valor de um conjunto de dados e o menor valor desse mesmo conjunto de dados.
- No pandas, podemos usar a função `max()`, que retorna o maior valor de um conjunto de dados e a função `min()`, que retorna o menor valor de um conjunto de dados.

- Para realizar o cálculo da diferença basta diminuirmos o valor máximo do valor mínimo.
- A variância no pandas é calculada por meio da função `var()`. Essa medida mostra o quanto os dados de um conjunto de dados estão distantes de seu valor esperado.
- Outra medida de dispersão é o desvio padrão, também é uma medida de dispersão, que demonstra o quanto os dados estão distanciados da média.
- No pandas, o cálculo do desvio padrão do pandas é realizado por meio da função `std()`.
- Para realizar o cálculo do desvio absoluto primeiro precisamos encontrar a média dos valores; posteriormente, devemos calcular a distância de cada ponto desta média; depois devemos somar as distâncias e dividir o resultado pela média destas distâncias.
- O cálculo no pandas do desvio absoluto é realizado por meio da função `mad()`.
- A correlação e a variância devem ser utilizadas nos casos que se queira ter conhecimento se duas variáveis contenham alguma relação mútua dentro de um conjunto de dados.
- No pandas, a covariância pode ser calculada por meio da função `cov()`, retornando uma matriz demonstrando a covariância de cada coluna com outra.
- No Pandas, a correlação é calculada por meio da função `corr()`.
- A função `corr()`, da mesma forma que a função `cov()`, retorna uma matriz com a respectiva correlação para cada coluna correspondente com as outras colunas do Dataframe.
- O Matplotlib é uma biblioteca de plotagem 2 Dimensões (2D) da linguagem Python que produz números de qualidade de publicação em formatos variados tanto de cópia impressa quanto em ambientes interativos entre plataformas.
- O Matplotlib pode ser utilizado em scripts Python, nos shell Python e IPython, no notebook Jupyter, em servidores de aplicativos da web e em quatro kits de ferramentas da interface gráfica do usuário.
- Existem kits de ferramentas complementares, incluindo plotagem 3 Dimensões (3D) com `mplot3d`, eixos auxiliares `axes_grid1` e eixos auxiliares `axisartist`.

- Os pacotes de terceiros objetivam estender a ferramenta. Nesses pacotes está incluído o Seaborn que veremos no item 3 deste tópico. Além dele, temos holoviews, ggplot entre outros e dois conjuntos de ferramentas utilizadas para projeção e mapeamento, que são BaseMap e cartopy.
- O Matplotlib visa apoiar as atividades fáceis e difíceis, podendo ser utilizado na geração de gráficos, histogramas, espectros de potência, gráficos de barras, gráficos de erros, gráficos de dispersão etc. com apenas algumas linhas de código.
- Para plotagem simples o módulo pyplot fornece uma interface semelhante ao MATLAB, principalmente quando utilizada em conjunto com o IPython.
- Frequentemente, precisamos usar variáveis categóricas no Matplotlib, sendo possível passar variáveis categóricas diretamente para muitas outras funções de plotagem.
- Na visualização de distribuição discreta, podemos utilizar plotagem de barras empilhadas.
- Em Matplotlib, o empilhamento horizontal é realizado por meio de `barh()` para cada categoria e passando o ponto de partida como a soma cumulativa dos bares já tiradas por meio do parâmetro `left`.
- Anexar uma transformação afim (`Affine2D`) à transformação de dados de uma imagem possibilita a manipulação e a orientação da imagem.
- Existe situação que desejamos apresentar dados que dependem de duas variáveis independentes como um gráfico de imagem com código de cores. Essa situação é chamada de mapa de calor.
- Quando os dados são categóricos é chamado de mapa de calor categórico.
- Em matplotlib, a função `imshow` facilita a produção de tais parcelas.
- Seaborn é uma biblioteca de visualização de dados na linguagem Python baseada na biblioteca matplotlib e estreitamente integrado às estruturas de dados do pandas.
- A biblioteca seaborn fornece uma interface de alto nível para desenhar gráficos estatísticos atraentes e informativos.
- O Seaborn visa tornar a visualização uma parte central da exploração e uma melhor compreensão dos dados.

- As funções de plotagem orientadas a conjuntos de dados operam em quadros de dados e matrizes, que contém conjuntos de dados inteiros, que executam internamente o mapeamento semântico necessário e a agregação estatística para produzir gráficos informativos.
- Não existe uma única forma de realização a visualização de dados.
- As diferentes perguntas serão mais bem respondidas se utilizarmos diferentes visualizações.
- A biblioteca Seaborn tenta facilitar a alternância entre diferentes representações visuais que podem ser parametrizadas com a mesma Application Programming Interface (API) orientada a conjuntos de dados.
- A função `relplot()` é chamada dessa maneira devido ter sido projetada para visualizar muitos relacionamentos estatísticos diferentes.
- Quando nos referimos que valores estatísticos são estimados, a biblioteca seaborn usa o bootstrapping para calcular intervalos de confiança e desenhar barras de erro que representam a incerteza da estimativa.
- A estimativa estatística vai além da estatística descritiva, permitindo aprimorar um gráfico de dispersão para incluir um modelo de regressão linear (e sua incerteza) usando a função `lmplot()`.
- Os gráficos de dispersão e linha padrão visualizam relacionamentos entre variáveis numéricas, mas muitas análises de dados envolvem variáveis categóricas.
- Existem plotagens otimizadas na biblioteca seaborn para visualizar esse tipo de dados, por meio de `catplot()`.
- A biblioteca seaborn utiliza `FacetGrid` para trabalhar com parte de eixo. Cada gráfico de nível de figura diferente `kind` combina uma função específica de "nível de eixo" com o objeto `FacetGrid`.
- Existem dois outros tipos de funções na biblioteca seaborn, que podem ser utilizados para fazer visualizações com vários gráficos, sendo `pairplot()` e `jointplot()`.
- A função `jointplot()` da biblioteca seaborn se concentra em um único relacionamento.
- A função `pairplot()` da biblioteca seaborn deve ser utilizada quando precisamos ter uma visão mais ampla, que seja necessário mostrar todos os relacionamentos em pares e as distribuições marginais, e de forma opcional condicionar uma variável categórica.

- Para realizar a personalização de uma figura específica da figura, a biblioteca seaborn conta com parâmetros opcionais, que possibilitam trabalhar com mapeamentos semânticos, ou seja, fora do padrão, como no caso de cores diferentes.
- Algumas customizações das funções no nível da figura podem ser realizadas por meio de parâmetros adicionais passados para FacetGrid, e você pode usar os métodos nesse objeto para controlar muitas outras propriedades da figura.
- Como as funções no nível da figura são orientadas para uma exploração eficiente, usá-las para gerenciar uma figura que precisa ser dimensionada e organizada com precisão pode exigir um esforço além do que configurar a figura diretamente no matplotlib e usar a função correspondente no nível dos eixos da biblioteca seaborn.



Ficou alguma dúvida? Construímos uma trilha de aprendizagem pensando em facilitar sua compreensão. Acesse o QR Code, que levará ao AVA, e veja as novidades que preparamos para seu estudo.






1 O Seaborn visa tornar a visualização uma parte central da exploração e uma melhor compreensão dos dados. Suas funções de plotagem orientadas a conjuntos de dados operam em quadros de dados e matrizes contém conjuntos de dados inteiros e executam internamente o mapeamento semântico necessário e a agregação estatística para produzir gráficos informativos. Diante disso, qual é a sentença que importa a biblioteca seaborn?


- a) ☐ Import matplotlib.
- b) ☐ Import seaborn as sns.
- c) ☐ Import pandas.
- d) ☐ Import sql.

2 Os gráficos de dispersão e linha padrão visualizam relacionamentos entre variáveis numéricas, mas muitas análises de dados envolvem variáveis categóricas. Existem plotagens otimizadas na biblioteca seaborn para visualizar esse tipo de dados, por meio de catplot(). Diante disso, qual sentença traz a plotagem que utiliza a codificação sns.catplot(x="day", y="total_bill", hue="smoker", kind="swarm", data=tips);?


a) ☐




b) ☐



c) ()




d) ()




3 Existem dois outros tipos de funções na biblioteca seaborn, que podem ser utilizados para fazer visualizações com vários gráficos, sendo pairplot() e jointplot(). Cada um deles é orientado para iluminar a estrutura de um conjunto de dados. A função jointplot() se concentra em um único relacionamento e a função pairplot() é utilizada quando precisamos ter uma visão mais ampla, ou seja, em situações que precisamos apresentar todos os relacionamentos em pares e as distribuições marginais, e de forma opcional condicionar uma variável categórica. Qual sentença traz a plotagem da codificação <iris = sns.load_dataset("iris") sns.jointplot(x="sepal_length", y="petal_length", data=iris);>?


a) ()




b) ()



c) ()




d) ()




- 4 Existem dois outros tipos de funções na biblioteca seaborn, que podem ser utilizados para fazer visualizações com vários gráficos, sendo `pairplot()` e `jointplot()`. Cada um deles é orientado para iluminar a estrutura de um conjunto de dados. A função `jointplot()` se concentra em um único relacionamento e a função `pairplot()` é utilizada quando precisamos ter uma visão mais ampla, ou seja, em situações que precisamos apresentar todos os relacionamentos em pares e as distribuições marginais, e de forma opcional condicionar uma variável categórica. Qual sentença traz a plotagem da codificação `<iris = sns.load_dataset("iris") sns.pairplot(data=iris, hue="species")>?`


a) ()




b) ()



c) ()



d) ()



5 As funções de plotagem de forma geral tentam usar boa estética por padrão, bem como costumam adicionar rótulos informativos para que a saída seja relevante. Contudo, ao se trabalhar com a formatação padrão não conseguimos ir muito longe, diferente de trabalharmos com gráficos personalizados. Uma das possibilidades que temos é utilizar a biblioteca seaborn para, por exemplo, definir um tema ou paleta de cores diferentes, fazendo com que seja aplicado a todos os gráficos. Diante disso, qual sentença traz esta codificação genérica?

a) ()

```
sns.set(style="ticks", palette="muted")
sns.relplot(x="total_bill", y="tip", col="time", Hue="smoker", style="smoker",
size="size",
data=tips);
```

b) ()

```
vsns.relplot(x="total_bill", y="tip", col="time", hue="size", style="smoker",
size="size", palette="YlGnBu", markers=["D", "o"], sizes=(10, 125),
edgecolor=".2", linewidth=.5, alpha=.75, data=tips);
```

c) ()

```
g = sns.catplot(x="total_bill", y="day", hue="time", height=3.5, aspect=1.5,
kind="box", legend=False, data=tips);
g.add_legend(title="Meal")
g.set_axis_labels("Total bill ($)", "")
g.set(xlim=(0, 60), yticklabels=["Thursday", "Friday", "Saturday", "Sunday"])
g.despine(trim=True)
g.fig.set_size_inches(6.5, 3.5)
g.ax.set_xticks([5, 15, 25, 35, 45, 55], minor=True);
9 plt.setp(g.ax.get_yticklabels(), rotation=30);
```

d) ()

```
sns.pairplot(data=iris, hue="species");
```

REFERÊNCIAS

AI MULTIPLE. **60 top Data Science tools**: in-depth guide. 2019. Disponível em: <https://blog.aimultiple.com/data-science-tools/>. Acesso em: 11 fev. 2020.

ALEGEORGELUSTOSA. **Métodos de tratamento para dados categóricos em python!** 2018. Disponível em: <https://medium.com/@alegeorgelustosa/m%C3%A9todos-de-tratamento-para-dados-categ%C3%B3ricos-em-python-a66f910215c7>. Acesso em: 18 fev. 2020.

ALTERYX. **Why organizations choose alteryx**. 2020. Disponível em: <https://www.alteryx.com/>. Acesso em: 11 fev. 2020.

AMAZON WEB SERVICES. **Qubole na base de data lake**. 2020. Disponível em: <https://aws.amazon.com/pt/quickstart/architecture/qubole-on-data-lake-foundation/>. Acesso em: 11 fev. 2020.

AZEVEDO, R. P. de. **Big Data e proteção dos dados (1)**. 2020. Disponível em: <https://www.diariodepernambuco.com.br/noticia/opiniaio/2020/01/big-data-e-protecao-dos-dados-1.html>. Acesso em: 30 jan. 2020.

CAETANO, J. A. **Por que estudar preparação de dados?** 2018a. Disponível em: <https://igti.com.br/blog/por-que-estudar-preparacao-de-dados/>. Acesso em: 11 fev. 2020.

CAETANO, J. A. **Preparação de dados**. 2018b. Disponível em: <https://rapido.igti.com.br/products/pdd-class>. Acesso em: 11 fev. 2020.

CAI, L.; ZHU, Y. The challenges of Data Quality and Data Quality assessment in the Big Data era. **Data Science Journal**, v. 2, n. 14, p. 1-10, 2015.

CHAPMAN, R. **50 reporting tools for Data scientists in 2019 from experts**. 2019. Disponível em: <https://limeproxies.com/blog/50-reporting-tools-data-scientists-2019-experts/#data>. Acesso em: 11 fev. 2020.

CLEVELAND, W. S. **Visualizing data**. EUA: Hobart Press, 1993.

CLEVELAND, W. S. **The elements of graphing data**. Massachusetts: Wadsworth Publ., 1985.

CLEVELAND, W. S.; MCGILL, R. Graphical perception: theory, experimentation, and application to the development of graphical methods. **Journal of the American Statistical Association**, v. 79, n. 387, p. 531-554, 1984.

COUGHLIN, T. **175 zettabytes until 2025**. 2018. Disponível em: <https://www.forbes.com/sites/tomcoughlin/2018/11/27/175-zettabytes-by-2025/#ed0e77c54597>. Acesso em: 30 jan. 2020.

DA COSTA CÔRTEZ, S.; PORCARO, R. M.; LIFSCHITZ, S. **Mineração de dados-funcionalidades, técnicas e abordagens**. São Paulo: PUC, 2002.

DATA ACIENCE ACADEMY. **Web Scraping e Web Crawling são legais ou ilegais?** 2018. Disponível em: <http://datascienceacademy.com.br/blog/web-scraping-e-web-crawling-sao-legais-ou-ilegais/>. Acesso em: 11 fev. 2020.

DATAROBOT. **Crie modelos incríveis com total transparência**. 2020. Disponível em: <https://www.datarobot.com/pt/solutions/it-professionals/>. Acesso em: 11 fev. 2020.

ECO R. **4. Análise Exploratória de Dados**. 2016. Disponível em: http://ecologia.ib.usp.br/bie5782/doku.php?id=bie5782:03_apostila:05-exploratoria#graficos_de_densidade. Acesso em: 11 mar. 2020.

ELIAS, D. **Conhecendo a arquitetura de Data Warehouse**. 2014. Disponível em: <https://canaltech.com.br/business-intelligence/conhecendo-a-arquitetura-de-data-warehouse-19266/>. Acesso em: 9 fev. 2020.

ETMANN, Al. **Big Data...The analytics life cycle**. 2018. Disponível em: <https://www.linkedin.com/pulse/big-datathe-analytics-life-cycle-alaa-etman/>. Acesso em: 4 fev. 2020.

GALARNYK, M. **Understanding boxplots**. 2018. Disponível em: <https://towardsdatascience.com/understanding-boxplots-5e2df7bcbd51>. Acesso em: 14 fev. 2020.

GALVÃO, F. **Estatística descritiva com pandas**. 2016. Disponível em: <http://felipegalvao.com.br/blog/2016/03/31/estatistica-descritiva-com-python/>. Acesso em: 3 mar. 2020.

GARG, A.; UPADHYAYA, S.; KWIAT, K. **A user behavior monitoring and profiling scheme for masquerade detection**. Amsterdã: Elsevier, 2013.

GELMAN, A.; HILL, J. **Missing-data imputation**. Cambridge: Cambridge University Press, 2006.

GOLDSCHMIDT, R.; PASSOS, E. **Data Mining: um guia prático**. Rio de Janeiro: Elsevier, 2005.

GOMES, P. C. T. **Conheça as etapas do pré-processamento de dados**. 2019. Disponível em: <https://www.datageeks.com.br/pre-processamento-de-dados/>. Acesso em: 9 fev. 2020.

GONZALEZ, L. F. P. *et al.* **Segmentação automática de tecidos cerebrais em imagens de ressonância magnética do tipo fluid-attenuated inversion recovery**. 2018. Tese (Doutorado em Computação Aplicada) – Programa de Pós-Graduação em Computação Aplicada, PUC, Rio Grande do Sul.

GONÇALVES, R. P.; LIMA, E. C. P. **Multidimensional interpolation filters development for risers' database analysis**. EUA: American Society of Mechanical Engineers Digital Collection, 2013.

HAMMER, C.; KOSTROCH, D.; QUIROS, G. Big Data: potential, challenges and statistical implications. **Staff Discussion Notes**, v. 17, n. 6, p. 41, 2017.

HAN, J.; KAMBER, M. **Data Mining – concepts and techniques**. San Francisco: Morgan Kaufman Publishers, 2001.

HASLWANTER, T. **An introduction to statistics with python**. Michigan: Springer, 2016.

HAYKIN, S. **Neural networks: a comprehensive foundation**. Saddle River: Prentice Hall, 1999.

HINTON, T. **What Is Data Enrichment?** 2018. Disponível em: <https://www.redpointglobal.com/blog/what-is-data-enrichment/>. Acesso em: 9 fev. 2020.

HOAGLIN, D. C.; MOSTELLER, F.; TUKEY, J. W. **Understanding robust and exploratory data analysis**. New York: Wiley, 1983.

HUNTER, J. *et al.* **Matplotlib**. 2020a. Disponível em <https://matplotlib.org/index.html>. Acesso em: 11 mar. 2020.

HUNTER, J. *et al.* **Grouped bar chart with labels**. 2020b. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/bar_stacked.html#sphx-glr-gallery-lines-bars-and-markers-bar-stacked-py. Acesso em: 11 mar. 2020.

HUNTER, J. *et al.* **Horizontal bar chart**. 2020c. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/barh.html#sphx-glr-gallery-lines-bars-and-markers-barh-py. Acesso em: 11 mar. 2020.

HUNTER, J. *et al.* **Plotting categorical variables**. 2020d. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/cohere.html#sphx-glr-gallery-lines-bars-and-markers-cohere-py. Acesso em: 11 mar. 2020.

HUNTER, J. *et al.* **Plotting the coherence of two signals**. 2020e. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/barh.html#sphx-glr-gallery-lines-bars-and-markers-barh-py. Acesso em: 3 mar. 2020.

HUNTER, J. *et al.* **Discrete distribution as horizontal bar chart.** 2020f. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/horizontal_barchart_distribution.html#sphx-glr-gallery-lines-bars-and-markers-horizontal-barchart-distribution-py. Acesso em: 3 mar. 2020.

HUNTER, J. *et al.* **Creating a timeline with lines, dates, and text.** 2020g. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/timeline.html#sphx-glr-gallery-lines-bars-and-markers-timeline-py. Acesso em: 3 mar. 2020.

HUNTER, J. *et al.* **Cross- and auto-correlation demo.** 2020h. Disponível em: https://matplotlib.org/gallery/lines_bars_and_markers/xcorr_acorr_demo.html#sphx-glr-gallery-lines-bars-and-markers-xcorr-acorr-demo-py. Acesso em: 3 mar. 2020.

HUNTER, J. *et al.* **Affine transform of an image.** 2020i. Disponível em: https://matplotlib.org/gallery/images_contours_and_fields/affine_image.html#sphx-glr-gallery-images-contours-and-fields-affine-image-py. Acesso em: 3 mar. 2020.

HUNTER, John *et al.* **Creating annotated heatmaps.** 2020j. Disponível em: https://matplotlib.org/gallery/images_contours_and_fields/image_annotated_heatmap.html#sphx-glr-gallery-images-contours-and-fields-image-annotated-heatmap-py. Acesso em: 3 mar. 2020.

IDC INFOGRAPHIC. **Data Age 2025.** 2017. Disponível em: <https://diarioti.com/wp-content/uploads/2017/07/data-age-2025-infographic-2017.pdf>. Acesso em: 30 jan. 2020.

INMON, W. H. **Building the Data Warehouse.** Indianapolis: John Wiley & Sons Inc., 2005.

JONES, L. V. **The collected works of John W. Tukey: philosophy and principles of data analysis 1949–1964.** London: Chapman and Hall/CRC, 1986.

KAGGLE. **Credit Card fraud detection.** 2018. Disponível em: <https://www.kaggle.com/mlg-ulb/creditcardfraud#>. Acesso em: 9 fev. 2020.

KAGGLE. **The state of Data Science & Machine Learning 2017.** 2017. Disponível em: <https://www.kaggle.com/surveys/2017>. Acesso em: 10 fev. 2020.

KATZ, E. **The complete guide to Data Enrichment.** 2019. Disponível em: <https://www.oktopost.com/blog/complete-guide-data-enrichment/>. Acesso em: 9 fev. 2020.

KENNETH, B.; TRINITY, C.; DUBLIN, I. **Data analysis, exploratory.** EUA: SAGE Publications, 2011.

LANEY, D. 3D Data Management: controlling data volume, velocity and variety. **Meta Group Research Note**, v. 1, n. 1, p. 1-3, 2001.

MASHANOVICH, N. **Credit Scoping**: Part 3 – Data Preparation and Exploratory Data Analysis. 2017. Disponível em: https://www.worldprogramming.com/blog/credit_scoring_pt3. Acesso em: 30 jan. 2020.

MONTEIRO, L. P. **Dados estruturados e não estruturados**. 2020. Disponível em <https://universidadedatecnologia.com.br/dados-estruturados-e-nao-estruturados/>. Acesso em: 9 fev. 2020.

MUNIZ, D. G. **Análise exploratória de dados**. 2017. Disponível em: <http://docplayer.com.br/68663747-Analise-exploratoria-de-dados-danilo-g-muniz-curso-de-r-ppg-em-ecologia-ib-usp.html>. Acesso em: 22 fev. 2020.

PANDAS. **Pandas**. 2020a. Disponível em: <https://pandas.pydata.org/>. Acesso em: 3 mar. 2020.

PANDAS. **Pandas documentation**. 2020b. Disponível em: <https://pandas.pydata.org/docs/>. Acesso em: 3 mar. 2020.

PANDAS. **Getting started**. 2020c. Disponível em: https://pandas.pydata.org/docs/getting_started/index.html#getting-started. Acesso em: 3 mar. 2020.

PANDAS. **About pandas**. 2018a. Disponível em: <https://pandas.pydata.org/about/index.html>. Acesso em: 2 mar. 2020.

PANDAS. **10 minutes to pandas**. 2018b. Disponível em: https://pandas.pydata.org/pandas-docs/stable/getting_started/10min.html. Acesso em: 3 mar. 2020.

PENNSSTATE. **Lesson 1(b)**: Exploratory Data Analysis (EDA). 2020. Disponível em: <https://online.stat.psu.edu/stat508/lesson/1b>. Acesso em: 30 jan. 2020.

PICKELL, D. **Structured vs Unstructured Data – what's the difference?** 2018. Disponível em: <https://learn.g2.com/structured-vs-unstructured-data>. Acesso em: 6 fev. 2020.

PRICEONOMICS. **How William Cleveland turned data visualization into a science**. 2016. Disponível em: <https://priceonomics.com/how-william-cleveland-turned-data-visualization/>. Acesso em: 27 fev. 2020.

PROJECTPRO. **Why Data Preparation is na important part of Data Science?** 2016. Disponível em: <https://www.dezyre.com/article/why-data-preparation-is-an-important-part-of-data-science/242>. Acesso em: 3 fev. 2020.

PYLE, D. **Data Preparation for Data Mining**. 1999. Disponível em: https://www.researchgate.net/publication/220355854_Data_Preparation_for_Data_Mining. Acesso em: 30 jan. 2020.

REINSEL, D.; GANTZ, J.; RYDNING, J. **Data Age 2025 the digitization of the world**. 2020. Disponível em: <https://www.seagate.com/br/pt/our-story/data-age-2025/>. Acesso em: 30 jan. 2020.

RUSSOM, P. Big Data analytics. **TDWI bests practices report, fourth quarter**, v. 19, n. 4, p. 1-37, 2011.

SANTANA, R. **One Hot Encoding? Entenda como funciona com exemplos em python**. 2018. Disponível em <https://minerandodados.com.br/one-hot-encoding-como-funciona-python/>. Acesso em: 19 fev. 2020.

SAS INSIGHTS. **Análises preditivas: o que são e qual sua importância?** 2019. Disponível em: https://www.sas.com/pt_br/insights/analytics/analises-preditivas.html. Acesso em: 9 mar. 2020.

SGB. **O que você precisa entender sobre dados para se tornar uma organização Data Driven**. 2019. Disponível em: <http://socialgoodbrasil.org.br/2019/05/15/entenda-tudo-sobre-dados-para-se-tornar-uma-organizacao-data-driven/>. Acesso em: 30 jan. 2020.

TAYLOR, C. **Structured vs. Unstructured Data**. 2018. Disponível em: <https://www.datamation.com/big-data/structured-vs-unstructured-data.html>. Acesso em: 5 fev. 2020.

TIBCO. **Criando um gráfico de densidade**. 2019. Disponível em: https://docs.tibco.com/pub/spotfire_server/10.3.3/doc/html/pt-BR/TIB_sfire-bauthor-consumer_usersguide/GUID-1FCED7C1-8FC8-4F19-B880-85D54570A90B.html. Acesso em: 11 fev. 2020.

TORGO, L. **Data Mining with R: learning with case studies**. New York: Chapman and Hall/CRC, 2017.

TUKEY, J. W. **Exploratory data analysis**. London: Pearson, 1977.

VARIAWA, R. **Data Pre-processing & Data Wrangling**. 2019. Disponível em: <https://medium.com/swlh/data-pre-processing-data-wrangling-4a6a8624e747>. Acesso em: 06 fev. 2020.

WANGENHEIM, A. V. **Ciência de dados: aprendendo a trabalhar com pandas**. 2019. Disponível em: <http://www.lapix.ufsc.br/ensino/reconhecimento-de-padroes/ciencia-de-dados-aprendendo-trabalhar-com-pandas/>. Acesso em: 2 mar. 2020.

WARCHOLINSKI, M. **5 steps on how to approach a new Data Science problem**. 2019. Disponível em: <https://brainhub.eu/blog/how-to-approach-data-science-problem/>. Acesso em: 4 fev. 2020.

WASKOM, M. **Seaborn**: statistical data visualization. 2020a. Disponível em: <https://seaborn.pydata.org/>. Acesso em: 3 mar. 2020.

WASKOM, M. **An introduction to seaborn**. 2020b. Disponível em: <https://seaborn.pydata.org/introduction.html>. Acesso em: 9 mar. 2020.

WICKHAM, H. Tidy data. **Journal of Statistical Software**, v. 59, n. 10, p. 1-23, 2014.

WIKIPEDIA. **Rapidminer**. 2019. Disponível em: <https://pt.wikipedia.org/wiki/RapidMiner>. Acesso em: 11 fev. 2020.

ZEVIANI, W. M. **Visualização de dados**: análise exploratória e explanatória. 2018. Disponível em: <http://www.leg.ufpr.br/~walmes/ensino/dsbd/visualizacao-dados.html#1>. Acesso em: 11 mar. 2020.