



SISTEMAS ESPECIALISTAS



HUGO BULEGON



ACESSE AQUI ESTE
MATERIAL DIGITAL!

EXPEDIENTE

Coordenador(a) de Conteúdo

Greisse Moser Badalotti

Projeto Gráfico e Capa

Arthur Cantareli Silva

Editoração

Ellen Jeane Versari

Yago Luiz Nardelli

Design Educacional

Letícia Matheucci Zambrana Grou

Revisão Textual

Carlos Augusto Brito Oliveira

Ilustração

André Azevedo

Geison Odlevati Ferreira

Fotos

Shutterstock e Envato

FICHA CATALOGRÁFICA

N964 Núcleo de Educação a Distância. **BULEGON**, Hugo.

Sistemas Especialistas / Hugo Bulegon. - Florianópolis, SC: Arquê,
2025.

208 p.

ISBN papel 978-65-279-0844-9

ISBN digital 978-65-279-0842-5

1. Especialista 2. Sistemas 3. Software. EaD. I. Título.

CDD - 005.14

Bibliotecária: Leila Regina do Nascimento - CRB- 9/1722.

Ficha catalográfica elaborada de acordo com os dados fornecidos pelo(a) autor(a).

Impresso por:

AVALIE ESTE LIVRO!



CRIAR MOMENTOS DE APRENDIZAGENS
INESQUECÍVEIS É O NOSSO OBJETIVO E POR ISSO,
GOSTARIAMOS DE SABER COMO FOI SUA EXPERIÊNCIA.

Conta para nós! leva menos de 2 minutos. Vamos lá?!

DIGITE O CÓDIGO

 03507507

— Aa

**RESPONDA A
PESQUISA**



— ...



RECURSOS DE IMERSÃO



PENSANDO JUNTOS

Este item corresponde a uma proposta de reflexão que pode ser apresentada por meio de uma frase, um trecho breve ou uma pergunta.



APROFUNDANDO

Utilizado para temas, assuntos ou conceitos avançados, levando ao aprofundamento do que está sendo trabalhado naquele momento do texto.

PRODUTOS AUDIOVISUAIS

Os elementos abaixo possuem recursos audiovisuais. Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.



PLAY NO CONHECIMENTO

Professores especialistas e convidados, ampliando as discussões sobre os temas por meio de fantásticos podcasts.



EU INDICO

Utilizado para agregar um conteúdo externo.



EM FOCO

Utilizado para aprofundar o conhecimento em conteúdos relevantes utilizando uma linguagem audiovisual.



ZOOM NO CONHECIMENTO

Utilizado para desmistificar pontos que possam gerar confusão sobre o tema. Após o texto trazer a explicação, essa interlocução pode trazer pontos adicionais que contribuam para que o estudante não fique com dúvidas sobre o tema.




INDICAÇÃO DE FILME

Uma dose extra de conhecimento é sempre bem-vinda. Aqui você terá indicações de filmes que se conectam com o tema do conteúdo.



INDICAÇÃO DE LIVRO

Uma dose extra de conhecimento é sempre bem-vinda. Aqui você terá indicações de livros que agregarão muito na sua vida profissional.



SUMÁRIO

7

UNIDADE 1

INTRODUÇÃO AOS SISTEMAS ESPECIALISTAS	8
REPRESENTAÇÃO DE CONHECIMENTO	26
ESTRATÉGIAS DE PESQUISA EM ESPAÇOS DE ESTADOS.	46

75

UNIDADE 2

ARQUITETURA E COMPONENTES DE SISTEMAS ESPECIALISTAS	76
REPRESENTAÇÃO E TRATAMENTO DE INCERTEZAS	94
APRENDIZAGEM DE MÁQUINA EM SISTEMAS ESPECIALISTAS.	114

143

UNIDADE 3

IA SIMBÓLICA EM SISTEMAS ESPECIALISTAS	144
IA CONEXIONISTA EM SISTEMAS ESPECIALISTAS	164
IA EVOLUCIONÁRIA	188

unidade





TEMA DE APRENDIZAGEM 1

INTRODUÇÃO AOS SISTEMAS ESPECIALISTAS

MINHAS METAS

- Definir o que é um sistema especialista.
- Diferenciar um sistema especialista de um sistema convencional.
- Conhecer a história dos sistemas especialistas.
- Aprender os benefícios de um sistema especialista.
- Compreender as limitações de um sistema especialista.
- Entender onde os sistemas especialistas podem ser aplicados.
- Refletir sobre os exemplos de aplicações de sistemas especialistas.

INICIE SUA JORNADA

Uma empresa que precisa tomar uma decisão complexa ou resolver um determinado problema difícil, por muitas vezes, precisa da orientação de um especialista. Estes especialistas detêm um conhecimento específico, uma experiência na área de atuação da empresa e do problema a ser resolvido e conhecem soluções alternativas, indicando as possibilidades de sucesso e despesas que a empresa poderá ter caso não resolva a situação em questão. Os conselhos que os especialistas fornecem são inúmeros, como compra de equipamentos, fusões e estratégias de publicidade. Quanto menos estruturada a empresa e a situação a ser solucionada, mais especializada deverá ser a consultoria.

Mas o que é um sistema especialista e o que o define? Se um especialista pode ser substituído por um sistema especialista, por que não substituir todos os especialistas? Essas questões são tratadas neste tema de aprendizado, onde vamos conhecer os detalhes dos sistemas especialistas e suas limitações.



PLAY NO CONHECIMENTO

Estudante, os sistemas especialistas têm diversas aplicações. Vamos conhecer alguns casos interessantes? Acesse e dê o play nesse podcast que preparamos especialmente para você!

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

VAMOS RECORDAR?

Os sistemas de informação são necessários e aplicados nos mais diversos segmentos de negócio. Os sistemas especialistas incrementam os sistemas de informação para auxiliar na tomada de decisão. Há vários meios para que o conhecimento seja aplicado em um sistema que o torne especialista em um negócio. Aprender a reconhecer um sistema especialista significa também, poder indicar o uso do mesmo para uma empresa que possua um sistema menos sofisticado mas que deseja melhorar as suas condições, de velocidade de entrega, identificação de problemas, aumentar a lucratividade, entre outros.



DESENVOLVA SEU POTENCIAL

SISTEMAS ESPECIALISTAS - DEFINIÇÃO

Um sistema especialista normalmente é um software de decisão que pode alcançar um nível de desempenho comparável ao especialista humano em algumas áreas especializadas e limitadas. A ideia básica é simples: O conhecimento especialista é transferido do especialista (ou outra fonte) para o computador. Quando necessário, os usuários podem pedir conselhos específicos ao computador. Este faz deduções e chega a uma conclusão. Então, ele apresenta recomendações para os não-especialistas e explica, se necessário, a lógica por trás de sua recomendação. Os sistemas especialistas podem às vezes apresentar um desempenho bem melhor do que especialistas humanos (Turban, 2004).

Essa definição de Turban (2004) pode ser um tanto quanto perturbadora, pois em um primeiro momento passa a informação de que os sistemas, quase que de forma unânime, podem substituir 100% de algumas atividades que são

dos seres humanos. Mas não é para menos, o conhecimento de um especialista é amplo, mas é possível especificar os relacionamentos a determinadas tarefas, obtidos por meios de treinamento, leitura e experiência.

Para transformar o conhecimento de um profissional especialista, que muitas vezes representa até 30 vezes mais conhecimento do que um profissional novato, é realizado por meio da atividade de representação do conhecimento. O conhecimento é obtido e organizado sob forma de regras ou estruturas e armazenadas em um banco de conhecimento.

Se o necessário conhecimento especialista for dado e armazenado, o computador poderá fazer deduções se assim programado. Dessa forma, o conhecimento do especialista é repassado a um sistema e consequentemente a outros profissionais. Uma característica exclusiva do sistema especialista é a capacidade de explicar suas recomendações.

Os sistemas especialistas podem fazer uso de diversas tecnologias, componentes e metodologias como representação de conhecimento, redes semânticas, frames, ontologias e sistemas baseados em regras, uma vez que um sistema especialista depende de alguém perito no assunto para ser desenvolvido e que, muitas vezes, é de difícil compreensão lógica sem passar por uma explanação do assunto.

Também podem utilizar algoritmos avançados como de busca cega, heurística, largura e profundidade. O tratamento de incertezas com métodos probabilísticos como a lógica fuzzy, teoria de Dempster-Shafer e redes Bayesianas. Utilizar a IA conexionista em redes neurais e na evolucionária algoritmos genéticos, estratégias evolutivas como métodos para otimizar e prover soluções.

Histórico dos sistemas especialistas

Os sistemas especialistas de consulta foram introduzidos nos anos 1970, e estão geralmente associados à inteligência artificial para a tomada de decisão. No primeiro período, de 1968 a 1976, foram apresentados os precursores da tomada de decisão no diagnóstico médico não especialista ou outros profissionais de saúde, na tomada de decisão de um diagnóstico médico imitando especialista. Alguns exemplos são CASNET - redes causais para descrever o processo da doença, DIALOG - redes bayesianas hierárquicas, PIP - padrões para definição de doenças e o MYCIN - raciocínio modular baseado em regras.

Detalhando a história de um deles, Feigenbaum e outros pesquisadores de Stanford iniciaram o *Heuristic Programming Project* (HPP) para investigar até que ponto a nova metodologia de sistemas especialistas poderia ser aplicada a outras áreas do conhecimento humano. Este foi o primeiro e principal esforço dedicado à área de diagnóstico médico.

Feigenbaum, Buchanan e o Dr. Edward Shortliffe desenvolveram o sistema MYCIN para diagnosticar infecções sanguíneas. Com cerca de 450 critérios (regras), o MYCIN foi capaz de sair tão bem quanto alguns especialistas e melhor do que médicos em início de carreira. O sistema não tinha nenhum modelo teórico geral a partir do qual as regras do MYCIN pudessem ser reduzidas, elas tinham de ser adquiridas a partir de entrevistas extensivas com especialistas, que, por sua vez, as adquiriram de outras fontes. As regras tinham de refletir a incerteza associada ao conhecimento médico, além de incorporar um cálculo de incerteza chamado fator de certeza que pareciam na época se adequar bem à forma como os médicos avaliavam o impacto das evidências no diagnóstico (Russel; Norvig, 2013).

A seguir, apresento um exemplo do que era possível criar de regras com o MYCIN, vamos ver um exemplo na prática em português (português estruturado):

SE a infecção é meningite **E**
 o tipo da infecção é bacterial **E**
 o paciente fez uma cirurgia **E**
 o paciente fez uma neurocirurgia **E**
 a neurocirurgia foi realizada há menos de 2 anos
 o paciente tem derivação ventricular uretral
ENTÃO infecção = e.coli (.8) ou klebsiella (.75)

As regras para criar as instruções do MYCIN e também do SINTA, outro sistema especialista tradicional estudado em disciplinas de inteligência artificial, são baseadas na lógica matemática. Não é necessário conhecer uma linguagem de computação ou as especificidades de uma linguagem, porém, é importante que, para entender melhor essas ferramentas, os conceitos de princípio da não contradição, conceito de proposição, valores lógicos das proposições, conectivos, tabela verdade e seus operadores lógicos sejam do seu domínio.

Nos anos 1980, há registros que em Singapura os sistemas especialistas começaram a ser utilizados em setores bancários, na área financeira e na manufatura, entre outros. Alguns exemplos: Audit Expert System, Credit Evaluation, Intelligent Fuzzy Logic Tutor. Na década de 1990, centenas de propostas de novos modelos ou de aperfeiçoamento de redes neurais surgiram. Reconhece-se também que os paradigmas biológico e psicológico são complementares e necessários para sistemas mais evoluídos. Dessa forma, começaram nesta década a serem construídos os chamados sistemas híbridos, que é a união de concepções das duas linhas de pesquisa, permitindo a construção de grandes sistemas que pretendem abranger de forma mais completa a representação do comportamento humano, ideal da própria inteligência artificial (Barrella, 2000).

A partir dos anos 2000 começou-se a presenciar diversas aplicações que ainda completarão a história dos sistemas especialistas. Carros autônomos que combinam sensores do próprio veículo com o controle de tráfego, semáforo e automóveis, caso de destaque é o veículo chamado Stanley criado por Sebastian Thrun, a Waymo da Alphabet (Google), que realiza testes com carros autônomos. Também estamos presenciando a era do processamento de linguagem natural, como a Siri, Alexa, Cortona, ChatGPT e Google Assistente. Ferramentas que ainda são atuais existem dentro dos sistemas especialistas e que devem completar a história com os seus grandes resultados em um breve futuro.



**EU INDICO**

Uma forma de conhecer melhor um exemplo de sistema especialista é utilizando um. Neste tema de aprendizado recomendo conhecer O software Expert Sinta, que foi desenvolvido pela LIA, Laboratório de Informática Artificial, da Universidade Federal do Ceará (UFC), em que a última atualização é de 1998, porém, é uma ferramenta computacional que utiliza técnicas de Inteligência Artificial para geração automática de sistemas especialistas, está disponível gratuitamente e ainda é utilizada como exemplo em diversos trabalhos científicos como referência, por ser uma ferramenta simples de usar e que promove o aprofundamento na lógica computacional ao invés de uma linguagem de programação específica. O site para download do SINTA é o <https://www.lia.ufc.br/~bezerra/exsinta/>. Acesse o manual! Este sistema está disponível apenas para o sistema operacional Windows.

APLICAÇÕES DE UM SISTEMA ESPECIALISTA

Para entendermos a motivação da existência de sistemas especialistas e suas aplicações, precisamos conhecer um pouco de filosofia, economia e matemática.

Na filosofia, de 428 a.C. até a atualidade, busca-se entender alguns questionamentos da humanidade (Russel; Norvig, 2013):

- Regras formais podem ser usadas para obter conclusões válidas?
- Como a mente (o intelecto) se desenvolve a partir de um cérebro físico?
- De onde vem o conhecimento?
- Como o conhecimento conduz à ação?

De 1776 até a atualidade, os seguintes questionamentos em economia foram discutidos:

- Como devemos tomar decisões para maximizar o lucro?
- Como devemos fazer isso quando outros não podem nos acompanhar?
- Como devemos fazer isso quando o lucro pode estar distante no futuro?

E a combinação destes questionamentos de economia com questionamento matemático:

- Quais são as regras formais para obter conclusões válidas?
- O que pode ser computado?
- Como raciocinamos com informações incertas?

As respostas destes questionamentos levam a outros desdobramentos, por exemplo na neurociência:

- Como o cérebro processa informações?

Na psicologia:

- Como os seres humanos e os animais pensam e agem?

Linguística:

- Como a linguagem se relaciona ao pensamento?

Controle e cibernética:

- Como os artefatos podem operar sob seu próprio controle?

Computação:

- Como podemos construir um computador eficiente?

Por consequência desses e ainda outros mais questionamentos de outras disciplinas não listadas neste tema de aprendizagem, os sistemas especialistas vêm sendo usados em diversas situações e empresas para resolver problemas distintos e de uma forma macro. Hayes-Roth, em 1983, agrupou pela primeira vez os sistemas especialistas em 10 categorias conforme Tabela 1.

CATEGORIA	PROBLEMA AO QUAL DÁ SUPORTE
Interpretação	Dedução de descrições de situações a partir de observações.
Previsão	Dedução de prováveis consequências de determinadas situações.
Diagnóstico	Dedução do mau funcionamento de sistema a partir de observações.
Desenho	Configuração de objetos sob restrições.
Planejamento	Desenvolvimento de planos para alcançar objetivo(s).
Monitoramento	Comparação de observações com planos, marcando as exceções.
Eliminação de falhas	Prescrição de soluções para falhas de funcionamento.
Conserto	Execução de plano para administrar uma solução prescrita.
Instrução	Diagnóstico, eliminação de falhas e correção do desempenho de alunos.
Controle	Interpretação, previsão, correção e monitoramento do comportamento de sistemas.

Tabela 1 - Categorias Genéricas de Sistemas Especialistas / Fonte: Hayes-Roth (1983).

Perceba que essa classificação é de fato uma categorização genérica de sistemas especialistas e ela serve para ter um conhecimento macro de quais problemas são possíveis de resolver. Apesar de que, essas categorias são amplas, para cada uma delas existe um desdobramento, um aprofundamento maior, pois existem técnicas, metodologias, algoritmos que podem ser incrementados que complementam essa ampla categoria e definem o objetivo de um determinado sistema especialista.

Diferenças entre sistemas especialistas e convencionais

Segundo Mihaguti (1996), Os sistemas especialistas não automatizam tarefas rotineiras, repetitivas, mas sim tarefas que anteriormente necessariamente precisam da participação efetiva de um especialista e que a execução dependia de raciocínio, decisão e da aplicação da experiência do especialista envolvido.



As características e habilidades dos sistemas especialistas os diferenciam dos sistemas convencionais. Consideramos que a grande distinção entre a programação simbólica (sistemas especialistas) e a programação convencional (sistemas convencionais) reside no fato de que os sistemas convencionais automatizam tarefas operacionais, manuais, repetitivas. Os indivíduos que as exerciam anteriormente não tinham necessidade de pensar ou raciocinar em demasia sobre suas atividades, mas apenas de assimilar a rotina e executá-la. Os programas convencionais são utilizados para realizar essas rotinas no lugar do homem, com o benefício da velocidade e da precisão, além de outros. Na tabela 1 é possível observar uma comparação entre os sistemas especialistas e convencionais (Mlhaguti, 1996, p. 15).

SISTEMAS CONVENCIONAIS	SISTEMAS ESPECIALISTAS
O processo de execução acontece passo a passo, por meio de algoritmos. As informações e seu processamento estão inseridos em um único corpo programático.	O processo de execução realiza-se por meio de lógica, baseado em heurísticas.
Os programas são exatos e programados de forma a não errar.	A base de conhecimento é nitidamente separada do processamento (mecanismo de inferência).

Precisa das informações completas de entrada para entrar em operação.	O programa pode errar, suas conclusões não são 100% exatas, pois pode basear-se em dados incertos, portanto fornecer respostas contendo também graus de incertezas.
Representação e uso de dados (informações).	Pode entrar em operação e gerar resultados, mesmo com os dados incompletos ou incertos.
Manipulação de dados quantitativos.	Representação e uso de conhecimentos.
Explicação de suas ações impossível no meio da execução.	Manipulação de dados qualitativos.
Processamento sequencial.	Explicação de suas ações possível no meio da execução. Processamento interativo.
Captura, amplia e distribui acesso a dados, informações.	Captura, amplia e distribui acesso a julgamentos e conhecimento.
Instrução	Diagnóstico, eliminação de falhas e correção do desempenho de alunos.
Controle	Interpretação, previsão, correção e monitoramento do comportamento de sistemas.

Tabela 1 - Comparação entre sistemas convencionais e sistemas especialistas Fonte: adaptado de Turban e Efraim (1992); Harmon e King (1988).

Benefícios e limitações de um sistema especialista

A seguir, vamos estudar uma tabela com uma lista de benefícios de um sistema especialista.

BENEFÍCIO	DESCRIÇÃO OU EXEMPLO
Maior rendimento e produtividade	Na Compaq, um software especialista pode planejar a configuração de componentes para cada pedido de cliente, aumentando em quatro vezes o preparo para produção.
Aumento de Qualidade	Pode fazer recomendações consistentes e reduzir os índices de erro.
Captura e disseminação de conhecimento especialista escasso	Oftalmologistas no Egito e na Argélia usam um sistema especialista para fazer diagnósticos e recomendar o tipo de tratamento.

Operação em ambientes perigosos	SE que interpretam informações coletadas por sensores que evitam que seres humanos tenham que trabalhar em ambientes quentes, úmidos ou contaminados.
Acesso ao conhecimento e a help desks	O SE pode aumentar a produtividade de funcionários de help desk ou mesmo automatizar a função.
Confiabilidade	O SE não fica cansado, aborrecido ou doente, e não entra em greve. Ele dá atenção a detalhes e não deixa informações relevantes passarem despercebidas.
Maiores recursos de outros sistemas	A integração do sistema especialista com outros sistemas torna-os mais eficientes.
Capacidade de trabalhar com informação incompleta ou duvidosa	Mesmo com uma resposta "não sei" ou "não tenho certeza", ainda assim o SE consegue dar uma resposta, mesmo que não muito segura.
Treinamento	Os novatos que trabalham com SE tornam-se mais experientes graças à capacidade de explicação, que serve como mecanismo de ensino e base de conhecimento.
Aperfeiçoamento dos recursos de tomada de decisão e de resolução de problemas	Permitem integrar a opinião especializada à análise, o que é aplicado com êxito no diagnóstico de funcionamento de máquinas e até mesmo de diagnósticos médicos.
Redução do tempo de tomada de decisão	Os SEs em geral tomam decisões mais rápidas do que as pessoas que trabalham sozinhas.
Máquinas paradas por menos tempo	Os SEs podem rapidamente diagnosticar problemas de funcionamento e sugerir consertos.

Tabela 2 - Benefícios de Sistemas Especialistas / Fonte: Turban (2004).



A vantagem em traduzir o conhecimento do especialista está na velocidade do processamento de informações, na redução de deslocamento, no aumento da disponibilidade e dissipação da informação entre pessoas não especialistas, o que faz com que a empresa possa contar com mais pessoas cujas quais podem resolver os seus problemas em menor tempo.

Apesar de seus benefícios, as metodologias disponíveis de um sistema especialistas nem sempre são diretas e eficientes. Algumas limitações:

- Nem sempre há conhecimento disponível para ser coletado.
- O conhecimento especialista é difícil de ser extraído das pessoas.
- As abordagens utilizadas pelos especialistas para uma mesma situação podem ser diferentes, apesar de estarem corretas.
- É difícil, mesmo para um especialista muito capacitado, avaliar corretamente situações quando está sob pressão de tempo.
- Os usuários de sistemas especialistas têm uma capacidade natural limitada de aprendizado; assim, eles não utilizam os benefícios do sistema de forma plena.
- O sistema especialista trabalha bem somente dentro de áreas estritamente delimitadas, como o diagnóstico de mau funcionamento de uma máquina.
- A maioria dos sistemas especialistas não têm meios independentes de verificar se suas conclusões são razoáveis ou se estão corretas.
- O vocabulário, ou jargão, que os especialistas usam para expressar fatos e relações muitas vezes é limitado e não é compreendido pelos outros.
- Muitas vezes se precisa da ajuda de engenheiros do conhecimento para construir sistemas especialistas, mas tais profissionais são poucos e cobram caro, o que onera bastante a construção do sistema especialista.
- A falta de confiança dos usuários finais pode ser uma barreira para o uso do SE.
- A transferência de conhecimento está sujeita a preconceitos de percepção e de julgamento.
- É difícil medir as responsabilidades por uma recomendação incorreta feita por um sistema especialista.

**PENSANDO JUNTOS**

Os sistemas especialistas possuem benefícios e limitações, além de ser possível classificar em categorias genéricas. Para praticar, coloque no papel a lista de 3 sistemas de sua preferência que considera especialista e analise os benefícios e limitação destes com base na teoria deste tema de aprendizado. Você consegue categorizar eles de acordo com as categorias genéricas de sistemas especialistas criados por Hayes-Roth?

**EM FOCO**

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementar e aprofundará ainda mais o seu entendimento sobre o tema.

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

NOVOS DESAFIOS

Conhecer os fundamentos de sistemas especialistas apresentados neste tema de aprendizagem é fundamental na vida profissional de quem deseja trabalhar com tecnologia, independente seja seu cargo no futuro: analista de sistemas, analista de suporte, engenheiro de software, administrador de banco de dados, gerente de produto, analista de negócios, analista de sistema entre outros cargos possíveis dentro da área de tecnologia, uma vez que são ferramentas que podem auxiliar o dia a dia de trabalho, além de resolver um problema em específico de negócio.

Este tema na atualidade ganhou muito destaque em noticiários nos últimos anos, pois muitos sistemas especialistas agora contam com o apoio de algoritmos mais avançados em inteligência artificial, que facilitam o aprendizado e se retroalimentam de conhecimento, podendo tomar decisões com mais dados e consequentemente mais acurácia. Uma vez aprendido os conceitos de um sistema especialista, se tornará comum observar em noticiários e na própria internet o desenvolvimento de um sistema inteligente capaz de resolver algum propósito específico. Quem sabe até o seu sistema seja o próximo da lista com base nos conhecimentos adquiridos neste curso.

AUTOATIVIDADE

1. Para entendermos a motivação da existência de sistemas especialistas e suas aplicações, precisamos conhecer um pouco de outras disciplinas que completam o entendimento e o desenvolvimento de novas aplicações especialistas.

Fonte: RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

Quais disciplinas são exemplos que devemos conhecer para entender e desenvolver aplicações especialistas?

- I - filosofia, economia e matemática.
- II - psicologia, linguística, computação, controle e cibernética.
- III - nenhuma das alternativas.

Identifique as alternativas corretas:

- a) I, apenas.
 - b) III, apenas.
 - c) I e II, apenas.
 - d) II e III, apenas.
 - e) I, II e III.
2. Hayes-Roth, em 1983, definiu os sistemas especialistas em 10 macrocategorias: Interpretação, Previsão, Desenho, Planejamento, Monitoramento, Eliminação de falhas, Conserto, Instrução, controle e Diagnóstico.

Assinale a alternativa que apresenta descrição de qual problema ao qual dá suporte a categoria diagnóstico:

- a) Dedução de descrições de situações a partir de observações.
- b) Dedução de prováveis consequências de determinadas situações.
- c) Dedução do mau funcionamento de sistema a partir de observações.
- d) Configuração de objetos sob restrições.
- e) Desenvolvimento de planos para alcançar objetivo(s).

AUTOATIVIDADE

3. Alguns questionamentos são discutidos na disciplina de economia e são pertinentes e vinculados aos sistemas especialistas. É importante lembrar quais são estes questionamentos para poder desenvolver ou tentar identificar um sistema especialista.

Quais afirmativas representam os questionamentos levantados pela economia?

I - De onde vem o conhecimento?

II - Como devemos fazer isso quando outros não podem nos acompanhar?

III - Como o conhecimento conduz à ação?

IV - Como devemos fazer isso quando o lucro pode estar distante no futuro?

Assinale a(s) correta(s):

- a) I e II, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) I, II, III e IV.

REFERÊNCIAS

BARRELLA, W. D. **Sistemas Especialistas Modulados e Abrangentes para a Gestão de Operações**. 2000. 179 f. Tese (Doutorado) – Escola Politécnica da Universidade de São Paulo, Universidade de São Paulo, São Paulo, 2000. Disponível em: <https://www.teses.usp.br/teses/disponiveis/3/3136/tde-29032001-213036/publico/tdew.pdf>. Acesso em: 25 out. 2024.

HARMON, P.; KING, D. **Sistemas Especialistas**. Rio de Janeiro: Campus, 1988.

HAYES-ROTH, F.; WATERMAN, D.; LENAT, D. **Building Expert Systems**. [S.l.]: [s.n.], 1983.

MIHAGUTI, E. H. F. **Sistemas Baseado em Conhecimento: Aplicações, Tendências e Implicações - Um Estudo Exploratório em Empresas Brasileiras**. 1996, 235 f. Dissertação (Mestrado em Administração de Empresas) – Escola de Administração de Empresas, Fundação Getúlio Vargas, São Paulo, 1996. Disponível em: <https://repositorio.fgv.br/server/api/core/bitstreams/1d0897d2-0b3c-41e4-b5e6-53307a2cca48/content>. Acesso em: 6 jun. 2024.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

TURBAN, E. **Expert Systems and Applied Artificial Intelligence**. New York: Macmillan, 1992.

TURBAN, E.; MCLEAN, E.; WETHERBE, J. **Tecnologia da informação para gestão**. 3. ed. Tradução: Renate Schinke. Porto Alegre: Bookman, 2004.

GABARITO

1. Alternativa correta C - I e II, apenas.

As alternativas I e II são verdadeiras, pois são exemplos de disciplinas que se interrelacionam e também completam definição, ajudando a construir sistemas especialistas.

2. Alternativa correta C - Dedução do mau funcionamento de sistema a partir de observações.

Dedução de descrições de situações a partir de observações - Categoria Interpretação. Dedução de prováveis consequências de determinadas situações - Categoria Previsão. Dedução do mau funcionamento de sistema a partir de observações - Categoria Diagnóstico. Configuração de objetos sob restrições - Categoria desenho. Desenvolvimento de planos para alcançar objetivo(s) - Categoria planejamento.

3. Alternativa correta B - II e IV, apenas.

De 1776 até a atualidade, os seguintes questionamentos em economia foram discutidos: Como devemos tomar decisões para maximizar o lucro? Como devemos fazer isso quando outros não podem nos acompanhar? Como devemos fazer isso quando o lucro pode estar distante no futuro? Os questionamentos: "Como o conhecimento conduz à ação? De onde vem o conhecimento?" São realizados pela área da filosofia.



TEMA DE APRENDIZAGEM 2

REPRESENTAÇÃO DE CONHECIMENTO

MINHAS METAS

- Definir o que é um conhecimento.
- Aprender o que é representar o conhecimento.
- Identificar os métodos para representar o conhecimento.
- Entender a lógica de predicados.
- Conhecer o que são frames.
- Conhecer o que são redes semânticas e a lógica de predicados.
- Conhecer o que são ontologias.

INICIE SUA JORNADA

Os sistemas especialistas não automatizam tarefas rotineiras ou repetitivas, pois o processo de execução realiza-se por meio de lógica, baseado em heurísticas. São diferentes dos sistemas convencionais onde o processo de execução acontece passo a passo, por meio de algoritmos.

Dado este fato, os sistemas especialistas precisam da participação efetiva de um especialista para que a execução apure o raciocínio, decisão e aplicação.

Para isso acontecer em um universo complexo de dados e informações especializadas, é necessária uma organização de forma sistemática, por isso, surgiram os meios de representação de conhecimento. E se não fosse a representação de conhecimento e seus formalismos, como poderíamos debater assuntos complexos e distintos?

Ao longo dos anos, diversos formalismos foram desenvolvidos de acordo com os desafios presenciados para cada época (e ainda assim, são utilizados na atualidade), porém, há muitas similaridades pois o objetivo se torna o mesmo: representar a abstração de dados e informações em conhecimento estruturado.



PLAY NO CONHECIMENTO

Estudante, convido você a ouvir sobre o Prolog, um sistema que se enquadra no paradigma de Programação em Lógica Matemática associada com a inteligência artificial e linguística computacional. Acesse e dê o play nesse podcast que preparamos especialmente para você!

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

VAMOS RECORDAR?

Uma característica exclusiva do sistema especialista é a capacidade de explicar suas recomendações que antes foram construídas através de formalismos da abstração de dados e informações prévias. Para que isso venha a ser possível, o conhecimento deve ser obtido através de especialistas ou fontes de informação especializadas e para que posteriormente venha a ser identificado o meio ideal para formalizar este conhecimento com o objetivo de fornecer informações mais claras de estruturação de pensamento, lógica e sistemas.

DESENVOLVA SEU POTENCIAL

O CONHECIMENTO

Para discutirmos a representação de conhecimento, antes disso precisamos defini-lo. No contexto da tecnologia da informação, conhecimento é diferente de informação e dados. Enquanto que os dados são uma coleção de fatos, parâmetros e estatísticas, a informação são dados organizados ou processados, precisos e fornecidos no momento oportuno (ou seja, conclusões tiradas a partir de dados dentro do prazo de validade) e precisos (ou seja, com relação aos dados originais (McFadden *et al.*, 1999)).

O conhecimento é a informação que possui contexto, é relevante e é acionável. A implicação é que o conhecimento tem fortes elementos experimentais e reflexivos que o distinguem da informação em determinado contexto. Ter conhecimento implica que ele pode ser aplicado para resolver um problema, enquanto que ter informação não possui a mesma conotação. A capacidade de agir é parte integrante de se possuir conhecimento (Turban, 2004).

O conhecimento tem pelo menos duas classificações. O **conhecimento tácito** geralmente está na área do aprendizado subjetivo, cognitivo e experimental. Já o **conhecimento explícito** liga com o conhecimento mais objetivo, racional e técnico (dados, políticas, procedimentos, software, documentos etc.) e é extremamente pessoal e difícil de ser formalizado (Nonaka; Takeuchi, 1995) (Polanyi, 2015).

O conhecimento explícito são as políticas, as diretrizes de procedimentos, os manuais, os relatórios, os desenhos, os produtos, as estratégias, as metas, a missão e as competências básicas da empresa e a infraestrutura da tecnologia da informação. É o conhecimento que foi codificado (documentado) em interação interpessoal, ou pode ser transformado em um processo ou em uma estratégia (Alavi, 2000).

O conhecimento tácito é o acúmulo de experiências, mapas mentais, perspicácia, conhecimento especializado, segredos de negócio, conjunto de capacidades, a compreensão e o aprendizado de uma empresa, bem como a cultura organizada que

nela embute as experiências passadas e presentes das pessoas, processos e valores que fazem parte da empresa. O conhecimento tácito é difuso, não-estruturado, não possui uma forma tangível e, portanto, é difícil de ser codificado (Polanyi, 2009).

Representação de Conhecimento

Elmasri e Navathe (2005) definem a representação de conhecimento como algo que substitui o objeto ou fenômeno real, de modo a permitir a uma entidade determinar as consequências de um ato pelo pensamento ao invés de sua realização. É uma forma sistemática de estruturar e codificar o que se sabe sobre uma determinada aplicação e deve apresentar as seguintes características:

- Ser compreensível ao ser humano (caso seja necessário avaliar o conhecimento do sistema).
- Não depender de detalhes sobre o processador de conhecimento que a interpretará.
- Ser robusta, permitir seu uso mesmo que não aborde todas as situações possíveis.
- Ser generalizável, para poder ser utilizada em diversas situações e interpretações.

Em uma segunda definição, John (2000) trata a representação do conhecimento como um conjunto de convenções sintáticas e semânticas que torna possível descrever coisas. Consiste na utilização de linguagens específicas, frases ou números que correspondem à descrição ou condição do mundo.

A seguir, são apresentadas três **perspectivas** no campo de representação do conhecimento (Rich; Knight, 1993):

REPRESENTAÇÃO DO CONHECIMENTO COMO EPISTEMOLOGIA APLICADA

utiliza como princípio a complexidade do conhecimento, ou seja, envolve-se com o problema do conhecimento pressuposto na atividade inteligente e a forma de representá-lo em uma base como estruturas e programas.

REPRESENTAÇÃO DO CONHECIMENTO COMO UM MÓDULO DE PERGUNTA RESPOSTA

é a mais baixa expectativa de um módulo de representação do conhecimento.

REPRESENTAÇÃO DO CONHECIMENTO COMO INCORPORAÇÃO DE SISTEMAS DE IA

esta é a visão conexionista, para a qual há várias unidades interconectadas idênticas que são coletivamente responsáveis por representar vários conceitos. Um conceito é representado num senso distribuído e é indicado por um envolvimento em atividades sobre uma coleção de unidades.

Algumas das características das **formas** de representação do conhecimento (Rich; Knight, 1993) são elencadas em seguida:

- **Escopo e granulosidade:** partes do domínio consideradas, detalhamento.
- **Indeterminância e definição das noções primitivas de representação:** alternativas de modelagem.
- **Modularidade/compreensibilidade:** agrupamento (clusterização) do conhecimento, legibilidade.
- **Conhecimento explícito e flexibilidade:** toda a informação necessária à solução do problema na Base de Conhecimento, e não embutida em outro componente.

MÉTODOS DE REPRESENTAÇÃO

O problema de compreender a linguagem, de acordo com Russel e Norvig (2013, s.p.),



logo se tornou consideravelmente mais complexo do que parecia em 1957, pois exige a compreensão do assunto e do contexto, não apenas a compreensão das frases. Isso pode parecer óbvio, mas só foi amplamente avaliado em 1960.

Grande parte deste trabalho realizado em entre 1957 e 1960 buscava encontrar uma forma com que o computador entendesse o conhecimento e que este conhecimento estivesse vinculado à linguagem natural, suprido com informações da pesquisa linguística e que, estava conectada a décadas de pesquisa sobre análise filosófica da linguagem. Os projetos de engenharia de conhecimento variam amplamente em conteúdo, escopo e dificuldade, mas todos eles incluem as etapas a seguir.

Observe, no Quadro 1, uma separação de momentos, em que o primeiro é a aquisição de conhecimento de um universo que é desejado para trabalhar, e o segundo é a preparação para trabalhar com esse conhecimento obtido da primeira etapa.

AQUISIÇÃO DE CONHECIMENTO	Identificar a tarefa	Delinear a variedade de questões que a base de conhecimento admitirá e os tipos de fatos que estarão disponíveis para cada instância específica do problema.
	Agregar o conhecimento relevante	Compreender o escopo da base de conhecimento, determinada pela tarefa, e entender como o domínio realmente funciona.
	Definir um vocabulário de predicados, funções e constantes	Converter os importantes conceitos de nível de domínio em nomes de nível de lógica.
ONTOLOGIA	Codificar o conhecimento geral sobre o domínio	Axiomas correspondentes a todos os termos do vocabulário, fixando o significado dos termos. Essa etapa pode revelar concepções erradas ou lacunas no vocabulário que devem ser corrigidas em etapas anteriores.
	Codificar uma descrição da instância específica do problema	Envolve a escrita de sentenças atômicas simples sobre instâncias de conceitos que já fazem parte da ontologia.

ONTOLOGIA	Formular consultas ao procedimento de inferência e obter respostas	É o procedimento de inferência operando sobre os axiomas e fatos específicos do problema para derivar os fatos que estamos interessados em saber.
	Depurar a base de conhecimento	As respostas às consultas poucas vezes estarão corretas na primeira tentativa. As respostas estarão corretas para a base de conhecimento criada, supondo-se que o procedimento de inferência seja consistente, mas não serão aquelas que o usuário espera.

Quadro 1. Etapas de Engenharia de Conhecimento / Fonte: adaptada de Russel e Norvig (2013, p. 253).

No exemplo do Quadro 1, a Ontologia foi definida como formalismo para representação deste conhecimento, mas também existem outras formas para utilizar:

- Sistemas baseados em regras;
- Lógica de Predicados.
- Redes Semânticas;
- *Frames*;
- Sistemas Fuzzy;

Nos próximos tópicos, veremos a introdução de cada um destes formalismos, em que será possível conhecer a similaridade entre os mesmos.

Sistemas baseados em regras

Na etapa de aquisição de conhecimento, nos processos de identificar tarefas e agregar o conhecimento, o especialista normalmente exerce algum tipo de poder, seja ele decisório ou apenas **preditivo**. As regras ou lógicas para estruturar este conhecimento se relacionam com informações ou fatos utilizando a forma “**SE** (antecedente) **ENTÃO** (consequente/condição/premis-

sa)”. Antecedentes podem ser compostos pela conjunção e/ou disjunções de múltiplas preposições. Cada proposição é dada por um objeto linguístico e seu valor, ligados por um operador que pode ser de atribuição (**é, não é**) ou de relação (**é maior / menor que**) (Filho, 2017).

A seguir, apresento um exemplo da aplicação de um sistema baseado em regras, o MYCIN:

SE a infecção é meningite **E**
 o tipo da infecção é bacterial **E**
 o paciente fez uma cirurgia **E**
 o paciente fez uma neurocirurgia **E**
 a neurocirurgia foi realizada há menos de 2 anos
 o paciente tem derivação ventricular uretral
ENTÃO infecção = e.coli (.8) ou klebsiella (.75)

Lógica de Predicados

A lógica de predicados pode ser estendida para a lógica de primeira ordem e é um termo genérico para os sistemas formais. A lógica de predicados ou a lógica de primeira ordem é composta por **objetos, predicados, variáveis** e **quantificadores**.

Com as **variáveis**, podemos estabelecer fatos a respeito de **objetos** de um determinado contexto de discurso e serve para expressar e representar um problema a ser resolvido em sentenças lógicas.

Os **objetos** podem estar relacionados de diversas maneiras. Para explicar com mais detalhes a lógica de predicados, veja um exemplo citado por Russel e Norvig (2013, s.p.), “Ricardo Coração de Leão, rei da Inglaterra de 1189 até 1199; seu irmão mais jovem, o perverso rei João, que governou de 1199 até 1215.

Formalmente falando, uma **relação** é apenas o conjunto de uma lista de **objetos** inter-relacionados, e se formalizarmos essa relação teríamos a seguinte sentença:

{ <Ricardo Coração de Leão, Rei João>, <Rei João, Ricardo Coração de Leão> }

Uma **função** é uma sentença declarativa contendo uma ou mais **variáveis** que se torna uma proposição quando valores particulares são atribuídos às variáveis.

Certos tipos de relacionamento podem ser pensados como se fossem funções, nas quais um determinado objeto deve estar relacionado a exatamente um objeto desse modo.

Seguindo o exemplo de Russel e Norvig (2013, s.p.), “cada pessoa tem uma perna esquerda, então o modelo tem uma função unária - perna esquerda” - que inclui os seguintes mapeamentos:

< Ricardo Coração de Leão > -> Perna esquerda de Ricardo
< Rei João > -> Perna esquerda de João

Os elementos sintáticos básicos da lógica de primeira ordem são os **símbolos** que representam **objetos**, **relações** e **funções**. Os símbolos são de três tipos: **constantes**, que representam os **objetos**, **predicados**, que representam **relações** e **funções**, representando a própria função.

Por exemplo, poderíamos definir Ricardo e João como símbolos de consoantes eirmão, Pessoa, Rei símbolo de predicado e símbolos de funções, a Perna Esquerda.

A lógica de primeira ordem também possui **quantificadores** e existem dois padrões chamados de **universal** e **existencial** e servem para expressar sentenças mais complexas, onde permite dizer formalmente, por exemplo, que Ricardo Coração de Leão é um rei e que é verdade que o Ricardo Coração de Leão é uma pessoa. Exemplo escrito em lógica de primeira ordem para o **quantificador universal**:

$$\forall x \text{ Rei}(x) \Rightarrow \text{Pessoa}(x)$$

O A invertido “ $\forall$ ” representa todos. Desse modo, Para todo x, se x é um rei, então x é uma pessoa, onde x, é uma variável deste exemplo. Neste exemplo também foi utilizado o símbolo $\Rightarrow$ que é um conectivo

Uma vez que o quantificador universal representa todos, o **quantificador existencial** $\exists$ permite fazer uma declaração sobre algum objeto sem precisar nomear. Exemplo: Para dizer que o rei João tem uma coroa em sua cabeça podemos escrever:

$$\exists x \text{ Coroa}(x) \wedge \text{Nacabeça}(x, \text{João})$$

Essa expressão permite dizer que “existe um x tal que ..” ou ainda “para algum x...”. Isso significa que **pelo menos uma** das afirmações deve ser verdadeira, que é o que diferente do quantificador universal onde a sentença representa todas as afirmações verdadeiras.

Outros elementos da lógica proposicional podem ser utilizados para expressar o domínio dos problemas que precisam ser resolvidos, por isso, o domínio das expressões lógicas matemáticas se tornam fundamentais para descrever sentenças.



INDICAÇÃO DE LIVRO

A disciplina de lógica matemática é importante para as regras e lógica de predicados o que poderíamos dedicar um capítulo inteiro da unidade aprofundando o tema, por isso, siga a indicação do livro: Iniciação à Lógica Matemática para conhecer mais e também para mais exercícios práticos. A obra possui diversos exemplos e exercícios que apuram o senso lógico, bem como o aprimoramento de outras habilidades em programação e banco de dados, por exemplo. A lógica proposicional tem o compromisso ontológico de expressar os fatos, já a lógica de primeira ordem além dos fatos, tem o compromisso de expressar objetos e relações além de fatos. Os conceitos de proposições e conectivos da lógica matemática se estendem à lógica proposicional, assim como a lógica matemática para as tabelas verdades podem ser aplicados aos quantificadores universais, por isso, se complementam.



Redes Semânticas

Em 1909, Charles Peirce propôs uma notação gráfica de nós e arcos, denominada grafos existenciais e logo depois, teve início um longo debate entre defensores da lógica e defensores de redes semânticas, o que na época, ofuscou o fato de que as redes semânticas são uma forma de lógica.

Existem muitas variantes de redes semânticas e todas são capazes de representar os objetos individuais, categorias de objetos e relações entre objetos.

As redes semânticas oferecem auxílios gráficos para visualização de uma base de conhecimento e também algoritmos eficientes para deduzir propriedades de um objeto, de acordo com sua pertinência a uma categoria (Russel; Norvig; 2013).

Observe a Figura 1 em que um fragmento de rede semântica é representado.




Figura 1. Representação de um fragmento de rede semântica / Fonte: o autor.

Descrição da Imagem: A figura 1 possui um primeiro nó denominado animal, com a derivação de um subconjunto invertebrado onde o mesmo possui outro subconjunto nomeado abelha e que possui asas como seu elemento final. o primeiro nó possui um segundo nó denominado mamífero, com cachorro de subconjunto e elemento final pelo. Mamífero ainda possui mais um subconjunto que é girafa seguido de um elemento final pescoço longo.

Conforme a representação na Figura 1, é possível compreender e descrever que a abelha é um subconjunto de um animal invertebrado e que é subconjunto de um animal. Bem como cachorro e girafa, são subconjuntos de mamíferos e também do conjunto animal. Asas é um elemento de abelha, bem como pelo é um elemento de cachorro e pescoço longo um elemento de girafa.

Frames

O enorme crescimento das aplicações para resolução de problemas causou um aumento simultâneo na demanda por esquemas utilizáveis de representação do conhecimento. Foi desenvolvido um grande número de diferentes linguagens de representação e raciocínio, como os *frames* (Minsky, 1974).

Para entender o que é um frame, vamos utilizar um exemplo do frame CINEMA que é citado no trabalho de Medeiros (2019, s.p.):



No cinema, estão armazenados todos os elementos e as experiências que cada pessoa possui com relação a um cinema: desde informações básicas, como a de saber que se trata de um local fechado, com pouca luz, equipado para projetar filmes, com poltronas distribuídas em fileiras, dentre outras; informações relacionadas a ações específicas, como comprar o ingresso, procurar a localização da poltrona, etc.; Até informações mais complexas, como as que envolvem questões culturais (diferentemente do Brasil, por exemplo, em alguns países, como em Portugal, é comum haver um intervalo durante o filme para que as pessoas possam ir ao banheiro ou comprar alguma coisa). Um exemplo que ilustra esse cenário foi retirado de um comentário da internet:

[...] isso deu ao JK Iguatemi o título de melhor cinema da cidade. Suas instalações são espaçosas e limpas, com um agradável lounge cheio de mesas e poltronas. Na compra do ingresso, funcionárias extremamente simpáticas dão um atendimento tranquilo, porém eficiente. Caso não queira enfrentar fila, é só recorrer a um dos totens de autoatendimento. Na bonbonnière, a pipoca pode levar temperos especiais, como o de lemon pepper. Dentro das salas, a qualidade de projeção impressiona [...]

A seguir, a Figura 2 representa este trecho resgatado de comentários da internet:



Figura 2 - Exemplo Frame / Fonte: Medeiros (2019).

Descrição da Imagem: A figura apresenta um primeiro nó nomeado cinema do JK Iguatemi. e a partir dele duas linhas com novos 8 novos nós representam a característica do cinema do JK Iguatemi. A primeira linha: melhor cinema da cidade e com seu segundo nó atendimento tranquilo, instalação espaçosas e limpas com seu segundo nó totens de atendimento, lounge cheio de mesas e poltronas com seu segundo nó pipoca, compra do ingresso com seu segundo nó salas, e funcionários extremamente simpáticas com seu segundo nó qualidade de projeção.

O frame deve ser capaz de realizar a análise, discussão dos dados e conseguir com que as interações se encaixem em quadros de sentido que moldam as interpretações e ações dos atores envolvidos, como o proposto no trabalho de Medeiros (2019). Perceba que, na Figura 2, como um texto extraído da internet pode ser representado em *frames* de uma forma lógica e prática de visualizar o seu conteúdo.

Ontologias

Quando um mundo muito amplo com muitas possibilidades precisa ser estudado, a engenharia ontológica mostra como criar as representações, concentrando-se em **conceitos gerais, como ações, tempo, objetos físicos e crenças** que ocorrem em domínios diferentes.



Ontologia é um campo da filosofia que trata da natureza do ser e na computação o termo ganha um novo significado: as ontologias descrevem normalmente um vocabulário de um domínio de interesse (Gruber, 1993, s.p.).

Gruber (1993) define uma ontologia como uma especificação explícita de uma conceitualização. Do mesmo modo, Borst (1997) completa esta definição afirmando que uma ontologia é uma especificação formal e explícita de uma conceitualização compartilhada (Reis, 2018, s.p.).

Uma ontologia de uso geral deve ser aplicável em quase todo domínio de uso especial, isso significa que, nenhuma representação deve ser desconsiderada. Para fixarmos estes conceitos, observe a figura 3 que é proposta por Russel e Norvig (2013), onde cada arco indica que o conceito inferior é uma especialização do conceito superior.




Figura 3. Ontologia, mostrando os tópicos a serem cobertos. Cada arco indica que o conceito inferior é uma especialização do conceito superior (Russel; Norvig, 2013, p. 310).

Descrição da Imagem: a figura apresenta um primeiro nó com nome qualquer coisa, ligado a uma primeira ramificação nomeada objetos abstratos que se subdivide em três novas ramificações: conjuntos com seu elemento final categoria, números, objetos representacionais que se subdivide em sentenças e medidas e finalmente este com tempos pesos de último elemento. A segunda ramificação de qualquer coisa parte para o nós eventos generalizados subdivididos em quatro nós, intervalo com o último elemento momentos, lugares e processos como último nó, objetos físicos divididos em duas ramificações coisas que se subdivide em animais, agentes e finalmente humanos e a outra ramificação material subdivididas nos elementos finais sólidos, líquido e gás.

Podemos considerar que a ontologia graficamente desenha uma árvore onde os conceitos se iniciam de algo mais abrangente e são especializados de acordo com a sua profundidade. Para praticar, imagine construir uma ontologia referente a uma Pizza. Quantos detalhes você consegue abstrair para defini-la?

Para o desenvolvimento de Ontologias, o *Protege* é um dos *softwares* mais conhecidos, por ser mantido por uma comunidade de usuários acadêmicos, governamentais e corporativos.




Figura 4 - Representando uma parte de uma ontologia sobre Pizza / Fonte: <https://protegewiki.stanford.edu/images/a/ab/Protege-OWL.jpg>. Acesso em: 1 jun. 2024.

Descrição da Imagem: A figura 4 apresenta uma ontologia criada através do sistema Protege. Ao lado esquerdo um menu onde as classes de pizza são representadas e a direita o modelo é desenhado em forma de diagrama.

O Sistema está disponível gratuitamente e pode ser utilizado para construir soluções baseadas em conhecimento em áreas tão diversas como biomedicina, comércio eletrônico e modelagem organizacional.

**EM FOCO**

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementar e aprofundará ainda mais o seu entendimento sobre o tema.

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

NOVOS DESAFIOS

A representação de conhecimento apresentado neste tema de aprendizagem possui formalismos e regras que permitem abstrair um conhecimento de um especialista e estruturar o pensamento de forma lógica para ser desenvolvido em um sistema. Praticar estes modelos permite que o raciocínio lógico venha a ser desenvolvido para que se torne cada vez mais ágil e apurado.

Perceba que as regras que precisamos elaborar para poder reproduzir visualmente os problemas que queremos resolver, estão em muitas situações cotidianas, não apenas em sistemas que resolvem problemas complexos. Por isso a prática é importante, pensando em casos mais simples e menores de como seria essa modelagem e representação de regras, para que, quando surgir um desafio maior, se torne algo mais simples de se resolver.

AUTOATIVIDADE

1. Russel e Norvig (2013) citam que os projetos de engenharia de conhecimento podem variar em conteúdo, escopo e dificuldade. Porém, há etapas que são comuns para a obtenção de conhecimento, o que pode auxiliar a decidir o método para a representação do mesmo.

Fonte: RUSSELL, S.; NORVIG, P. **Inteligência artificial**. 2. ed. Upper Saddle River, NJ: Prentice-Hall, 2003.

Quais afirmativas abaixo representam etapas de aquisição do conhecimento?

- I - Codificar uma descrição da instância específica do problema. Envolve a escrita de sentenças atômicas simples sobre instâncias de conceitos.
- II - Identificar a tarefa - Delinear a variedade de questões que a base de conhecimento admitirá e os tipos de fatos que estarão disponíveis para cada instância específica do problema.
- III - Converter os importantes conceitos de nível de domínio em nomes de nível de lógica.
- IV - Agregar o conhecimento relevante - Compreender o escopo da base de conhecimento, determinada pela tarefa, e entender como o domínio realmente funciona.

Assinale a alternativa verdadeira.

- a) I, apenas.
 - b) II e IV, apenas.
 - c) III e IV, apenas.
 - d) I, II e III, apenas.
 - e) I, II, III e IV.
2. Interpretar informações e dados gerando conhecimento nem sempre é uma atividade trivial. Para auxiliar a descrever e também visualizar de forma gráfica os elementos que compõem um problema a ser interpretado, diversos métodos de representação foram criados ao longo do tempo.

Fonte: adaptado de RUSSELL, S.; NORVIG, P. **Inteligência artificial**. 2. ed. Upper Saddle River, NJ: Prentice-Hall, 2003.

Qual alternativa não é um método de representação de conhecimento? Assinale a alternativa verdadeira.

- a) Ontologia.
- b) Fuzzy.
- c) Redes Semânticas
- d) *Frames*
- e) Cobol

3. Sabendo que o conhecimento é uma informação com contexto, saber representá-lo significa estruturar sistematicamente um determinado problema a ser resolvido e os formalismos de representação de conhecimento auxiliam no processo.

Fonte: ELMASRI, R.; NAVATHE, S. B. **Sistemas de banco de dados**. 4. ed. Boston: Addison Wesley, 2005.

Mas afinal, quais são as características da representação de conhecimento?

- I - Ser compreensível ao ser humano
- II - Ser robusta, permitir seu uso mesmo que não aborde todas as situações possíveis;
- III - Ser generalizável, para poder ser utilizada em diversas situações e interpretações

Assinale a alternativa verdadeira.

- a) I, apenas.
- b) III, apenas.
- c) I e II, apenas.
- d) II e III, apenas.
- e) I, II e III.

REFERÊNCIAS

ALAVI, M. Framing the domains of IT management: projecting the future... through the past. *In*: PINNAFLEX EDUCATIONAL RESOURCES, 2000.

ELMASRI, R.; NAVATHE, S. B. **Sistemas de banco de dados**. 4. ed. Boston: Addison Wesley, 2005.

FILHO, E. A. **Iniciação à lógica matemática**. [S.l.:s.n.], 2017.

JOHN, S. F. **Knowledge representation**: logical, philosophical, and computational foundations. Pacific Grove, CA: Brooks Cole Publishing Co., 2000.

MCFADDEN, F. R. *et al.* **Modern database management**. Reading, MA: Addison-Wesley, 1999.

MEDEIROS, I. S. **Frames**: da teoria à prática. Disponível em: <https://periodicos2.uesb.br/index.php/estudosdalinguagem/article/view/5931/4447>. Acesso em: 18 jun. 2024.

MINSKY, N. **A framework for representing knowledge**. [S.l.:s.n.], 1974. Disponível em: <https://pages.ucsd.edu/~scoulson/203/minsky.pdf>. Acesso em: 18 jun. 2024.

POLANYI, M. **Personal knowledge**: towards a post-critical philosophy. Chicago: University of Chicago Press, 2015.

POLANYI, M. **The tacit dimension**. Chicago: University of Chicago Press, 2009.

PROLOG. Disponível em: <https://www.let.rug.nl/bos/lpn/>. Acesso em: 18 jun. 2024.

REIS, J. S. **Redes de valor semânticas**. 2018. 151 f. Dissertação (Mestrado em Ciência da Computação) – Programa de Pós-Graduação em Ciência da Computação, Universidade do Estado do Rio Grande do Norte e Universidade Federal Rural do Semi-Árido, Mossoró, RN, 2018. Disponível em: <https://ppgcc.ufersa.edu.br/wp-content/uploads/sites/42/2018/12/Disserta%C3%A7%C3%A3o-de-Mestrado-Jefferson-Reis-Redes-de-Valor-S.pdf>. Acesso em: 25 out. 2024.

RICH, E.; KNIGHT, K. **Inteligência artificial**. São Paulo: Makron Books, 1993.

RUSSELL, S.; NORVIG, P. **Inteligência artificial**. 2. ed. Upper Saddle River, NJ: Prentice-Hall, 2003.

TURBAN, E.; MCLEAN, E.; WETHERBE, J. **Tecnologia da informação para gestão**. 3. ed. Tradução: Renate Schinke. Porto Alegre: Bookman, 2004.

GABARITO

1. Alternativa correta B - II e IV, apenas.


Identificar a tarefa e agregar o conhecimento relevante são etapas para a aquisição do conhecimento. Já as etapas de codificar uma descrição da instância específica do problema e converter os importantes conceitos de nível de domínio são etapas após a aquisição de conhecimento, sendo relacionadas com um meio de representação de conhecimento, como a Ontologia.

2. Alternativa correta E - Cobol

Ontologia, Fuzzy, Redes Semânticas e *Frames* são métodos de representação de conhecimento. Cobol, na verdade, é uma linguagem de programação.

3. Alternativa correta E - I, II e III.

A representação de conhecimento pode ser definida como algo que substitui o objeto ou fenômeno real, de modo a permitir a uma entidade determinar as consequências de um ato pelo pensamento ao invés de sua realização. É uma forma sistemática de estruturar e codificar o que se sabe sobre uma determinada aplicação e deve apresentar as seguintes características: Ser compreensível ao ser humano (caso seja necessário avaliar o conhecimento do sistema); Não depender de detalhes sobre o processador de conhecimento que a interpretará; Ser robusta, permitir seu uso mesmo que não aborde todas as situações possíveis; Ser generalizável, para poder ser utilizada em diversas situações e interpretações (Elmasri; Navathe, 2005).



TEMA DE APRENDIZAGEM 3

ESTRATÉGIAS DE PESQUISA EM ESPAÇOS DE ESTADOS

MINHAS METAS

- Estudar os conceitos de estratégias de pesquisa em espaço de estados.
- Descobrir quais são os algoritmos de estratégia de pesquisa em espaço de estados.
- Conhecer o algoritmo de Busca Cega.
- Conhecer o algoritmo de Heurística.
- Conhecer o algoritmo de Busca em Largura.
- Conhecer o algoritmo de Busca em Profundidade.
- Conhecer o algoritmo de Busca em A^* .

INICIE SUA JORNADA

Como ir de um ponto A para o ponto B? Qual é a opção mais rápida? Qual é a opção mais econômica? Essas são algumas perguntas que a sociedade precisou ter e que hoje são resolvidas com pequenos toques no seu GPS que está em seu telefone. Mas qual é a lógica que está por trás dessas aplicações? Estes sistemas de navegação possuem diversos algoritmos para que o sistema de recomendação venha a ser cada vez mais preciso de modo a atender as demandas de um mundo que precisa de informações exatas e no menor tempo de resposta possível. Um sistema de logística de entregas também é beneficiado com algoritmos de busca. Já imaginou o quanto um grande site de entregas de produtos de diversos vendedores pode ser beneficiado por um sistema bem apurado?



PLAY NO CONHECIMENTO

Estudante, neste podcast conheça o vínculo da estratégia de pesquisa em espaço de estados e aplicações de navegação. Que tal ouvir agora? Acesse e dê o play nesse podcast que preparamos especialmente para você!. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

No desenvolvimento de software, precisamos trabalhar com algoritmos para desenvolver uma aplicação. Para este tema de aprendizagem, tenha em mente que os recursos disponíveis como recursividade e estruturas de controle, pois os algoritmos de estratégia de pesquisa em espaço de estados estão relacionadas para que possa resolver diversos tipos de problemas de negócio.

DESENVOLVA SEU POTENCIAL

ESTRATÉGIAS DE PESQUISA EM ESPAÇOS DE ESTADOS

Para trabalhar as estratégias de pesquisa em espaço de estados, precisamos definir o que é um **agente**. Um agente é tudo o que pode ser considerado capaz de perceber em seu ambiente por meio de sensores e agir sobre esse ambiente por intermédio de atuadores. Essa definição é importante pois as resoluções de problemas por meio de busca utilizam agentes de resolução de problemas, que decidem o que fazer encontrando sequências de **ações** que levam a **estados** desejáveis (Russel; Norvig, 2013).

Uma solução para um problema é um caminho desde o estado inicial, até um **estado objetivo** explorando todos os estados possíveis. A qualidade da solução é medida pela função de custo de caminho e para saber a função de custo de caminho, precisamos conhecer o **estado inicial** em que o agente começa e as ações possíveis após identificar este estado para que o conjunto de todos os estados acessíveis sejam conhecidos e é isso que define um **espaço de estados**: a partir de um ponto inicial que podemos nomear de **n** , quais próximos passos ou ações são possíveis de realizar partindo de **n** (Russel; Norvig, 2013).

Um **caminho** no espaço de estados é a sequência de estados conectados por meio de ações, com a **função (f)** de custo de caminho (ou função de transição) atribuindo um valor



numérico a cada trajeto percorrido. Esse caminho é validado pelo **teste de objetivo**, que verifica se os próximos estados são possíveis ou não. Um exemplo de função: $f(n) = h(n)$, onde $f(n)$ representa o custo estimado total do caminho através de n até a meta e $h(n)$ é a estimativa heurística do custo de n até o objetivo. Essa função é referente a um algoritmo de busca informada, a busca gulosa que será abordada em próximos tópicos (Russel; Norvig, 2013).

Por exemplo, um GPS desatualizado pode indicar seguir em frente para a próxima rua para alcançar um determinado destino, mas se houver obras no local, o caminho, embora existente, não é válido.

A melhor forma de aprendermos sobre estratégia de pesquisa em espaços de estados é os representando através de grafos matemáticos, pois as aplicações que resolvem problemas partem através deles - estes grafos serão utilizados para representar os seus algoritmos e facilitar o entendimento. A teoria dos grafos foi redescoberta muitas vezes (Boaventura; Oswaldo, 2011).

Há registro, do ano 1847, que os primeiros grafos foram utilizados para estudos de circuitos elétricos e que gerou outras teorias como das árvores. Também há registros na química orgânica, jogos, mapas, sobre o uso de grafos, isso antes de 1980, agora as aplicações são infinitas (Boaventura; Oswaldo, 2011).




Figura 1 - Exemplo simples de parte de um grafo / Fonte: o autor.

Descrição da Imagem: A figura apresenta 6 círculos, cada um possui uma letra, que são A, B, C, D, E e F. A letra A está conectada a B, C com D e E e F com E. As conexões são realizadas por setas indicativas.

ALGORITMOS DE ESTRATÉGIA DE PESQUISA EM ESPAÇOS DE ESTADOS

Os algoritmos de estratégia de pesquisa em espaços de estado podem ser divididos em duas opções: os **algoritmos de busca cega** - que também podem ser definidos como algoritmos de busca não informada e os **algoritmos heurísticos** ou de busca informada (Russel; Norvig, 2013).

Os algoritmos de busca cega ou busca não informada são técnicas de exploração de espaços de estados onde o algoritmo não possui informações adicionais sobre o problema além da definição do espaço de estados, já as heurísticas são funções que fornecem uma estimativa do custo restante para alcançar o objetivo a partir de um estado atual (Russel; Norvig, 2013).

A seguir, uma tabela com um resumo comparativo sobre os algoritmos de estratégia de pesquisa em espaço de estados.

TIPO	ALGORITMO	VANTAGEM	DESVANTAGEM
BUSCA CEGA OU BUSCA NÃO INFORMADA	Busca em Largura	Garante encontrar a solução mais curta se todos os custos de caminho forem iguais.	Pode consumir muita memória e tempo, especialmente em espaços de estados grandes.
	Busca em Profundidade	Menor uso de memória comparado à busca em largura. Pode ser mais rápido em encontrar uma solução se a profundidade da solução for baixa.	Não garante a solução mais curta. Pode entrar em loops infinitos se não for implementado com controle de nós visitados.

BUSCA INFORMADA	Algoritmos A* (A estrela)	Garante encontrar a solução ótima se a heurística não superestimar o custo real.	É comum o alto uso de memória em problemas com espaços de estados grandes.
	Busca Gulosa	Rápido para encontrar uma solução para heurísticas precisas.	Procurar a solução ótima não é seu objetivo. Pode demorar a encontrar o objetivo final. Pode "se perder" no caminho e encontrar nós finais sem ser o objetivo final.

Tabela 1 - Comparativo entre algoritmos de estratégia de pesquisa em espaços Fonte: adaptado de Russel e Norvig (2013).

ALGORITMOS DE BUSCA CEGA (NÃO INFORMADA)

Este tipo de busca cega (não informada) explora os nós de maneira sistemática sem usar heurísticas (busca informada) ou estimativas de quão perto está do objetivo.



A expressão busca cega significa que elas não têm nenhuma informação adicional sobre os estados, além daquelas fornecidas na definição do problema. Tudo o que elas podem fazer é gerar sucessores e distinguir um estado objetivo de um não-objetivo (Russel; Norvig, 2013, s.p.).

Alguns exemplos, que serão aprofundados neste tema de aprendizagem, são Algoritmo de Busca em Largura e Algoritmo de Busca em Profundidade.

Algoritmos de Busca em Largura

O termo em inglês “**Breadth-First Search**” é uma busca não informada que explora todos os nós em um nível antes de avançar para o próximo nível. É garantido que encontra a solução mais curta, mas pode ser ineficiente em termos de tempo e memória (Anderson; Blelloch; Tangwongsan, 2020).

Na Figura 2, observe a movimentação da busca onde as letras representam estados e números a movimentação ordenada pelo algoritmo. Os números de 1 a 6 representam a ordem de visita dos estados de A a F disponíveis aplicando o algoritmo de busca em largura. Ou seja, o algoritmo quando iniciado visitará em ordem os estados A, C, B, D, E e F. Neste exemplo, as letras de A a F poderiam ser trocadas por um nome de uma rua, para ser utilizado em um sistema de navegação, por exemplo.




Figura 2 - Representação do algoritmo busca em largura / Fonte: o autor.

Descrição da Imagem: A figura 2 apresenta 6 círculos, cada um possui uma letra, que são A, B, C, D, E e F. As conexões são realizadas por setas indicativas. Números estão representando o caminho visitado A-1, C-2, B-3, D-4, E-5, F-6.

Lógica do algoritmo - portugol

Colocar o estado inicial em uma fila

Fila: [A]

Visitados: { }

Se é A o estado objetivo

fim

Se não for

Remover o estado A da fila

Adicionar todos os seus sucessores (estados resultantes das ações) ao final da fila.

// comentário: como A não é o estado objetivo do grafo da figura 2, é preciso adicionar os estados sucessores B e C na fila marcando como visitados //

Fila: [A,B,A,C]

Visitados: {A, B, C}

Se é B o estado objetivo

fim

Se não for

Remover A,B da fila

Adicionar todos os seus sucessores (estados resultantes das ações) ao final da fila.

// comentário: B não tem estados conectados //

Fila: [A,C]

fim

Se é C o estado objetivo

Se não for

Remover A,C da fila

Adicionar todos os seus sucessores (estados resultantes das ações) ao final da fila

// comentário: como C não é o estado objetivo do grafo da figura 2, é preciso adicionar os estados sucessores D e E na fila marcando como visitados //

Fila: [A,C, D, A, C, E]

Visitados: {A,B,C,D,E}

Repetir o processo até encontrar o **estado objetivo**

fim

Os números de 1 a 6 representam a ordem de visita dos estados de A a F disponíveis. Ou seja, o algoritmo quando iniciado visitará por ordem os estados A, C, B, D, E e F. Neste exemplo, as letras de A a F poderiam representar um nome de uma rua, para ser utilizado em um sistema de navegação.

Perceba que o algoritmo visita os nós por níveis, ou seja, C e B (largura) foram visitados antes de seguir A, C e D (profundidade).

Algoritmos de Busca em Profundidade

O termo em inglês “*Depth-First Search*” é uma busca não informada que explora o máximo possível ao longo de um ramo antes de retroceder. É mais eficiente em termos de memória, mas pode não encontrar a solução mais curta e pode entrar em loops infinitos em espaços de estados grandes ou cíclicos. Este algoritmo é conhecido também como algoritmo de Trémaux’s (Even, 2012).




Figura 3 - Representação do algoritmo busca em profundidade / Fonte: o autor.

Descrição da Imagem: A figura 3 apresenta 6 círculos, cada um possui uma letra, que são A, B, C, D, E e F. As conexões são realizadas por setas indicativas. Números representando o caminho visitado A-1, C-2, D-3, E-4, F-5, B-6.

Observe que a figura 3 apresenta 6 círculos que são os estados disponíveis para visitar, cada um possui uma letra, que são A, B, C, D, E e F. As conexões são realizadas por setas indicativas. Números representam ordenadamente os estados que são visitados e que neste exemplo: A, C, D, E e F.

A seguir, será apresentado a lógica do algoritmo de busca em profundidade, que é responsável por ordenar a busca conforme observado na Figura 3:

Lógica do algoritmo - português

Colocar o estado inicial em uma **pilha**

Pilha: [A]
Visitados: { }

Remover o estado A da **pilha**

Adicionar todos os seus sucessores (estados resultantes das ações) a pilha:

// comentário: como A não é o estado objetivo do grafo da figura 3, é preciso adicionar os estados sucessores B e C na pilha marcando como visitados //

Pilha: [A,B,A,C]
Visitados: {A}

Se é A o estado objetivo

fim

Se não for

Remover A,C da **pilha**

Adicionar todos os seus sucessores (estados resultantes das ações) ao final da **pilha**.

// comentário: como A não é o estado objetivo do grafo da figura 3, é preciso adicionar os estados sucessores D e E na pilha marcando como visitados //

Pilha: $[A, B, A, C, D, A, C, E]$

Visitados: $\{A, C\}$

Se é C o estado objetivo

fim

Se não for

Remover A, C, E da pilha (último adicionado).

Adicionar todos os seus sucessores (estados resultantes das ações) ao final da pilha.

// comentário: como C não é o estado objetivo do grafo da figura 2, é preciso adicionar os estados sucessores D e E na fila marcando como visitados //

Pilha: $[A, C, D, A, C, E, F]$

Visitados: $\{A, C, E\}$

Repetir o processo até encontrar o **estado objetivo**

fim

Perceba que nesse grafo proposto na Figura 3, e para o algoritmo de busca em profundidade, o estado B será considerado na pilha mas não será visitado, pois F é o estado objetivo e acessado antes de B pela busca em profundidade. Uma vez encontrado, o algoritmo é finalizado sem precisar passar por B.

ALGORITMOS DE BUSCA INFORMADA (HEURÍSTICAS)

Uma boa heurística pode melhorar significativamente a eficiência das buscas informadas, guiando a exploração do espaço de estados de maneira mais inteligente e rápida. Estas heurísticas são estimativas de custo que ajudam a priorizar quais caminhos seguir em direção ao objetivo.



A busca informada é uma estratégia que utiliza o conhecimento específico do problema, além da definição do próprio problema - pode encontrar soluções de forma mais eficiente que uma estratégia sem informação (Russel; Norvig, 2013, s.p.).

A qualidade das heurísticas é crucial para a eficiência dos algoritmos de busca informada. Algumas propriedades importantes das heurísticas incluem (Russel; Norvig, 2013):

- **Admissibilidade:** A heurística nunca superestima o custo real para chegar ao objetivo. Isso garante que a busca A^* encontra o que é chamado de solução ótima.
- **Consistência** (ou Monotonicidade): Para qualquer estado n e seu sucessor n' , a diferença entre as heurísticas deve ser menor ou igual ao custo de transição entre esses estados. Isso assegura que a função f nunca diminua ao longo do caminho.

Vamos explorar algumas das estratégias de busca informada mais comuns, Algoritmos A^* (A-estrela) e Busca Gulosa.

Algoritmos A^* (A-estrela)

Descrito pela primeira vez por Peter Hart *et al.*, (1968), o algoritmo A^* utiliza uma função heurística que estima o custo total do caminho até o objetivo. É completa e ótima, desde que a heurística seja admissível (nunca superestima o custo real para alcançar o objetivo).




Figura 4 - Representação do algoritmo busca A* (A-estrela) / Fonte: o autor.

Descrição da Imagem: A figura 4 apresenta 7 círculos com as letras de A até G. As conexões são realizadas por setas indicativas A está conectada com C com um valor de 13, A conectada com B com valor de 10. B conectada com G com valor de 7. C conectada com D com valor 1 e também com E com valor 6. E conectada com F com valor 2. Números representando o caminho visitado A-1,B-2,C-3,D-4,G-5,E-6,-F-7. Também é apresentada uma tabela com estado e h de heurística com o valor a=30, b=12, c=15, d=5, e=8, f=7 e g=6.

Observe que a Figura 4 apresenta 7 círculos que são os estados disponíveis para visitar, cada um possui uma letra, que são A, B, C, D, E, F e G. As conexões são realizadas por setas indicativas. Números em vermelho representam ordenadamente os estados que são visitados e que neste exemplo: A, B, C, D, G, E e F. Em verde nós temos o custo do valor para visitar os estados. Ou seja, se você desejar ir do estado A até C terá o custo 13 ou do estado A até B, 10. Esse custo do caminho que está em verde na figura 4 precisa ser somado ao custo da heurística apresentado na tabela.

Ou seja, se partindo do estado A, deseja-se descobrir o valor para ir ao estado C, deve-se considerar o valor heurística de C que está na tabela representado por 15 e somar com o valor do caminho que de A até B (que está em verde) com o

valor 13, ou seja, 28. Se queremos o custo total de A até B, ainda falta considerar a soma com o valor de 30 que é o valor heurístico na tabela representada para o valor $A = 30 + 28$ (valor heurístico de B 12 + o valor de 13 do caminho A-B) = 58 de custo total partindo de A com chegada em B.

Assumindo que A é o estado inicial e F é o estado final objetivo, para cada próximo passo a função $f(n) = g(n) + h(n)$ deve ser aplicada, vamos ao teste de mesa na prática para todo o restante do grafo (teste de mesa é um processo manual para validar a lógica de um algoritmo):

O primeiro estado é o A e inicia valendo 30.

Quais são os estados disponíveis para visitar? B e C.

Para ir para B: $A = 30$, $B = 12$ + o caminho de A até B que vale 10, **total 52**.

Para ir para C: $A = 30$, $C = 15$ + o caminho de A até C que vale 13, **total 58**.

Escolha a opção com menor custo, então, vá para B.

Quais são os estados disponíveis para visitar? C e G.

Para ir para C: $A = 30$, $C = 15$ + o caminho de A até C que vale 13, **total 58**.

Para ir para G: $A = 30$, $B = 12$ + o caminho de A até B que vale 10, **total 52** + o custo até G que é $7+6$ do seu valor = 13. Somado aos 52 do caminho anterior = **total 65**.

Neste caso, não vá para G e sim vá para C por ter o menor custo.

Quais são os estados disponíveis para visitar? D, E e G.

G descobrimos que tem o **total 65**.

Para ir para D: $A = 30$, $C = 15$ + o caminho de A até C que vale 13, total 58 + o custo de D que é $5 + 1$ do seu custo do total de 6. $58 + 6 =$ **total 64**.

Para ir para E: $A = 30$, $C = 15$ + o caminho de A até C que vale 13, total 58 + o custo de E que é $8 + 6$ do total do seu custo 14. $58 + 14 =$ **total 72**.

Neste caso, vá para D que tem o menor custo entre as opções disponíveis.

Quais são os estados disponíveis para visitar? Dado que D é um estado onde o grafo se encerra, sobram as possibilidades E e G.

Para ir para G: $A = 30$, $B = 12$ + o caminho de A até B que vale 10, **total 52** + o custo até G que é $7+6$ do seu valor = 13. Somado aos 52 do caminho anterior = **total 65**.

Para ir para E: $A = 30$, $C = 15$ + o caminho de A até C que vale 13, total 58 + o custo de E que é 8 + 6 do total do seu custo 14. $58 + 14 = \text{total } 72$.

Neste caso, vá para G.

E então, vá para F que é o último estado disponível a ser visitado.

Neste caso, todos os estados foram visitados até identificar o fim, mas não é uma obrigatoriedade visitar todos os nós.

A seguir, será apresentado a lógica do algoritmo de busca em profundidade, que é responsável por ordenar a busca conforme observado na Figura 4:

Lógica do algoritmo - portugol

Colocar o estado inicial em uma **fila de prioridade** com custo inicial de 0

// comentário: Seguindo a figura 4 como exemplo, A é colocado como o estado inicial e aplicado a função $f(A) = g(A) + \text{heurística}(A) \rightarrow 0 + 30 = 30$ para o seu estado //

Fila de prioridade: (A,30)

$g = \{ A: 0 \}$

$f = \{ A: 30 \}$

Visitados: $\{ \}$

Remover o nó com o menor valor da função $f(n) = g(n) + h(n)$

// comentário: No caso da figura 4, remova A. //

Calcular o custo real do caminho percorrido até o vizinho e a estimativa total do custo

// comentário: Vizinhos de A: B e C.//

// comentário: cálculo para B //

$$g(B) = g(A) + \text{custo}(A, B) = 0 + 10 = 10$$

$$f(B) = g(B) + \text{heurística}(B) = 10 + 12 = 22$$

// **comentário:** *cálculo para C* //

$$g(C) = g(A) + \text{custo}(A, C) = 0 + 13 = 13$$

$$f(C) = g(C) + \text{heurística}(C) = 13 + 15 = 28$$

Fila de prioridade: (B,22),(C,28)

Visitados: {A}

Se A é o estado objetivo

fim

Se não for

Calcular o custo real do caminho percorrido até o vizinho e a estimativa total do custo

$$g(G) = g(B) + \text{custo}(B, G) = 10 + 7 = 17$$

$$f(G) = g(G) + \text{heurística}(G) = 17 + 6 = 23$$

Fila de prioridade: (C,28),(G,23)

Visitados: {A,B}

Repetir o processo até encontrar o **estado objetivo**

fim

O algoritmo A^* é uma busca informada que combina as abordagens de Menor Custo Acumulado e gulosa, neste exemplo observamos que $g(n) = 0$ representa a Busca Gulosa, e $h(n) = 0$, a Busca Não Informada de Menor Custo Acumulado.

**EU INDICO**

Neste vídeo, conheça o projeto Shakey, que foi realizado em um centro de inteligência artificial, no instituto de pesquisa de Stanford. O projeto propôs a construção de um robô que tinha a capacidade limitada de perceber e modelar seu ambiente, realizar tarefas que exigiam planejamento, localização de rotas e reorganização de simples objetos. O algoritmo A* (A-estrela) foi criado como parte das tarefas deste robô. Um grande avanço para a época. Assista em: <https://www.youtube.com/watch?v=GmU7SimFkpU>

Busca Gulosa

Do inglês “*Greedy Search*”, Busca Gulosa é uma busca informada que seleciona o nó que parece ser o mais próximo do objetivo, baseado em uma função heurística para estimar o custo do caminho $f(n) = h(n)$, onde $f(n)$ é o custo estimado total do caminho através de n até a meta e $h(n)$ é a estimativa heurística do custo de n até o objetivo. Pode ser muito rápida, mas não garante a melhor solução, pois a busca gulosa pode se comprometer com um caminho que pode parecer promissor, mas acaba sendo mais caro.



O primeiro registro deste algoritmo foi através do trabalho de Borůvkapode, em 1926, em seu trabalho: *O jistém problému minimálním. Práce Mor. Prírodved. Spol. v Brne (Acta Societ. Scienc. Natur. Moravicae)* 3, 3 (1926), 37-58. Este algoritmo surgiu como solução para fornecer cobertura elétrica eficiente na área rural de uma cidade. De seu trabalho há a variação de algoritmos como os de Prim e Kruskal, a diferença é que estes dois últimos acrescentam uma fila de prioridade além do algoritmo original (Anderson; Billeloch; Tangwongsan, 2020).




Figura 5 - Representação do algoritmo busca gulosa / Fonte: o autor.

Descrição da Imagem: A figura apresenta 7 círculos com as letras de A até G. A está conectado com C com um valor de 13, A conectado com B com valor de 10. B conectado com G com valor de 7. C conectado com D com valor 1 e também com E com valor 6. E conectado com F com valor 2. A ordem de visitação é A,B,C,G,D,E,F. Também é apresentada uma tabela com estado de A até G e h de heurística com o valor a=30, b=12, c=15, d=5, e=8, f=7 e g=6.

A seguir, será apresentado um **teste de mesa** que devemos utilizar para validar o resultado e, neste caso, valida a Figura 5.

B OU C?

B - $30 + 12 = 42$

C = $30 + 15 = 45$

2 - VISITE B

C OU G?

$$G \rightarrow B - 30 + 12 = 42 + 6 = 48$$

$$C = 30 + 15 = 45$$

3 - VISITE C

G OU D OU E?

$$G \rightarrow B - 30 + 12 = 42 + 6 = 48$$

$$D \rightarrow C = 30 + 15 = 45 + 5 = 50$$

$$E \rightarrow C = 30 + 15 = 45 + 8 = 53$$

4 - VISITE G

D OU E?

$$D \rightarrow C = 30 + 15 = 45 + 5 = 50$$

$$E \rightarrow C = 30 + 15 = 45 + 8 = 53$$

5 - VISITE D

6 - VISITE E

7 - VISITE F

Para a busca Gulosa não consideramos $g(n)$ que representa o custo do caminho desde o estado inicial até o nó n , então os valores em verde que são as arestas ligando os estados, não são contabilizados no caminho - é aplicado $f(n) = h(n)$. Essa é a diferença entre as buscas informadas gulosa e o a^* . Observe na figura 5 como o resultado da pesquisa de A até F a alteração do caminho realizado comparando a busca gulosa e o a^* .

A seguir, será apresentado a lógica do algoritmo em português para a busca gulosa, que é responsável por ordenar a busca conforme observado na Figura 5:

Colocar o estado inicial em uma fila de prioridade

// comentário: Para o exemplo da figura 5, considere A o estado inicial com a heurística 30.

Fila de prioridade: (A,30)

Visitados: { }

Remover A - que é o nó inicial e de menor heurística atual

// comentário: $f(n)$ Custo estimado total do caminho através de n até a meta. $h(n)$ é a estimativa heurística do custo de n até o objetivo.

Calcular a estimativa heurística do custo de vizinhos

$H(B) = 12, H(C) = 15$

Fila de prioridade: (B,12),(C,15)

Visitados: { A }

Se A é o estado objetivo

fim

Se não for

Remover B - que é o nó de menor heurística

Calcular a estimativa heurística do custo de vizinhos

$H(G) = 6$

Fila de prioridade: (C,15),(G,6)

Visitados: {A,B}

Se A é o estado objetivo

fim

Se não for

Repetir o processo até encontrar o estado objetivo

// Grafo de estados não visitados voltam a ser avaliados através da função $f(n) = h(n)$. //

fim

Perceba novamente neste algoritmo que o valor em verde no grafo da Figura 5 não é contabilizado no algoritmo. Ou seja, a busca gulosa considera apenas o valor da heurística, diferente do algoritmo a^* (a estrela) que contabiliza o custo do caminho e também o valor da heurística para definir a melhor estratégia.

Estes são 4 exemplos algoritmos de estratégia de pesquisa em espaço de estados, busca em largura, busca em profundidade, a * (a estrela) e busca gulosa e cada um dele terá uma melhor aplicação para problemas específicos. Por isso, aprenda e pratique todos para que possa aplicar a melhor solução sempre.

 EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementar e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Trabalhar com inteligência artificial (IA) significa estar familiarizado com as definições de lógica e poder aplicá-la na solução dos mais variados problemas de negócio. A importância de conhecer estratégias de pesquisa em espaços de estados e algoritmos de busca cega (não informada) e busca informada é fundamental para qualquer profissional ou estudante que deseje se aprofundar no campo da IA.

Essas estratégias são essenciais para a resolução de problemas complexos, podendo ser modelados como espaços de estados, onde a solução pode ser encontrada navegando através de diferentes estados possíveis. Existem uma infinidade de aplicações que utilizam estes conceitos, desde o GPS até sites de entrega, por isso é importante conhecê-las e também explorar as possibilidades em aplicações existentes de modo a estar preparado para o mercado de trabalho.

AUTOATIVIDADE

1. Em relação aos algoritmos de estratégia de pesquisa em espaços de estados, eles estão divididos entre dois tipos, um é a busca cega ou não informada e o outro é a busca informada. Em relação às vantagens e desvantagens do algoritmo busca gulosa:

I - Procurar a solução ótima não é seu objetivo.

PORQUE

II - Pode demorar a encontrar o objetivo final. Pode "se perder" no caminho e encontrar nós finais sem ser o objetivo final.

A respeito dessas asserções, assinale a opção correta:

- a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
 - b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
 - c) A asserção I é uma proposição verdadeira e a II é uma proposição falsa.
 - d) A asserção I é uma proposição falsa e a II é uma proposição verdadeira.
 - e) As asserções I e II são falsas.
2. As resoluções de **problemas** por meio de busca, das pesquisas em espaço de estados utilizam agentes de resolução de problemas e que decidem o que fazer encontrando sequências de **ações** que levam a **estados** desejáveis.

Para ter a solução para um problema de um caminho, quais alternativas a seguir representam dois estados que são necessários conhecer?

- a) Transverso e Reverso.
- b) Singular e Plural.
- c) Inicial e Objetivo.
- d) Aresta e percurso.
- e) Nenhuma das anteriores.

AUTOATIVIDADE

3. Levando em consideração o algoritmo de **busca em LARGURA** (Anderson; Blleloch; Tangwongsan, 2020) :

1. **Colocar o estado inicial** em uma fila.


2. **Remove** o nó da frente da fila

Se é o estado objetivo - fim.

Se não for, adicionar todos os seus sucessores (estados resultantes das ações) ao final da fila.

3. **Repetir** o processo até encontrar o **estado objetivo - fim**

E o seguinte grafo:



Qual é a ordem de visitação dos estados considerando o estado inicial A e o estado objetivo final F?

- a) A, B, C, D, E e F.
- b) A, C, B, D, E e F.
- c) A, C, D, E, F e G.
- d) A, C, E e F.
- e) A, C, D e F.

REFERÊNCIAS

ANDERSON, D., BLELLOCH, G. E., TANGWONGSAN, K. Work-Efficient Batch-Incremental Minimum Spanning Trees with Applications to the Sliding-Window Model. *In: SPAA'20*, 15-17 july, virtual event, USA. **Proceddings** [...], 2020. Disponível em: <https://dl.acm.org/doi/pdf/10.1145/3350755.3400241>. Acesso em: 5 jul. 2024.

EVEN, S. **Graph Algorithms**. 2. ed. Cambridge: Cambridge University Press, 2012.

BOAVENTURA, N.; OSWALDO, P. **Grafos: Teoria, Modelos, Algoritmos**. São Paulo: E. Blücher, 2011.

HART, E. P., NILSSON, N. J., RAPAHEL, B. A Formal Basis for the Heuristic Determination of Minimum Cost Paths. **IEEE Transactions of systems science and cybernetics**, v. 4, n. 2, july, 1986. Disponível em: <https://ai.stanford.edu/~nilsson/OnlinePubs-Nils/PublishedPapers/astar.pdf>. Acesso em: 4 jul. 2024.

RUSSEL, S.; NORVIG, P.; **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

GABARITO

1. Alternativa Correta A - As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.

A vantagem do algoritmo busca informada - busca gulosa é que é Rápido para encontrar uma solução para heurísticas precisas, porém, como desvantagem, Procurar a solução ótima não é seu objetivo. Pode demorar a encontrar o objetivo final. Pode "se perder" no caminho e encontrar nós finais sem ser o objetivo final.

B OU C?

$$\mathbf{B - 30 + 12 = 42}$$

$$\mathbf{C = 30 + 15 = 45}$$

2 - VISITE B

C OU G?

$$\mathbf{G \rightarrow B - 30 + 12 = 42 + 6 = 48}$$

$$\mathbf{C = 30 + 15 = 45}$$

3 - VISITE C

G OU D OU E?

$$\mathbf{G \rightarrow B - 30 + 12 = 42 + 6 = 48}$$

$$\mathbf{D \rightarrow C = 30 + 15 = 45 + 5 = 50}$$

$$\mathbf{E \rightarrow C = 30 + 15 = 45 + 8 = 53}$$

4 - VISITE G

D OU E?

$$\mathbf{D \rightarrow C = 30 + 15 = 45 + 5 = 50}$$

$$\mathbf{E \rightarrow C = 30 + 15 = 45 + 8 = 53}$$

5 - VISITE D

6 - VISITE E

7 - VISITE F


2. Alternativa correta C - Inicial e Objetivo.

Uma solução para um problema é um caminho desde o **estado inicial**, até um **estado objetivo** explorando todos os estados possíveis. Para saber a função de custo caminho, precisamos conhecer o **estado inicial** em que o agente começa e as **ações** possíveis após identificar este estado para que o conjunto de todos os estados acessíveis sejam conhecidos.

GABARITO

3. Alternativa correta B - A, C, B, D, E e F.

A, C, B, D, E e F. A busca em largura visita todos os nós em seus níveis até chegar ao seu objetivo:





unidalle



TEMA DE APRENDIZAGEM 4

ARQUITETURA E COMPONENTES DE SISTEMAS ESPECIALISTAS

MINHAS METAS

- Assimilar elementos básicos da arquitetura de sistemas especialistas.
- Aprender a criar uma base de conhecimento.
- Distinguir encadeamento progressivo e regressivo.
- Compreender as interfaces de usuário.
- Definir os componentes de sistemas especialistas.
- Entender a interação entre os componentes de sistemas especialistas.
- Conhecer conceitos da interface de usuário.

INICIE SUA JORNADA

Um sistema especialista normalmente é um software de decisão que pode alcançar um nível de desempenho comparável ao especialista humano. Isso significa que o conhecimento foi aprendido através de uma fonte especialista e transformado e armazenado em regras em um sistema capaz de sugerir ações ou conselhos para seus utilizadores.

Imagine que você trabalha em um hospital e está interessado em implementar um sistema especialista para auxiliar os médicos no diagnóstico de pacientes. O hospital atende a um grande número de pacientes e possui uma equipe de médicos com experiências diferentes, desde residentes a médicos especialistas com muitos anos de trabalho. O objetivo do sistema é garantir que todos os médicos, independentemente de seu nível de experiência, possam oferecer diagnósticos precisos e recomendação de tratamentos adequados.

Utilizar a inteligência de um sistema é gratificante, é possível fazer perguntas ou cadastrar informações que são processadas em segundo plano e devolvem informação acrescida a pesquisa realizada por um usuário. Mas quais são as etapas ou qual é a arquitetura e quais componentes são necessários para que um sistema venha a ser caracterizado como Sistema Especialista?

Este é o objetivo deste tema: conceitualizar e descrever características do funcionamento destes sistemas.



PLAY NO CONHECIMENTO

Estudante, convido você a ouvir sobre os casos reais da aplicação de componentes de sistemas especialistas. Acesse e dê o play nesse podcast que preparamos especialmente para você!

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

VAMOS RECORDAR?

A ideia básica e simples de um sistema especialista é transferir o conhecimento do especialista (ou outra fonte) para o computador. Os usuários podem pedir conselhos específicos ao sistema e este faz deduções para obter uma conclusão. Então, recomendações são apresentadas e as explicações por trás de sua recomendação. Os sistemas especialistas podem às vezes apresentar um desempenho bem melhor do que especialistas humanos

DESENVOLVA SEU POTENCIAL

ARQUITETURA E COMPONENTES DE SISTEMAS ESPECIALISTAS

A arquitetura de um sistema especialista é composta por diversos componentes principais que trabalham de forma integrada para alcançar a capacidade necessária para resolver problemas complexos, simulando o julgamento e comportamento humano (Russel; Norvig, 2013).

Estes componentes são essenciais para a construção de sistemas especialistas, como o exemplo a seguir do sistema MYCIN, onde há a representação de regras ou lógicas para estruturar o conhecimento e relacionando com informações ou fatos utilizando a forma “**SE** (antecedente) **ENTÃO** (consequente/condição/premissa)”. Antecedentes podem ser compostos pela conjunção e/ou disjunções de múltiplas preposições. Cada proposição é dada por um objeto linguístico e seu valor, ligados por um operador que pode ser de atribuição (**é, não é**) ou de relação (**é maior / menor que**) (Russel; Norvig, 2013).

SE a infecção é meningite **E**
 o tipo da infecção é bacterial **E**
 o paciente fez uma cirurgia **E**
 o paciente fez uma neurocirurgia **E**
 a neurocirurgia foi realizada há menos de 2 anos
 o paciente tem derivação ventricular uretral
ENTÃO infecção = e.coli (.8) ou klebsiella (.75)

Para que uma lógica de um sistema com o MYCIN venha a ser estruturado, é necessário um conjunto de componentes essenciais, como:

- Base de conhecimento.
- Motor de inferência.
- Interface de usuário.
- Módulo de explicação.
- Base de dados de casos.

Podemos ilustrar as interações entre estes componentes da seguinte forma:




Figura 1. Interação entre componentes de sistemas especialistas / Fonte: o autor.

Descrição da Imagem: A figura apresenta um fluxograma que contém cinco retângulos com informações escritas em seu interior. À direita, no retângulo acima, lê-se base de conhecimento. Ligado a esse, outro retângulo, abaixo, informa Base de dados de casos. Estes dois indicam um retângulo à sua frente, em que se lê Motor de inferência. Este está conectado, seguido por uma flecha indicativa, ao Módulo de explicação, também num retângulo. Por fim, a interface de usuário é indicada após o penúltimo retângulo, conectando novamente ao Motor de inferência.

A integração desses componentes formam sistemas especialistas capazes de tomar decisões complexas de maneira eficiente e precisa. A interface de usuário permite que os dados sejam inseridos e os resultados sejam apresentados de forma clara e intuitiva. O motor de inferência aplica as regras da base de conhecimento aos dados fornecidos, permitindo obter novas conclusões. A base de dados fornece o contexto histórico e os fatos necessários para apoiar essas inferências. O módulo de explicação garante que as decisões sejam transparentes e compreensíveis (Luger, 2004).

A seguir, serão aprofundados os conceitos e relacionamentos de cada etapa.

Base de Dados de Casos

A base de dados de casos possui exemplos, soluções e resultados de problemas para que possam ser resolvidos por analogia e em alguns casos pode ajudar associando casos semelhantes ao atual. Uma base de dados de casos especializada ajuda a aumentar a acurácia de um sistema especialista pois contribui para o funcionamento de um sistema especialista fornecendo exemplos de casos passados para comparação (Watson, 1997).



A base de dados de casos ou módulo de aquisição de conhecimento é responsável pela atualização da **base de conhecimentos** através de um mecanismo de interação cooperativa, gerado a partir do **módulo de explicação/explanação** (Ribeiro; Melo, 2013, p. 16).

A base de conhecimento é atualizada através da base de dados de casos para encontrar problemas semelhantes e passar a usar como referência. Exemplo: O histórico de um paciente com diagnóstico de meningite, tipo da infecção bacteriana, o paciente fez uma cirurgia, a cirurgia foi uma neurocirurgia realizada há 1 ano e paciente tem uma derivação ventricular uretral com o resultado que a infecção pode ser causada por e.coli (.8) ou klebsiella (.75).

Base de Conhecimento

A base de conhecimento possui informações, dados, fatos, heurísticas, relações, declarações condicionais e outras informações relevantes e necessárias que são utilizados para inferir novos fatos a partir de dados existentes. Segundo Ri-

beiro e Melo (2013, p. 15) “a base de conhecimentos reúne o conhecimento do especialista modelado conforme a representação de conhecimento escolhida para modelar em questão”.

Com base nas informações fornecidas pelo especialista e pelo usuário do sistema, o motor de inferência consulta a base de conhecimento para poder processar as regras competentes para o cenário consultado. Exemplo: O histórico de um paciente com diagnóstico de meningite, tipo da infecção bacteriana, o paciente fez uma cirurgia, a cirurgia foi uma neurocirurgia realizada há 1 ano e o paciente tem uma derivação ventricular uretral. Perceba que na base de conhecimento não é apresentado o resultado final assim como na base de dados de casos.

Perceba que conhecimento nessa etapa é derivado de um trabalho anterior, onde é trabalhado a representação do conhecimento obtido através de um especialista, representando o conhecimento através de redes semânticas, frames e outros.

Motor de Inferência

O motor de inferência é responsável pelo raciocínio processando os fatos e pela tomada de decisões aplicando as regras dentro do sistema especialista para chegar a uma conclusão e as regras podem ser executadas utilizando duas formas de encadeamento: **progressivo** (também conhecido como encadeamento para frente, *forward chaining*) ou **regressivo** (também conhecido como encadeamento para trás, *backward chaining*). Segundo Ribeiro e Melo (2013, p. 15):



O mecanismo de inferência examina o conteúdo da base de conhecimentos, decidindo a ordem em que são realizadas as inferências. Ao fazê-las, o mecanismo de inferência conduz a consulta com o usuário, transferindo os fatos e regras utilizadas durante uma consulta, para a memória de trabalho. O mecanismo de inferência evoca o módulo de explanação visando um processo de transformação do conhecimento, representado na base de conhecimento do SE ou deduzido no processo de busca de uma solução.

A partir dos fatos conhecidos o encadeamento progressivo aplica regras para inferir novos fatos com objetivo de alcançar uma conclusão, trata-se de um método adequado para sistemas onde os dados de entrada são dinâmicos e frequentemente atualizados, permitindo processar novas informações em tempo real (Luger, 2004). Exemplo:

Fatos Conhecidos:

- O paciente fez cirurgia.
- O paciente tem infecção por meningite.
- O paciente tem um tipo de infecção bacteriana.
- O paciente fez uma neurocirurgia há menos de 2 anos.
- O paciente tem uma derivação ventricular uretral.

Regras:

SE a infecção é meningite **E**

o tipo da infecção é bacteriana **E**

o paciente fez uma cirurgia **E**

o paciente fez uma neurocirurgia **E**

a neurocirurgia foi realizada há menos de 2 anos

o paciente tem derivação ventricular uretral

ENTÃO infecção = e.coli (.8) ou klebsiella (.75)

A partir de uma **meta** ou **hipótese** o encadeamento regressivo verifica se os fatos e regras são atendidas de trás para frente, o objetivo é confirmar ou negar uma determinada hipótese e é usado principalmente em diagnósticos médicos e resolução de problemas complexos, como o nosso exemplo MYCIN: (Luger, 2004).

Meta: Determinar se o paciente pode ter uma infecção que pode ser causada por e.coli (com probabilidade 0.8) ou klebsiella (com probabilidade 0.75).

Verificar se todas as informações necessárias para inferir a meta são informadas:

- O paciente fez cirurgia.
- O paciente tem infecção por meningite.

- O paciente tem um tipo de infecção bacteriana.
- O paciente fez uma neurocirurgia há menos de 2 anos.
- O paciente tem uma derivação ventricular uretral.

E faz o processo reverso:

SE o paciente tem derivação ventricular uretral **E**
 o paciente fez uma neurocirurgia **E**
 a neurocirurgia foi realizada há menos de 2 anos **E**
 o paciente fez uma cirurgia **E**
 o tipo da infecção é bacteriana e
 a infecção é meningite

ENTÃO infecção = e.coli (.8) ou klebsiella (.75)

Embora para estes exemplos citamos trechos do sistema MYCIN, ele serve apenas para fins didáticos e entender os tipos de encadeamento. Para fins de conhecimento do sistema MYCIN. Ele usou o encadeamento regressivo, começando com a hipótese de uma infecção específica e trabalhando para trás para verificar se os sintomas e dados laboratoriais suportavam essa hipótese.



Um exemplo fácil, simples e didático sobre os componentes de sistemas especialista é reproduzido no sistema especialista SINTA. Mantido pelo LIA - Laboratórios de Pesquisa em Computação da Universidade do Ceará, é uma ferramenta produzida para o sistema operacional Windows, gratuita, que utiliza um modelo de representação do conhecimento baseado em regras de produção e probabilidades e assim, permite simplificar o trabalho de implementação de um sistema especialista através de um motor de inferência compartilhada e também de interfaces de usuário.




Figura 2. Sistema SINTA / Fonte: <https://www.cin.ufpe.br/~fab/expert-sinta/manual.pdf>. Acesso em: 28 out. 2024.

Descrição da Imagem: A figura é um print de tela de computador e apresenta o funcionamento do sistema SINTA, em que é possível escrever as regras “se”, “então” que é utilizada para obter resultados sobre um determinado assunto que se deseja conhecer. A figura apresenta abas resultados, históricos e todos os valores fechadas enquanto a aba o sistema está aberta demonstrando as seguintes regras: REGRA 1 SE castanha broqueada com amêndoa totalmente destruída então praga = traça das castanhas CNF 100%, REGRA 2 SE galerias nos ramos ou inflorescências = Sim praga = broca das pontas CNF 100%, REGRA 3 SE inflorescências = Murchas ou secas e brotações novas murchas = sim e orifícios laterais nos ramos ou inflorescências = SIM então praga = broca das pontas CNF 100%, REGRA 4 se inseto mole amarelo ou verde = Sim então praga = pulgão das inflorescências CNF 100%, Regra 5 se ácaro estreito ou longo nas inflorescências = SIM então praga = eriofídeo das flores CNF 100%. A tela apresentada ainda apresenta um botão de fechar e outro de ajuda.

Também é possível utilizar os encadeamentos progressivos e regressivos. É um bom sistema para praticar o conteúdo deste tema de aprendizagem.

**EU INDICO**

Estudante, para conhecer o sistema SINTA, em que é possível praticar a construção de regras de sistemas especialistas observando os componentes como base de conhecimento, base de dados de casos, interface de usuário, motor de inferência e módulo de explicação, basta fazer o download. Trata-se de um sistema gratuito mas com a limitação de sistema operacional Windows®. É um sistema simples para poder colocar em prática os componentes do sistema, há também está referenciado o manual para um maior entendimento desse software específico. Acesse agora: <https://www.lia.ufc.br/~bezerra/exsinta>

Módulo de Explicação

O módulo de explicação contém a lógica e as justificadas conclusões alcançadas pelo motor de inferência para determinar uma solução, pois explica as regras e fatos usados em cada etapa inferida (Jackson, 1998). Segundo Ribeiro e Melo (p. 16, 2013), o módulo de explicação (ou explanação), tem por objetivo fundamental o auxílio à depuração e à construção incremental da base de conhecimentos de SE já existentes ou daqueles em fase de criação. Esse módulo de explicação que contém as lógicas, justificativas e conclusões que são alcançadas pelo motor de inferência pode ser percebido quando desenvolvidas regras através do sistema Expert Sinta, assim como foi indicado neste tema de aprendizado.

Para o exemplo que estamos utilizando neste tema de aprendizagem, o método de explicação descreve o processo de inferência: “A infecção foi diagnosticada como causada por E. coli (0.8) ou Klebsiella (0.75) porque todas as condições da regra foram satisfeitas ou A infecção não pode ser diagnosticada como causada porque pelo menos uma das condições da regra não foram satisfeitas”. De todas as formas, para a justificativa apresentada, o módulo de explicação precisa mostrar quais regras foram usadas e como foram aplicadas para que o usuário final consiga compreender o raciocínio realizado pela aplicação.

Interface de Usuário

Através da interface de usuário ele deve conseguir inserir informações e também receber os resultados finais com detalhes do módulo de explicações. Segundo Ribeiro e Melo (2013, p. 16), “a interação entre usuário-sistema é utilizada pelo mecanismo de inferência e pelo módulo de aquisição de conhecimento (base de dados de casos) através do módulo de explanação (explicação).

Para o nosso exemplo, a interface de usuário deve permitir que profissionais de saúde insiram dados sobre o paciente e apresentar o resultado ao usuário com as explicações fornecidas pelo módulo responsável, também deve permitir o acesso e atualização da base de conhecimento para que venha a ser possível adicionar novas regras ou modificar as existentes, além de permitir consultar e inserir casos na base dados de casos.

Ilustrando um segundo exemplo de interface de usuário e também do sistema **SINTA**, imagine um sistema especialista que precise tomar decisões a respeito da qualidade e o estado de um determinado carro. Uma das informações que o usuário do sistema deve inserir é o ano de fabricação de um carro. A interface deve ser simples ao usuário e fornecer informações de como essa informação será utilizada:




Figura 3. Sistema SINTA - Interface de usuário. Fonte: <https://www.cin.ufpe.br/~fab/expert-sinta/manual.pdf>. Acesso em: 28 out. 2024.


Descrição da Imagem: A figura apresenta um print de tela do sistema SINTA, em que se lê, no canto superior, Mecânica On-line. Abaixo, no centro, lê-se: “Qual o ano de fabricação do seu carro? Deixe em branco se não souber”. Há um campo de texto onde é possível inserir o valor, no exemplo lemos 1976. Abaixo, dois botões, um de OK e o outro de Por quê? O fundo é cinza, as letras são pretas.

Perceba que nessa figura é representada apenas uma parte do sistema, uma caixa de diálogo que faz uma pergunta simples e direta, todas as regras estão armazenadas em outro local onde não necessariamente o usuário final precisa ter conhecimento. A necessidade de uma interface simplificada para a coleta de dados do usuário é citada no livro de Inteligência Artificial de Russel e Norvig, recomendação desse tema de aprendizagem.



INDICAÇÃO DE LIVRO

Inteligência Artificial, de Stuart Russel e Peter Norvig, é um livro essencial para quem deseja trabalhar com inteligência artificial (IA). Este livro é recomendado para desmistificar e aprofundar os conceitos e aplicações de IA, promovendo uma leitura reveladora por diversos temas que muitas vezes são supervalorizados entre áreas que não são da tecnologia. Em outras palavras, a obra permite entender como trabalhar e desenvolver IA e não apenas utilizar uma aplicação que faz uso de IA.



É importante que o estudante, e futuro profissional, que deseja trabalhar com sistemas especialistas e inteligência artificial tenha a consciência que o apoio da literatura é complementar e um hábito necessário que deverá ser cultuado. Seja com livros tradicionais e referenciados como este de Inteligência Artificial de Stuart Russel e Peter Norvig, como também novos artigos que tratam da aplicação de técnicas e conceitos que estão descritos neste livro, pois um apresenta a teoria e os artigos apresentam temas mais recentes dessas aplicações.



EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementará e aprofundará ainda mais o seu entendimento sobre o tema.

Recurso de mídia disponível no conteúdo digital do ambiente virtual de aprendizagem.

NOVOS DESAFIOS

Entender as etapas, componentes e arquitetura de um sistema especialista significa compreender quais são as características e as necessidades que precisam ser incluídas para o seu correto funcionamento.

O profissional que desenvolve um sistema especialista deverá ser capaz de entender o papel de cada componente, como a base de conhecimento, o motor de inferência, a base de dados e o módulo de explicação. Entender como é o processo de aquisição e representação de conhecimento em um sistema especialista, descrever como o conhecimento é coletado, representado e armazenado no sistema, compreender a importância do motor de inferência e como ele utiliza a base de conhecimento para tomar decisões.

Lembre-se que as etapas de base de dados e de conhecimento podem ser associadas aos sistemas baseados em regras, lógica de predicados, redes semânticas, frames e ontologias.

Preparar a base de dados e conhecimento de um sistema especialista, bem como ela se relaciona com a etapa de aquisição e representação de conhecimento, como é possível obter vantagens da representação de conhecimento em específico, as suas regras no motor de inferência, significa que terá uma maior taxa de acerto em seus resultados.

Saber escolher o melhor tipo de encadeamento (progressivo e regressivo) para as situações de negócio que precisam ser resolvidas e como o motor de inferência aplica as regras para gerar conclusões. É necessário considerar os aspectos como precisão, custo e a dependência de especialistas humanos para a entrada de dados.

Também dentro desses componentes, é possível trabalhar com as incertezas de resultados e determinar o que as causam, melhorando a performance de um sistema. São componentes e estruturas que precisam ser estudados para que se conheça o funcionamento dos sistemas especialistas e também saiba o que está acontecendo ao utilizar um mecanismo inteligente, para que assim, tenha o conhecimento para trabalhar no desenvolvimento de novos sistemas.

AUTOATIVIDADE

1. O motor de inferência utiliza informações fornecidas através da base de conhecimento, da base de dados de casos e da interface de usuário.

Fonte: LUGER, G. F. **Inteligência Artificial**: Estruturas e Estratégias para a Complexidade Humana. São Paulo: Pearson Prentice Hal, 2004.

Quais características são verdadeiras para o encadeamento progressivo no motor de inferência de um sistema especialista? Assinale as verdadeiras.

- I - Começa com os fatos conhecidos e aplica as regras para obter conclusões.
- II - Trabalha para trás, partindo de uma hipótese.
- III - Justifica as inferências realizadas através do módulo de explicação.
- IV - É adequado para sistemas onde os dados de entrada são dinâmicos e frequentemente atualizados.

É correto o que se afirma em:

- a) I e IV, apenas.
 - b) II e III, apenas.
 - c) III e IV, apenas.
 - d) I, II e III, apenas.
 - e) II, III e IV, apenas.
-
2. A base de conhecimento, motor de inferência, interface de usuário, módulo de explicação e base de dados de casos são componentes de sistemas especialistas.

Quais destes componentes são responsáveis por armazenar conhecimento e justificar decisões? Assinale a(s) correta(s):

- I - Interface de Usuário.
- II - Motor de Inferência.
- III - Base de Conhecimento.
- IV - Módulo de Explicação.

É correto o que se afirma em:

- a) I, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) I, II, III e IV, apenas.

AUTOATIVIDADE

3. A arquitetura de um sistema especialista é composta por diversos componentes principais que trabalham de forma integrada para alcançar a capacidade necessária para resolver problemas complexos, simulando o julgamento e comportamento humano.

Como o módulo de explicação contribui para a transparência do sistema especialista?
Assinale a(s) alternativa(s) correta(s):

- a) Coletando dados dos usuários.
- b) Armazenando regras e heurísticas.
- c) Fornecendo justificativas detalhadas sobre como as conclusões foram alcançadas.
- d) Comparando novos casos com casos passados.
- e) Nenhuma das alternativas.

REFERÊNCIAS

LUGER, G. F. **Inteligência Artificial**: Estruturas e Estratégias para a Complexidade Humana. São Paulo: Pearson Prentice Hal, 2004.

JACKSON, P. **Introduction to Expert Systems**. EUA: Addison-Wesley, 1998.

RIBEIRO, D. T. M.; MELO, D. T. **Sistemas Especialistas e Lógica Fuzzy**. São Paulo: [s.n.], 2013.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

WATSON, L. **Aplicações Práticas de Raciocínio Baseado em Casos**. [S.l.]: Springer-Verlag, 1997.

GABARITO

1. Alternativa correta A - I e IV, apenas.

O encadeamento progressivo começa com os fatos ou dados conhecidos e aplica as regras de inferência para chegar a novas conclusões. É particularmente adequado para sistemas onde os dados de entrada são dinâmicos e precisam ser processados em tempo real ou frequentemente atualizados.

2. Alternativa correta C - III e IV, apenas.

A Base de Conhecimento armazena as regras que são utilizadas pelo sistema especialista para tomar decisões. O Módulo de Explicação é responsável por justificar as decisões e conclusões do sistema, explicando ao usuário o raciocínio por trás das inferências realizadas.

3. Alternativa correta C.

Fornecendo justificativas detalhadas sobre como as conclusões foram alcançadas. O módulo de explicação contém a lógica seguida pelo motor de inferência para determinar uma solução, pois explica as regras e fatos usados em cada etapa inferida.



TEMA DE APRENDIZAGEM 5

REPRESENTAÇÃO E TRATAMENTO DE INCERTEZAS

MINHAS METAS

- Entender os métodos probabilísticos.
- Conhecer aplicações práticas de métodos probabilísticos.
- Definir conceitos da lógica fuzzy.
- Estudar os conceitos da teoria de Dempster-Shafer.
- Aprender a utilizar as redes Bayesianas.
- Aprender a aplicar a lógica fuzzy.
- Compreender as fórmulas e aplicações das teorias e lógicas.

INICIE SUA JORNADA

Estudante, você sabia que para que os sistemas especialistas se tornem efetivo, eles precisam de informações na base de dados e de conhecimento? A falta de informação, os dados incompletos e/ou ausentes que não tem informações definidas e até com erros, permite interpretações múltiplas e ambíguas para o mesmo conjunto de dados. Principalmente os sistemas em saúde, em muitos casos, não são capazes de apresentar apenas um único resultado, mas sim um conjunto de possibilidades que auxiliar no critério final de decisão.

Se não for possível concluir uma ação ou uma resposta para um determinado problema, o planejamento condicional pode superar a incerteza até um certo ponto, mas apenas se as ações puderem obter as informações necessárias e se não houver muitas contingências diferentes.

Os métodos probabilísticos lidam com as incertezas permitindo que sistemas especialistas tomem decisões com base em evidências. Um sistema para médicos, por exemplo, nem sempre consegue revelar um diagnóstico 100% exato, por mais que tenha sua base de dados e conhecimento repleta de informações.

Quando não é possível atingir um resultado exato, os sistemas precisam trabalhar com a probabilidade que eventos ocorram, no nosso exemplo, para que com base nos sintomas e na anamnese de um determinado paciente e somado com o que há de registros na base de dados e conhecimentos, sugestões de diagnóstico devem ser oferecidos representando o grau de incerteza para que auxilie o médico na tomada de decisão.



PLAY NO CONHECIMENTO

Estudante, convido você a ouvir sobre A Incerteza em Sistemas Especialistas e como os métodos probabilísticos estão relacionados à incerteza. Acesse e dê o play nesse podcast que preparamos especialmente para você! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**




PLAY NO CONHECIMENTO

No motor de inferência existem dois tipos de encadeamento: progressivo e o regressivo. O encadeamento regressivo devolve resultados através de uma **meta**, ou **hipótese**, que avalia se os fatos e regras são atendidas de trás para frente com o objetivo de confirmar ou negar uma determinada hipótese. A representação e o tratamento de incertezas através das probabilidades podem ajudar a entender melhor as ações que são possíveis de realizar através deste tipo de encadeamento auxiliando e apurando os resultados. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

DESENVOLVA SEU POTENCIAL

REPRESENTAÇÃO E TRATAMENTO DE INCERTEZAS



A incerteza é uma característica a muitos domínios do conhecimento, especialmente naqueles em que a informação disponível é incompleta, ambígua ou sujeita a variabilidade. Em sistemas especialistas, que são projetados para

imitar o processo de tomada de decisão de um especialista humano em um domínio específico, a representação e o tratamento das incertezas tornam-se cruciais para a eficácia do sistema (Russel; Norvig, 2003).

Quando um agente conhece os fatos suficientes sobre seu ambiente, a abordagem permite derivar planos que podem oferecer a garantia de funcionamento. Infelizmente, em sua maior parte os agentes quase nunca têm acesso a toda verdade sobre o seu ambiente e por isso devem agir sob incerteza. Imagine um agente informando coordenadas para chegar até ao aeroporto e onde é preciso chegar em 90 minutos.

No máximo o que poderá ser ofertado pelo agente, é que será possível chegar em um determinado momento, mas ele não terá o controle sobre outras variáveis, como supor que o meio de transporte até ao aeroporto não vá quebrar, que não vá ficar sem combustível, que não haja acidentes no percurso e assim não é possível inferir o sucesso do plano. Se um agente lógico não puder concluir que qualquer curso de ação específico atingirá sua meta, ele será incapaz de agir.

A decisão racional, depende tanto da importância relativa de várias metas quanto da probabilidade de que (e do grau que) elas serão alcançadas. Os métodos probabilísticos fornecem uma base sólida para lidar com a incerteza, permitindo que os sistemas façam previsões e tomem decisões com base em evidências incompletas ou incertas, combinando essas evidências de diferentes fontes para calcular probabilidades (Russel; Norvig, 2003).

PROBABILIDADES E MÉTODOS PROBABILÍSTICOS

Os métodos probabilísticos são ferramentas matemáticas utilizadas para quantificar a incerteza. Eles se baseiam na teoria das probabilidades, que foi formalmente desenvolvida por matemáticos como Blaise Pascal e Pierre-Simon Laplace (1623-1662). As probabilidades quanto ao seu status e origem surgem de diversas visões: frequentista, objetivista e subjetivista e com o objetivo de ser uma medida que expressa o grau de crença na ocorrência de um evento incerto, permitindo em sistemas especialistas avaliar a confiabilidade de diferentes hipóteses ou diagnósticos com bases nas evidências disponíveis.

FREQUENTISTA

A frequentista afirma que os números só podem vir de experimentos, por exemplo: se 100 pessoas são testadas e 10 delas têm cáries, podemos afirmar que a probabilidade de uma cárie é aproximadamente 0,1, onde 0,1 é a fração que seria observada no limite de infinitamente muitas amostras.

OBJETIVISTA

A visão objetivista trata as probabilidades como aspectos reais do universo com objetos tendendo a se comportar de uma determinada maneira, por exemplo: o fato de o lançamento de uma moeda comum dar cara com probabilidade 0,5 é uma tendência da própria moeda, dessa forma, as medições frequentistas são tentativas de observar tendências.

SUBJETIVISTA

A visão subjetivista descreve probabilidades como modo de caracterizar as crenças de um agente, ao invés de ter algum significado físico externo o que permite, por exemplo, um especialista possa dizer que: "em minha opinião, devemos esperar que a probabilidade de uma cárie seja aproximadamente 0,1".

Dentre essas visões, acredita-se que não existe nenhuma lógica indutiva única mas sim acredita-se que qualquer lógica se baseia em uma distribuição subjetiva de probabilidade cujo efeito é reduzido à medida que são coletados resultados de outras observações (Russel; Norvig, 2003).

Diferentes métodos oferecem várias maneiras de tratar os resultados e ações de incertezas, que utilizam a teoria das probabilidades para quantificar a incerteza associada a eventos ou fatos, seja por desenvolvimento de modelos baseados em lógica fuzzy, Dempster-Shafer, ou redes bayesianas. As simulações permitem testar os modelos em cenários para avaliar o desempenho analisando os resultados de forma comparativa para validar a eficácia, reconhecer as limitações dos métodos ou refinar os modelos com base nos resultados simulados (Ribeiro; Melo, 2013).

Notação Básica de Probabilidade

Neste subcapítulo, vamos resumir e destacar o papel das proposições, as variáveis aleatórias, eventos atômicos, probabilidade a priori e condicional, além dos axiomas de kolmogorov, que são base das notações básicas em probabilidade.

Uma notação básica de probabilidade é uma linguagem formal para representar e raciocinar o conhecimento incerto. Qualquer notação deve ser capaz de lidar com a natureza das sentenças das quais são atribuídos graus e a dependência de crença em relação à experiência do agente. Estes graus de crença sempre são aplicados a **proposições**, que são afirmações que determinada situação está ocorrendo sendo verdadeiras ou falsas e que podem ser expressadas através da lógica proposicional e a lógica de primeira ordem. As variáveis aleatórias podem ser imaginadas como algo que se refere a uma parte do mundo cujo o “status” inicial é desconhecido (Russel; Norvig, 2003).

As **variáveis aleatórias** podem ser divididas em três tipos a depender do **domínio** (valores que uma variável aleatória pode assumir): booleanas (verdadeiro / falso), discretas (se o domínio for tempo, a variável aleatória discreta pode ser ensolarado, chuvoso, nublado) e variáveis aleatórias contínuas, que são valores a partir dos número reais como a proposição $x = 4,05$ afirma que a variável aleatória x tem o valor exato 4,05.


As proposições relativas a variáveis aleatórias contínuas também podem ser desigualdades, como $x \leq 4,05$. A **probabilidade a priori** (incondicional) $P(a)$, consegue descrever quando queremos nos referir às probabilidades de todos os valores possíveis de uma variável aleatória. É a probabilidade inicial que se tem sobre um evento, antes de qualquer nova informação ou evidência ser considerada. Se usarmos a expressão como: $P(\text{tempo})$ em vez de escrever as equações:

$$P(\text{tempo} = \text{ensolarado}) = 0,7$$

$$P(\text{tempo} = \text{chuvoso}) = 0,1$$

$$P(\text{tempo} = \text{nublado}) = 0,2$$

Podemos simplesmente escrever: $P(\text{Tempo}) = \langle 0,7, 0,1, 0,2 \rangle$, essa declaração define uma distribuição de probabilidade a priori para a variável aleatória tempo.



Assim como para um conjunto simples que queremos representar um paciente que tem a probabilidade a priori é de 0,1 de ter cárie podemos escrever $P(\text{Cárie} = \text{verdadeiro}) = 0,1$ ou $P(\text{cárie}) = 0,1$. Já a **probabilidade condicional**, expressa como $P(A|B)$ ou seguindo o exemplo prático relacionado ao paciente com cárie $P(\text{cárie}|\text{dordedente}) = 0,8$, indicando que, é a probabilidade de um evento A ocorrer dado que B é verdadeiro, ou de acordo com o exemplo, a probabilidade de o paciente ter uma cárie será de 0,8 (Russel; Norvig, 2003).

Os **eventos atômicos**, por sua vez, podem explicar os princípios básicos da teoria da probabilidade, pois são representados como elementos do espaço amostral dentro dos possíveis resultados de um experimento, onde cada evento é mutuamente exclusivo e coletivo, cobrindo todos os resultados possíveis. Por exemplo, ao lançar um dado, uma variável aleatória x pode representar o número que aparece na face superior do dado, e os eventos atômicos seriam $x = 1$, $x = 2$, ..., $x = 6$ (Russel; Norvig, 2003).

Em relação aos axiomas, eles são uma proposição que não requer prova e serve como base para a construção de teorias e sistemas lógicos (Lezzi *et al.*, 2012).

Os três axiomas a seguir são frequentemente chamados axiomas de Kolmogorov, em homenagem ao matemático russo que mostrou como elaborar o restante da teoria da probabilidade e fornecem a base para toda a teoria probabilística.

Os três axiomas principais são:

1. **Todas as probabilidades estão entre 0 e 1. Para qualquer proposição de a :**

$$0 \leq P(a) \leq 1$$

A notação básica de probabilidade envolve a atribuição de um valor $P(a)$ a um evento a , onde $P(a)$ é um número entre 0 e 1 que indica a probabilidade de a ocorrer.

2. **Proposições necessariamente verdadeiras (isto é, válidas) tem probabilidade 1, e proposições necessariamente falsas (isto é, não satisfatórias) têm probabilidade 0.**

$$P(\text{verdadeira}) = 1$$

$$P(\text{falsa}) = 0$$

3. **A probabilidade de uma disjunção é dada por:**

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b) \quad (\text{Kolmogorov, 1993})$$

Esses axiomas garantem que as probabilidades sejam consistentes e possam ser manipuladas matematicamente de forma lógica. No contexto de sistemas especialistas, essas regras são aplicadas para calcular probabilidades compostas, atualizar crenças com base em novas evidências e integrar diferentes fontes de informação (Russel; Norvig, 2003).

Redes Bayesianas

O **Teorema de Bayes** relaciona a probabilidade condicional de eventos e é uma ferramenta essencial para atualizar as crenças em sistemas especialistas. A fórmula do teorema de Bayes é expressa como o produto de $P(B|A)$ e $P(A)$, dividido por $P(B)$ - a probabilidade do evento “a” dado a ocorrência do evento “b”, fórmula:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

A fórmula relaciona as probabilidades a priori e condicionais de eventos, permitindo a atualização de crenças com base em novas evidências, onde $P(A|B)$ é a probabilidade de A dado B, $P(B|A)$ é a probabilidade de B dado A, $P(A)$ é a probabilidade a priori de A e $P(B)$ é a probabilidade, a priori, de B (Russel; Norvig, 2003).

Para ter como exemplo a aplicação do teorema, imagine que se deseja determinar a probabilidade de um paciente ter uma doença (A) dado que o mesmo testou positivo para um teste (B). Se sabemos a probabilidade de um teste positivo dado que o paciente tem a doença $P(B|A)$, a probabilidade a priori da doença $P(A)$, e a probabilidade de um teste positivo $P(B)$, podemos usar a Regra de Bayes para calcular $P(A|B)$.

Já as redes Bayesianas são estruturas de grafo que são utilizadas para representar relações de dependência probabilística entre variáveis, usando nós para variáveis e arestas para dependências condicionais. O uso de redes bayesianas são particularmente eficazes em modelar situações complexas onde múltiplas variáveis interagem, como no diagnóstico médico, onde diversos sintomas e sinais podem estar inter-relacionados, mas também como em outros casos como o exemplo a seguir (Russel; Norvig, 2003):




Figura 1. Rede bayesiana com tabelas de probabilidade condicional
Fonte: Russel e Norvig (2003, p. 481).

Descrição da Imagem: A figura possui 5 círculos, um círculo tem a palavra roubo e possui uma tabela ao lado com o nome $P(R)$ e o valor 0,001, o círculo terremoto possui uma tabela ao lado com o nome $P(T)$ com valor 0,002 e ambas estão apontando para o círculo alarme que tem a tabela com R e T para o valor de $P(A)$ 0,95 na primeira linha, R e T para o valor de $P(A)$ 0,94 na segunda linha, R e T para o valor de $P(A)$ 0,29 na terceira linha, R e T para o valor de $P(A)$ 0,001 na quarta linha e que por sua vez liga ao círculo JoãoLiga com a tabela A com valor v de verdadeiro para $P(J)$ de valor 0,90 e f de falso com o valor 0,05 de $P(J)$, por fim, o círculo MariaLiga com a coluna A apontando v de verdadeiro para $P(M)$ 0,70 e f de falso de $p(m)$ 0,01.

Este exemplo supõe que um morador principal tem João e Maria como vizinhos, e que avisam o morador principal quando escutam o alarme da sua casa tocar. João sempre chama quando ouve o alarme, mas também avisa ao morador principal quando seu telefone toca por ter um som parecido. Maria gosta de ouvir música em alto volume e por vezes, não escuta o alarme tocar. Quanto a esta topologia, no caso da rede de roubo, a topologia mostra que roubos e terremotos afetam diretamente a probabilidade de o alarme soar, mas o fato de João e Maria ligarem só depende do alarme, assim como a rede não tem nós correspondentes sobre Maria ouvir música alta ou João que se confunde o som do alarme com seu telefone (Russel; Norvig, 2003).

As tabelas da figura estão apresentadas sob forma de uma tabela de probabilidade condicional (TPC). Cada linha contém uma probabilidade condicional de cada valor de nó para um caso de condicionamento (uma combinação possível de valores para os nós superiores), que permite identificar a quantidade de vezes que o alarme toca e que é ou não causado por roubo, terremoto e que, foi avisado por João ou Maria. A cada vez que João ou Maria liga ou que um terremoto ou roubo acontecem e o alarme é soado, aplica-se o teorema de Bayes que permite uma atualização de probabilidades a priori com base nessas novas evidências, ajustando assim as crenças e apurando o sistema especialista (Russel; Norvig, 2003).

Teoria de Dempster-Shafer

A teoria de Dempster-Shafer, em vez de calcular a probabilidade de uma proposição, calcula a probabilidade de que a evidência admita essa proposição como uma medida de crença por sua função *Bel*(x) .

É composta de conceitos básicos como um **conjunto de hipóteses** onde relaciona todas as possíveis, um conjunto finito que armazena todas as respostas de um problema, a função de massa que atribui a probabilidade a cada subconjunto das hipóteses, a combinação de evidências uma vez que quando existem várias fontes de evidências as massas podem ser combinadas, a função de crença (*bel*), que é derivada da função de massa para quantificar a confiança mínima a ser atribuída ao conjunto de hipótese e a função de plausibilidade para representar a confiança máxima que pode ser atribuída ao conjunto de hipóteses (Shafer, 1976).

Vamos retornar ao exemplo em que o sistema de alarme pode ser ativado por duas situações: um terremoto ou roubo. Além disso, João e Maria, dois vizinhos, ligam para o dono para informar que o alarme tocou.

Hipóteses:

H1: Houve um roubo.

H2: Houve um terremoto.

H3: Houve um roubo ou um terremoto.

H4: Nenhuma das opções.

Evidências:

João, ouviu o alarme tocar, mas não sabe dizer se foi por terremoto ou roubo, suportando a hipótese H3. Maria, está mais certa que foi um roubo, suportando a hipótese H1.

Funções de Massa:

João

- $mJ(H3) = 0.8$ representa que acredita que o alarme tocou por causa de um roubo ou terremoto.
- $mJ(H4) = 0.2$ representa pequena chance de o alarme tocar por outra causa.

Maria

- $mM(H1) = 0.7$ representa a sua maior confiança que o alarme tocou por roubo.
- $mM(H3) = 0.3$ representa uma pequena chance de o alarme ser tocado por terremoto ou ambos.

Para determinar a credibilidade das diferentes hipóteses com base nas ligações de João e Maria precisamos utilizar a **regra de combinação de Dempster**:

$$mJM(H) = \frac{1}{1-K} \sum_{Hi \cap Hj = H} mJ(Hi).mM(Hj)$$

Explicando cada elemento da regra:

- mJm é a função de massa resultante da combinação de evidências (massa de João e Maria neste exemplo), medida do grau de crença em H com base na evidência a ser considerada.
- A fração $\frac{1}{1-K}$ é um fator de normalização que ajusta a soma das massas combinadas para garantir que as probabilidades resultantes somem 1, necessário para redistribuir a massa das hipóteses conflitantes para não conflitantes.
- K representa a **massa de conflito**, que é obtida através de outro cálculo a seguir:

$$K = \sum_{H_i \cap H_j = \emptyset} mJ(H_i) \cdot mM(H_j)$$

- $\sum$ representa a estrutura geral da somatória de com a variável i de somação, com a interseção das hipóteses H_i e H_j das duas fontes e é calculado somando as funções de massa de todas as hipóteses cuja interseção é vazia.

Aplicação: Se João acredita em $H3$ (Houve um roubo ou um terremoto), Maria acredita em $H4$ (Nenhuma das opções), mas $H3 \cap H4 = \emptyset$, então: $mJ(H3) \cdot mM(H4) = 0.8 \cdot 0$.

Se João acredita em $H4$ (Nenhuma das opções), Maria em $H1$ (Houve um roubo), mas $H4 \cap H1 = \emptyset$, então: $mJ(H4) \cdot mM(H1) = 0.2 \cdot 0.7 = 0.14$.

Com a massa de conflito K encontrada, é possível calcular as novas massas combinadas aplicando a fórmula de combinação de Dempster:

Para $H1$ - A crença combinada de que houve um roubo é 16,3%: $mJM(H1) \approx 0.163$ ($\approx$ significa aproximadamente igual a. É usado para indicar que o valor calculado da massa combinada é aproximadamente este valor, permitindo pequenas diferenças ou arredondamentos), cálculo aplicado na fórmula:

$$mJM(H1) = \frac{1}{1-0.14} \cdot (0.2 \cdot 0.7) = \frac{0.14}{0.86} \approx 0.163$$

Para H2: A crença combinada de que houve um roubo ou terremoto é de 55,8%:
 $mJM(H3) \approx 0.558$, cálculo aplicado na fórmula:

$$mJM(H3) = \frac{1}{1 - 0.14} \cdot (0.8 \cdot 0.3 + 0.8 \cdot 0.3) = \frac{0.48}{0.86} \approx 0.558$$

Para H4: Não há crença combinada de que nenhum dos dois eventos aconteceu:
 $mJM(H4) = 0$, cálculo aplicado na fórmula:

$$mJM(H4) = \frac{0}{0.86} = 0$$

Com os cálculos realizados pela Teoria de Dempster-Shafer e baseados nas evidências de João e Maria, o grau de crença mais forte é de que o alarme foi disparado por um terremoto ou roubo. Perceba que a conclusão reflete a incerteza envolvida na situação, sem exigir que toda a massa de probabilidade seja atribuída a uma única hipótese, como seria exigido na teoria da probabilidade clássica. Ou seja, portanto, a Teoria de Dempster-Shafer é útil em situações em que as evidências são parciais e em que é necessário modelar explicitamente a incerteza e o conflito entre fontes de informação.

Lógica Fuzzy

A lógica fuzzy, introduzida por Lotfi Zadeh em 1965, é um método para lidar com a incerteza e a imprecisão em sistemas complexos. Diferentemente da lógica clássica, onde as proposições são estritamente verdadeiras ou falsas (1 ou 0), a lógica fuzzy permite graus intermediários de verdade. Isso é feito através de valores que variam entre 0 e 1, refletindo o grau de pertencimento de um elemento a um determinado conjunto fuzzy (Mendel, 2001).

A lógica fuzzy é similar a Teoria de Dempster-Shafer, oferece uma estrutura para tratar a incerteza, mas o faz a partir de uma perspectiva diferente, baseada na **evidência**. Ela permite a representação de incertezas sem a necessidade de atribuir probabilidades específicas, mas sim com intervalos de crença. Enquanto a probabilidade tradicional e Bayes trabalham com a frequência ou a crença na ocorrência de eventos específicos, a lógica fuzzy trata do grau de verdade das proposições em contextos vagos.

Ribeiro e Melo (2013) detalham como a lógica fuzzy pode ser aplicada para avaliar o risco cardíaco de pacientes, considerando múltiplos fatores de risco simultaneamente. Por exemplo, a pressão arterial pode ser categorizada em conjuntos como “normal”, “elevada”, e “muito elevada”. As regras fuzzy, que são semelhantes às regras “se-então” dos sistemas especialistas, então combinam essas variáveis para calcular uma pontuação geral de risco. Regras Fuzzy:

1. Se João ouviu o alarme (μJ (ouvir alarme) é alto) e não confundiu com o telefone (μJ (telefone) é baixo), então a probabilidade de ele ligar é alta.
2. Se João ouviu o alarme (μJ (ouvir alarme) é alto) mas confundiu com o telefone (μJ (telefone) é alto), a probabilidade de ele ligar ainda é alta, mas com maior incerteza.
3. Se Maria ouviu o alarme (μM (ouvir alarme) é alto) e a música não estava alta (μM (música alta) é baixo), então a probabilidade de ela ligar é alta.
4. Se maria não ouviu o alarme (μM (ouvir alarme) é baixo) porque a música estava alta (μM (música alta) é alto), então a probabilidade de ela ligar é baixa.

Com as regras definidas e as funções de pertinência, o sistema fuzzy consegue avaliar o grau de ativação das regras determinando o nível de acionamento do alarme, por exemplo:

Para o cenário que o alarme dispara devido a um roubo:

João: μJ (ouvir alarme) = 0.8 e μJ (telefone) = 0.3 (ele tem dúvidas se ouviu o alarme tocar, com chance de não fazer a ligação)

Probabilidade de João ligar = $\min(0.8, 1 - 0.3) = 0.7$ $\min(0.8, 1 - 0.3) = 0.7$.

Maria: μM (ouvir alarme) = 0.5 e μM (música alta) = 0.6 (Maria estava com música alta, com a chance de não fazer a ligação).

Probabilidade de Maria ligar = $\min(0.5, 1 - 0.6) = 0.4$ $\min(0.5, 1 - 0.6) = 0.4$.

Para este cenário é possível concluir:

- João tem uma probabilidade média de ligar.
- Maria tem uma baixa probabilidade de ligar.

A Lógica Fuzzy permite modelar a incerteza no comportamento de João e Maria. O modelo leva em consideração os fatores subjetivos (como a música alta ou a confusão de João) que afetam a probabilidade de eles ligarem para o morador. A rede de roubo, que considera eventos como roubos e terremotos, afeta diretamente a probabilidade de o alarme soar. No entanto, a probabilidade de João e Maria ligarem depende não só do alarme, mas também de suas próprias condições.



INDICAÇÃO DE LIVRO

Sistemas Especialistas e Lógica Fuzzy

Convido você a conhecer o livro *Sistemas Especialistas e Lógica Fuzzy*, de Daiani Ribeiro e Daniel Teodoro de Melo. Além de aprofundar os conhecimentos em lógica fuzzy, é possível fazer uma revisão sobre motor de inferência, módulos de explicação, encadeamento progressivo e regressivo. Assim como já foi possível perceber durante este tema, este livro relaciona as teorias citadas com uma abordagem para a análise de risco cardíaco, ou seja, um aprofundamento de aplicação clínica.



A lógica fuzzy também pode ser integrada com outros métodos de análise, como os métodos probabilísticos ou as redes Bayesianas para potencializar ainda mais a capacidade dos sistemas especialistas em lidar com a incerteza, fornecendo análises mais robustas e confiáveis, onde a lógica fuzzy pode modelar a imprecisão, enquanto Bayes ou Dempster-Shafer são utilizados para atualizar as probabilidades com base em novas evidências (Ribeiro; Melo, 2013).



EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementar e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

A representação e o tratamento de incertezas são fundamentais em sistemas especialistas. O uso de probabilidades e métodos probabilísticos é uma das abordagens mais robustas para lidar com essa incerteza. Neste contexto, é crucial compreender conceitos como proposições, variáveis aleatórias, eventos atômicos, probabilidade a priori, probabilidade condicional e os axiomas de Kolmogorov, que formam a base da teoria das probabilidades, pois os sistemas especialistas principalmente os que estão focados na área da saúde em muitos casos não são capazes de apresentar uma resposta exata, mas sim, uma probabilidade de um resultado final.

A escolha dos métodos para tratar incertezas influencia diretamente o design e a implementação desses componentes. Por exemplo, o uso de lógica fuzzy exige um motor de inferência que possa identificar os graus de verdade.

Uma abordagem baseada em redes Bayesianas precisa de uma estrutura de dados para representar as dependências condicionais e algoritmos para realizar inferências probabilísticas e quando a estrutura de dados se satisfaz, as redes bayesianas podem ser utilizadas para modelar as preferências do usuário e atualizar as recomendações conforme novas interações ocorrem, aumentando a precisão do sistema.

O aprendizado supervisionado pode aprimorar a base de conhecimento ao treinar modelos em dados históricos de falhas de equipamentos sugerindo ações preventivas, combinando esses modelos com lógica fuzzy é possível trabalhar com as incertezas medindo dados sensoriais. Utilizando a teoria de Dempster-Shafer é possível em um conjunto grande de dados identificar possíveis fraudes em transações financeiras. Elas podem ser tratadas e utilizadas como evidências para atualizar o grau de crença sobre as mesmas.

Essas são as características dos métodos de representação e tratamento de incertezas que podem e são combinadas com métodos de aprendizagem de máquina para criar sistemas especialistas cada vez mais inteligentes e úteis para tomada de decisão.

AUTOATIVIDADE

1. Assim como os axiomas de Kolmogorov, na aplicação do teorema de Bayes, existe uma fórmula para a probabilidade condicional $P(A|B)$.

Fonte: RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

Como ela é determinada? Assinale a questão correta:

- a) A soma das probabilidades de A e B.
 - b) O produto das probabilidades $P(A)$ e $P(B)$.
 - c) A probabilidade de A multiplicada pela probabilidade de B, dividida pela probabilidade de B.
 - d) A probabilidade de B multiplicada pela probabilidade de A, dividida pela probabilidade de B.
 - e) O produto de $P(B|A)$ e $P(A)$, dividido por $P(B)$.
2. Kolmogorov, matemático russo, mostrou, através de axiomas, como elaborar o restante da teoria da probabilidade fornecendo a base para toda a teoria probabilística.

Fonte: RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

Qual das seguintes alternativas não é um dos axiomas de Kolmogorov?

- I - $0 \leq P(a) \leq 1$
- II - $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$
- III - $P(A | B) = (P(B|A).P(A))/P(B)$
- IV - TPC

É correto o que se afirma em:

- a) I, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) I, II, III e IV.

AUTOATIVIDADE

3. A Teoria de Dempster-Shafer é composta de conceitos básicos relacionando um subconjunto de hipóteses para calcular probabilidades de massa combinada.

Fonte: SHAFER, G. **A Mathematical Theory of Evidence**. Princeton: Princeton University Press, 1976.

Sobre estes conceitos fundamentais, o que é possível afirmar? Identifique as corretas?

- I - A função de massa atribui valores a subconjuntos de hipóteses, indicando a quantidade de crença que pode ser diretamente atribuída a esses subconjuntos.
- II - A função de crença (Bel) quantifica a confiança mínima que pode ser atribuída a um subconjunto de hipóteses, considerando todas as evidências que suportam diretamente esse subconjunto.
- III - A regra de combinação de Dempster normaliza a soma das massas para garantir que a soma das crenças atribuídas às hipóteses seja igual a 1.
- IV - A combinação de evidências na Teoria de Dempster-Shafer sempre resulta em uma função de massa que distribui toda a crença exclusivamente entre hipóteses mutuamente exclusivas.

É correto o que se afirma em:

- a) I, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) I, II, III e IV.

REFERÊNCIAS

KOLMOGOROV, A. N. **Foundations of the Theory of Probability**. Chelsea Publishing Company, 1933.

LEZZI, G.; MURAKAMI, C. T.; DOLCE, O. **Fundamentos da Matemática Elementar**: Volume 1 - Conjuntos e Funções. São Paulo: Atual Editora, 2012.

MENDEL, J. M. **Uncertain Rule-Based Fuzzy Systems**: Introduction and New Directions. Upper Saddle River: Prentice-Hall, 2001.

RIBEIRO, D. T. M.; MELO, D. T. **Sistemas Especialistas e Lógica Fuzzy - Análise de Risco Cardíaco**. [S.l.]: Mococa-SP, 2013.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

SHAFER, G. **A Mathematical Theory of Evidence**. Princeton: Princeton University Press, 1976.

GABARITO

1. Alternativa correta - E) O produto de $P(B|A)$ e $P(A)$, dividido por $P(B)$.

O produto de $P(B|A)$ e $P(A)$, dividido por $P(B)$ é a resposta que apresenta a fórmula correta para calcular a probabilidade condicional $P(A|B)$ segundo o Teorema de Bayes. Todas as outras questões não representam o teorema de Bayes.

4. Alternativa correta - III e IV, apenas. $0 \leq P(a) \leq 1$ e $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$ são axiomas de Kolmogorov, enquanto $P(A | B) = (P(B|A).P(A))/P(B)$ é a fórmula de Bayes e TPC significa tabela de probabilidade condicional, que não tem relação com os axiomas de Kolmogorov.

2. Alternativa correta D.

I - Verdadeiro: A função de massa é responsável por atribuir valores a subconjuntos de hipóteses, indicando o grau de crença diretamente atribuível a esses subconjuntos.

II - Verdadeiro: A função de crença $Bel(H)$ é de fato utilizada para medir a confiança mínima que pode ser atribuída a um subconjunto de hipóteses.

III - Verdadeiro - A regra de combinação de Dempster inclui um fator de normalização para garantir que a soma das crenças seja igual a 1, conforme exigido pela teoria.

IV - Falso: A combinação de evidências na Teoria de Dempster-Shafer pode resultar em uma função de massa que não distribui toda a crença exclusivamente entre hipóteses mutuamente exclusivas, especialmente em situações em que há conflito entre as fontes de evidência.



TEMA DE APRENDIZAGEM 6

APRENDIZAGEM DE MÁQUINA EM SISTEMAS ESPECIALISTAS

MINHAS METAS

- Entender o vínculo da aprendizagem de máquina com o sistema especialista.
- Conhecer as técnicas de aprendizado supervisionado.
- Diferenciar as técnicas de aprendizado supervisionado e por reforço.
- Compreender como técnicas de aprendizado melhoram o sistema.
- Conhecer os exemplos de técnicas e aplicação de aprendizado de máquina.
- Entender a relação da estatística com a aprendizagem de máquina.
- Identificar a melhor técnica a ser aplicada para resolver um problema.

INICIE SUA JORNADA

Os sistemas especialistas precisam trabalhar com a incerteza, a variabilidade e as limitações em contextos em que o conhecimento não está completamente definido. As soluções que são desenvolvidas precisam melhorar e adaptar a precisão destes sistemas para que passem a depender de uma menor intervenção humana.

O aprendizado de máquina é um ramo da inteligência artificial baseado em algoritmos, técnicas e heurísticas que auxiliam o sistema a apresentar soluções.


São sistemas que podem testar diferentes configurações para medir precisão e eficiência, auxiliar em diagnósticos médicos, controle de tráfego, categorização de documentos e identificação de fraudes financeiras. Para sistemas que precisam controlar o tráfego urbano, por exemplo, imagine se um sistema for capaz de aprender e se adaptar às situações de fluxo de tráfego com o objetivo de reduzir o tempo no semáforo para reduzir a emissão de poluentes?

Estes sistemas também são muito úteis quando é necessário tratar informações sensíveis e que há uma grande gama de variedade possível em seus resultados, pois pode resumir com mais velocidade a maior gama de cenários possíveis e apresentar um grau de confiança para a definição final de um especialista.



PLAY NO CONHECIMENTO

Estudante, convido você a ouvir sobre como a Amazon está relacionada à aprendizagem de máquina. Acesse e dê o play nesse podcast que preparamos especialmente para você! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**



VAMOS RECORDAR?

Os sistemas especialistas se beneficiam do tratamento de incertezas uma vez que nem sempre um sistema consegue chegar a uma conclusão única para todo o tipo de negócio. O uso de métodos probabilísticos é uma das maneiras para lidar com essa incerteza. O aprendizado supervisionado pode aprimorar a base de conhecimento que é utilizada para entender as probabilidades estatísticas e deve ser treinada em modelos de dados históricos que podem ser alimentados através do próprio uso do sistema ou de uma massa de dados inferida diretamente e depois aferida. As probabilidades e o aprendizado de máquina estão fortemente correlacionados em sistemas inteligentes.

DESENVOLVA SEU POTENCIAL

APRENDIZAGEM DE MÁQUINA EM SISTEMAS ESPECIALISTAS

O aprendizado de máquina ou *machine learning* nasceu na década de 60, como um campo da inteligência artificial que tinha o objetivo de aprender padrões com base em dados (Santos; Izbicki; Ri, 2022).

A integração de aprendizagem de máquina em sistemas especialistas busca combinar a expertise embutida no sistema com a capacidade de aprendizado automático, permitindo a adaptação contínua e a evolução do sistema com base em novos dados. Essa integração pode resultar em sistemas especialistas mais robustos e flexíveis, capazes de lidar melhor com a incerteza e variabilidade (Rezende, 2005).

Segundo Russel e Norvig (2003), um projeto de um elemento de aprendizagem é afetado por três questões importantes:

- Os componentes do elemento de desempenho que devem ser aprendidos.
- A realimentação que estará disponível para aprender esses componentes.
- A representação que será usada para os componentes.

O tipo de realimentação disponível para aprendizagem normalmente é o fator mais importante na determinação da natureza do problema de aprendizagem. O campo de aprendizagem de máquina costuma ser distinguido em três casos: aprendizagem supervisionada, não-supervisionada e por reforço (Russel; Norvig, 2003).

A seguir, um quadro resumindo as técnicas, dados de treinamento, objetivos e exemplos de aplicação dessas técnicas:

TÉCNICA	DADOS DE TREINAMENTO	OBJETIVO	EXEMPLOS
Supervisionado	Rotulados	Prever ou classificar	Diagnóstico médico, classificação de documentos.
Não supervisionado	Não rotulados	Encontrar padrões ocultos	Segmentação de clientes, detecção de fraudes.
Reforço	Interação com o ambiente	Maximizar recompensa	Jogos, robótica, controles de tráfego aéreo e terrestre.

Tabela 1 - Comparativo entre técnicas de aprendizado de máquina / Fonte: adaptado de Rezende (2005) e Russel e Norvig (2003).

Originalmente, as aplicações de aprendizado de máquina eram de cunho estritamente computacional. Contudo, desde o final dos anos 90, essa área expandiu seus horizontes e começou a se estabelecer como um campo por si mesma, mas também permaneceram a forte intersecção com a estatística (Santos; Izbicki; Ri, 2022).

TÉCNICAS DE APRENDIZADO SUPERVISIONADO

O aprendizado supervisionado permite ajustar as regras e parâmetros do sistema com base em exemplos rotulados. Isso é especialmente útil em aplicações onde os resultados corretos são conhecidos e o sistema pode ser treinado para melhorar sua acurácia (Filho, 2023).

A melhor aplicação para o aprendizado supervisionado são as situações para problemas com um conjunto de dados rotulados e um objetivo claro de previsão ou classificação, algumas características:

- Um mapeamento direto de condições no estado atual para ações.
- Um meio para deduzir propriedades relevantes do mundo a partir da sequência de percepções.
- Informações sobre o modo como o mundo evolui e sobre os resultados de ações possíveis que um agente pode executar.

Esses componentes podem ser aprendidos através de uma realimentação de informações apropriadas. Exemplo: Imagine um instrutor de iniciantes a prática de veículo a motor e que solicite a instrução “Freie”, um agente poderá aprender quais são as condições para executar essa tarefa (1), também podem identificar os objetos que estão disponíveis na via (2), como um ônibus e, por fim, (3) entender os efeitos de uma frenagem em pista molhada e seca, aprendendo a melhor frenagem para cada uma dessas situações com base na experiência anterior (Russel; Norvig, 2003).

Existem diversos algoritmos ou métodos de classificação que aplicam as técnicas de aprendizado supervisionado. Para este tema de aprendizado vamos aprofundar a regressão logística, linear e árvores de decisão com exemplos práticos. As redes neurais estão dentro das técnicas de aprendizado supervisionado, mas não iremos nos deter nelas neste momento.

Além disso, para explicar essas três técnicas, vamos levar em consideração um problema igual a ser resolvido para permitir comparações: No contexto de emergência médica, a priorização do atendimento dos pacientes pode ser vital. A escala de Glasgow, na área médica, permite medir o nível de consciência de um paciente, e é frequentemente utilizada como um dos critérios para determinar a gravidade do estado de um paciente. O que queremos neste exemplo é que as técnicas nos ajudem a identificar se um paciente deve ou não ser atendido com urgência. No exemplo, basta saber que *Glasgow* representa uma variável que recebe um valor único e quanto maior o valor, menor é o seu risco.

Regressão Linear

A regressão linear é um método estatístico que modela a relação entre uma e outra variável, deve ser utilizada quando a variável dependente for contínua e as variáveis lineares, e também quando o objetivo é prever uma variável categórica (Filho, 2023). A expressão para o cálculo da regressão linear está declarada a seguir. Perceba a diferença dessa fórmula da regressão linear para a logística que não há o cálculo exponencial da regressão logística presente, onde Y é a variável dependente (urgência no atendimento):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5$$

Mesmos coeficientes para aplicar na expressão e variáveis da paciente Bruna:

$$\beta_0 = -3.0, \beta_1 = -0.5, \beta_2 = 0.03, \beta_3 = 0.2, \beta_4 = -0.02, \beta_5 = 0.01$$

Substituindo os valores na fórmula e calculando:

$$y = -3.0 - 0.5 \cdot 9 + 0.03 \cdot 135 + 0.2 \cdot 10 - 0.02 \cdot 88 + 0.01 \cdot 150$$

$$y = -3.0 - 4.5 + 4.05 + 2.0 - 1.76 + 1.5$$

$$y = -3.0 - 4.5 + 4.05 + 2.0 - 1.76 + 1.5 = -1.71$$

Onde o -1,71 define que a urgência é relativamente negativa e próxima a zero. O resultado de urgência diferente ao da regressão progressiva não significa que uma é melhor que outra ou que uma está errada e outra está certa. Os exemplos supervisionados foram elaborados com a mesma massa de dados para este tema de aprendizagem para explicar que a escolha entre os métodos **depende do problema a ser resolvido** e o tipo de resultado desejado. Se é uma ciência exata (sim, não, ou um valor específico) ou uma probabilidade (indicação de algo acontecer). Cada um tem uma aplicação mais adequada.

Vamos estudar um outro cenário a seguir, onde as árvores de decisão são mais versáteis para problemas de classificação de múltiplas variáveis interdependentes.

Regressão Logística

A regressão logística é uma técnica de aprendizado supervisionado que pode ser utilizada para modelar a probabilidade de ocorrência de um evento com duas categorias (binária). Ela é apropriada para problemas de classificação onde o objetivo é prever a probabilidade de uma variável dependente (por exemplo, “sim” ou “não”, “0” ou “1”) com base em uma ou mais variáveis independentes (Filho, 2023).



A seguir, vamos utilizar como exemplo uma base de dados com dados fictícios, com informações mínimas para descrever o cálculo e a regressão logística. Re-forço que, neste exemplo, busca-se identificar se um paciente deve ser atendido com urgência ou não.

PACIENTE (P)	GLASGOW (X1)	FREQUÊNCIA CARDÍACA (X2)	DOR (X3)	SATURAÇÃO OXIGÊNIO (X4)	PRESSÃO ARTERIAL SISTÓLICA (X5)
Afonso	13	120	7	95	140
Bruna	9	135	10	88	150

Tabela 2 - Massa de dados fictícia de testes para exemplo prático / Fonte: o autor.

A regressão logística também requer saber o coeficiente das variáveis que constam no cálculo, para este exemplo vamos supor o seguinte:

$\beta_0 = -3.0$ (intercepto), $\beta_1 = -0.5$ (Glasgow), $\beta_2 = 0.03$ (Frequência Cardíaca:),

$\beta_3 = 0.2$ (Dor), $\beta_4 = -0.02$ (Saturação oxigênio), $\beta_5 = 0.01$ (pressão arterial).

Os dados das variáveis e seus coeficientes são utilizados para treinar a base e ajustar os coeficientes $\beta_0, \beta_1, \dots, \beta_n$ para maximizar a probabilidade de prever a alta e baixa urgência para o conjunto de sintomas $x_1, x_2, \dots, x_n$.

A partir destes dados coletados, que em nosso exemplo poderiam ser coletados em registros clínicos em que os pacientes são rotulados como baixa ou alta urgência, é possível treinar um modelo de regressão logística para que possa aprender a relação entre as variáveis de sintomas (variáveis independentes) e a urgência de atendimento (variáveis dependentes).

Assim, quando um novo paciente é identificado com variáveis que já foram treinadas, o sistema especialista está em condições de prever se o paciente deve ser atendido de forma urgente ou se deve esperar. A seguir, está representado como a regressão logística é expressada:

$$p(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_n x_n)}}$$

$p(x)$ é a probabilidade de um paciente ser classificado de “alta urgência”.

$\beta_0, \beta_1, \beta_2, \dots, \beta_n$ é a influência de cada variável, termo de intercepto, com os coeficientes das variáveis independentes e que precisam ser estimados. $x_1, x_2, \dots, x_n$ são as variáveis independentes (x_1 = pontuação Glasgow, x_2 = frequência cardíaca, x_3 = dor, x_4 = saturação de oxigênio e x_5 = pressão arterial), e e , é a base do logaritmo natural.

A seguir, como exemplo, vamos substituir os valores na fórmula para calcular a urgência da paciente Bruna, onde z representa a combinação linear dos coeficientes β e as variáveis x , é a soma ponderada das variáveis multiplicadas pelo coeficiente:

$$z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5$$

Substituindo os valores e calculando:

$$z = -3.0 + (-0.5 \cdot 9) + (0.03 \cdot 135) + (0.2 \cdot 10) + (-0.02 \cdot 88) + (0.01 \cdot 150)$$

$$z = -3.0 = (-4.5) + 4.05 + 2.0 + (-1.76) + 1.5$$

$$z = -3.0 - 4.5 + 4.05 + 2.0 - 1.76 + 1.5 = -1.71$$

Função logística para determinar a probabilidade:

$$p(x) = \frac{1}{1 + e^{-(1.71)}} \quad \text{logo: } p(x) = \frac{1}{1 + e^{1.71}} \approx 0.153$$

Sendo assim, é possível concluir que, com base nos sintomas registrados para a paciente Bruna, ela tem aproximadamente 15,3% - $P(x)=0.153$ de chance de ser classificada como de alta urgência, trata-se de uma chance pequena, mas o especialista deve dar a palavra final ao treinar essa base de dados confirmando ou não a urgência, e assim os próximos casos passam a aprender o resultado com o modelo.

Árvore de decisão

O algoritmo divide repetidamente os dados históricos com informações anteriores em subconjuntos com base nos valores das variáveis, criando uma estrutura de árvore onde cada nó interno representa uma “pergunta” baseada em uma variável e cada folha representa uma decisão final ou classificação.

Para a árvore de decisão, os coeficientes β não precisam ser utilizados, pois são típicos de um modelo de regressão linear. Porém, na árvore de decisão é preciso inferir critérios de divisão e de cada variável. Então, precisamos inferir mais informações nas variáveis para criar condições de sim e não, assim será possível identificar um paciente com urgência de atendimento (Santos; Izbicki; Ri, 2022).

EXEMPLIFICANDO

Escala Glasgow ($x1 = 13 \cdot 1 = 13$): **13 < 10**? Não → Próximo nó. Frequência Cardíaca
 ($x2 = 120 \cdot 2 = 2 = 120$): **120 > 130**? Não → Próximo nó. Saturação de Oxigênio
 ($x4 = 95 \cdot 4 = 95$): **95 < 90**? Não → Classificação Final: Não Urgente.

Com estes dados, a paciente Bruna não atende aos critérios para ser classificada como urgente, uma vez que seus valores de Escala *Glasgow*, Frequência Cardíaca e Saturação de Oxigênio não indicam uma condição crítica segundo as novas regras definidas. Observe a seguir as mesmas regras:




Figura 1 - Árvore de Decisão com critérios de classificação de urgência de atendimento / Fonte: adaptado de Rezende (2005) e Russel e Norvig (2003).

Descrição da Imagem: a figura apresenta 5 círculos conectados entre si com setas de decisões sim e não para o resultado final urgente e não urgente. O primeiro círculo tem escrito a pergunta escala de Glasgow menor que 10? Se sim, existe uma seta indicativa para o círculo urgente. Se a seta é não, segue para a próxima pergunta, que é frequência cardíaca maior que 130? Se sim, a seta indicativa indica para o círculo com a palavra urgente, se não, segue para a próxima pergunta que é saturação é menor que 90? Se sim, a seta indicativa indica para o círculo com a palavra urgente, se não, indica para o círculo com a palavra não urgente.

A simplicidade das árvores de decisão é uma escolha popular para sistemas especialistas, especialmente em áreas como a medicina, pois a possibilidade de apresentação visual dos critérios de decisão tomada pelo sistema tornam o mesmo mais confiáveis e, quando permitido, mais fáceis e rápidos de serem ajustados.



INDICAÇÃO DE LIVRO

Aprendizado de Máquina - Uma Abordagem Estatística

Recomendo o livro *Aprendizado de Máquina - uma abordagem estatística* de Rafael Izbicki e Tiago Mendonça dos Santos. Este livro foi criado em função da necessidade que os professores identificaram em suas aulas de pós-graduação em ter um material que fizesse a ponte entre estatística e aprendizado de máquina, apresenta capítulos práticos com algoritmos e também com teoria matemática, completando a visão de aprendizado de máquina e estatística.



TÉCNICAS DE APRENDIZADO NÃO SUPERVISIONADO

O aprendizado não supervisionado é utilizado para descobrir padrões em dados não rotulados, permitindo que sistemas especialistas identifiquem novas regras ou categorias sem supervisão direta. São métodos de análise de agrupamento (*clustering*) que tem como objetivo dividir a amostra em grupos de modo que um seja diferente dos outros, mas os elementos pertencentes ao mesmo grupo sejam parecidos entre si (Santos; Izbicki; Ri, 2022).



Para o próximo cenário de estudo, imagine um banco que deseja ter o controle das transações realizadas por seus clientes com o objetivo de identificar fraudes. Vamos a uma pequena massa de dados de exemplo:

NÚMERO DA TRANSAÇÃO	VALOR	LOCAL	HORÁRIO
1	50	São Paulo	09:00
2	45	São Paulo	09:30
3	10	Curitiba	14:00
4	1000	Florianópolis	02:00

Tabela 3 - Massa de dados fictícia de testes para exemplo prático / Fonte: o autor.

O *K-means* (ou K-média) é dos meios mais utilizados para agrupar (*clustering*) informações. Calcula a distância entre os centroides (ponto que representa o centro do cluster) de pelo menos dois clusters, ainda que, em outras palavras, assume-se que a medida de dissimilaridade usada é a distância Euclidiana (a distância entre dois pontos) (Santos; Izbicki, 2022).

Na prática:

Para definir de clusters (k), vamos dividir as transações entre normais e suspeitas, $k=2$.

A distância de cada ponto pode ser calculada utilizando a fórmula da distância euclidiana, tratando x e y como vetores que representam o **valor, localização e hora** no nosso exemplo: $d = \sqrt{(x1 - x2)^2 + (y1 - y2)^2}$

Para poder utilizar a fórmula, é necessário normalizar horas em minutos:

Transação 1: 9:00 = 540 minutos

Transação 2: 9:30 = 570 minutos

Transação 3: 14:00 = 840 minutos

Transação 4: 02:00 = 120 minutos

Distância da Transação 3 e o Centróide 1:

$$d = \sqrt{(10 - 50)^2 + (840 - 540)^2},$$

$$d = \sqrt{(-40)^2 + (300)^2},$$

$$d = \sqrt{1225 + 72900} \text{ logo: } d = \sqrt{74125} \approx 302.66$$

Distância da Transação 3 e o Centróide 2:

$$d = \sqrt{(10 - 45)^2 + (840 - 570)^2},$$

$$d = \sqrt{(-35)^2 + (270)^2},$$

$$d = \sqrt{1225 + 72900} \text{ logo: } d = \sqrt{74125} \approx 272.16$$

Distância da Transação 4 e o Centróide 1:

$$d = \sqrt{(1000 - 50)^2 + (120 + 540)^2},$$

$$d = \sqrt{(950)^2 + (-420)^2},$$

$$d = \sqrt{902500 + 176400}, \text{ logo: } d = \sqrt{1078900} \approx 1038.64$$

Distância da Transação 4 o Centróide 2:

$$d = \sqrt{(1000 - 45)^2 + (120 + 570)^2},$$

$$d = \sqrt{(955)^2 + (-450)^2},$$

$$d = \sqrt{912025 + 202500}, \text{ logo: } d = \sqrt{1114525} \approx 1056.15$$

Neste caso, observamos que a transação 4 é a mais distante dos clusters principais que são as transações 1 e 2 (foi maior valor encontrado no resultado da fórmula aplicada), sugerindo a descoberta que ela é potencialmente a transação suspeita a ser analisada pelo especialista.

Esse tipo de técnica é muito utilizado na categorização de documentos baseado em algoritmos de clustering que auxiliam na descoberta de novas classes de documentos, ampliando a base de conhecimento do sistema. A melhor aplicação para o aprendizado não supervisionado são as situações para explorar dados sem rótulos e descobrir padrões ocultos (Santos; Izbicki, 2022).

TÉCNICAS DE REFORÇO

As técnicas de reforço têm sua melhor aplicação em problemas onde o agente precisa tomar decisões sequenciais em um ambiente dinâmico recebendo feedback para o reforço das suas decisões. Imagine o exemplo da necessidade de otimizar os tempos dos semáforos de trânsito (vermelho, verde e amarelo) essas situações fornecem a informação de um comportamento em que a aprendizagem por reforço, recebendo recompensas e inclui o subproblema ao aprender como o ambiente funciona (Russel; Norvig, 2003).



EU INDICO

No vídeo indicado, conheça BREET (*Berkeley Robot for the Elimination of Tedious Tasks*), um robô construído com base em técnicas de reforço para eliminar atividades simples. Ninguém fornece instruções sobre como o robô deve posicionar as peças, ele aprende através da técnica de reforço como essa apresentada neste tema. <https://www.youtube.com/watch?v=JeVppkoloXs>

O Q-Learning é um dos algoritmos mais conhecidos no aprendizado por reforço, pois busca aprender o valor de função (valor de Q), que é o valor da recompensa acumulada como resultado de uma ação tomada.

Sua função $Q(s,a)$ representa o valor esperado de seguir uma determinada política ao tomar a ação a no estado s e é atualizada iterativamente pela seguinte equação (Busoniu; Babuska; Schutter, 2017):

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

- α é a taxa de aprendizado.
- r é a recompensa recebida após tomar uma ação a no estado s .
- γ é o fator de desconto.
- $\max_{a'} Q(s',a')$ é o valor máx. estimado da próxima ação no estado s' .



Exemplo: imagine um robô que pode se mover para cima, para baixo, para esquerda ou direita em um ambiente 2x2 e deve encontrar a melhor estratégia para chegar em um objetivo enquanto evita outras opções, vamos representar da seguinte forma:

- Quando acerta: Recompensa +10 - estado (2x2).
- Penalidade: Recompensa - 10: estado (1,2).
- Espaços vazios: Recompensa nula (0).

Representação - Objetivo (2,2), Penalidade (1,2):

(1,1)	(1,2)
(2,1)	(2,2)

Tabela 4 - Representação do cenário 2x2 de movimentação do robô / Fonte: o autor.

A taxa de aprendizado é definida como 0.1 e o fator de desconto 0.9:

ESTADO	PARA CIMA	PARA BAIXO	PARA ESQUERDA	PARA DIREITA
(1,1)	o	o	o	o
(1,2)	o	o	o	o
(2,1)	o	o	o	o
(2,2)	o	o	o	o

Tabela 5 - Representação de todos os estados e ações possíveis do robô / Fonte: o autor.

Atualizações da tabela Q

Primeira iteração: **Estado inicial:** (1,1), **ação selecionada:** para direita (é movido para o estado (1,2)), **estado resultante:** (1,2) com a **recompensa:** -10 (penalidade), atualizando a tabela Q :

$$Q((1,1), ParaDireita) \leftarrow 0 + 0.1[-10 + 0.9 \cdot 0 - 0]$$

$$Q((1,1), ParaDireita) \leftarrow 0 + 0.1[-10]$$

$$Q((1,1), ParaDireita) \leftarrow -1$$

- s é o estado default (1,1), a é ação (para direita), r é a recompensa (-10), s' o próximo estado (1,2) e $\max_a Q(s', a')$ o valor máximo das ações no estado (1,2), que é 0 porque ainda não foi atualizado.

ESTADO	PARA CIMA	PARA BAIXO	PARA ESQUERDA	PARA DIREITA
(1,1)	0	0	0	-1
(1,2)	0	0	0	0
(2,1)	0	0	0	0
(2,2)	0	0	0	0

Tabela 6 - Representação da tabela Q atualizada após a primeira iteração / Fonte: o autor.

Segunda iteração: **Estado inicial:** (2,1), **ação selecionada:** para cima (é movido para o estado (1,1)), **estado resultante:** (1,1) com a **recompensa:** 0 (nulo) por ser um espaço vazio, atualizando a tabela Q :

$$Q((2,2), Nenhuma) \leftarrow 0 + \alpha[10 + \gamma \cdot 0 - 0]$$

$$Q((2,1), Paracima) \leftarrow -0.09$$

- r é a recompensa: 0, $\max_a Q(s', a')$ é o valor máximo das ações no estado (1,1) que é -1 (valor atualizado na primeira iteração).

ESTADO	PARA CIMA	PARA BAIXO	PARA ESQUERDA	PARA DIREITA
(1,1)	0	0	0	-1
(1,2)	0	0	0	0
(2,1)	-0.09	0	0	0
(2,2)	0	0	0	0

Tabela 7 - Representação da tabela Q atualizada após a segunda iteração / Fonte: o autor.

Terceira iteração: **Estado inicial:** (2,2), **ação selecionada:** nenhuma (é o objetivo), com a **recompensa:** +10 (por ser o objetivo), atualizando a tabela Q :

$$Q((2,2), \text{Nenhuma}) \leftarrow 0 + \alpha[10 + \gamma \cdot 0 - 0]$$

$$Q((2,2), \text{Nenhuma}) \leftarrow 1$$

Neste caso para o objetivo o valor máximo das ações será 0 já que não há mais ações a tomar.

ESTADO	PARA CIMA	PARA BAIXO	PARA ESQUERDA	PARA DIREITA
(1,1)	0	0	0	-1
(1,2)	0	0	0	0
(2,1)	-0.09	0	0	0
(2,2)	0	0	0	1

Tabela 8 - Representação da tabela Q atualizada após a terceira iteração / Fonte: o autor.

Após as iterações, a tabela Q mostra os valores esperados para cada estado e ação, onde o robô deve seguir a política que vai maximizar a recompensa acumulada. Para o estado (1,1) a melhor ação é “Para Direita” com um valor de Q de -1. Para o estado (2,1): a melhor ação é “Para Cima” com um valor de Q de -0.09 e para o Estado (2,2) já é o objetivo, com valor de Q de 1.

Para os ambientes dinâmicos, as técnicas de reforço permitem que o sistema aprenda com a interação e o feedback do ambiente, ajustando as suas ações com base nas recompensas recebidas, o que é útil para otimização contínua.

EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementar e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

A aprendizagem de máquina tem um papel fundamental na construção de sistemas especialistas mais inteligentes e adaptáveis. Ao compreender as diferentes técnicas de aprendizado e seus prós e contras, é possível escolher a abordagem mais adequada para cada problema, resultando em sistemas mais precisos e eficientes.

O aprendizado de máquina também está ligado à inteligência artificial simbólica, conexionista e evolucionária, uma vez que o aprendizado de máquina complementa informações a partir de novos dados e permite lidar com incertezas e ambiguidades e a IA simbólica fornece a estrutura lógica e a base de conhecimento para a tomada de decisões. Essa integração precisa ser aprofundada por resultar em sistemas especialistas que evoluem com o tempo, mais precisos e eficazes quando expostos a novos cenários.

REFERÊNCIAS

BUSONI, L.; BABUSKA, R.; SCHUTTER, B. **Reinforcement Learning - Principles, Concepts and Applications**. [S.l.]: CRC Press, 2017.

FILHO, G. F. **Inteligência Artificial e Aprendizagem de Máquina**: aspectos teóricos e aplicações. São Paulo: Blucher, 2023.

REZENDE, S. O. **Sistemas Inteligentes**: Fundamentos e Aplicações. São Paulo: Manole, 2005.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

SANTOS, T. M., IZBICKI, R. L. **Aprendizado de Máquina**. São Paulo: UICLAP, 2022.

AUTOATIVIDADE

1. O tipo de realimentação disponível para aprendizagem normalmente é o fator mais importante na determinação da natureza do problema de aprendizagem. Com base nessa afirmação, sobre o aprendizado supervisionado, não supervisionado e técnicas de reforço (Russel; Norvig, 2003; Santos; Izbicki, 2022).

Assinale as alternativas verdadeiras:

- I - A melhor aplicação para o aprendizado supervisionado são as situações para problemas com um conjunto de dados rotulados e um objetivo claro de previsão ou classificação.
- II - A melhor aplicação para o aprendizado não supervisionado são as situações para explorar dados sem rótulos e descobrir padrões ocultos.
- III - As técnicas de reforço tem sua melhor aplicação em problemas onde o agente precisa tomar decisões sequenciais em um ambiente dinâmico recebendo feedback para o reforço das suas decisões.
- IV - As técnicas de reforço tem sua melhor aplicação em problemas onde o agente precisa tomar decisões sequenciais em um ambiente dinâmico aprendendo automaticamente os cenários sem precisar de um feedback em suas decisões.

Alternativas

- a) I, apenas.
 - b) II e IV, apenas.
 - c) III e IV, apenas.
 - d) I, II e III apenas
 - e) I, II, III, IV.
-
2. Um cliente de um banco realiza 4 transações em um mesmo dia e o banco deseja automaticamente identificar possíveis fraudes:

Transação 1

Valor: 50 reais.

Local: São Paulo

Horário: 09:00

Transação 2

Valor: 45 reais.

Local: São Paulo

Horário: 09:30

AUTOATIVIDADE

Transação 3

Valor: 10 reais.

Local: Curitiba

Horário: 14:00

Transação 4

Valor: 1000 reais.

Local: Florianópolis

Horário: 02:00

Sabendo que o K-means (k-média) é uma técnica **não supervisionada** que pode auxiliar a identificar a distância das transações e centroides como forma de identificar as fraudes, utilize a fórmula abaixo para analisar as afirmativas a seguir:

Fonte: adaptado de Santos e Izbicki (2022).

$$d = \sqrt{(x1 - x2)^2 + (y1 - y2)^2}$$

Quais afirmações são verdadeiras?

- I - A distância da transação 3 e o centroide 1 é aproximadamente 272.16.
- II - A distância da transação 4 e o centroide 1 é aproximadamente 1038.64.
- III - A distância da transação 3 e o centroide 1 é aproximadamente 302.66.
- IV - A distância da transação 4 e o centroide 1 é aproximadamente 1056.15.

Alternativas

- a) I, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III apenas
- e) I, II, III, IV.

AUTOATIVIDADE

3. A regressão logística é uma técnica de **aprendizado supervisionado** que pode ser utilizada para modelar a probabilidade de ocorrência de um evento com duas categorias (binária). Suponha que, em um atendimento hospitalar, deseja-se identificar se um paciente tem ou não urgência em ser atendido automaticamente. Com base nos dados da tabela a seguir:

Fonte: adaptado de Santos e Izbicki (2022).

PACIENTE (P)	GLASGOW (X ₁)	FREQUÊNCIA CARDÍACA (X ₂)	DOR (X ₃)	SATURAÇÃO OXIGÊNIO (X ₄)	PRESSÃO ARTERIAL SISTÓLICA (X ₅)
Afonso	13	120	7	95	140
Bruna	9	135	10	88	150

Com os coeficientes pré-treinados: $\beta_0 = -3.0$ (intercepto), $\beta_1 = -0.5$ (Glasgow), $\beta_2 = 0.03$ (Frequência Cardíaca), $\beta_3 = 0.2$ (Dor), $\beta_4 = -0.02$ (Saturação oxigênio), $\beta_5 = 0.01$ (pressão arterial).

E a fórmula da regressão logística:

$$p(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_n x_n)}}$$

Analise e identifique as afirmativas corretas:

- I - Aplicando a fórmula para a paciente Bruna (p), a mesma tem aproximadamente 10,3% (0.103) de chance de ser classificada como alta urgência.
- II - Aplicando a fórmula para a paciente Bruna(p), a mesma tem aproximadamente 15,3% (0.153) de chance de ser classificada como alta urgência.
- III - Aplicando a fórmula para o paciente Afonso(p), o mesmo tem aproximadamente 0,63% (0.0063) de chance de ser classificado como baixa urgência.
- IV - Aplicando a fórmula para o paciente Afonso(p), o mesmo tem aproximadamente 0,33% (0.0033) de chance de ser classificado como baixa urgência.

AUTOATIVIDADE

É correto que se afirma em:

- a) I e IV, apenas.
- b) II e III, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) II, III e IV, apenas.

GABARITO

1. III e IV, apenas. Alternativas I, II e III estão corretas, a alternativa IV não é verdadeira ao afirmar que um ambiente dinâmico aprendendo automaticamente os cenários sem precisar de um feedback em suas decisões. O aprendizado por reforço requer feedback.
2. II e IV, apenas. A distância de cada ponto pode ser calculada utilizando a fórmula da distância euclidiana, tratando x e y como vetores que representam o valor, localização e hora no nosso exemplo: $d = \sqrt{(x1 - x2)^2 + (y1 - y2)^2}$

Para poder utilizar a fórmula, é necessário normalizar horas em minutos:

Transação 1: 9:00 = 540 minutos

Transação 2: 9:30 = 570 minutos

Transação 3: 14:00 = 840 minutos

Transação 4: 02:00 = 120 minutos

Distância da Transação 3 e o Centróide 1:

$$d = \sqrt{(10 - 50)^2 + (840 - 540)^2},$$

$$d = \sqrt{(-40)^2 + (300)^2},$$

$$d = \sqrt{1225 + 72900} \text{ logo: } d = \sqrt{74125} \approx 302.66$$

Distância da Transação 3 e o Centróide 2:

$$d = \sqrt{(10 - 45)^2 + (840 - 570)^2},$$

$$d = \sqrt{(-35)^2 + (270)^2},$$

$$d = \sqrt{1225 + 72900} \text{ logo: } d = \sqrt{74125} \approx 272.16$$

Distância da Transação 4 e o Centróide 1:

$$d = \sqrt{(1000 - 50)^2 + (120 + 540)^2},$$

$$d = \sqrt{(950)^2 + (-420)^2},$$

$$d = \sqrt{902500 + 176400}, \text{ logo: } d = \sqrt{1078900} \approx 1038.64$$

GABARITO

Distância da Transação 4 o Centróide 2:

$$d = \sqrt{(1000 - 45)^2 + (120 + 570)^2},$$

$$d = \sqrt{(955)^2 + (-450)^2},$$

$$d = \sqrt{912025 + 202500}, \text{ logo: } d = \sqrt{1114525} \approx 1056.15$$

3. II e III, apenas.

Cálculo da Bruna, variáveis X representadas pelos sintomas:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5$$

Substituindo os valores e calculando:

$$z = -3.0 + (0.5 \cdot 9) + (0.03 \cdot 135) + (0.2 \cdot 10) + (-0.02 \cdot 88) + (0.01 \cdot 150)$$

$$z = -3.0 = (-4.5) + 4.05 + 2.0 + (-1.76) + 1.5$$

$$z = -3.0 - 4.5 + 4.05 + 2.0 - 1.76 + 1.5 = -1.71$$

Função logística para determinar a probabilidade:

$$p(x) = \frac{1}{1 + e^{-(1.71)}} \text{ logo: } p(x) = \frac{1}{1 + e^{1.71}} \approx 0.153$$

Cálculo do Afonso, sintomas substituídos por X :

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5$$

Substituindo os valores e calculando:

$$z = -3.0 + (-0.5 \cdot 13) + (0.03 \cdot 120) + (0.2 \cdot 7) + (-0.02 \cdot 98) + (0.01 \cdot 140)$$

$$z = -3.0 = (-6.5) + (3.6) + (1.4) + (-1.96) + 1.4$$

$$z = -3.0 - 6.5 + 3.6 + 1.4 - 1.96 + 1.4 = -5.06$$

GABARITO

Função logística para determinar a probabilidade:


$$P(Y=1) = \frac{1}{1+e^{-5.06}} \text{ logo: } p(x) = \frac{1}{1+e^{1.71}} \approx 0.153$$


Função logística para determinar a probabilidade:

$$P(Y=1) = \frac{1}{1+e^{-5.06}}$$

$$P(Y=1) = \frac{1}{1+e^{5.06}} \approx \frac{1}{1+157.85} \approx \frac{1}{158.85} \approx 0.0063$$

unidade





TEMA DE APRENDIZAGEM 7

IA SIMBÓLICA EM SISTEMAS ESPECIALISTAS

MINHAS METAS

- Conhecer a história da inteligência artificial simbólica.
- Aprender os conceitos da IA simbólica
- Entender os exemplos da aplicação da IA simbólica.
- Praticar em exemplos a IA simbólica.
- Manipular símbolos e criar regras.
- Solucionar problemas com IA simbólica.
- Entender os componentes da IA simbólica.

INICIE SUA JORNADA

A inteligência artificial simbólica surgiu da necessidade de existir um processo de resolução de problemas em que o sistema utiliza regras explícitas para inferir novas informações com base em fatos e hipóteses conhecidas. A inteligência artificial simbólica, no período em que o estudo foi lançado, busca questionar o raciocínio estruturado, ora, se não existir a estruturação de regras e dados conhecidos, como seria possível desenvolver um sistema inteligente?

A inteligência artificial simbólica foi a primeira na literatura a ser reconhecida e é determinada a trabalhar com a manipulação de símbolos e regras explícitas para processar, representar e explicar o conhecimento.

Os símbolos podem representar os objetos, as relações, os eventos e os estados e têm características da lógica booleana, o raciocínio formal como regras “se-então”, que são definidos em sistemas especialistas e os distinguem de sistemas convencionais.

Sistemas que utilizam a IA simbólica buscam simular o conhecimento humano para a tomada de decisão, como o diagnóstico médico, consultoria jurídica e financeira. A complexidade do raciocínio simbólico é maior conforme maior é o número de regras e variáveis.



PLAY NO CONHECIMENTO

Estudante, convido você a ouvir sobre a relação da inteligência artificial simbólica e a aprendizagem de máquina. Acesse e dê o play nesse podcast que preparamos especialmente para você! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Podemos dizer que inteligência artificial é um subgrupo da ciência da computação, composto por técnicas voltadas ao desenvolvimento de sistemas para solucionar problemas simbólicos em vez de numéricos, e que simulam o raciocínio humano. Problemas simbólicos são problemas da vida diária que, em vez de lidar com números, lidam com conceitos simbólicos. Nomes de objetos e atributos são símbolos. As características e habilidades dos sistemas especialistas os diferenciam dos sistemas convencionais.

DESENVOLVA SEU POTENCIAL

IA SIMBÓLICA EM SISTEMAS ESPECIALISTAS

É possível considerar que a grande distinção entre a programação simbólica (sistemas especialistas) e a programação convencional (sistemas convencionais) reside no fato de que os sistemas convencionais automatizam – tarefas operacionais, manuais, repetitivas. Os indivíduos que as exerciam anteriormente não tinham necessidade de pensar ou raciocinar em demasia sobre suas atividades, mas apenas de assimilar a rotina e executá-la. Os programas convencionais são utilizados para realizar essas rotinas no lugar do homem, com o benefício da velocidade e da precisão, além de outros (Mihaguti, p. 15, 1996).

Com base nos diversos campos de estudo que fundamentaram os princípios da inteligência artificial, três abordagens características clássicas são referenciadas: simbólica, conexionista e evolucionária. Neste tema de aprendizagem, vamos abordar a IA simbólica em sistemas especialistas, onde há registro da década de 1950 e tiveram como base as regras de produção e a lógica de predicados.

A formalização da lógica facilitou o processo de formalização e representação dos conhecimentos que são de uso dos sistemas especialistas (Lima; Pinheiro; Santos, 2014).



A IA simbólica oferece **transparência** no processo de raciocínio, facilitando a compreensão de como um sistema chegou a uma conclusão. Ela é altamente **flexível** e pode ser adaptada a diferentes domínios, modificando as regras e a base de conhecimento. Pode representar conhecimentos complexos de maneira formal e estruturada, permitindo fácil manipulação e raciocínio.

Entre as limitações da IA simbólica, ela requer um conhecimento completo e bem definido para funcionar corretamente. Em domínios em que o conhecimento é incompleto, incerto ou ambíguo, a IA simbólica pode não ser eficaz, pois pode se tornar computacionalmente “cara” à medida que o número de símbolos e regras aumenta, dificultando o dimensionamento para grandes domínios e gerando situações que podem afetar a escalabilidade. O raciocínio simbólico também tem capacidade limitada de aprender e se adaptar, pois exigem programação manual e podem não permitir aprendizado e adaptação em tempo real (Luger, 2004, on-line).

Para entender a relação entre a IA simbólica e os sistemas especialistas, é necessário revisarmos a arquitetura de sistemas especialistas:




Figura 1 - Componentes de sistemas especialistas / Fonte: o autor.

Descrição da Imagem: A figura apresenta um fluxograma que contém cinco retângulos com informações escritas em seu interior. À direita, no retângulo acima, lê-se base de conhecimento. Ligado a esse, outro retângulo, abaixo, informa Base de dados de casos. Estes dois indicam um retângulo à sua frente, em que lê-se Motor de inferência. Este está conectado, seguido por uma flecha indicativa, ao Módulo de explicação, também num retângulo. Por fim, a interface de usuário é indicada após o penúltimo retângulo, conectando novamente ao Motor de inferência.

A IA simbólica é representada através do módulo de explicação, onde é necessário que o sistema especialista forneça os passos lógicos que levaram à decisão, apresentando quais regras foram usadas e quais fatos foram considerados. A Figura 2 representa o conjunto de regras obtidas através do sistema especialista SINTA:




Figura 2. Sistema SINTA

Fonte: <https://www.cin.ufpe.br/~fab/expert-sinta/manual.pdf>. Acesso em: 20 set. 2024.

Descrição da Imagem: A figura é um print de tela de computador e apresenta o funcionamento do sistema SINTA, em que é possível escrever as regras “se”, “então” que é utilizada para obter resultados sobre um determinado assunto que se deseja conhecer. A figura apresenta abas resultados, históricos e todos os valores fechadas enquanto a aba o sistema está aberta demonstrando as seguintes regras: REGRA 1 SE castanha broqueada com amêndoa totalmente destruída então praga = traça das castanhas CNF 100%, REGRA 2 SE galerias nos ramos ou inflorescências = Sim praga = broca das pontas CNF 100%, REGRA 3 SE inflorescências = Murchas ou secas e brotações novas murchas = sim e orifícios laterais nos ramos ou inflorescências = SIM então praga = broca das pontas CNF 100%, REGRA 4 se inseto mole amarelo ou verde = Sim então praga = pulgão das inflorescências CNF 100%, Regra 5 se ácaro estreito ou longo nas inflorescências = SIM então praga = eriofídeo das flores CNF 100%. A tela apresentada ainda apresenta um botão de fechar e outro de ajuda.

**EU INDICO**

Assista este vídeo referente a introdução aos paradigmas de IA? Simbolismo, Conexionismo e Behaviorismo. Neste vídeo, é descrito como foi elaborado o pensamento para a criação de um sistema especialista e também a comparação com outras escolas clássicas de inteligência artificial. Assista em: <https://youtu.be/sh-QWrjO1zQ8?si=gCgc-rt8TaMOXeug>

Solução de Problemas

Os problemas que são resolvidos pela IA simbólica são aqueles que são bem definidos, por exemplo o planejamento de tarefas, e sua principal contribuição são os sistemas especialistas (Lima; Pinheiro; Santos, 2014).

Um exemplo clássico de IA simbólica em sistemas especialistas são os sistemas clínicos e de diagnósticos, como por exemplo o MYCIN, um sistema especialista desenvolvido na década de 1970 para o diagnóstico de doenças infecciosas. O MYCIN utilizava regras simbólicas para fazer diagnósticos e podia explicar as razões para suas decisões. Exemplo: MYCIN (Russel; Norvig, 2020):

- **Regra simbólica:** "Se o paciente tem febre e a contagem de glóbulos brancos é alta, então há uma probabilidade de infecção bacteriana."
- **Módulo de Explicação:** O sistema especialista poderia explicar essa inferência com base na regra simbólica aplicada a um conjunto de sintomas fornecidos.

Para mais um exemplo de solução de problemas na IA simbólica, vamos imaginar a necessidade de construir um sistema especialista com o objetivo de priorizar pacientes em emergências médicas com base na Escala de Glasgow e outros sintomas como frequência cardíaca, dor, saturação de oxigênio e pressão arterial. O sistema deve determinar qual paciente precisa de atendimento urgente.



Para os não familiarizados com a escala de Glasgow, na área médica ela é reconhecida por medir o nível de consciência de um paciente, é frequentemente utilizada como um dos critérios para determinar a gravidade do estado de um paciente, o que queremos neste exemplo é que as técnicas nos ajudem a identificar se um paciente deve ou não ser atendido com urgência. No exemplo, basta saber que *Glasgow* representa uma variável que recebe um valor único e quanto maior o valor, menor é o seu risco. A IA simbólica com base no seu raciocínio lógico permite automatizar e resolver problemas como este.

Manipulação de Símbolos

A IA simbólica, também denominada descendente ou cognitiva, tem como objetivo dar ênfase aos processos que se identificam como o ser humano raciocina. Procura encontrar uma explicação para comportamentos inteligentes com base em aspectos psicológicos complementares aos algoritmos, em que há um conjunto de estruturas simbólicas e pelos quais são os meios necessários e suficientes para criar um comportamento inteligente (Lima; Pinheiro; Santos, 2014).

Agora, vamos retornar ao nosso exemplo prático onde queremos criar um sistema especialista que tenha a capacidade de priorizar pacientes em emergências médicas. Temos as seguintes informações representadas na tabela a seguir:

PACIENTE	GLASGOW	FREQUÊNCIA CARDÍACA	DOR	SATURAÇÃO OXIGÊNIO	PRESSÃO ARTERIAL SISTÓLICA
Afonso	13	120	7	95	140
Bruna	9	135	10	88	150

Tabela 1 - Massa de dados fictícia de testes para exemplo prático / Fonte: o autor.

A IA simbólica opera com a noção de que a IA tem a capacidade de manipular símbolos que estão representando um mundo e as diversas experiências que vivenciamos. Tal manipulação ocorre por meio de inferências lógicas derivadas de um conjunto de regras formais para delimitar o que é ou não permissível. Para um exemplo prático, entenda os seguintes casos como símbolos:

- **Pacientes:** Pacientes serão representados por variáveis como X, que se referem a uma pessoa específica.
- **Sintomas:** Sintomas como frequência cardíaca, dor, saturação de oxigênio e pressão arterial são representados por funções:
- **Glasgow(X)** - Retorna a pontuação de Glasgow do paciente X.
- **FrequenciaCardiaca(X)** - Retorna a frequência cardíaca do paciente X.
- **Dor(X)** - Retorna a escala de dor do paciente X.
- **SaturacaoOxigenio(X)** - Retorna a saturação de oxigênio do paciente X.
- **PressaoArterial(X)** - Retorna a pressão arterial do paciente X.
- **Predicados:** Urgente(X) - Indica que o paciente X necessita de atendimento urgente.

Estes elementos sintáticos básicos da lógica de primeira ordem são essenciais para que os símbolos da IA simbólica venham a ser manipulados com o objetivo de encontrar resultados através de regras conhecidas e codificadas:

- Os **símbolos** são abstrações que representam entidades do mundo real, como “paciente”, “frequência cardíaca” e “diagnóstico”.
- Os **objetos** são entidades específicas que podem ser referenciadas como os nomes dos pacientes, seus sintomas e seus diagnósticos.
- As **relações** definem como os objetos se relacionam. Por exemplo, “frequência cardíaca elevada está relacionada a uma maior urgência”.

- As **funções** mapeiam objetos a valores ou categorias. Uma função pode ser usada para calcular uma pontuação de gravidade de sintomas.
- As **constantes** são valores fixos no sistema, como um valor de frequência cardíaca para identificar risco elevado.
- Os **predicados** representam propriedades dos objetos ou relações entre eles. Exemplo: Urgente (Paciente) pode indicar que o paciente precisa de atendimento urgente.
- E, por fim, as **variáveis** são os símbolos que podem representar diferentes valores, como “Bruna” para um paciente ou “135” para uma variável de frequência cardíaca.

Na lógica proposicional, também existem os operadores (ou conectores) e que são aplicados também a lógica de programação, como a negação, conjunção, disjunção, condicional e a bicondicional. Esses operadores permitem atribuir símbolos e ações entre objetos, relações, funções e constantes:

OPERADOR	SÍMBOLO	EXEMPLO	DESCRIÇÃO
Negação	$\neg$	$\neg p$	não / não é verdade que / é falso que
Conjunção	$\wedge$	$p \wedge q$	e / mas / no entanto / embora
Disjunção inclusiva	$\vee$	$p \vee q$	ou
Disjunção exclusiva	$\vee_{-}$	$p \vee_{-} q$	ou ... ou
Condicional	$\rightarrow$	$p \rightarrow q$	se ..., então...
Bicondicional	$\leftrightarrow$	$p \leftrightarrow q$	se e só se; é condição necessária e suficiente

Tabela 2 - Operadores e símbolos / Fonte: adaptado de Filho (2017).

Os símbolos são manipulados através de regras e operadores, que são definidos através do raciocínio simbólico, como será visto no tópico a seguir.



INDICAÇÃO DE LIVRO

Livro Introdução à Inteligência Artificial

O livro Introdução à inteligência artificial - Uma abordagem não técnica de Tom Taulli, 2020 - Novatec apresenta os fundamentos da IA e suas evoluções ao longo do tempo. Trata-se de um livro mais descritivo sem abordagens aprofundadas em matemática. Pode servir como base e complemento a esse tema de aprendizado para aqueles que desejam mais detalhes sobre as relações da IA simbólica e os sistemas especialistas.



Raciocínio Simbólico

O raciocínio simbólico utiliza os elementos sintáticos básicos da lógica de primeira ordem. Os **símbolos** representam objetos, relações e funções. Os símbolos são de três tipos: **constantes**, que representam os objetos, **predicados**, que representam relações e funções, que são uma sentença declarativa contendo uma ou mais **variáveis**, que se torna uma proposição quando valores particulares são atribuídos às variáveis (Russel; Norvig, 2003).



Seguindo o exemplo prático, os objetos são representados por pacientes, e seus sintomas são os objetos do nosso sistema. Afonso e Bruna são pacientes deste exemplo. Os objetos, que são os sintomas, se relacionam para definir a condição de urgência do paciente, enquanto as funções permitem calcular ou retornar valores a partir dos sintomas. Por exemplo, a função Glasgow (Paciente) retorna a pontuação Glasgow do paciente.

As constantes são valores fixos usados em regras, como limiares de gravidade para frequência cardíaca ou saturação de oxigênio e os predicados: são funções booleanas que retornam verdadeiro ou falso, por exemplo: Urgente(Paciente) avalia se o paciente precisa ou não de atenção urgente. Já as variáveis representam os pacientes e os sintomas, podendo assumir diferentes valores. Exemplo: X representa um paciente qualquer, onde este X pode ser substituído por Bruna ou Afonso, de acordo com a Tabela 1.

Agora, seguindo a tabela 1, vamos avaliar os símbolos utilizados:

Objetos: Paciente (Bruna); Sintomas (frequência cardíaca, dor, saturação de oxigênio, pressão arterial).

Predicados: Urgente(Paciente) – Paciente precisa de atendimento urgente.

Funções: Glasgow(Paciente) – Retorna a pontuação de Glasgow do paciente;

FrequenciaCardiaca(Paciente) – Retorna a frequência cardíaca;

Dor(Paciente) – Retorna a intensidade da dor;

SaturacaoOxigenio(Paciente) – Retorna o nível de saturação de oxigênio;

PressaoArterial(Paciente) – Retorna a pressão arterial.

Com base nestes símbolos utilizados, é possível criar regras e operadores lógicos para construir um sistema especialista. A seguir, estão exemplos das regras que utilizam operadores de lógica proposicional, na prática:

Negações ($\neg$): Se a saturação de oxigênio não for menor que 90%, o paciente não é urgente devido à saturação:

$$\neg(\text{SaturacaoOxigenio}(X) < 90) \rightarrow \neg\text{Urgente}(X)$$

Conjunção ($\wedge$): Se a pontuação de Glasgow for menor que 10 e a frequência cardíaca for maior que 100, o paciente é considerado urgente:

$$(Glasgow(X) < 10) \wedge (FrequenciaCardiaca(X) > 100 \rightarrow Urgente(X))$$

Disjunção Inclusiva ($\vee$): Se a dor for maior ou igual a 8 ou a pressão arterial sistólica for maior que 140, o paciente é urgente:

$$(Dor(X) \geq 8) \vee (PressaoArterial(X) > 140 \rightarrow Urgente(X))$$

Disjunção Exclusiva ($\oplus$): O paciente é urgente se e somente se a pontuação de Glasgow for menor que 10, ou se a saturação de oxigênio for menor que 90, mas não ambos:

$$(Glasgow(X) < 10) \oplus (SaturacaoOxigenio(X) < 90 \rightarrow Urgente(X))$$

Condicional ($\rightarrow$): Se a pontuação de Glasgow for menor que 10, então o paciente é urgente:

$$(Glasgow(X) < 10) \rightarrow Urgente(X)$$

Bicondicional ($\leftrightarrow$):

O paciente é urgente se e somente se a saturação de oxigênio for menor que 90 e a frequência cardíaca for maior que 100:

$$Urgente(X) \leftrightarrow (SaturacaoOxigenio(X) < 90) \wedge (FrequenciaCardiaca(X) > 100)$$

Continuando o exemplo, com base nos símbolos e as regras e operadores lógicos, é possível aplicar a prática aos registros da Tabela 1. Com base nos sintomas de Bruna, vamos avaliar a urgência do atendimento:

Sintomas

Glasgow: 9

Frequência Cardíaca: 135

Dor: 10

Saturação de Oxigênio: 88

Pressão Arterial: 150/8/100

Aplicação das regras propostas:

Negações: $\neg(\text{SaturacaoOxigenio}(\text{Bruna}) < 90)$ é falso, porque a saturação de Bruna é 88, que é menor que 90. Portanto, Bruna é considerada caso de atendimento urgente.

Conjunção: Como $\text{Glasgow}(\text{Bruna}) = 9$ e $\text{FrequenciaCardiaca}(\text{Bruna}) = 135$, ambos são verdadeiros. Regra satisfeita, neste caso, é possível concluir que Bruna terá o atendimento urgente.

Disjunção Inclusiva: $\text{Dor}(\text{Bruna}) = 10$ é verdadeiro, e $\text{PressaoArterial}(\text{Bruna}) = 150$ também é verdadeiro. Disjunção é verdadeira, e Bruna terá o atendimento urgente.

Disjunção Exclusiva: Ambos são verdadeiros ($\text{Glasgow}(\text{Bruna}) = 9$ e $\text{SaturacaoOxigenio}(\text{Bruna}) = 88$), então a disjunção exclusiva é falsa. Neste cenário, Bruna não terá o atendimento urgente.

Condicional: Como $\text{Glasgow}(\text{Bruna}) = 9$, a regra é verdadeira, e Bruna é terá o atendimento urgente.

Bicondicional: Ambas as condições são verdadeiras ($\text{SaturacaoOxigenio}(\text{Bruna}) = 88$ e $\text{FrequenciaCardiaca}(\text{Bruna}) = 135$), portanto o bicondicional é verdadeiro e Bruna terá o atendimento urgente.

O sistema de raciocínio simbólico avalia as condições dos pacientes de forma automática, verificando os sintomas e aplicando as regras predefinidas para determinar a urgência. Nesse caso, o sistema infere que a paciente Bruna tem

alta prioridade de atendimento com base na análise dos sintomas e regras simbólicas definidas. Para efeito de comparação, um sistema convencional apenas faz o cadastro de informação sem realizar a manipulação e o raciocínio de regras e símbolos.



EU INDICO

Entre as linguagens de programação que estão relacionadas a IA simbólica, está o LISP, que permite fácil codificação de regras e inferências lógicas, facilitando a criação de sistemas especialistas e a resolução de problemas. Também foi reconhecido especialmente para a manipulação de listas e processamento simbólico. Ambas as linguagens de programação estão relacionadas a IA simbólica e tem suas características que permitem praticar e aprofundar os conhecimentos deste tema de aprendizado.



EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementará e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

O raciocínio simbólico aplicado em sistemas especialistas é uma poderosa ferramenta para lidar com problemas complexos, como diagnósticos médicos de emergência. Através de regras simbólicas que relacionam sintomas a diagnósticos, esses sistemas podem fornecer decisões precisas e justificadas, ajudando médicos a priorizar pacientes em situações críticas.

Contudo, a precisão preditiva alcançada por modelos simbólicos individuais fica aquém de outros modelos considerados como “caixa-preta”. É necessária a combinação de múltiplos modelos para obter desempenho preditivo competitivo,

mas mesmo assim, perde-se a capacidade da interpretação do modelo obtido. Por isso, deve-se levar em consideração os seus objetivos na decisão da abordagem a ser adotada na resolução do seu problema, bem como, conhecer outros modelos de como os conexionistas e evolucionistas.

A relação entre a IA simbólica e a IA conexionista é historicamente marcada por rivalidade, mas evoluiu para uma possível complementaridade. Enquanto a IA simbólica oferece regras explícitas e raciocínio lógico, a IA conexionista proporciona a capacidade de aprender a partir de dados complexos e não estruturados. Ambas as abordagens têm suas aplicações, e o futuro da IA pode envolver a combinação dessas técnicas em sistemas híbridos capazes de capturar o melhor dos dois mundos.

AUTOATIVIDADE

1. Considere um sistema especialista que deverá avaliar um paciente que só será atendido com urgência se as seguintes condições forem verdadeiras (conjunção):

A frequência cardíaca é maior que 120.

A saturação de oxigênio é menor que 90%.

Para uma paciente que tem frequência cardíaca de 135 e saturação de oxigênio de 88%:

A frequência cardíaca é maior que 120.

A saturação de oxigênio é menor que 90%.

Para uma paciente que tem frequência cardíaca de 135 e saturação de oxigênio de 88%

Fonte: adaptado de FILHO, E. A. **Iniciação à lógica matemática**. [S.l.: s.n.], 2017.

Com base nas informações apresentadas, avalie as asserções a seguir e a relação proposta entre elas:

Asserções:

I - O atendimento é emergencial apenas se a frequência cardíaca fosse maior que 140.

PORQUE

II - sua saturação de oxigênio está abaixo de 90%.

A respeito dessas asserções, assinale a opção correta:

- a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
- b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
- c) A asserção I é uma proposição verdadeira e a II é uma proposição falsa.
- d) A asserção I é uma proposição falsa e a II é uma proposição verdadeira.
- e) As asserções I e II são falsas.

AUTOATIVIDADE

2. Podemos dizer que inteligência artificial é um subgrupo da ciência da computação composto por técnicas voltadas ao desenvolvimento de sistemas para solucionar problemas simbólicos em vez de numéricos e que simulam o raciocínio humano.

Fonte: LUGER, G. F. **Inteligência Artificial: Estruturas e Estratégias para a Complexidade do Mundo Real**. Porto Alegre: Bookman, 2004.

O que é um sistema especialista na IA Simbólica? Identifique a alternativa verdadeira.

- a) Um sistema que aprende com grandes volumes de dados.
 - b) Um sistema que utiliza redes neurais para tomar decisões.
 - c) Um sistema que utiliza regras e conhecimento simbólico para resolver problemas específicos.
 - d) Um sistema que aplica algoritmos genéticos para resolver problemas de otimização.
 - e) Um sistema baseado exclusivamente em técnicas de aprendizado supervisionado.
3. A IA simbólica é altamente flexível e pode ser adaptada a diferentes domínios, modificando as regras e a base de conhecimento. Pode representar conhecimentos complexos de maneira formal e estruturada, permitindo facilmente manipulação e raciocínio. Qual a principal limitação dos sistemas especialistas baseados em IA Simbólica?

Fonte: LUGER, G. F. **Inteligência Artificial: Estruturas e Estratégias para a Complexidade do Mundo Real**. Porto Alegre: Bookman, 2004.

Identifique a alternativa verdadeira:

- a) Dificuldade em justificar as decisões.
- b) Necessidade de grande volume de dados para treinamento.
- c) Dificuldade em adaptar-se a novos cenários sem reprogramação.
- d) Capacidade limitada de resolver problemas simples.
- e) Dependência de algoritmos complexos para aprendizagem.

REFERÊNCIAS

FILHO, E. A. **Iniciação à lógica matemática**. [S.l.: s.n.], 2017.

LIMA, I.; PINHEIRO, C. A. M.; SANTOS, F. A. O. **Inteligência Artificial**. Rio de Janeiro: Grupo GEN, 2014.

LUGER, G. F. **Inteligência Artificial**: Estruturas e Estratégias para a Complexidade do Mundo Real. Porto Alegre: Bookman, 2004.

MIHAGUTI, E. H. F. **Sistemas Baseado em Conhecimento**: aplicações , tendências e implicações - um estudo exploratório em empresas brasileiras. 1996. 235 f. Dissertação (Mestrado em Administração) – Fundação Getúlio Vargas, São Paulo. 1996. Disponível em: <https://repositorio.fgv.br/server/api/core/bitstreams/1d0897d2-0b3c-41e4-b5e6-53307a2cca48/content>. Acesso em: 6 jun. 2024.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

GABARITO

1. Alternativa correta.E.


A conjunção exige que ambas as condições sejam verdadeiras. Como a frequência cardíaca da paciente é 135 (maior que 120) e a saturação de oxigênio é 88% (menor que 90%), as duas condições são satisfeitas, o que confirma a urgência, então neste caso, as duas asserções são falsas.

2. Alternativa correta C.

Os sistemas especialistas são construídos com regras explícitas, baseados no conhecimento de especialistas humanos, aplicando a lógica simbólica para resolver problemas em domínios específicos. Refere-se a aprendizado de máquina, que se baseia em dados, não em regras simbólicas. Redes neurais são usadas em aprendizado profundo, não em IA simbólica. Algoritmos genéticos são usados em otimização evolutiva, outra abordagem da IA. O aprendizado supervisionado é relacionado ao aprendizado de máquina, não à IA simbólica.

3. Alternativa correta E.

Dificuldade em adaptar-se a novos cenários sem reprogramação é a alternativa correta pois Sistemas especialistas têm dificuldade em lidar com situações fora de sua programação, exigindo que novas regras sejam adicionadas manualmente. Justificar as decisões é uma vantagem, não uma limitação. A IA simbólica não depende de grandes volumes de dados para funcionar. Sistemas especialistas podem resolver problemas simples e complexos, dependendo das regras. Algoritmos complexos são mais associados ao aprendizado de máquina do que à IA simbólica.



TEMA DE APRENDIZAGEM 8

IA CONEXIONISTA EM SISTEMAS ESPECIALISTAS

MINHAS METAS

- Definir redes neurais.
- Relacionar as redes neurais e sistemas especialistas.
- Entender o processo de aprendizagem da rede neural.
- Compreender a relação híbrida entre IA conexionista e outras.
- Aprender a calcular soma ponderada em redes neurais.
- Compreender a função de ativação.
- Diferenciar as estruturas de rede.

INICIE SUA JORNADA

A ciência da computação, em sua maioria nos anos 70, estende seus trabalhos para outros campos de atuação em inteligência artificial diferentes das redes neurais, mas físicos e psicólogos continuaram a pesquisar técnicas da mecânica estatística para analisar as propriedades de armazenamento e de otimização das redes, além de estudos de modelos de memória de redes neurais.

Em 1980, grupos de estudo recriaram o algoritmo de aprendizado por retropropagação, que havia sido descoberto em 1969 e que foi aplicado a muitos problemas de aprendizagem em ciência da computação e psicologia.

Os chamados modelos conexionistas, aplicados a sistemas inteligentes, foram vistos por alguns como concorrentes diretos dos modelos simbólicos. Pode parecer óbvio que os seres humanos manipulam símbolos, mas os conexionistas questionavam se: a manipulação de símbolos tinha qualquer função para explicar em modelos detalhados de cognição? Na prática, nos dias de hoje, consideramos que essa pergunta não tem resposta, entendendo que as abordagens conexionistas e simbólica são complementares.



PLAY NO CONHECIMENTO

Você conhece o Whisper? Neste podcast, conheça algumas características dessa ferramenta gratuita, open source e que é utilizada para reconhecimento de fala e está relacionada às redes neurais. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

O aprendizado de máquina está ligado à inteligência artificial simbólica, conexionista e evolucionária, uma vez que o aprendizado de máquina complementa informações a partir de novos dados e permite lidar com incertezas e ambiguidades e a IA simbólica fornece a estrutura lógica e a base de conhecimento para a tomada de decisões. Essa integração entre a IA simbólica e conexionista precisa ser aprofundada, pois pode resultar em sistemas especialistas que evoluem com o tempo, mais precisos e eficazes.

DESENVOLVA SEU POTENCIAL

IA CONEXIONISTA EM SISTEMAS ESPECIALISTAS

A inteligência artificial conexionista também é conhecida por redes neurais. Suporta-se a ideia de que a inteligência pode ser modelada pela interconexão de elementos e processos simples, assim como acontece no cérebro humano e é possível relacionar a temas como aprendizado de máquina, visão computacional e processamento de linguagem natural.

Quando o assunto são as redes neurais, precisamos entender o que são os neurônios. Podemos entender que os neurônios são elementos de processamentos muito simples, compostos por uma soma, que é seu corpo, um axônio e vários dendritos. A função de um dendrito é receber os sinais de entrada dos demais neurônios e quando a intensidade desses sinais ultrapassa determinado limiar, leva a ativação do neurônio o que promove a enviar um pulso elétrico ao axônio (saída) em direção às sinapses e assim conectando aos demais neurônios, formando uma rede neural (Coppin, 2010).

De acordo com Russel e Norvig (2003, p. 713):



Um neurônio é uma célula no cérebro cuja principal função é coletar, processar e disseminar sinais elétricos. Acredita-se que a capacidade de processamento de informações do cérebro emerge principalmente de redes de tais neurônios. Por essa razão, uma parte do trabalho inicial da IA teve como objetivo criar redes neurais artificiais. Desde 1943, foram desenvolvidos modelos muito mais detalhados e realistas, tanto para neurônios, quanto para sistemas maiores no cérebro.



Segundo a IA simbólica trata como manipular de maneira formal uma linguagem de algoritmos e representações de dados de uma forma de cima para baixo, já as redes neurais podem ser descritas como processadores distribuídos e paralelos naturalmente para aprender e que normalmente operam de baixo para cima. Portanto, para tarefas cognitivas uma abordagem potencialmente vantajosa seria construir modelos conexionistas estruturados também conhecidos como híbridos, que interagem entre as abordagens para obter adaptabilidade, robustez e uniformidades (Haykin, 2001).

REDES NEURAIS

Redes neurais artificiais são compostas por neurônios interconectados organizados em camadas. Cada neurônio processa entradas e gera uma saída através de uma função de ativação. Os nós ou **unidades** são conectadas por vínculos orientados, onde um **vínculo** da unidade j para unidade i serve para propagar a ativação a_j desde j até i . Cada vínculo também tem um **peso** numérico $w_{j,i}$ associado a ele, o qual determina a intensidade e o sinal da conexão. Cada unidade i calcula primeiro uma soma ponderada de suas entradas (Russel; Norvig, 2003):

$$in_i = \sum_{j=0}^n w_{j,i} a_j$$

[1] Onde in_i é o **input ponderado** que o neurônio i recebe, $w_{j,i}$ são os **pesos sinápticos** que conectam o neurônio j ao neurônio i . Cada peso controla a importância relativa da ativação anterior a_j . a_j são as **atividades** (ou ativações) dos neurônios da camada anterior ou as entradas dos dados.

[2] O índice j varia de 000 até n , abrangendo todos os neurônios da camada anterior ou entradas do modelo.

[3] E então, depois que a soma ponderada in_i é calculada, o neurônio aplica uma **função de ativação g** a essa soma para derivar a saída:

$$a_i = g(in_i) = g\left(\sum_{j=0}^n w_{j,i} a_j\right)$$

$g(x)$ é uma função que introduz não-linearidade no modelo, o que permite que a rede aprenda e modele comportamentos complexos, como a classificação de imagens ou o reconhecimento de voz. Para ilustrar, observe a Figura 1, é apresentado um modelo matemático simples para um neurônio. A ativação da saída da unidade j e $W_{j,i}$ é o peso no vínculo da unidade j até essa unidade.

Para ter um resumo visual do modelo matemático de um neurônio, os vínculos de entrada, a função de entrada e de ativação, a saída e o vínculo de saída estão representados na figura a seguir.




Figura 1 - Um modelo matemático simples para um neurônio / Fonte: Russel e Norvig (2003).

Descrição da Imagem: A figura 1 apresenta 4 flechas que significam 4 vínculos de entrada e dois deles estão indicando $a_0 = -1$ a $0 = -1$ e a_j , respectivamente recebem o peso de desvio $W_{0,i}$ e $W_{j,i}$. As 4 flechas apontam para uma elipse dividida em três partes e que representa um neurônio representado por $a_i = g(in_i)$ a primeira divisão existe a representação da função de entrada, a divisão do meio representa a função de ativação com o que gera a última divisão da elipse que é a saída gerada, representada por 3 novas flechas com o nome vínculos de saída.

A função de ativação é o que decide se o neurônio será ativado ou não, e o quanto da informação será levada para a próxima camada.

O processo de soma ponderada e da função de ativação é a essência do funcionamento de uma rede neural, pois permite que a rede aprenda padrões nos dados ajustando os pesos $W_{j,i}$ durante o treinamento.

Na prática, imagine as seguintes ativações de entrada:

$$a_1 = 0.7, a_2 = 0.2 \text{ e } a_3 = 0.5$$

com os pesos:

$$W_{1,1} = 0.2, W_{2,1} = -0.6 \text{ e } W_{3,1} = 0.1$$

A fórmula $in_i = W_{1,1}a_1 + W_{2,1}a_2 + W_{3,1}a_3$ descreve o cálculo da soma ponderada e cada entrada é **multiplicada** por seu respectivo peso:

$$W_{1,1}a_1 = 0.2 \cdot 0.7 = 0.14$$

$$W_{2,1}a_2 = -0.6 \cdot 0.2 = -0.12$$

$$W_{3,1}a_3 = 0.1 \cdot 0.5 = 0.05$$

E depois **somadas**:

$$in_i = 0.14 + (-0.12) + 0.05 = 0.07$$

Logo, o resultado é **0.07**. Essa abordagem demonstra o processamento de informação nas redes neurais e que são aplicadas em arquiteturas de aprendizado. O processo da soma ponderada em redes neurais que é multiplicado pelo peso das entradas é fundamental para que o neurônio possa aprender a importância de cada entrada no modelo, conforme vamos aprofundar no próximo tema.

PROCESSO DE APRENDIZAGEM DA REDE NEURAL

As redes neurais funcionam como um processador paralelamente distribuído e que é constituído de uma unidade de processamento simples, que armazena conhecimento experimental e torna disponível para uso e se assemelha ao cérebro em dois aspectos:

1. O conhecimento é adquirido pela rede a partir de seu ambiente através de um processo de aprendizagem.
2. Forças de conexão entre neurônios, conhecidas como pesos sinápticos, são utilizadas para armazenar o conhecimento adquirido (Haykin, 2001, p. 28).

A função do processo de aprendizado é modificar os pesos sinápticos da rede de uma forma ordenada para alcançar um objetivo, em outras palavras:

Um processo pelo qual os parâmetros livres de uma rede neural são adaptados através de um processo de estimulação pelo ambiente no qual a rede está inserida. O tipo de aprendizagem é determinado pela maneira pela qual a modificação dos parâmetros ocorre (Russel; Norvig, 2003, p. 715).

Segundo Haykin (2001), essa definição implica a seguinte sequência de eventos:

3. A rede neural é estimulada por um ambiente.
4. A rede neural sofre modificações nos seus parâmetros livres como resultado desta estimulação.
5. A rede neural responde de uma maneira nova ao ambiente, devido às modificações ocorridas na sua estrutura interna.

Para entender o processo de aprendizado da rede neural precisamos entender as estruturas de rede que são divididas em duas principais categorias: **redes acíclicas** (redes de alimentação direta) e **redes cíclicas** (redes recorrentes).

Estruturas de Rede Neural

Uma rede de alimentação direta representa uma função de sua entrada atual, ou seja, ela não tem nenhum estado interno além dos pesos. Já a rede recorrente utiliza suas saídas para alimentar de volta suas próprias entradas. A resposta da rede a uma determinada entrada depende de seu estado inicial, que pode vir a depender de entradas anteriores, o que admite memória de curto prazo (Russel; Norvig, 2003).

A seguir, vamos detalhar uma rede neural simples com duas entradas, uma camada oculta e uma saída:




Figura 2 - Rede neural simples com duas entradas, uma camada oculta de duas unidades e uma saída / Fonte: Russel e Norvig (2003).

Descrição da Imagem: A figura 2 apresenta dois quadrados iniciais com os números 1 e 2. O Quadrado 1 aponta com uma flecha para o círculo 3 com $W_{1,3}$ e círculo 4 com $W_{1,4}$. O Quadrado 2 aponta com uma flecha para o círculo 3 com $W_{2,3}$ e círculo 4 com $W_{2,4}$. O círculo 3 aponta com uma flecha para o círculo 5 com $W_{3,5}$ e o círculo 4 aponta para o círculo 5 com $W_{4,5}$.

Com base nessas informações da Figura 2, um vetor de entrada $x = (x_1, x_2)$, as ativações de entrada $(a_1, a_2) = (x_1, x_2)$, a rede calcula:

$$\begin{aligned} a_5 &= g(W_{3,5}a_3 + W_{4,5}a_4) \\ &= g(W_{3,5}g(W_{1,3}a_1 + W_{2,3}a_2) + W_{4,5}g(W_{1,4}a_1 + W_{2,4}a_2)) \end{aligned}$$

Isto quer dizer que a saída de cada unidade oculta como uma função de suas entradas, a saída de rede como um todo, a_5 é uma função da entrada de rede. Os pesos na rede podem ser considerados como parâmetros da função, ou seja, W para os parâmetros e a rede calcula a função $h_w(x)$. Ao mudar os pesos, muda a função que a rede representa e é assim que a aprendizagem ocorre em redes neurais.

Rede neural de alimentação direta de uma única camada

As redes neurais também podem ter todas as entradas conectadas diretamente às saídas, essas redes são conhecidas como rede neural de alimentação direta de uma única camada (rede de perceptron). O perceptron é uma rede neural

com alimentação direta e sem unidades ocultas, podendo representar apenas funções **linearmente separáveis**. Ou seja, se os dados forem linear e separáveis, uma regra simples de atualização dos pesos poderá ser utilizada para realizar a adaptação exata dos dados. A Figura 3 ilustra este modelo de rede neural.




Figura 3 - Uma rede de perceptrons / Fonte: Russel e Norvig (2003).

Descrição da Imagem: A figura 3 apresenta uma rede de perceptrons representadas por 5 quadrados onde 3 são brancos e 2 são pretos. Cada quadrado deste que está nomeado como unidades de entrada está conectado por flechas em três círculos com tons de cinza onde representam as unidades de saída. As flechas têm a indicação de $w_{j,i}$, que representa o peso de cada flecha conectando os quadrados aos círculos.

Nessa figura, podemos observar a rede de perceptrons com três unidades de saída que compartilham cinco entradas. Os pesos em seus vínculos de entrada não tem nenhum efeito sobre as outras unidades de saída. Também podemos visualizar o perceptron como a representação de uma função booleana, a seguir, uma ilustração representando as funções booleanas E, OU e NÃO representados por unidades de limiar (função de ativação ou desativação de neurônio) com pesos apropriados:




Figura 4 - Unidades com uma função de ativação de limiar atuando como portas lógicas / Fonte: Russel e Norvig (2003).

Descrição da Imagem: A imagem ilustra diagramas de unidades com função de ativação por limiar, simulando o funcionamento de portas lógicas do tipo "E", "OU" e "NÃO". Cada diagrama apresenta um círculo central, que representa o núcleo lógico, conectado a setas de entrada e saída. Na porta lógica "E", há dois vetores de entrada, identificados como $W_1=1$ e $W_2=1$, que convergem para o círculo central, com um limiar de ativação de $W=1.5$. Na porta lógica "OU", os dois vetores de entrada são $W_1=1$ e $W_2=0.5$, com um limiar de ativação de $W=0.5$. Na porta lógica "NÃO", há apenas um vetor de entrada, $W=1$, e o limiar de ativação é $W=0.5$, sendo o resultado inverso da entrada, indicado pela seta de saída.

A possibilidade de criar unidades com uma função de ativação de limiar com entrada apropriada e pesos de desvio significa que podemos utilizar essas unidades para construir uma rede, com o objetivo de calcular qualquer função booleana das entradas. A função de limiar determina a ativação dos neurônios e a função de sigmoide (função logística) é importante para o algoritmo de aprendizagem de pesos (Russel; Norvig, 2003).

A ideia da função limiar é se a soma ponderada das entradas exceder um determinado valor a saída será ativada (normalmente representado por 1) ou caso contrário será desativada (normalmente representada por 0), que em mais um exemplo, se temos θ como limiar podemos expressar:

$$a(x) = \begin{cases} 1 & \text{sex} \geq 0 \\ 0 & \text{sex} < 0 \end{cases}$$

Somada a função de sigmoide, é possível utilizar, por exemplo, em sistemas capazes de calcular transações fraudulentas. O sigmoide pode informar a probabilidade de uma fraude baseada em informações que são recebidas no modelo. Se a saída da função $g(x) = \frac{1}{1+e^{-x}}$ resultar em 0.7, por exemplo, isso significa que há 70% de chance de que uma transação possa ser considerada fraudulenta. A sigmoide facilita o ajuste dos pesos $W_{i,j}$ através do uso de algoritmos de otimização e enquanto antes a função de limiar durante o treinamento da rede faz com que as ativações dos neurônios se aproximem das respostas corretas, quando utilizadas no processo de aprendizagem supervisionada.

Russel e Norvig (2003) apresentam a derivação de um algoritmo para aprendizagem em perceptrons de sigmóides. O algoritmo tem como objetivo ajustar os pesos da rede para minimizar alguma medida do erro no conjunto de treinamento para que a aprendizagem seja formulada como uma busca de otimização no espaço de peso, representação:

função APRENDIZAGEM-DE-PERCEPTRON (exemplos, rede)

retorna uma hipótese de perceptrons

entrada: exemplos, um conjunto de exemplos, cada um com entrada $x = x_1, \dots, x_n$ e saída y rede, um perceptron com pesos $W_{i,j} = 0 \dots n$ e função de ativação g

repita

para cada e **em** exemplos **faça**

$$in \leftarrow \sum_{j=0}^n w_j x_j[e]$$

$$Err \leftarrow y[e] - g(in)$$

$$W_j \leftarrow W_j + \alpha \cdot Err \cdot g'(in) \cdot x_j[e]$$

até algum critério de parada ser satisfeito
retornar HIPÓTESE-DA-RE-DE-NEURAL(rede)
 (Russel; Norvig, 2003, p. 719).

Para seguir e explicar com a matemática didática sobre este algoritmo, vamos considerar uma rede neural simples com duas entradas x_1 e x_2 , um neurônio com uma função de ativação sigmoide e pesos W_1 e W_2 que conectam as entradas ao neurônio. A saída prevista pela rede é:

$$\hat{y} = g(W_1x_1 + W_2x_2) \text{ onde } g \text{ é a função do sigmoide: } g(z) = \frac{1}{1+e^{-z}}$$

O erro quadrático mede a diferença entre a saída prevista e a saída verdadeira e é escrito como, se dado um valor verdadeiro y para a saída o erro quadrático é representada por:

$$E = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y})^2$$

O declínio de gradiente é utilizado para minimizar os erros da rede, a derivada parcial do erro em relação ao peso indica a direção cujo os pesos devem ser ajustados assim, reduzindo o erro e com taxa de aprendizagem controlando a magnitude das atualizações, neste caso do exemplo, vamos atualizar W_1 e W_2 :

$$\frac{\partial E}{\partial W_2} = (y - \hat{y}) \cdot g'(W_1x_1 + W_2x_2) \cdot x_2$$

e assim é possível utilizar as derivadas para atualizar os pesos, exemplo para W_1 :

$$W_1^{novo} = W_1^{anterior} - \alpha \cdot \frac{\partial E}{\partial W_1}$$

A taxa de aprendizagem α é responsável por controlar o quanto os pesos se ajustam em cada iteração. Se α for muito grande, o modelo pode vir a ignorar o mínimo da função de erro, enquanto se α for muito pequeno, o modelo poderá demorar a convergir.

Para um exemplo prático, precisamos supor alguns valores:

Entrada: $x_1 = 0.6, x_2 = 0.4$

Pesos: $W_1 = 0.5, W_2 = -0.5$

Saída esperada: $y = 1$

Taxa de aprendizagem: $\alpha = 0.1$

Calcular a saída de rede:

$$\hat{y} = g(W_1 x_1 + W_2 x_2)$$

$$(0.5 \cdot 0.6) + (-0.5 \cdot 0.4) = 0.3 - 0.2 = 0.1$$

E a função de ativação do sigmoide:

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$g(z) = \frac{1}{1 + e^{-z}} \approx 0.525$$

Para calcular o erro quadrático:

$$E = \frac{1}{2}(y - \hat{y})^2 = \frac{1}{2}(1 - 0.525)^2 = \frac{1}{2}(0.475)^2 \approx 0.113$$

Atualizando W_1, W_2 com base nas derivadas parciais do erro em relação a seus pesos. Derivada do erro E em relação a $\hat{y}$:

$$\frac{\partial E}{\partial \hat{y}} = -(y - \hat{y}) = -(1 - 0.525) = -0.475$$

Derivada do erro z em relação a W_1, W_2 :

$$\frac{\alpha z}{\alpha w_1} = x_1 = 0.6$$

$$\frac{\alpha z}{\alpha w_2} = x_2 = 0.4$$

Com base na derivada do erro z em relação a W_1, W_2 , o resultado da derivada da função de sigmoide, vamos aplicar:

$$\frac{\partial E}{\partial W_1} = \frac{\partial E}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial W_1} = (-0.475) \cdot 0.249 \cdot 0.6 \approx -0.071$$

$$\frac{\partial E}{\partial W_2} = \frac{\partial E}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial W_2} = (-0.475) \cdot 0.249 \cdot 0.4 \approx -0.047$$

Atualizando pesos:

$$W_1 \leftarrow W_1 - \alpha \frac{\partial E}{\partial W_1} = 0.5 - 0.1 \cdot (-0.071) = 0.5 + 0.0071 = 0.5071$$

$$W_2 \leftarrow W_2 - \alpha \frac{\partial E}{\partial W_2} = -0.5 - 0.1 \cdot (-0.047) = -0.5 + 0.0047 = -0.4953$$

Este processo de cálculo demonstrado no exemplo é repetido até que o erro quadrático seja minimizado, o que faz com que ajuste continuamente os pesos de W_1, W_2 . O modelo trata os perceptrons como funções determinísticas com saídas possivelmente errôneas, mas também é possível interpretar a saída de um perceptron de sigmoide com uma probabilidade de que a saída verdadeira seja 1 dadas as entradas, usando o sigmoide como uma representação canônica para distribuições condicionais em redes bayesianas ou então, usando o método padrão de maximizar a probabilidade logarítmica condicional dos dados (Russel; Norvig, 2003).



Redes neurais de alimentação direta de várias camadas

Tratando-se de alimentação direta de várias camadas em redes neurais, ao considerarmos redes com unidades ocultas, o caso mais comum envolve uma única camada ao exemplo da Figura 5. Ao adicionar camadas ocultas a mesma aumenta o espaço de hipóteses que a rede pode representar.

Os algoritmos de aprendizagem para redes com várias camadas são semelhantes aos de aprendizagem de perceptrons, com a diferença é que é possível ter várias saídas em vez de um único valor e cada exemplo tem um vetor de saída (Russel; Norvig, 2003).




Figura 5 - Rede alimentada adiante ou acíclica totalmente conectada com uma camada oculta e uma camada de saída / Fonte: Haykin (2001).

Descrição da Imagem: A figura apresenta 10 pequenos quadrados representando os nós de fonte da camada de entrada e cada quadrado tem uma flecha direcionando para 4 círculos que representam a camada de neurônios ocultos. Todos os quadrados se conectam com todos os círculos. Os 4 círculos da camada de neurônios ocultos, todos eles, se conectam a 2 novos círculos que representam a camada de neurônios de saída.

Na camada oculta, os dados de treinamento não informam qual valor os nós ocultos devem ter, mas é possível efetuar a propagação de retorno do erro da camada de saída para as camadas ocultas, processo de retorno emerge diretamente de uma derivação do gradiente de erro global.

Para atualizar as conexões entre unidades de entrada e ocultas, é preciso definir uma quantidade análoga ao termo de erro para os nós de saída. Então, efetuar a propagação do retorno do erro.

A seguir, o algoritmo seguindo Russel e Norvig (2003):

função APRENDIZAGEM-POR-PROPAGAÇÃO-DE-RETORNO(exemplos, rede) retorna uma rede neural

entradas: exemplos, um conjunto de exemplos, cada um com vetor de entrada x e vetor de saída y rede, uma rede de várias camadas com L camadas, pesos $W_{j,i}$, função de ativação g

repita

para cada e **em** exemplos **faça**

para cada nó j na camada de entrada **faça**

$$a_j \leftarrow x_j[e]$$

Para $l = 2$ **até** M **faça**

$$in_i \leftarrow \sum_j w_{j,i} a_j$$

$$a_i \leftarrow g(in_i)$$

para cada nó i na camada de saída **faça**

$$\Delta_i \leftarrow g'(in_i) \cdot (y_i[e] - a_i)$$

para $l = M-1$ **até** 1 **faça**

para cada nó j na camada l **faça**

$$\Delta_j \leftarrow g'(in_j) \sum_i w_{j,i} \Delta_i$$

para cada nó i na camada $l+1$

faça

$$w_{j,i} \leftarrow W_{j,i} + \alpha \cdot \alpha_j \cdot \Delta_i$$

até algum critério de parada ser satisfeito

retornar HIPÓTESE-DA-REDE-NEURAL(rede)

Este algoritmo está no livro de Russel e Norvig (2003), *Inteligência Artificial*. Prentice-Hall, Segunda Edição, 2003, para a derivação das equações de propagação de retorno. Na página 722 do livro estão descritas, em detalhes, para aqueles que desejam um maior aprofundamento matemático do tema e do algoritmo.

Se nos limitarmos a redes completamente conectadas, as únicas escolhas a serem feitas vão estar relacionadas ao número de camadas ocultas e seus tamanhos. É necessário escolher a arquitetura de rede que oferece a mais alta exatidão de previsão sobre os conjuntos de validação que estão à disposição.

Otimizadores

Existem vários utilizadores que podem ser utilizados no treinamento das redes neurais com características e velocidades diferentes para cada modelo. Podemos citar os otimizadores Gradiente Descendente Estocástico (SGD), Adagrad, RMSProp, e Adam como os quatro mais conhecidos. Segundo Toledo (2022):

O SGD reduz a computação redundante em dados de larga escala atualizando dos parâmetros uma única vez por interação mais frequentes como uma alta taxa de variância. O RMSProp lida melhor com taxas de aprendizagem radicalmente decrescentes que ocorrem com o uso de Adagrad, dividindo a taxa de aprendizado por uma média quadrática exponencialmente decrescente dos gradientes. Por sua vez, Adagrad adapta a taxa de aprendizado dos parâmetros ao realizar pequenas atualizações para parâmetros associados com valores que aparecem com maior frequência, e atualizações maiores para parâmetros associados a valores que aparecem com menor frequência. Adam tem como diferencial armazenar a média geral exponencialmente decrescente dos gradientes anteriores, estimando a média e a variância não centrada denominada da função (Toledo, 2022, on-line).


Para cada um destes otimizadores existe um algoritmo para que venha a ser aplicado. Neste tema de aprendizado não aprofundaremos cada um deles, pois a lógica é próxima do conteúdo apresentado, nas redes neurais e do processo de aprendizado. Porém, é necessário a citação destes otimizadores para o aluno que deseja prosseguir os estudos, ter um norte de próximos passos. O tema é extenso e há diversos algoritmos que podem ser estudados, modelados e aplicados em redes neurais.



INDICAÇÃO DE LIVRO

Redes Neurais - Princípios e Prática

Este livro *Redes Neurais - Princípios e Prática*, de Simon Haykin, fornece as bases para o entendimento das redes neurais, reconhecendo a natureza multidisciplinar do tem, aplicações em neurociência, matemática, estatística, física, ciência da computação e estatística demonstradas em exemplos de modelagem, análise de séries temporais, reconhecimento de padrões, processamento de sinais e controle. A indicação deste livro traz um complemento do que foi estudado neste tema.



O tema de aprendizado por redes neurais é uma intersecção em diversas áreas o que em um primeiro contato possa parecer complexo. A melhor forma de aprender o conteúdo é buscando entender melhor o funcionamento de neurônios para que assim venha ser possível correlacionar ao aplicar em um sistema especialista que pode resolver outros tipos de problemas negociais.



EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementará e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Os métodos estatísticos relacionados à aprendizagem variam desde o cálculo simples de médias até os mais complexos modelos, como redes bayesianas e redes neurais.

A rede neural tem grande poder computacional através de sua estrutura paralelamente distribuída e da sua habilidade de aprender, portanto, do poder de generalizar, que significa que **a rede neural pode produzir saídas adequadas para entradas que não estavam presentes durante o processo de aprendizagem**. Isso torna a rede neural capaz de resolver problemas complexos e de grande escala, na prática, não podem fornecer uma solução trabalhando individualmente.

As redes neurais precisam ser integradas em sistemas especialistas com abordagem consistente na engenharia, para poder resolver um problema complexo precisa ser decomposto em um número de tarefas relativamente simples e atribui-se às redes nesse subconjunto de tarefas que coincidem com suas capacidades inerentes.

Redes neurais são funções não lineares e complexas composta de muitos parâmetros cujo os quais podem ser aprendidos a partir de dados incompletos e, elas são aplicadas em milhares de aplicações como a psicologia, neurobiologia, engenharia e física. Como visto no tema de aprendizado, modelos a partir da rede neural podem ser criados para aprender e identificar fraudes bancárias e outras aplicações.

A IA evolucionária pode complementar a IA conexionista uma vez que ambas possuem como a característica de aprendizado indireto e ajustável ao longo do tempo, ambos os paradigmas utilizam processos iterativos para alcançar soluções. A IA evolucionária pode ajustar os pesos ou arquitetura de uma rede neural, também pode ser usada para ajustar regras em sistemas simbólicos ou encontrar soluções ótimas em ambientes mal definidos. Por isso, precisa ser estudada com o objetivo de entender melhor as aplicações híbridas entre conexionista, evolucionária e simbólica.

AUTOATIVIDADE

1. Dada a fórmula $in_i = \sum_{j=0}^n w_{j,i} a_j$, onde $w_{j,i}$ são os pesos sinápticos e a_j são as ativações da camada anterior, considere uma rede neural com duas entradas = 1.0 e = 0.5, e os pesos. Qual será o valor de in_1 (a soma ponderada das entradas)?

Fonte: adaptado de RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

Identifique a alternativa correta:

- a) 0.10
 - b) -0.21
 - c) 0.26
 - d) 0.01
 - e) -0.3
2. Uma rede neural utiliza a função de ativação sigmoide:

$$g(x) = \frac{1}{1 + e^{-x}}$$

Se a soma ponderada das entradas de um neurônio for igual a 0.7, qual será o valor da ativação do neurônio após aplicar a função de ativação sigmoide?



Fonte: adaptado de RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

Identifique a alternativa correta.

- a) 0.668
- b) 0.50
- c) 0.85
- d) 0.25
- e) 0.75

AUTOATIVIDADE

3. Para entender o processo de aprendizado das redes neurais é necessário entender as estruturas de rede. Referente à essas estruturas de rede neural, analise as figuras a seguir analisando as afirmações sobre elas:



Fonte: adaptado de RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

AUTOATIVIDADE

Identifique as afirmativas corretas:

- I - A figura 1 representa uma rede de perceptrons.
- II - A figura 1 representa uma rede neural simples com duas entradas, uma camada oculta de duas unidades e uma saída.
- III - A figura 2 representa uma rede neural simples com duas entradas, uma camada oculta de duas unidades e uma saída.
- IV - A figura 2 representa uma rede de perceptrons.

ALTERNATIVAS (indique a alternativa correta na última coluna):

- a) I, apenas.
- b) II e IV, apenas.
- c) III e IV, apenas.
- d) I, II e III, apenas.
- e) I, II, III e IV.

REFERÊNCIAS

COPPIN, B. **Inteligência artificial**. Rio de Janeiro: LTC, 2010.

HAYKIN, S. **Redes Neurais - Princípios e Prática**. 2. ed. São Paulo: Prentice Hall, 2001.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall, 2003.

TOLEDO, M. **Redes Neurais para Sistemas de Recomendação**. São Paulo: Dialética, 2022.

GABARITO

1. Alternativa correta C - 0.26.

$$\text{in1} = 0.3 \times 1.0 + (-0.7) \times 0.5 + 0.2 \times 0.8$$

$$\text{in1} = 0.3 - 0.35 + 0.16 = 0.26 \quad \text{in}_1 = 0.3 - 0.35 + 0.16 = 0.26 \quad \text{in1} = 0.3 - 0.35 + 0.16 = 0.26$$

2. Alternativa correta A - 0.668.

A função sigmoide é calculada como $g(x) = \frac{1}{1 + e^{-x}}$. Para $x = 0.7$, o cálculo resulta em aproximadamente 0.668

3. Alternativa correta B - II e IV apenas.

A figura 1 representa uma rede neural simples com duas entradas, uma camada oculta de duas unidades e uma saída.

A figura 2 representa uma rede de perceptrons que é uma rede neural de alimentação direta de uma única camada.



TEMA DE APRENDIZAGEM 9

IA EVOLUCIONÁRIA

MINHAS METAS

- Explorar algoritmos genéticos.
- Entender a aplicação de algoritmos genéticos em sistemas especialistas.
- Aprender sobre programação genética.
- Compreender as estratégias evolutivas para otimizar sistemas.
- Conhecer a história da IA evolucionária.
- Distinguir e relacionar a IA evolucionária de simbólica e conexionista.
- Praticar algoritmos e exercícios práticos.

INICIE SUA JORNADA

A IA evolucionária é inspirada nos mecanismos de evolução natural, como a seleção natural e a mutação genética. Ela busca resolver problemas complexos imitando processos evolutivos. Pensando nisso, você sabe como é possível otimizar soluções em ambientes dinâmicos e multifacetados? Essa pergunta é o que a IA evolucionária busca responder, pois precisa otimizar soluções onde métodos tradicionais muitas vezes falham devido à alta complexidade ou a falta de modelos determinísticos claros.

A IA evolucionária tem a capacidade de explorar amplos espaços e soluções para adaptar-se às mudanças, como alternativa a métodos analíticos que falharam ao tentar resolver alguns desafios de robótica e industriais. Ao buscar utilizar os conceitos da biologia evolutiva, tais como a seleção natural, reprodução, mutação e recombinação, os algoritmos genéticos podem ser aplicados em áreas de atuação distintas para resolver situações de engenharia, biologia, finanças, entre outros, pois para uma boa porção de problemas que precisam ser resolvidos envolvem iterações que estão cobertas no algoritmo genético.



PLAY NO CONHECIMENTO

Estudante, neste podcast convido você a conhecer algumas bibliotecas relacionadas à inteligência artificial e que estão disponíveis para a linguagem Python. Uma oportunidade para aplicar os seus conhecimentos na prática com instrumentos prontos para emular a teoria. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Neste momento, é importante que você se lembre de todas as escolas de inteligência artificial. A inteligência artificial conexionista e a inteligência artificial simbólica podem ser trabalhadas de formas híbridas com a inteligência artificial evolucionária. Ao longo deste tema de aprendizado, será possível observar as nuances da IA simbólica e seus correlatos, bem como algumas oportunidades onde as redes neurais podem servir como intersecção e melhorar possíveis soluções que são direcionadas à IA evolucionária. Assista esse vídeo para recordar o uso da IA conexionista e também da simbolista.


DESENVOLVA SEU POTENCIAL

IA EVOLUCIONÁRIA

Ao longo da história, nós, humanos, adquirimos uma base de conhecimento para compreender fenômenos sociais, culturais, terrestres e até prever o clima em graus variados, os movimentos dos planetas, as doenças, as oscilações da economia, entre outros. Muitas das soluções para problemas complexos do mundo moderno envolvem o uso de inteligência artificial e *machine learning* (Freitas, 2024).

A **computação evolutiva** tem seus primeiros registros na primeira metade do século XX, através da lei da seleção natural de Charles Darwin. A partir dessa descoberta, os cientistas iniciaram o estudo de possibilidades de simular a seleção natural usando códigos de computadores. Em 1960, John Holland e colegas da Universidade de Michigan desenharam o primeiro algoritmo evolutivo chamado Estocástico, que logo foi expandido abordando conceitos como cruzamento, mutação e elitismo (Mitchell, 1998).

A computação evolutiva tem tecnologias importantes de aprendizado de máquina, pois promovem soluções de otimização inspiradas na natureza (Russel; Norvig, 2003).



ALGORITMOS GENÉTICOS

Os algoritmos evolutivos fornecem um novo paradigma para solução de problemas de otimização, são os problemas nos quais se procura determinar os valores extremos, seja o maior ou o menor, que uma função pode assumir em um intervalo. O algoritmo, neste caso, é um genoma que é representado por um programa que passa por mutações em cruzamentos. Em linhas gerais, as etapas do algoritmo genético são:




Figura 1 - Representação Esquemática do funcionamento do Algoritmo Genético / Fonte: Freitas (2024).

Descrição da Imagem: A figura 1 apresenta 4 retângulos, o primeiro deles contém a frase criação da população inicial e existe uma flecha apontando para o próximo retângulo abaixo deste com a frase realizar primeira avaliação. Este retângulo aponta para o próximo abaixo com um grupo de frases: enquanto $t < t_{\text{final}}$ repita: 1-selecionar indivíduos, 2-realizar cruzamento, 3- provocar mutações controladas e 4 avaliar a população. Este retângulo aponta com uma flecha para o último abaixo com a frase escolher a melhor solução.

Os algoritmos genéticos são algoritmos de otimização com base nos princípios da biologia evolutiva, como seleção natural, reprodução, mutação e recombinação e que podem ser utilizados em engenharia, biologia, finanças e entre outros exemplos (Freitas, 2024). A seguir, vamos entender melhor as características dos ciclos de um algoritmo genético:

CICLO	CARACTERÍSTICAS
REPRESENTAÇÃO	Cada solução é representada como um cromossomo, que pode ser símbolo, número reais ou vetor de bits.
POPULAÇÃO	Os algoritmos genéticos processam conjuntos (populações) de elementos do espaço de procura (potenciais soluções para um problema)
SELEÇÃO OU AVALIAÇÃO	O processo de escolher os melhores indivíduos é determinado como seleção. É possível definir probabilidades diferentes para escolher um indivíduo de acordo com o quão bom ele representa para uma solução. O valor numérico da qualidade do indivíduo é chamado de fitness, que quanto maior, maior a possibilidade de procriação.
CRUZAMENTO OU RECOMBINAÇÃO	Após a etapa de seleção , efetua a troca de material genético entre dois progenitores (pais), conduzindo a criação de dois novos indivíduos (descendentes). Estes serão formados por sequências genéticas parciais de cada um dos elementos originais. O cruzamento é o principal mecanismo de recombinação na programação genética, onde dois pais são trocados para criar novos indivíduos. Isso permite que partes dos pais sejam combinados para gerar soluções potencialmente melhores.
MUTAÇÃO	Atua sobre as soluções resultantes da recombinação que altera um pouco algumas características. O processo é aleatório e tem objetivo manter um nível de diversidade na população para garantir que alelos que eventualmente desaparecem tenham a possibilidade de reaparecer.
EVOLUÇÃO OU SUBSTITUIÇÃO	Consiste em aplicar os passos de seleção, cruzamento e mutação a cada nova população durante um número de iterações pré definidas pelo desenvolvedor. Espera-se encontrar indivíduos que representam a melhor solução para um dado problema.
CRITÉRIO DE PARADA	Quando o critério é atingido e a iteração é interrompida, por número máximo de gerações ou encontrou solução ótima (fitness) - mínima. Sendo estes, os critérios mais comuns.

Quadro 1 - Características do Ciclo de Algoritmo Genético / Fonte: adaptado de Freitas (2024).

Em relação às populações, elas podem ser transformadas (evoluídas) ao longo de sucessivas iterações (gerações). As transformações na população das soluções são realizadas através dos mecanismos básicos de seleção e recombinação da seguinte forma:

- Os elementos mais aptos de uma determinada geração são selecionados para servir de progenitores das soluções que aparecem na geração seguinte.
- Operadores de transformação são designados operadores genéticos e atuam sobre os elementos selecionados originando as novas soluções (Cunha; Takahashi; Antunes, 2012).

Isto dito, é necessário tomar duas decisões quando se pretende aplicar um algoritmo genético na resolução de um problema:

1. Escolha para representar as soluções que fazem parte do espaço de procura. Ou seja, Os indivíduos processados por um algoritmo genérico são clássico são simplesmente sequências de zero e um, codificando a informação necessária para representar um ponto do espaço de procura.
2. Definir a função de aptidão para associar cada solução uma medida de qualidade, representando a capacidade para resolver o problema (Cunha, Takahashi; Antunes, 2012).

Programação e Estrutura de um Algoritmo Genético

Os algoritmos genéticos são muitos utilizados para a análise de agrupamento de dados, um tipo de algoritmo de aprendizado de máquina não supervisionado para agrupar dados em grupos (clusters). Neste exemplo, o algoritmo utiliza técnicas de otimização para gerar novos indivíduos a partir de um melhor indivíduo, por meio de processos de mutação, combinação e seleção.

Nele é possível observar nos passos 4 a 9 o processo iterativo que vai gerando sucessivas populações:

ESTRUTURA GENÉRICA DE UM ALGORITMO GENÉTICO

- 1 $T \leftarrow 0$
- 2 Gerar a população inicial $P(t)$
- 3 Avaliar os indivíduos de $P(t)$
- 4 **repita**
- 5 Selecionar progenitores $P'(t)$ a partir de $P(t)$
- 6 Aplicar operadores genéticos a $P'(t)$ obtendo a nova população $P(t+1)$
- 7 Avaliar $P(t+1)$
- 8 $t \leftarrow t+1$
- 9 **até** (critério de terminação atingido)
- 10 Devolver resultado final da otimização

Figura 2 - Estrutura genérica de um algoritmo genético / Fonte: Cunha, Takahashi e Antunes (2012).

Descrição da Imagem: A figura 2 apresenta o título estrutura genérica de um algoritmo genético, com o passo 1 t recebe o valor 0, passo 2 gerar a população inicial $p(t)$, passo 3 avaliar os indivíduos de $p(t)$, passo 4 repita, passo 5 selecionar progenitores $p'(t)$ a partir de $p(t)$, passo 6 aplicar operadores genéticos a $P'(t)$ obtendo a nova população $P(t+1)$, passo 7 avaliar $P(t+1)$, passo 8, t recebe o valor de $t+1$, passo 9 até (critério de terminação atingido) e passo 10 devolver resultado final da otimização.

Para entender melhor a aplicação deste algoritmo genético genérico, vamos usar como exemplo um caso de um sistema especialista onde deseja-se identificar a melhor planta de café com base em três características: resistência a pragas, produtividade e adaptação ao clima, com objetivo de selecionar e otimizar plantas considerando dois tipos de café: conilon e a arábica:

População inicial (plantas para avaliar):

- Conilon 1: {8,6,7}
- Conilon 2: {7,5,6}
- Arábica 1: {6,9,5}
- Arábica 2: {5,8,6}

Avaliação da população:

Neste momento, iremos avaliar o fitness de cada planta. Vamos considerar que o fitness será a soma ponderada das três características: resistência a pragas, produtividade e adaptação ao clima, representado da seguinte forma: fitness =

$0.5 \times \text{resistência} + 0.3 \times \text{produtividade} + 0.2 \times \text{adaptação}$. Aplicando para a primeira planta como exemplo:

- Conilon 1: {8,6,7}
- fitness conilon 1 = $0.5 \times 8 + 0.3 \times 6 + 0.2 \times 7 = 4 + 1.8 + 1.4 = 7.2$.

Fitness de todos os indivíduos (plantas):

Conilon 1: {8, 6, 7} , fitness = 7.2

Conilon 2: {7, 5, 6} , fitness = 6.1

Arábica 1: {6, 9, 5} , fitness = 7.1

Arábica 2: {5, 8, 6} , fitness = 6.4

A seleção dos pais pode ser feita de forma aleatória, por exemplo, selecionar dois pares de indivíduos que o indivíduo com maior fitness em cada par é selecionado como pai e a recombinação entre os pais é realizada através de um cruzamento de um ponto. Exemplo: se Conilon 1 e Arábica 1 são os pais:

- Conilon 1 = {8,6,7}
- Arábica 1 = {6,9,5}

Cruzamento em um ponto:

- Filho 1 {8,9,5}
- Filho 2 {6,6,7}

A mutação é aplicada com uma pequena probabilidade, por exemplo, o gene de resistência a pragas do filho 1 pode sofrer uma mutação de +1:

- Filho 1: {9,9,5}, fitness 7.6 - após mutação.
- Filho 2: {6,6,7}, fitness, 6,6

Os filhos gerados substituem os piores indivíduos da população inicial e as populações (plantas) continuam sendo geradas até que a melhora na função de fitness seja insignificante, ou seja, produzida a melhor planta através das 3 características iniciais, dos indivíduos (plantas) participantes e seus tipos:

- Conilon 1: {8, 6, 7}
- Arábica 1: {6, 9, 5}
- Filho 1: {9, 9, 5}
- Filho 2: {6, 6, 7}

Nessa avaliação de exemplo, a melhor planta selecionada seria o Filho 1 {9,9,5} com o fitness 7.6.

ESTRATÉGIAS EVOLUTIVAS

As estratégias evolutivas são um conjunto de técnicas de otimização que são baseadas na ideia da evolução natural e são usadas para encontrar soluções ótimas para problemas complexos e não lineares (Freitas, 2024).

Em linhas gerais, o que se busca com a otimização em sistemas especialistas é que à medida que o número de gerações aumenta, um algoritmo genético venha a convergir gradualmente para regiões do espaço de procura onde encontram-se soluções promissoras.

A otimização é encerrada quando um determinado critério é atingido, por exemplo: número limite de gerações atingido, descoberta de uma solução com qualidade pretendida e inexistência de melhoria durante um determinado período de tempo.

Então, o resultado devolve a melhor solução encontrada na otimização ou devolve um conjunto de indivíduos de qualidade elevada (ou os indivíduos que fazem parte da última geração).

Métodos para Otimizar Soluções em Sistemas Especialistas

O primeiro registro de algoritmos de otimização, também conhecidos como algoritmos de otimização de enxame, são da década de 1980 e criados por cientistas da computação (Faceli et al., 2011), a seguir, 5 princípios dos sistemas baseados em inteligência de enxame segundo Millonas (1994):

PRINCÍPIO	DESCRIÇÃO
PROXIMIDADE	Indivíduos de uma população devem interagir entre si.
QUALIDADE	Indivíduos devem ser capazes de avaliar a interação entre si e com o ambiente.
DIVERSIDADE	Corresponde à capacidade de um sistema reagir a ações inesperadas.
ESTABILIDADE	Os indivíduos não podem modificar seu comportamento em resposta a qualquer modificação no ambiente.
ADAPTABILIDADE	Os indivíduos devem ser capazes de se adaptar às mudanças do ambiente e da população.

Quadro 3 - Princípios dos sistemas baseados em inteligência de enxame / Fonte: Freitas (2024).

Existem mais variações de algoritmo como colônia de formigas e enxame de abelha. Estes algoritmos podem ser utilizados em diversas aplicações como agendamento de tarefas, aprendizagem por reforço, problemas de caixeiro viajante (rota mais curta) e reconhecimento de padrões, por exemplo (Freitas, 2024).

O algoritmo de colônia de formigas simula o modo como elas resolvem problemas usando feromônios, que é utilizado para trocar informações entre si e é uma otimização baseada em meta-heurística baseado na sua locomoção em suas trilhas para ter melhores fontes de alimento (Freitas, 2024).

A figura a seguir ilustra essa analogia em **três fases**: a primeira representa o caminho aleatório entre dois pontos com poucas formigas buscando alimentos, na segunda, um fluxo maior na movimentação das formigas e por fim, o caminho único percorrido pela maioria das formigas no melhor fluxo (Freitas, 2024).




Figura 3 - Analogia ao algoritmo de otimização por colônia de formigas / Fonte: Freitas (2024).

Descrição da Imagem: A figura apresenta 3 desenhos. O primeiro tem um círculo inicial com a letra F (food-comida) com dois caminhos imitando túnel de formiga até chegar ao círculo final N (nest-ninho), no caminho existe o percurso de uma formiga por um caminho aleatório com setas indicativas A e B em direções distintas de N a F. Há uma formiga e um traço acompanhando o trajeto da formiga. O Segundo desenho tem um círculo inicial com a letra F (food-comida) com dois caminhos imitando um túnel de formiga até chegar ao círculo final N (nest-ninho), o fluxo intenso com várias formigas por todo o percurso e o caminho que elas estão realizando está marcado no desenho. No desenho 3 diversas formigas em um caminho único no caminho mais curto entre o círculo f (food-comida) e n (nest-ninho), existe outros caminhos que as formigas podem seguir mas a maioria segue o fluxo do caminho mais curto, com uma rara exceção seguindo por um fluxo alternativo.

Assim como a idealização do algoritmo por colônia de formigas, o algoritmo de otimização por enxame de partículas é inspirado no comportamento de insetos ou aves, como o de um enxame de abelhas. Tem por objetivo procurar soluções ótimas para problemas difíceis, aplicando métodos de busca e processamento paralelo.

Trata-se de uma técnica baseada no conceito de que o compartilhamento de informações entre indivíduos oferece a vantagem evolutiva, para otimizar funções contínuas e não lineares. Existem três abordagens para explicar brevemente o processo de adaptação cultural de partículas (Freitas, 2024):

AVALIAR

Cada partícula deve avaliar a solução encontrada por ela no espaço de busca.

COMPARAR

Cada partícula deve comparar a solução obtida por ela com as soluções obtidas pelas demais partículas.

IMITAR

As partículas devem imitar o funcionamento da partícula que mais se aproxima da solução desejada.

A seguir, a representação de um pseudocódigo com a sequência de passos para construir a otimização por enxame de partículas:

ALGORITMO POR ENXAME DE PARTÍCULAS

Entrada: uma função-objetivo capaz de avaliar cada solução

Saída: um conjunto de soluções otimizadas

- 1 Iniciar as partículas
- 2 repita
- 3 para cada $pa.n$
- 4 Avaliar a solução para o problema no espaço de busca
- 5 Fim
- 6 Escolher partícula com maior aptidão
- 7 para cada partícula faça
- 8 atualizar sua velocidade
- 9 Atualizar sua posição
- 10 fim
- 11 até o critério de parada ser satisfeito

Figura 4 - Pseudocódigo para otimização por enxame de partículas / Fonte: Freitas (2024) adaptado de Faceli et al. (2011, p. 310).

Descrição da Imagem: A figura apresenta o título algoritmo de otimização por enxame de partículas. A seguir é apresentado o algoritmo com entrada: uma função-objetivo capaz de avaliar cada solução, saída um conjunto de soluções otimizadas e a sequência de passos 1: inicializar as partículas, 2 repita, 3 para cada $pa.n$, 4 avaliar a solução para o problema no espaço de busca, 5 fim, 6 escolher partícula com maior aptidão, 7 para cada partícula faça, 8 atualizar sua velocidade, 9 atualizar sua posição, 10 fim, 11, até o critério de parada ser satisfeito.

Quando o algoritmo termina, a posição da partícula melhor avaliada é a melhor solução para resolver o problema de otimização e cada componente do vetor que representa a posição será parte da solução.

Como exemplo de aplicação, imagine que é necessário otimizar a posição de pontos de rede para maximizar a cobertura de internet em uma determinada área. Vamos determinar 4 partículas como população inicial que estão representando um possível **ponto de rede** espalhados em uma área onde o objetivo é encontrar a posição ideal para maximizar o sinal da internet:

- Partícula 1 (ponto de rede): Posição (2, 3), Velocidade (0.5, -0.2)
- Partícula 2 (ponto de rede): Posição (4, 7), Velocidade (-0.3, 0.4)
- Partícula 3 (ponto de rede): Posição (6, 2), Velocidade (0.2, 0.1)
- Partícula 4 (ponto de rede): Posição (1, 5), Velocidade (-0.4, -0.3)

Uma função objetiva avalia a cobertura de internet de cada ponto de rede com base em fatores desejados, que poderíamos ter como exemplo a intensidade do sinal e a área de cobertura. Quanto mais eficiente o ponto de rede, maior será sua qualidade e logo, mais atraente para o enxame.

Fórmula para atualizar a velocidade:

$$v_i(t+1) = w \cdot v_i(t) + c_1 \cdot r_1 \cdot (p_{melhor_i} x_i) + c_2 \cdot r_2 \cdot (g_{melhor} - x_i)$$

onde:

w é o fator de inércia, controlando a influência da velocidade anterior.

c_1 c_2 os coeficientes que ajustam a influência das melhores posições pessoais e globais.

r_1 r_2 os números aleatórios entre 0 e 1.

p_{melhor_i} a melhor posição encontrada pela partícula i .

g_{melhor} a melhor posição encontrada por todo o enxame.

A nova posição é atualizada pela seguinte fórmula: $x_i(t+1) = x_i(t) + v_i(t+1)$ e o algoritmo itera até que um critério de parada venha a ser atingido, como por exemplo um número máximo de iterações ou a solução satisfatória da função objetivo.



INDICAÇÃO DE LIVRO

Manual de Computação Evolutiva e Metaheurística

O livro manual de computação evolutiva e metaheurística, de Antônio Gaspar-Cunha, Ricardo Takahashi e Carlos Henggeler Antunes, é indicado para complementar e avançar os estudos em inteligência artificial evolucionária e metaheurística. Nele é possível encontrar mais contexto de otimização, além de mais algoritmos evolutivos e tratamentos de restrições com a matemática explicada.



Agora que estudamos os algoritmos genéticos e entendemos de forma genérica como funcionam, é possível perceber que pode ser aplicado a diversas situações além da biologia.



EM FOCO

Estudante, para expandir seus conhecimentos do assunto abordado, gostaríamos de indicar a aula que preparamos especialmente para você. Acreditamos que essa aula complementará e aprofundará ainda mais o seu entendimento sobre o tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Estudante, após conhecer a inteligência artificial simbólica, conexionista e evolucionária, você está pronto para entender as suas aplicações, o raciocínio matemático que envolve os temas e pronto para desenvolver algoritmos e programas para resolver diversas situações e problemas na sua carreira.

Entender como otimizar o processo significa reduzir custos com recursos operacionais e ganhar tempo para obtenção de respostas. Todas essas inteligências têm matemática como base, sendo a inteligência artificial uma área de intersecção entre estatística, matemática e filosofia. Por isso, partindo deste ponto de vista, se torna complexa.

Os meios evolucionários estudados neste tema de aprendizado podem parecer um pouco estranhos à associação, porém, podemos levar como base para outros tipos de situação onde precisaremos de um raciocínio lógico e conseguir comparar com algum fato, fator ou “coisas” com comportamentos que já existem, pois se tornam mais simples de estruturar o pensamento e ter soluções assim como a IA evolucionária teve.

AUTOATIVIDADE

1. A computação evolutiva tem tecnologias importantes de aprendizado de máquina, pois promovem soluções de otimização inspiradas na natureza.

Com base nessa afirmação, qual é o papel da mutação em um algoritmo de Programação Genética?

- a) Garantir que apenas os melhores indivíduos sejam selecionados.
 - b) Criar diversidade na população, alterando partes dos programas.
 - c) Eliminar programas redundantes da população.
 - d) Substituir os programas com melhor desempenho por programas novos.
 - e) Gerar indivíduos completamente novos do zero.
2. Considerando os ciclos e características da programação genética e tratando-se em específico as características das populações, através de quais meios exclusivos da biologia evolutiva as populações são transformadas e evoluídas ao longo de sucessivas iterações?
 - a) Cálculo diferencial.
 - b) Análise combinatória.
 - c) Seleção e recombinação.
 - d) Regressão linear.
 - e) Clustering.
 3. Na programação genética a população é processada buscando elementos do espaço de procura para identificar potenciais soluções para um problema.

Qual é o principal método para criar novos indivíduos a partir dos pais selecionados?

- a) Adição de novos operadores aleatórios.
- b) Substituição de árvores inteiras por números.
- c) Cruzamento entre dois pais.
- d) Seleção dos piores indivíduos para reprodução.
- e) Expansão de funções para gerar novas árvores.

REFERÊNCIAS

CUNHA, A. G., TAKAHASHI, R. ANTUNES, C. H. **Computação Evolutiva e Metaheurística**. Minas Gerais: Editora UFMG, 2012.

FACELI, K. *et al.* **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.

FREITAS, N. C. A. **Introdução à inteligência artificial e à computação cognitiva**. São Paulo: SENAC, 2024.

KENNEDY, J. EBERHART, R. **Swarm Intelligence**. Burlington: Morgan Kaufmann Publishers, 2001.

MILLONAS, M. **Swarms, phase transitions and collective intelligence**. Washington, DC:USDOE, 1994.

MITCHELL, M. **An Introduction to Genetic Algorithms**. Massachusetts, MIT Press: 1998.

RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 2. ed. São Paulo: Prentice-Hall: 2003.

GABARITO

1. Alternativa correta B.

A mutação altera pequenas partes dos programas (como operadores) para introduzir variação e explorar diferentes regiões do espaço de busca.

Erradas:

A - Errada: Selecionar os melhores indivíduos: esse é o papel da seleção, não da mutação.

C - Errada: Eliminar programas redundantes: isso não é feito pela mutação.

D - Errada: Substituir programas com melhor desempenho: a mutação não substitui diretamente os melhores programas, ela apenas altera indivíduos para manter diversidade.

E - Errada: Gerar indivíduos do zero: isso seria parte da inicialização, não da mutação.

2. Alternativa C.

Verdadeira. Em relação às populações, elas podem ser transformadas (evoluídas) ao longo de sucessivas iterações (gerações). As transformações na população das soluções são realizadas através dos mecanismos básicos de seleção e recombinação da seguinte forma: Os elementos mais aptos de uma determinada geração são selecionados para servir de progenitores das soluções que aparecem na geração seguinte.

Operadores de transformação são designados operadores genéticos e atuam sobre os elementos selecionados originando as novas soluções.

Todas as outras não são exclusivas da biologia evolutiva.

3. Alternativa Correta C.

O cruzamento é o principal mecanismo de recombinação na programação genética, onde dois pais são trocados para criar novos indivíduos. Isso permite que partes dos pais sejam combinados para gerar soluções potencialmente melhores.

A - Errada: Adição de novos operadores aleatórios: isso seria mais associado à mutação, e não ao cruzamento.

B - Errada: Substituição de árvores inteiras por números: não faz parte do processo de programação genética, onde trabalhamos com expressões.

D - Errada: Seleção dos piores indivíduos para reprodução: na programação genética, os melhores indivíduos são escolhidos para reprodução.

E - Errada: Expansão de funções para gerar novas árvores: não é uma técnica usada para criar novos indivíduos diretamente.

